
Implementación de soluciones en la nube para el análisis de datos públicos a través de modelos de Inteligencia Artificial

-

Implementation of cloud solutions for public data analysis through Artificial Intelligence models



Trabajo de Fin de Máster
Curso 2025–2026

Autor

Cristian Molina Muñoz

Director

José Luis Vázquez-Poletti

Rubén Fuentes-Fernández

Máster en Ingeniería Informática

Facultad de Informática

Universidad Complutense de Madrid

Implementación de soluciones en la
nube para el análisis de datos
públicos a través de modelos de
Inteligencia Artificial

-

Implementation of cloud solutions
for public data analysis through
Artificial Intelligence models

Trabajo de Fin de máster en Ingeniería Informática

Autor

Cristian Molina Muñoz

Director

José Luis Vázquez-Poletti

Rubén Fuentes-Fernández

Convocatoria: *Septiembre 2026*

Calificación: *9.5*

Máster en Ingeniería Informática

Facultad de Informática

Universidad Complutense de Madrid

18 de septiembre de 2026

Autorización de difusión

El abajo firmante, matriculado en el Máster en Ingeniería en Informática de la Facultad de Informática, autoriza a la Universidad Complutense de Madrid (UCM) a difundir y utilizar con fines académicos, no comerciales y mencionando expresamente a sus autores el presente Trabajo Fin de Master: “Implementación de soluciones en la nube para el análisis de datos públicos a través de modelos de Inteligencia Artificial“, realizado durante el curso académico 2025-2026 bajo la dirección de José Luis Vázquez-Poletti y Rubén Fuentes-Fernández, y a la Biblioteca de la UCM a depositarlo en el Archivo Institucional E-Prints Complutense con el objeto de incrementar la difusión, uso e impacto del trabajo en Internet y garantizar su preservación y acceso a largo plazo.

Cristian Molina Muñoz

18 de septiembre de 2026

Dedicatoria

A mis padres, por hacer posible todo esto. Por su esfuerzo

Agradecimientos

Agradecer a todas las personas que han aportado su granito de arena a la persona que soy, y por extensión, a este mismo trabajo. Sobre todo a profesores y compañeros de estudio y trabajo, de los que tanto he aprendido.

Resumen

La computación en la nube, la Inteligencia Artificial y el tratamiento de grandes volúmenes de datos se revelaron como tres tecnologías profundamente disruptivas en el panorama tecnológico de los últimos años. En este trabajo se estudió el estado de la cuestión de estas tecnologías en profundidad, analizando su utilidad intrínseca y explorando las distintas metodologías, técnicas y servicios existentes, aportando también una implementación práctica para examinar su capacidad de aportar un beneficio público tangible.

Se examinó la disponibilidad de conjuntos de datos públicos a nivel europeo como base para el proyecto, cumpliendo con los nuevos marcos legales que este impone. A partir de ello, se elaboró una metodología replicable que describió el recorrido de los datos desde su origen hasta la generación de valor público, haciendo uso de la computación en la nube y las capacidades avanzadas de los algoritmos de Aprendizaje Automático, así como los entornos gestionados de Inteligencia Artificial que las grandes nubes públicas proporcionan. Esto permitió identificar las configuraciones más eficientes y óptimas para la construcción de estas soluciones, comparando con el resto de opciones disponibles. De igual manera, permitió desarrollar un enfoque general del estado actual de las tecnologías estudiadas.

Los ficheros de GitHub se encuentran en el siguiente repositorio: <https://github.com/crismo04/TFM-cloud-solutions-to-public-data/>

Palabras clave

Big Data, Computación en la nube, Inteligencia Artificial, Aprendizaje Automático, Datos abiertos, Tratamiento de datos, Valor público

Abstract

Cloud computing, artificial intelligence, and big data processing emerged as profoundly disruptive technologies in the technological landscape of recent years. In this work, the state of the art of these technologies was studied in depth, analyzing their intrinsic utility and exploring the different methodologies, techniques, and services available, while also providing a practical implementation to examine their ability to deliver tangible public benefit.

The availability of public datasets at the European level was examined as the foundation of the project, in compliance with the new legal frameworks imposed in this area. Based on this, a replicable methodology was developed that described the journey of data from its origin to the generation of public value, making use of cloud computing and the advanced capabilities of Machine Learning algorithms, as well as the managed Artificial Intelligence environments provided by the major public cloud providers. This made it possible to identify the most efficient and optimal configurations for building such solutions, in comparison with other available options. Likewise, it enabled the development of a general overview of the current state of the three technologies under study.

The project files can be found in the following repository: <https://github.com/crismo04/TFM-cloud-solutions-to-public-data/>

Keywords

Artificial Intelligence, Big Data, Cloud Computing, Data Processing, Machine Learning, Open Data, Public Value

Índice

1. Introducción	1
1.1. Motivación	1
1.2. Objetivos y alcance	2
1.3. Plan de trabajo	2
1.4. Estructura de esta memoria	3
1. Introduction	5
1.1. Motivation	5
1.2. Objectives and Scope	6
1.3. Work Plan	6
1.4. Structure of this Thesis	7
2. Estado de la Cuestión	9
2.1. Datos	10
2.1.1. Obtención de datos públicos	11
2.1.2. Estudios anteriores y relacionados	12
2.1.3. Conjuntos de datos	15
2.1.4. Gobierno de los datos	16
2.2. Nubes	17
2.2.1. Principales Proveedores de Nube y sus Capas Gratuitas	19
2.2.2. Otras herramientas de interés	24
2.2.3. Estudios anteriores y relacionados	28
2.3. Inteligencia Artificial	29
2.3.1. Modelos de ML	30
2.3.2. ML en la nube	31
2.3.3. IA, normativa y ética	35
2.3.4. Estudios anteriores y relacionados	35
2.4. Conclusiones del capítulo	37
3. Materiales y métodos	39

3.1.	Materiales	39
3.1.1.	Conjuntos de Datos	39
3.1.2.	Nubes	41
3.1.3.	Recursos para el desarrollo	43
3.2.	Métodos	45
3.2.1.	Marco metodológico	46
3.2.2.	Desarrollo de la solución	47
3.2.3.	Aplicados a Datos	52
3.2.4.	Aplicados a Aprendizaje Automático	56
3.2.5.	Aplicados a la Nube	58
3.3.	Conclusiones del capítulo	61
4.	Resultados	63
4.1.	Hallazgos sobre la calidad de los datos publicados	63
4.1.1.	Evolución no documentada de los esquemas	64
4.1.2.	Continuidad de la publicación y cobertura de la red	65
4.2.	Resultados del análisis de ML: isla de calor	65
4.2.1.	Replicación del trabajo de referencia	65
4.2.2.	Relación entre superficie arbórea y temperatura	68
4.2.3.	Análisis de sensibilidad	68
4.2.4.	Variables externas: altitud y superficie relativa	69
4.2.5.	Evaluación de los agrupamientos	71
4.2.6.	Limitaciones e interpretación	74
4.3.	Comparación entre la ejecución local y las plataformas cloud	75
4.3.1.	Comparación de costes en las diferentes nubes	75
4.4.	Conclusiones del capítulo	77
5.	Manual de usuario y casos de uso	79
5.1.	Manual de usuario en Local	80
5.1.1.	Despliegue y utilización del código en Local	80
5.1.2.	Ingesta y descarga de datos	80
5.1.3.	Ejecución de modelos y resultados	81
5.2.	Manual de usuario en AWS	83
5.2.1.	Despliegue	83
5.2.2.	Configuración del entorno y autenticación	84
5.2.3.	Infraestructura de Almacenamiento en Amazon S3	85
5.2.4.	Orquestación y Procesamiento ETL con AWS Glue	87
5.2.5.	Modelos de ML y resultados con Amazon SageMaker	91
5.2.6.	Consulta de costes en AWS	93
5.3.	Manual de usuario en GCP	94
5.3.1.	Despliegue	94
5.3.2.	Configuración del entorno y autenticación	95
5.3.3.	Infraestructura de almacenamiento en Cloud Storage	96
5.3.4.	Procesamiento y análisis en Vertex AI Workbench	97

5.3.5. Consulta de costes en GCP	100
5.4. Conclusiones del capítulo	101
6. Conclusiones y Trabajo Futuro	103
6.1. Conclusiones	103
6.2. Limitaciones conocidas del proyecto	105
6.3. Trabajo futuro	105
6.4. Valoración final	108
6. Conclusions and Future Work	109
6.1. Conclusions	109
6.2. Known limitations of the project	110
6.3. Final reflections	113
A. Apéndice A: Definiciones y acrónimos	115
A.1. Definiciones	115
A.1.1. Referentes a datos	115
A.1.2. Referentes a Cloud	121
A.1.3. Referentes a Inteligencia Artificial	125
A.2. Acrónimos	131
B. Apéndice B: Uso ético de herramientas de IA	137
Bibliografía	139

Índice de figuras

4.1. Días válidos de temperatura por estación y año. Se aprecia la degradación de la subred municipal (códigos mayores a 100) durante 2021 y 2022.	66
4.2. Relación entre superficie arbórea y temperatura media por distrito, año 2021.	69
4.3. Evolución de la correlación entre superficie arbórea y temperatura media por distrito (2019-2025) en ambas configuraciones del análisis.	70
4.4. Relación entre superficie arbórea relativa y temperatura media por distrito, año 2021.	71
4.5. Scatter 3D de temperatura, altitud y superficie relativa para el año 2022.	72
4.6. Diagrama del codo de la aproximación de temperatura y humedad relativa (2021).	73
4.7. Dendrograma del agrupamiento jerárquico de Ward sobre temperatura y humedad relativa (2021).	74
5.1. Árbol de archivos de resultados	82
5.2. Abrir terminal AWS en consola	84
5.3. Estructura de carpetas generada en S3	86
5.4. Ejecuciones del trabajo ETL en AWS Glue	90
5.5. Consola de SageMaker	91
5.6. Ejecucion de Jupyter en SageMaker	93
5.7. Abrir terminal GCP en consola	94
5.8. Conjuntos de datos cargados en Cloud Storage	97
5.9. Instancia de Vertex AI Workbench	98
5.10. Consola para crear un estudio de regresión y clasificación en Vertex AI AutoML	100
A.1. Capas de gobierno del dato	120

A.2. Distintos tipos de cloud	124
A.3. Tendencias de búsqueda de IA	127

Índice de tablas

2.1. Ventanas de contexto en tokens de principales LLM (Junio 2026), con su cálculo de filas de datos posibles que entrarían dentro de esa ventana.	34
3.1. Conjuntos de datos utilizados, su procedencia es (Ayuntamiento de Madrid, 2026b).	40
3.2. Correspondencia entre los procesos del <i>pipeline</i> y las etapas de la arquitectura de medalla ([<i>Definición 11</i>]).	48
4.1. Patologías de calidad detectadas en los conjuntos publicados, su efecto sobre la reutilización automatizada y nivel de documentación.	64
4.2. Replicación del agrupamiento de (Meneses Vicente y García Ruíz, 2023) para 2021. El acuerdo se calcula sobre el total de pares posibles entre las estaciones comunes: para cada par se comprueba si ambos trabajos coinciden en agruparlas juntas o en grupos distintos, con independencia de la etiqueta numérica del grupo.	67
4.3. Correlación de Pearson entre superficie arbórea y temperatura media por distrito (2019-2025), reproduciendo las condiciones del trabajo original, y aplicando el criterio de cobertura mínima propio.	68
4.4. Correlación de Pearson entre temperatura media anual y altitud (por estación) y superficie arbórea relativa (por distrito).	70
4.5. Coeficiente de silueta por año y aproximación, aplicando el criterio de cobertura mínima. Se incluyen las cinco aproximaciones originales y las dos propias. En negrita, el mejor valor de cada año. “—” indica que la aproximación no reunió estaciones suficientes ese año.	73

4.6.	Comparativa de esfuerzo de desarrollo, tiempo de ejecución y coste por etapa y entorno.	76
4.7.	Comparativa de costes brutos y netos en AWS y GCP durante el período de ejecución del proyecto.	76
A.1.	Resumen de las principales características de las denominadas olas de datos abiertos.	119
A.2.	Comparación de modelos relacionados con la computación distribuida.	122
A.3.	Línea de tiempo de la IA	126

Índice de bloques de código

5.1. Preparación del entorno y ejecución de la ingesta	81
5.2. Ejecución local de limpieza	81
5.3. Ejecución local del modelado analítico	81
5.4. Obtención del código fuente del proyecto	84
5.5. Persistencia de las variables del proyecto	85
5.6. Creación y configuración del contenedor en S3	85
5.7. Carga de procesos e ingesta directa sobre S3	86
5.8. Ingesta manual directa de un nuevo dataset a S3	87
5.9. Creación del rol de servicio de Glue	88
5.10. Empaquetado del módulo de configuración	88
5.11. Definición y despliegue del trabajo de limpieza en Glue	89
5.12. Ejecución, seguimiento y verificación del resultado	90
5.13. Ejecución del análisis en SageMaker.	92
5.14. Consulta de costes históricos en AWS CLI	93
5.15. Creación del proyecto en GCP	95
5.16. Creación del archivo de variables de entorno	96
5.17. Creación y configuración del contenedor de Cloud Storage . .	96
5.18. Descarga del código e ingesta en Cloud Storage	97
5.19. Creación de la instancia de Vertex AI Workbench	98
5.20. Ejecución de limpieza en Vertex AI Workbench	99
5.21. Ejecución del análisis en Vertex AI Workbench	99
5.22. Detención de la instancia de Vertex AI	99
5.23. Consulta de costes históricos en BigQuery	101

Capítulo 1

Introducción

“We can only see a short distance ahead, but we can see plenty there that needs to be done.”

— Alan Turing

Este proyecto se basa en tres tecnologías. La computación en la nube, la cuál se entiende como el suministro de servicios informáticos (servidores, almacenamiento, bases de datos, redes, software, análisis y más) a través de Internet, permitiendo un acceso flexible y escalable a recursos sin la necesidad de poseer ni gestionar la infraestructura física. La segunda es la Inteligencia Artificial (IA), que abarca el desarrollo de sistemas que demuestran la capacidades (una o varias) de aprender, adaptarse, razonar y resolver problemas complejos, así como de percibir y comprender su entorno (virtual o físico), a menudo a través del análisis y la inferencia a partir de grandes volúmenes de datos (mediante la rama de la IA conocida como Aprendizaje Automático, ML por sus siglas en inglés). Finalmente, el procesamiento de los grandes volúmenes de datos, que se refieren a colecciones masivas y heterogéneas de información generada o recopilada por entidades gubernamentales u organizaciones, accesible al público. El proyecto estudia la manera en la que estas tres tecnologías se pueden combinar para aportar un valor tangible.

1.1. Motivación

La motivación de este proyecto surge debido al enorme auge que han tenido las tres tecnologías estudiadas, así como de su capacidad para crear sinergias y aportar valor público. En el marco de la Unión Europea, se están toman-

do medidas para la liberalización de grandes volúmenes de datos públicos y promoviendo su uso por entidades públicas, así como poniendo el foco en la IA y su potencial transformador. La sociedad es cada vez más consciente del potencial de los grandes modelos del lenguaje (LLM), una potente parte de la IA cuyo desarrollo ha avanzado y ganado popularidad en los últimos años. Pero aun falta camino para que estos sean capaces de generar beneficios sociales de la manera más automatizada posible. Este trabajo pretende centrarse en eso, en estudiar cuál es la mejor manera de que los distintos actores (individuales, públicos y privados) puedan generar valor a través de estas tecnologías.

1.2. Objetivos y alcance

El objetivo y alcance de este proyecto es triple:

- Realizar un análisis exhaustivo del panorama actual de la computación en la nube, la IA y el estado de los datos públicos, identificando las metodologías, técnicas y servicios más relevantes.
- Desarrollar una metodología replicable que permita el uso de estos datos, desde su origen, hasta la generación de valor, afinando esta metodología a través de la puesta en práctica de la misma.
- Aplicar la metodología propuesta a diversos conjuntos de datos disponibles a nivel europeo y/o nacional, evaluando diferentes modelos y configuraciones para identificar las soluciones más eficientes y efectivas para generar valor público a partir de la información analizada.

1.3. Plan de trabajo

Una vez definido el alcance, destacaremos las seis fases en las que se ha dividido el proyecto, que se han ido iterando en un esquema ágil para la creación de varias versiones funcionales:

1. **Fase de investigación académica:** Búsqueda de estudios o trabajos acerca del estado actual de las tres tecnologías y las últimas innovaciones para establecer el marco teórico y contextualizar las bases del proyecto.
2. **Fase de investigación técnica:** Búsqueda de información acerca de diferentes fuentes públicas de datos, tecnologías en la nube y modelos o herramientas de IA que nos ayuden a tratar, filtrar y entender todos los datos públicos recopilados.

3. **Fase de análisis de requisitos:** A partir del conocimiento adquirido, se diseñó la arquitectura de la solución, se seleccionaron los conjuntos de datos públicos objetivo y se planificó la metodología concreta a seguir, estableciendo las métricas para evaluar el éxito del proyecto.
4. **Fase de implementación:** Fase central para materializar la solución. Esta aplica la metodología definida para llevar a la práctica e integrar todos los elementos: la configuración del entorno en la nube, la adquisición y limpieza de los datasets seleccionados, el entrenamiento de los modelos de ML y su despliegue y el uso del resto de tecnologías.
5. **Fase de pruebas y evaluación:** Valoración de los prototipos desarrollados y resultados obtenidos, así como del rendimiento de los modelos y la calidad del valor público generado, teniendo en cuenta el aspecto ético de los mismos.
6. **Fase de documentación:** Etapa transversal al resto, documentando los pasos seguidos y hallazgos en la elaboración de este documento, plasmando también los resultados obtenidos, las conclusiones y las posibles líneas de trabajo futuras.

1.4. Estructura de esta memoria

Toda esta memoria se ha construido con L^AT_EX y ayuda de la plantilla T_EX^S. El resto de la memoria se estructurará por capítulos de esta manera:

Capítulo 2: Estado de la cuestión, donde se plasmarán las conclusiones de las primeras dos fases de investigación: estudios, trabajos, marcos, tecnologías, conjuntos de datos y demás herramientas encontradas. También estudiará el panorama actual en la sociedad con respecto a estas.

Capítulo 3: Materiales y métodos, donde se plasmarán las siguientes dos fases de análisis e implementación, concretando las tecnologías y conjuntos de datos utilizados finalmente en el proyecto, al igual que la metodología y pasos que se han seguido durante el proyecto para obtener resultados.

Capítulo 4: Resultados En este capítulo se redactarán en detalle los resultados obtenidos en el proyecto, teniendo en cuenta todas las plataformas estudiadas y modelos usados.

Manual de usuario 5: Se centrará en la especificación técnica paso a paso de la solución, aportando la sintaxis completa de los comandos ejecutados tanto en local como en la nube, para que el trabajo sea lo más fácil posible de reproducir.

Anexo A “Definiciones y acrónimos”: Para evitar la excesiva longitud

de ciertos apartados, **algunas definiciones se han movido a este apartado, apareciendo en el texto de la siguiente manera: [Definición 1]**. Aquí también se podrán encontrar los Acrónimos que aparecen durante todo el trabajo [A.2].

Conclusiones y Trabajo Futuro 6: Donde se definirá (también en inglés), más resumidamente que en el capítulo de resultados, las conclusiones que se han podido sacar de este estudio, así como las líneas de investigación que inevitablemente quedan abiertas debido a la extensión de los temas tratados.

Aclarar que esta memoria utilizará las palabras en español o sus anglicismos correspondientes indistintamente, debido a su popularización y uso en la rama de la computación. Esto es palabras tales como “machine learning” o “aprendizaje automático”, “dataset” o “conjunto de datos”, “cloud” o “nube”, etc.

Chapter 1

Introduction

“We can only see a short distance ahead, but we can see plenty there that needs to be done.”

— Alan Turing

This project is based on three main technologies. First, cloud computing, understood as the provision of computing services (servers, storage, databases, networking, software, analytics, and more) over the internet, allowing flexible and scalable access to resources without the need to own or manage physical infrastructure. Second, Artificial Intelligence (AI), which encompasses the development of systems that demonstrate the ability to learn, adapt, reason, and solve complex problems, as well perceive and understand their environment (either virtual or physical), often through analysis and inference from large volumes of data, and specifically, employing the methodologies of Machine Learning (ML), a branch of AI. Finally, public big data processing, which involves analyzing massive and heterogeneous data collections generated or collected by governmental or public entities and made accessible to the public.

This project studies the way in which these three technologies can combine to deliver tangible value.

1.1. Motivation

The motivation for this project arises from the enormous growth of the three studied technologies, as well as their capacity to create synergies and deliver public value. Within the framework of the European Union, actions are

being taken to liberalize large volumes of public data and promote their use by public entities, while also focusing on artificial intelligence and its transformative potential. Society is increasingly aware of the potential of Large Language Models (LLM), a powerful part of AI whose development has advanced and gained popularity in recent years. However, there is still a long way to go before these can generate social benefits in the most automated way possible. This work aims to focus precisely on that: studying the best way for different actors (individuals, public and private entities) to generate value using these technologies.

1.2. Objectives and Scope

The objective and scope of this project are triple:

- Conduct a comprehensive analysis of the current landscape of cloud computing, artificial intelligence, and the state of public data, identifying the most relevant methodologies, techniques, and services.
- Develop a replicable methodology that allows the use of these data, from their origin to the generation of value, refining this methodology through practical implementation.
- Apply the proposed methodology to various datasets available at the European and national levels, evaluating different models and configurations to identify the most efficient and effective solutions for generating public value from the analyzed information.

1.3. Work Plan

Once the scope has been defined, we will highlight the six phases into which the project has been divided, which have been iterated in an agile framework for the creation of several functional releases:

1. **Academic research phase:** Search for studies or works about the current state of the three technologies and the latest innovations to establish the theoretical framework and contextualize the foundations of the project.
2. **Technical research phase:** Search for information about different public data sources, cloud technologies, and AI models or tools that help process, filter, and understand all the collected public data.
3. **Requirements analysis phase:** Based on the knowledge acquired, the solution architecture was designed, target public datasets were se-

lected, and a concrete methodology was planned, establishing metrics to evaluate the project's success.

4. **Implementation phase:** Central phase to materialize the solution. This applies the defined methodology to practically integrate all elements: cloud environment configuration, acquisition and cleaning of selected datasets, training of machine learning models, their deployment, and the use of the other technologies.
5. **Testing and evaluation phase:** Assessment of developed prototypes and obtained results, as well as model performance and the quality of the public value generated, taking ethical aspects into account.
6. **Documentation phase:** Cross-cutting stage documenting the steps followed and findings in the preparation of this document, also reflecting the obtained results, conclusions, and future lines of work.

1.4. Structure of this Thesis

This thesis has been written using L^AT_EX with the help of the T_EX_IS template. The rest of the thesis is structured in chapters as follows:

Chapter 2: State of the Art, which will present the conclusions of the first two research phases: studies, works, frameworks, technologies, datasets, and other tools found. It will also study the current landscape in society regarding these topics.

Chapter 3: Materials and Methods, which will cover the next two phases of analysis and implementation, specifying the technologies and datasets finally used in the project, as well as the methodology and steps followed to obtain results.

Chapter 4: Results, which will explain in detail the results obtained in the project, taking into account all the platforms and machine learning methods used.

User manual 5: This chapter is focused on the technical specification, step by step, of the solution's syntax with all the commands used in the project, to provide the reader with the way to reproduce the full process.

Appendix A “Definitions and Acronyms”: To avoid excessive length in certain sections, some definitions have been moved to this appendix, appearing in the text as follows: [Definition 1]. Here, the acronyms used throughout the work can also be found [A.2].

Conclusions and Future Work 6: In this last chapter (which will also be available in English), the results obtained in the project will be summarized

and discussed, as well as the research lines that inevitably remain open due to the breadth of the topics covered.

Capítulo 2

Estado de la Cuestión

“Somos una generación frontera. La única que ha conocido la vida antes y después de la hiperconectividad y los dispositivos móviles. [...] La última que pudo abarcar toda la tecnología de su tiempo.”
— Jaime Gómez-Obregón

En este apartado expondremos el estado actual de los puntos principales de este proyecto, así como los artículos relacionados con los temas a tratar: trabajos relacionados con los principales proveedores Cloud y su comparación, trabajos que traten con grandes volúmenes de datos públicos o que estudien los datos públicos, o trabajos que utilicen diferentes técnicas de IA para el tratamiento de datos y la obtención de conclusiones a partir de estos. No es una tarea fácil, ya que los artículos relacionados en “Google Scholar” se cuentan por millones al buscar “data”, “Artificial Intelligence” o “cloud computing”, por lo que, aunque también se estudiarán conjuntos de datos, artículos y aplicaciones de otras partes del globo, la parte práctica del proyecto se intentará centrar en datos del territorio español. De esta manera acotaremos el alcance del proyecto y contribuiremos a aprovechar datos que no han sido tan explotados y explorados como pueden ser los datos abiertos disponibles en plataformas como Google (Google, 2025a) o Amazon (Amazon, 2025).

También dividiremos esta sección en los tres elementos que componen el trabajo, y estudiaremos las posibilidades y estado de la cuestión de cada uno.

2.1. Datos

Llevamos mucho tiempo escuchando que vivimos en la era de la información, o de los datos, desde la invención del transistor en 1947 (Wikipedia, 2025), pasando por la primera vez que se acuñó en 2005 el término “web 2.0” y “Big Data” (Press, 2013), así como su rápido crecimiento y adopción en todas las esferas (Brown et al., 2011), hasta el presente, donde los datos y su tratamiento a través de múltiples herramientas, incluyendo la recientemente omnipresente IA, generan enormes volúmenes de datos.

Según proyecciones, hemos alcanzado la asombrosa cifra de 149 Zettabytes de datos creados, capturados, copiados y consumidos en 2024, cifra estimada en 181 Zettabytes para 2025 y que las proyecciones sitúan en torno a los 394 Zettabytes en 2028 (Taylor, 2025; Pangarkar, 2025) (número impresionante a pesar de la naturaleza especulativa de estas proyecciones).

Esta evolución no ha sido lineal ni uniforme, sino que ha estado marcada por distintos enfoques, motivaciones y metodologías en todo el mundo en lo que se denominan las tres olas de datos abiertos *Definición 5*: diferentes etapas evolutivas por las que ha transitado el movimiento de apertura de datos.

En España, los datos también muestran un aumento significativo. Según el informe económico de telecomunicaciones y audiovisual de la Comisión Nacional de los Mercados y la Competencia (CNMC), en 2025 el tráfico de banda ancha y datos móviles creció hasta los 0,095 Zettabytes (Comisión Nacional de los Mercados y la Competencia, 2026). Aunque estas cifras miden el tráfico cursado por las redes de las principales operadoras, y no es directamente comparable con las estimaciones globales de datos generados, sí que permiten observar que ambas mediciones son elevadas, con tendencia común de crecimiento sostenido año tras año.

Aún con estas discrepancias en cuanto a números, lo que está claro es que el mercado de los datos no para de crecer año tras año y cada vez resulta más difícil separar la información relevante del ruido, evitando la “infoxicación” o sobrecarga informativa (Cornella, 2000). En este escenario, tecnologías como la computación en la nube e IA pueden ser claves para encontrar los patrones o llegar a conclusiones.

Mencionar también brevemente que los “datos” no suelen aparecer en formatos consistentes, y para este trabajo se han tratado diferentes formatos: CSV, JSON, bases de datos diversas, Excel, APIs, etc. (Khan y Alam, 2019). Esto es así porque queríamos que las fuentes de datos fueran heterogéneas y no excluir datos porque su extracción o tratamiento fueran complejos, ya que este es el caso para la mayoría de aplicaciones en el mundo real. Esto se explicará más en detalle en la *Sección 3.2.2.2*: Normalización y limpieza.

2.1.1. Obtención de datos públicos

Lo primero para la realización de este proyecto es la obtención de datos públicos, o datos abiertos *Definición 4*. Esto presenta tres grandes complicaciones a tener en cuenta.

La primera es que, aunque existe un consenso creciente sobre la importancia de la apertura de datos, la realidad muestra que **muchos datos de alto valor aún no son accesibles, lo son de forma limitada o su uso es complejo**, ya sea a conciencia o por indolencia. Según la Organización para la Cooperación y el Desarrollo Económicos (OECD, 2023), sólo el 48 % de los conjuntos de datos de gran valor están disponibles como datos abiertos en los países estudiados, datos que bajan al 30 % cuando se trata de datos financieros. Estudios de otras partes del mundo también avalan esta reticencia a la correcta apertura de información pública (De la Torre y Núñez, 2023; Jorge y Herrera, 2023).

La segunda causa es **la regulación**. El tratamiento de datos en Europa debe seguir el Reglamento General de Protección de Datos (RGPD) de 2016, además de las regulaciones propias de cada Estado miembro (Ramos-Simón, 2017) & (Unión Europea, 2016), así como la más reciente Ley de Gobernanza de Datos (Unión Europea, 2023; Valero Torrijos y Martínez Gutiérrez, 2022). Para cumplir con estas normativas, en este proyecto nos centraremos en el uso de datos oficiales abiertos, evitando técnicas como el “web scraping” que pueden estar sujetas a controversia a la vista de estas regulaciones. También se verificarán las licencias de todos los datos y modelos utilizados para asegurarnos de que no incumplimos ninguna de las regulaciones existentes.

En cuanto a datos de otros países fuera de la Unión Europea, tenemos panoramas diversos los cuales vale la pena mencionar, desde una regulación más laxa en Estados Unidos, hasta un control estricto en países como China. Estos datos no se utilizarán en este trabajo por temas de alcance, ya que se prefiere dar prioridad a fuentes de datos nacionales, pero las herramientas desarrolladas serían aplicables a estos mismos datos cumpliendo sus normativas.

En Estados Unidos, el panorama es sobre todo abierto, pero fragmentado. Cuentan con regulaciones sectoriales, como la “Health Insurance Portability and Accountability Act” (HIPAA) para datos médicos (Congreso de los Estados Unidos de América, 1996) y regulaciones estatales como la “California Consumer Privacy Act” (CCPA) (Estado de California, 2018) para proteger derechos individuales. También existe una legislación nacional que promueve los datos abiertos, la “OPEN Government Data Act” (2019) (Congreso de los Estados Unidos de América, 2019), que establece que los datos gubernamentales deben ser abiertos y utilizables.

Por su parte, China ha establecido un marco regulatorio estricto con leyes como la “Personal Information Protection Law” (PIPL) (Standing Committee of the National People’s Congress, 2021b), que habla de principios de consentimiento y derechos del individuo, y la “Data Security Law” (DSL) (Standing Committee of the National People’s Congress, 2021a), que prioriza la seguridad nacional y el control sobre los datos generados en el país.

Por último, la tercera complicación es **la tecnología**, como ya se ha hablado, los datos pueden estar en formatos diferentes, y la cantidad de herramientas para su tratamiento va en aumento, y hay que tener en cuenta también la integración, el procesamiento escalable a la cantidad de datos en aumento y el gobierno de los flujos de datos y modelos en un entorno “cloud” que está en evolución constante. Por ello, en este trabajo se ha optado por emplear herramientas ampliamente extendidas, soportadas, y principalmente abiertas, así como intentar hacer del conjunto de ellas lo más amplio posible, para estudiar y comparar un amplio abanico de soluciones. Además se ha utilizado una de las metodologías mas extendidas, la arquitectura de medalla o *medallion architecture*, definida en [Definición 11].

2.1.2. Estudios anteriores y relacionados

Aparte de todas las referencias ya incluidas en esta sección, nos gustaría destacar todo el trabajo de Jaime Gómez-Obregón para liberar y hacer accesibles los datos de España (Gómez-Obregón, 2025a), con acciones como publicar las subvenciones a las empresas en España a través del portal ministerial y hacerlas accesibles (Gómez-Obregón, 2025c), o estudios sobre donaciones sospechosas de corrupción (Gómez-Obregón, 2025b). Todo este trabajo ha guiado también a este proyecto hacia un uso ético de los datos.

Sobre “Big data” y datos públicos, han surgido trabajos en España desde los inicios del *Open government* (definido en el Apéndice A, *Definición 2*) desde 2011, por ejemplo (Ferrer-Sapena et al., 2011), y desde diversos campos como las Ciencias de la Información.

Uno de los más completos que se han podido encontrar en nuestro territorio es el de Mariana Elena Herrera Capriz (Herrera Capriz, 2024), un reciente y extenso trabajo sobre los datos abiertos en España donde, partiendo de una extensa experiencia en la administración pública, la autora busca combinar dos campos con demandas complementarias bajo el marco teórico de la “Teoría de la Ventana” (explicada en el Apéndice A, *Definición 6*) y estudios anteriores de valor público:

- Los Estudios de **Valor Público** (explicados en *Definición 3*) han adolecido tradicionalmente de una base empírica sólida. Existen numero-

sas definiciones teóricas (desde Moore hasta Meynhardt) (Meynhardt, 2009), pero son escasos los estudios que cuantifiquen de manera rigurosa cómo la transparencia y los datos abiertos generan valor público efectivo en la ciudadanía, lo que limita su capacidad para justificar inversiones y guiar la toma de decisiones.

- En lo que respecta a **transparencia y Datos Abiertos** (explicados en *Definición 4*) se ha avanzado significativamente, tanto en la publicación de conjuntos de datos, como en el desarrollo de infraestructuras técnicas. Pero se ha prestado menos atención a la medición del valor final que estos datos generan para los ciudadanos. A menudo se asume que la mera publicación de datos abiertos produce valor, sin evaluar si estos son realmente utilizados, si resuelven problemas concretos o si contribuyen a la creación de servicios que mejoren la calidad de vida de los ciudadanos. Esta falta de evaluación del impacto dificulta la priorización de recursos y la mejora de las políticas de datos abiertos.

La autora trata de medir el valor real que la transparencia y los datos abiertos generan para los ciudadanos, más allá de su mera publicación. Para ello propone un marco metodológico que permite cuantificar el valor de los datos abiertos a través de la percepción de los usuarios. Este enfoque consigue identificar que las dimensiones utilitaria y hedonista (relacionadas con la funcionalidad y la experiencia de usuario) reciben puntuaciones altas, mientras que las dimensiones político-social y moral-ética (relacionadas con la generación de comunidad, equidad y trato justo) lastran el valor potencial, y detectan también que determinantes clave como la frecuencia de uso y el tipo de datos (geoespaciales, movilidad, turismo) son factores condicionantes para maximizar el valor.

Se quiere destacar también la gran labor de investigación sobre datos abiertos del trabajo, que ha sido clave como base para la realización de este mismo proyecto y la utilidad de los resultados, que influirá en la utilización de los datos públicos de este proyecto.

En cuanto a trabajos más práctico-tecnológicos, hay muchos de ellos que destacar. En la Unión Europea, a través de la iniciativa *Use Case Observatory*, ha realizado un extenso estudio sobre la reutilización de datos abiertos. Este proyecto, liderado por el Portal Europeo de Datos (data.europa.eu), tiene como objetivo medir el impacto económico, gubernamental, social y medioambiental de los datos abiertos a partir de casos de uso reales (Carzaniga et al., 2022). Para ello, seleccionó una muestra inicial de más de 600 aplicaciones y servicios que utilizaban datos abiertos, de los cuales escogieron a 150 con valor significativo, y 30 pasaron a formar parte del estudio longitudinal. De estos 30 casos, el seguimiento se centró finalmente en 13, cuyos resultados se recogen en los tres volúmenes del observatorio (Nijssen, 2022).

Entre la amplia variedad de casos estudiados, nos gustaría destacar los siguientes tres españoles y uno francés:

- **UniversiDATA:** Un portal que integra seis universidades españolas para el análisis avanzado y dinámico de datos abiertos con el objetivo de crear resultados interactivos y en tiempo real, facilitando el uso compartido de recursos y mejorando la comprensión de datos abiertos (UniversiDATA, 2025). El equipo también fomentó el uso de sus datos con diferentes análisis propios (UniversiDATA, 2020) o el lanzamiento de eventos centrados en datos (o “Datathones” *Definición 7* (UniversiDATA, 2024) de los cuales hablaremos a continuación). También resuelven dudas de usuarios e investigadores en los conjuntos de datos o análisis a través de comentarios, fomentando aún más la comprensión de los datos.
- **Tangible Data:** Transforma datos espaciales digitales en esculturas físicas accesibles.
- **Planttes:** Aplicación que informa sobre la floración de plantas y su impacto en las alergias al polen, combinando datos abiertos con aportaciones de usuarios. Esto fomenta la concienciación, información y educación sobre alergias (Concepción De Linares, 2025b).
- **Open Food Facts:** Aplicación que informa sobre detalles de productos de supermercado. Destaca por la enorme cantidad de datos que ha conseguido recopilar de usuarios de todo el mundo, y lo intuitiva que es a la hora de usar toda esta cantidad de datos (con más de 4,6 millones de productos). (Concepción De Linares, 2025a).

Como ya se ha comentado, otra fuente importante de proyectos relacionados con datos serían los “Datathones” *Definición 7*. De estas competiciones pueden salir decenas de proyectos relacionados con datos abiertos en muy poco tiempo, literatura que sería inabarcable mencionar en este proyecto debido a los más de 20 Datathones diferentes que se pueden encontrar, así como los múltiples proyectos que hay en cada uno. Aun así, nos gustaría mencionar iniciativas como la del Gobierno de España (Gobierno de España, 2025b,a) con centenares de eventos sobre datos a fecha de publicación de este trabajo.

Por último, también mencionaremos trabajos académicos de fin de máster (TFM) de compañeros que han implementado soluciones con datos públicos, que aunque son algo antiguos siguen aportando valor:

- **“Auditoría y metodología de implantación de open data para smart cities”** (Melendrez Moreto, 2016): Donde el autor hace un análisis extensivo de los datos abiertos, de los índices y métricas para evaluar el valor de estos datos y de herramientas como “CKAN” para

la gestión de los datos. Audita diversas fuentes de datos nacionales dejando todas dentro del umbral de datos abiertos según AENOR.

- **“Uso de geolocalización y de fuentes de datos abiertas para la creación de servicios turísticos por la ciudad de Madrid”** (Arellano Bruno, 2019): El cual utiliza datos abiertos de geolocalización en Madrid para buscar sitios cercanos en una app móvil.
- **“Integración y visualización de datos abiertos medioambientales”** (Llamocca Portela, 2016): También hace un análisis extensivo de los datos abiertos, de las definiciones para evaluar estos datos y de herramientas como “CKAN”. Además, comenta iniciativas de limpieza de datos interesantes como “Data Tamer” o “Data Wrangler”. Finalmente, crea una aplicación para el uso de datos medioambientales en tiempo real.

2.1.3. Conjuntos de datos

Para embarcarse en el tema de los conjuntos de datos, primero tenemos que saber qué tipos de datos hay en el mundo real (Sarker, 2021) dependiendo de formato y forma, estos pueden ser:

- **Estructurados:** Datos con un formato definido, siguiendo un modelo de datos estándar como tablas o bases de datos relacionales (ej. fechas, direcciones, geolocalización).
- **No estructurados:** Datos sin un formato o estructura predefinida, más difíciles de procesar y analizar, principalmente texto y multimedia (ej. correos electrónicos, blogs, PDFs, audio, videos, etc.).
- **Semi-estructurados:** Datos que no se almacenan en bases de datos relacionales, pero tienen cierta organización (ej. HTML, XML, JSON o bases de datos NoSQL).
- **Metadatos:** Datos sobre otros datos, que describen información relevante para dar significado a los datos (ej. autor de un documento, tamaño de archivo, fecha de creación, palabras clave, etc.).

Teniendo esto en cuenta, para el desarrollo de este proyecto donde pretendemos obtener valor de los mismos de la forma más automática y escalable, se elegirán principalmente datos estructurados, semiestructurados y los metadatos que proporcionen los portales. También, recalando la prioridad de este proyecto en conjuntos de datos cercanos, destacamos algunos de los conjuntos de datos e iniciativas más interesantes encontrados durante el estudio:

- **Internacionales:** Iniciativas individuales como “Awesome public datasets” (Awesome data, 2025), que recopila fuentes de datos fiables (aunque principalmente de Estados Unidos) o los repositorios de las nubes privadas, como los de AWS y Google, que alojan petabytes de datos estructurados y no estructurados.
- **Europeos:** Europa cuenta con su propio portal para acceder a datos públicos (Unión Europea, 2025b) con más de 1,7 millones de conjuntos de datos de 36 países de la eurozona, y con todo tipo de estructuras: datos tabulares (CSV, Excel), geoespaciales y APIs sobre economía, ciencia, medio ambiente, etc.
- **Españoles:**
 - El Instituto Nacional de Estadística (INE) y la Agencia Tributaria han sido actores clave en la liberación de datos abiertos y el fomento de su reutilización para investigación e innovación.
 - Proyectos como el Portal de Transparencia del Gobierno de España y las iniciativas de datos abiertos de comunidades autónomas y ayuntamientos (Gobierno de España, 2025c; Ayuntamiento de Madrid, 2025; Registradores de España, 2025), los cuales se esfuerzan por hacer públicos datos de “alto valor” *Definición 1*.
 - Famosas iniciativas como “Kaggle” cuentan con datos de todo tipo sobre España, muchos recopilados de otras fuentes públicas ya nombradas (Kaggle, 2025b).
 - Iniciativas que fomentan la transparencia, como InfoParticipa (Universitat Autònoma de Barcelona, 2025).
 - Propuestas privadas para la recolección de datos públicos (Esri España, 2025).
 - Iniciativas ya mencionadas como UniversiDATA (UniversiDATA, 2025).

Todos estos portales y aplicaciones son de gran importancia y constituyen la base material sobre la que se sustentan trabajos como el presente. Los conjuntos de datos escogidos se detallan en el apartado *Sección 3.1.1: Materiales y datos*.

2.1.4. Gobierno de los datos

Por último, y habiendo explicado todo lo relativo a los datos, destacaremos la importancia de la gobernanza (definida en la *Definición 8*) de estos datos como uno de los desafíos fundamentales al manejarlos (Leonidas et al.,

2024). En el marco europeo llevamos años promulgando mecanismos para aumentar la confianza y lograr un mayor y mejor intercambio de datos, con reglamentos como el Reglamento de Gobernanza de Datos (DGA) (European Parliament, 2022). Este reglamento presenta tres vías principales: la reutilización segura de datos protegidos del sector público, la intermediación neutral de datos y la cesión altruista de datos para el interés general. Estos mecanismos operativos materializan los principios de la gobernanza: calidad, seguridad, interoperabilidad y confianza.

Para la gestión de datos en este proyecto, adoptaremos un marco de gobernanza de datos basado en el modelo de tres capas propuesto por la OECD (Estratégica, Táctica y Operativa) (OECD, 2019), integrado con el resto de normativas europeas vigentes, como el nombrado DGA, o el Reglamento General de Protección de Datos (RGPD) (Unión Europea, 2016). La aplicación de este marco al proyecto se articulará en la *Sección 3.2.3.1: Métodos de Gobernanza*.

2.2. Nubes

La capacidad real de extraer valor de los volúmenes masivos de datos abiertos detallados en la sección anterior está intrínsecamente ligada a la disponibilidad de recursos computacionales potentes, escalables y económicamente accesibles. Aunque se lleva años hablando de soluciones como las nubes distribuidas *Definición 9*, el paradigma de la computación en la nube gestionada (o pública, que no abierta) (*cloud computing*), con planes gratuitos, es muy relevante para democratizar este acceso, permitiendo a investigadores, startups e instituciones públicas superar las limitaciones del hardware local.

Estas nubes gestionadas nos proporcionan unidades de procesamiento gráfico (GPU) y tensorial (TPU) bajo demanda, además de un ecosistema completo de servicios gestionados diseñados específicamente para el ciclo de vida completo de los datos y la IA. También nos brindan mecanismos de seguridad que, junto a la implementación diligente por parte del usuario (modelo de responsabilidad compartida), aportan la seguridad necesaria para el proyecto. Para este trabajo se ha optado por esta solución. Otra opción posible sería la nube híbrida, que combina el control de una infraestructura privada (“On premise”) con la escalabilidad y economía de la nube pública. Esto es ideal para cargas con datos sensibles, pero complicaría el enfoque de este proyecto.

Para ayudarnos mejor a valorar todas las opciones, vamos a listar la oferta gratuita de algunas de las nubes estudiadas en la *Sección 2.2.1*, basadas en las páginas facilitadas por las mismas nubes, comparadores de precios y artículos independientes (Microsoft, 2026a; Lisdorf, 2021).

En el panorama español, la encuesta del INE, se sitúa en un 44,3 % las empresas españolas de diez o más empleados que utilizaron servicios de computación en la nube de pago en el primer trimestre de 2025, 6,6 puntos porcentuales más que el año anterior (Instituto Nacional de Estadística, 2025). La cifra se mantiene por debajo de la media europea, que Eurostat sitúa en el 52,7 % para ese mismo año, con un crecimiento de 7,4 puntos respecto a la edición anterior de la encuesta (Eurostat, 2026).

De cara al futuro, mientras la estrategia europea prioriza el “edge computing” frente a la cloud privada para ganar autonomía tecnológica y soberanía de datos (European Commission, 2026a)¹, el enfoque del Plan de Digitalización español (Gobierno de España, 2021b) no se aleja de la nube pública, sino que aboga por un modelo híbrido soberano usando NubeSARA (plataforma híbrida que, por sus precios (Gobierno de España, 2026b), e información encontrada (Gobierno de España, 2026a; PreparaTIC, 2026) no vamos a utilizar en este estudio).

También hay alternativas para usar cloud en el territorio europeo y español, como pueden ser: (clouding.io, 2026; GmbH, 2026; Gigas, 2026), en las cuales se podría desplegar máquinas virtuales (*virtual machines* en inglés, (VM)) para la ejecución de modelos y tratamiento de datos, pero que al no tener infraestructura especializada en IA y carecer en su mayoría de capa gratuita, se han excluido del estudio.

Resultaba interesante, por ejemplo, la iniciativa europea *Big Data Test Infrastructure* (BDTI) (European Commission, 2026b; Gobierno de España, 2021a), que ofrecía infraestructura gratuita a organismos públicos y trabajos como este, pero el proyecto concluyó en marzo de 2025 y sus recursos quedaron archivados. También SIMPL (European Commission, 2024), un *framework* para construir sobre diferentes proveedores cloud y edge. Telefónica Tech también vende una especie de nube pública basada en VMware, pero principalmente son servicios gestionados multi-cloud (Telefónica, 2026). Por último, nombrar dos herramientas europeas que sí pueden resultar útiles, y que analizaremos en *la próxima sección 2.2.1*, como “OVHcloud” (proveedor de cloud francés) y “OpenNebula” (plataforma española open-source para gestionar clouds).

¹Matiz sobre “edge computing”: Aunque es especialmente importante en el uso de aplicaciones de IA *Tabla A.2*, debido a la importancia de la privacidad en escenarios con datos tratados automáticamente, al ser esto una investigación y no una tecnología dirigida a un usuario final (el cual requeriría velocidad y privacidad), se optará por ejecutar los modelos en la nube en vez de en edge, aunque se reconoce su potencial para aplicaciones prácticas.

2.2.1. Principales Proveedores de Nube y sus Capas Gratuitas

A continuación detallaremos las pruebas gratuitas de los principales proveedores de servicios en la nube, información crucial para la selección tecnológica de este proyecto. (R.I.Penaar, 2025). Estas cifras se verificaron por última vez en agosto de 2026, pero al ser ofertas comerciales sujetas a cambios ² se genera una volatilidad que hay que considerar en proyectos que dependan de estos recursos.

Google Cloud Platform

Ecosistema de servicios en la nube de Google con infraestructura escalable, herramientas de análisis y soluciones de IA gestionadas que cubre todo el ciclo de vida de los datos y aplicaciones. Aparte de las aplicaciones listadas, Google también ofrece 300€ para exceder estos límites los primeros 3 meses de prueba ³. A continuación se describen brevemente los servicios más relevantes:

- **App Engine:** plataforma PaaS para desplegar aplicaciones web sin gestionar la infraestructura subyacente (28 horas/día de ejecución “frontend”, 9 horas/día de ejecución “backend”). ⁴
- **Cloud Firestore:** base de datos NoSQL en tiempo real (1 GB almacenamiento, 50.000 lecturas, 20.000 escrituras, 20.000 borrados por día).
- **Compute Engine:** VM (IaaS) para cargas de trabajo personalizadas (1 instancia e2-micro, 30 GB disco, 5 GB de instantáneas).
- **Cloud Storage:** almacenamiento de objetos para cualquier tipo de dato (5 GB, 1 GB de tráfico de salida).
- **Cloud Shell:** terminal Linux en el navegador con 5 GB de almacenamiento persistente (límite de 60 horas/semana).
- **Cloud Pub/Sub:** servicio de mensajería para comunicar aplicaciones (10 GB de mensajes por mes).
- **Cloud Functions:** ejecuta código en respuesta a eventos (2 millones de invocaciones por mes).

²Como evidenció el propio desarrollo de este trabajo, entre la redacción inicial de esta sección y su revisión final, varios de los servicios consultados modificaron sus límites

³Lista completa: <https://cloud.google.com/free>

⁴Nota: 28 horas/día es el total de horas de instancia que se pueden acumular en un día, por ejemplo, 1 hora de 28 instancias diferentes.

- **Cloud Run**: ejecuta contenedores sin servidor (2M de peticiones por mes, 360.000 GB/segundos de memoria).
- **Google Kubernetes Engine (GKE)**: orquestación de contenedores con Kubernetes (sin tarifa de gestión para un clúster zonal).
- **BigQuery**: almacén de datos para análisis SQL (1 TB de consultas por mes, 10 GB de almacenamiento).
- **Cloud Build**: construcción de imágenes y despliegue continuo (120 minutos de construcción por día).
- **Cloud Source Repositories**: repositorios Git privados (hasta 5 usuarios, 50 GB de almacenamiento, 50 GB de tráfico).
- **Google Colab**: entorno de Jupyter Notebooks gratuito para ML.

Amazon Web Services

Plataforma de cloud computing más usada a nivel empresarial, con una enorme cantidad de servicios, desde cómputo básico hasta servicios de IA, ML, IoT, etc. Tiene una capa gratuita de 6 meses y 100 dólares de gastos + 100 adicionales al completar tareas⁵.

- **CloudFront**: CDN para distribuir contenido estático y dinámico (1 TB de tráfico de salida por mes y 2M invocaciones de funciones).
- **CloudWatch**: monitorización y observabilidad de recursos (10 métricas personalizadas y 10 alarmas).
- **CodeBuild**: servicio de construcción de código (100 min de tiempo de ejecución por mes).
- **CodeCommit**: repositorios Git privados (5 usuarios activos, 50 GB almacenamiento, 10.000 peticiones por mes).
- **CodePipeline**: automatización de despliegues (1 pipeline activo por mes).
- **DynamoDB**: base de datos NoSQL clave-valor (25 GB).
- **EC2**: VM (750 horas/mes de t2.micro o t3.micro, 6 meses).
- **EBS**: discos persistentes para EC2 (30 GB por mes de SSD, 6 meses).
- **Elastic Load Balancing**: distribución de tráfico entre instancias (750 horas por mes, 6 meses).

⁵Lista completa: <https://aws.amazon.com/free/>

- **RDS**: bases de datos relacionales gestionadas (750 horas/mes de db.t2.micro, 20 GB almacenamiento SSD, 6 meses).
- **S3**: almacenamiento de objetos (5 GB estándar, 20K peticiones Get, 2K peticiones Put, 6 meses).
- **Glacier**: almacenamiento a largo plazo (10 GB).
- **Lambda**: código sin servidor basado en eventos (1 millón de peticiones por mes).
- **SNS**: notificaciones y mensajería push (1 millón de publicaciones por mes).
- **SES**: envío de correos electrónicos (3.000 mensajes por mes, 6 meses).
- **SQS**: colas de mensajería desacoplada (1 millón de peticiones).

Microsoft Azure

Ecosistema cloud de Microsoft, muy integrado con todas sus herramientas empresariales y de desarrollo, como la suite de DevOps, soluciones de IA y enfoque en el lenguaje .NET entre otras. También tiene una capa gratuita de 12 meses⁶.

- **Virtual Machines**: VM IaaS (1 B1S Linux VM, 1 B1S Windows VM, 12 meses).
- **App Service**: PaaS para aplicaciones web y APIs (10 apps con 60 min CPU/día).
- **Functions**: computación serverless basada en eventos (1 millón de peticiones por mes).
- **DevTest Labs**: entornos de desarrollo y pruebas.
- **Active Directory**: servicio de directorio y autenticación (500.000 objetos).
- **Azure DevOps**: herramientas de CI/CD (5 usuarios activos, repositorios Git privados ilimitados).
- **Azure Pipelines**: automatización de construcción y despliegue (10 trabajos paralelos, minutos ilimitados para código abierto).
- **Microsoft IoT Hub**: plataforma para dispositivos IoT (8.000 mensajes por día).

⁶Lista completa: <https://azure.microsoft.com/free/>

- **Load Balancer:** balanceo de carga (1 IP pública con balanceo gratuito).
- **Notification Hubs:** envío de notificaciones push (1 millón de notificaciones).
- **Ancho de banda:** transferencia de datos (15 GB de entrada y 5 GB de salida por mes, 12 meses).
- **Cosmos DB:** base de datos NoSQL global (25 GB y 1.000 unidades de solicitud de rendimiento).
- **Static Web Apps:** alojamiento de aplicaciones estáticas con SSL y autenticación.
- **Storage:** almacenamiento de blobs y archivos (5 GB con redundancia local, 12 meses).
- **Cognitive Services:** APIs de IA pre-entrenadas (transacciones limitadas).
- **Cognitive Search:** búsqueda basada en IA (10.000 documentos).
- **Azure Kubernetes Service (AKS):** Kubernetes gestionado (gestión de clústeres).
- **Event Grid:** enrutamiento de eventos (100K operaciones/mes).

Oracle Cloud

Nube especializada en bases de datos de alto rendimiento (Oracle Database), aplicaciones Java, y soluciones de analytics. Ofrece una capa gratuita con recursos que no expiran⁷.

- **Compute:** VM IaaS (2 VM AMD con 1/8 OCPU y 1 GB memoria cada una).⁸
- **Block Volume:** discos persistentes (2 volúmenes, 200 GB total).
- **Object Storage:** almacenamiento de objetos (10 GB).
- **Load Balancer:** balanceo de carga (1 instancia con 10 Mbps).
- **Databases:** bases de datos (2 bases de datos, 20 GB cada una).
- **Monitoring:** monitorización de recursos (500 millones de puntos de ingesta, 1 millardo de recuperación).

⁷Lista completa: <https://www.oracle.com/cloud/free/>

⁸OCPU (Oracle CPU) es la unidad de procesamiento de Oracle.

- **Ancho de banda:** transferencia de datos (10 TB de tráfico de salida por mes, limitado a 50 Mbps).
- **IP Pública:** direcciones IP (2 IPv4 para VMs, 1 IPv4 para balanceador).
- **Notifications:** notificaciones push y email (1 millón de entregas por mes, 1.000 emails).

IBM Cloud

Plataforma centrada en la transformación digital de grandes empresas con necesidades híbridas y multicloud, aunque también con una capa gratuita⁹.

- **Cloudant database:** base de datos NoSQL (1 GB de almacenamiento).
- **Db2 database:** base de datos relacional (100 MB).
- **API Connect:** gestión y exposición de APIs (50.000 llamadas API por mes).
- **Availability Monitoring:** monitorización de disponibilidad (3 millones de puntos de datos por mes).
- **Log Analysis:** análisis de logs (500 MB de registros diarios).

Cloudflare

Plataforma especializada en rendimiento web, seguridad y confiabilidad. Aunque no es una nube generalista, sino más bien una red global que acelera y protege sitios web, APIs y aplicaciones mediante su CDN, DNS, servicios de seguridad, etc. También tiene capa gratuita¹⁰.

- **Application Services:** DNS, protección DDoS, CDN con SSL, firewall WAF.
- **Zero Trust & SASE:** seguridad de acceso (hasta 50 usuarios, 24 horas de registro de actividad).
- **Cloudflare Tunnel:** exposición de servicios locales sin puertos públicos.
- **Workers:** computación serverless en el edge (100k peticiones diarias).

⁹Lista completa: <https://www.ibm.com/cloud/free/>

¹⁰Lista completa: <https://www.cloudflare.com/plans/free/>

- **Workers KV**: almacenamiento clave-valor para Workers (100k lecturas, 1000 escrituras diarias, 1 GB).
- **R2**: almacenamiento de objetos compatible con S3 (10 GB por mes, 1 millón operaciones).
- **D1**: base de datos SQLite distribuida (5 millones de filas leídas, 100k escritas por día, 1 GB).
- **Pages**: alojamiento de aplicaciones web estáticas (500 despliegues mensuales, 100 dominios personalizados).
- **Queues**: colas de mensajería (1 millón de operaciones por mes).
- **TURN**: servidor TURN para WebRTC (1 TB de tráfico saliente por mes).

OVHcloud

Proveedor de cloud francés con un fuerte compromiso con la soberanía de los datos y el RGPD. Ofrece una gama completa de servicios de infraestructura (IaaS) y plataforma (PaaS) desde sus centros de datos. Ofrece 200 euros en créditos para probar el servicio durante un mes¹¹. Los planes gratuitos disponibles son los siguientes (OVHCloud, 2026):

- **Despliegue de un e-commerce**: incluye 2 servidores B2-7, 1 base de datos MySQL, 1 IP adicional, 1 Balanceador de Carga y 10 GB de Almacenamiento de Objetos.
- **Prueba de Kubernetes y escalado**: 3 servidores B2-15 durante 1 mes y 12 horas de picos de tráfico en 10 servidores C2-30.
- **Desarrollo y Entrenamiento de IA**: 1 TB de almacenamiento de objetos, 35 horas de IA Notebook (AI1-1-GPU) y 5 horas de entrenamiento de IA en 4 nodos AI1-1-GPU.

2.2.2. Otras herramientas de interés

También, aunque no son nubes propiamente dichas, se ha querido añadir en esta sección otras herramientas que tienen interés para el proyecto:

¹¹Lista completa: <https://www.ovhcloud.com/en/public-cloud/prices/>

Hugging Face Spaces

- **Tipo:** Plataforma para desplegar, compartir y descubrir modelos de Aprendizaje Automático (MLOps). Esencial para proyectos de IA. Permite desplegar demostraciones de modelos con interfaz web de forma sencilla ¹².
- **Capa Gratuita - CPU:**
 - 2 CPUs virtuales por espacio.
 - 16 GB de RAM.
 - Espacio de almacenamiento: 50 GB (para modelos, datos y código).
 - Ancho de banda: 100 MB/hora para CPUs.
 - **Apagado automático:** Los espacios se suspenden tras 48 horas de inactividad para ahorrar recursos, reactivándose con la siguiente visita.
- **Capa Gratuita - GPU (T4):**
 - Acceso a una GPU NVIDIA T4 por espacio.
 - 16 GB de RAM.
 - Espacio de almacenamiento: 50 GB.
 - Ancho de banda: 30 MB/hora para GPUs.
 - Uso: Hasta 30 horas de uso de GPU por mes, pero sujeto a disponibilidad.
 - **Apagado automático:** Las GPU se apagan automáticamente tras 1 hora de inactividad.
- **Enfoque:** Despliegue, demostración y compartición de modelos de IA. Integración nativa con el Hub de modelos y conjuntos de datos.

Kaggle Kernels/Notebooks

- **Tipo:** Entorno de ejecución para cuadernos “Jupyter” en la nube. Proporciona acceso gratuito a aceleradores hardware de gama alta, eliminando la barrera de entrada para entrenar modelos complejos ¹³.
- **Capa Gratuita - Sesiones de Ejecución:**

¹²URL: <https://huggingface.co/spaces>

¹³URL: <https://www.kaggle.com/code>

- **GPU (NVIDIA Tesla P100)**: Hasta 30 horas por semana (4,3 h/día aprox.).
 - **TPU (v3)**: Hasta 20 horas por semana (2,8 h/día aprox.).
 - **CPU**: 20 horas de tiempo total por semana, sin límite de sesiones concurrentes.
- **Límites por Sesión:**
- **Tiempo máximo de ejecución**: 12 horas por sesión. Tras este tiempo, el kernel se detiene automáticamente.
 - **Internet**: Los cuadernos deben tener la opción de Internet activada manualmente para acceder a datos externos o instalar librerías.
 - **Almacenamiento Volátil**: 20 GB de espacio temporal de disco. Los datos no persisten entre sesiones, aunque se puede usar el sistema de conjuntos de datos de Kaggle para almacenamiento persistente.
- **Enfoque**: Análisis exploratorio de datos, competiciones de ML y, crucialmente, **entrenamiento de modelos** que requieran GPU/TPU.

Open Data Editor

Herramienta de código abierto¹⁴ diseñada para la gestión y publicación de datos abiertos. Desarrollada por la “Open Knowledge Foundation”, facilita la creación, validación y limpieza de conjuntos de datos en formatos abiertos, con un enfoque en la usabilidad para usuarios no técnicos, para garantizar la calidad y accesibilidad de los datos públicos. Funcionalidades clave:

- Creación y edición tabular de datos.
- Validación de esquemas y metadatos.
- Integración con plataformas de datos abiertos (CKAN, S3, etc.).
- Exportación a formatos estandarizados (CSV, JSON, XLSX).

Canonical MicroCloud

Se trata de una nube privada impulsada por Canonical (Canonical Ltd., 2026), (empresa que desarrolla y mantiene el sistema operativo Ubuntu). Está orientada al *edge computing* y a despliegues de pequeña escala. Permite orquestar infraestructura agrupando un mínimo de tres servidores físicos

¹⁴<https://okfn.org/en/projects/open-data-editor/>

(nodos). Su arquitectura es un conjunto de tecnologías de código abierto: emplea *LXD* para la gestión conjunta de VM y contenedores de sistema, *MicroCeph* para el almacenamiento distribuido, y *MicroOVN* para la configuración de las redes de forma definida por software (SDN). Para el proyecto, esta solución podría permitir levantar una infraestructura autogestionada y de bajo consumo de recursos en minutos para ejecutar los procesos y modelos. Funcionalidades clave:

- Despliegue automatizado (*Zero-ops*) a través de una red (mDNS).
- Ejecución tanto de contenedores de sistema como VM completas.
- Almacenamiento y redes distribuidas.
- Optimización con distribución inmutable mediante paquetes *Snap*.

RapidMiner Studio (actualmente Altair AI Studio)

Aunque sin ser una cloud, tiene relevancia por ser una plataforma de software para el ciclo de vida completo de la ciencia de datos y ML ¹⁵, abarcando desde la preparación de datos hasta la creación y despliegue de modelos, centrándose en la automatización y la facilidad de uso mediante una interfaz gráfica de usuario con modelo de “cajas” (Tallin university (TLU), 2024).

- **Tipo:** Plataforma integral de Data Science y ML (desde ETL hasta MLOps básicos).
- **Capa Gratuita - RapidMiner Studio Free:**
 - **Funcionalidades:** Acceso a algoritmos de ML (clasificación, regresión, clustering, etc.), herramientas de preparación de datos, evaluación y visualización. Incluye capacidades de AutoML (ML Automatizado, explicado en la *Sección 2.3.2.3*) para la selección de modelos y optimización de hiperparámetros.
 - **Limitaciones:** Generalmente restringido en el número de filas de datos procesables en memoria y el número de operadores por proceso, adecuado para aprendizaje y proyectos de tamaño pequeño a mediano.

Nubes descentralizadas

Plataformas descentralizadas como *Golem Network* (Golem Network, 2026), *Akash cloud* (Akash, 2026) o *Render Network* (Render Network, 2026), podrían ser útiles en proyectos con exceso de potencia de computación, ya que

¹⁵URL: <https://altair.com/altair-rapidminer>

se permiten alquilar este exceso a cambio de tokens, que más tarde se pueden usar para las tareas intensivas cuando fuera necesario (Se definen en más detalle en *Definición 9*).

OpenNebula

Plataforma de código abierto con origen en España y EE.UU¹⁶, la cual se centra en virtualización de centros de datos y gestión de nubes privadas, híbridas y públicas. Permite construir y gestionar infraestructuras IaaS (Infraestructura como Servicio) para cloud sobre la infraestructura de tecnología existente. Ofrece funcionalidades para el aprovisionamiento automático, es independiente del proveedor y soporta diversas interfaces de nube, proporcionando flexibilidad, control y soberanía de datos (Kumar et al., 2014; Vogel et al., 2016). Sin embargo, pese a ser una opción interesante, no se ha tenido en cuenta para este proyecto, que prioriza el acceso inmediato a hardware y servicios de IA gestionados sin coste inicial de infraestructura ni tiempo.

2.2.3. Estudios anteriores y relacionados

Existen numerosos trabajos que abordan aspectos generales de la computación en la nube, más que herramientas específicas. A continuación se revisan algunos relevantes.

El libro **“Cloud Computing Technology”** (Huawei Technologies Co., Ltd., 2023) agrupa todos los conceptos del panorama cloud actual, así como los elementos que todas las nubes comparten entre sí. También da un panorama de la situación cloud en China, lo cual amplía los horizontes del conocimiento cloud. El libro (Fowdur, 2021) introduce en su capítulo 2 interesantes definiciones sobre cloud. También es interesante el trabajo de (Nigro, 2022), que estudia las oportunidades, desafíos y antecedentes de la computación en la nube, o el trabajo de (Bommala et al., 2024), que tiene un enfoque muy interesante, denominando al ecosistema “cloud verse” y centrándose en las innovaciones de los últimos años (infraestructuras de nube híbrida, modelos de computación sin servidor o “serverless”, “edge computing”, integración de IA, etc.), con un interesante enfoque en seguridad y cumplimiento de normativas, la integración de “blockchain” y el énfasis en la computación en la nube “verde” y sostenible.

Aunque no únicamente dirigido a cloud, también vale la pena destacar portales o iniciativas que buscan opciones de código abierto o de fácil acceso,

¹⁶<https://opennebula.io/>

las cuales han sido de mucha ayuda, como la iniciativa de la Unión Europea (Unión Europea, 2025a) o compilaciones como (R.I.Pienaar, 2025).

Por último, querría destacar trabajos de compañeros como **“Optimización de infraestructuras de Cloud Computing basadas en VM”** (Sánchez de Paz, 2023), el cual hace una excelente labor de investigación de todo lo relacionado con la computación en la nube para predecir el consumo futuro de recursos en VM de Azure (con sus datos públicos), y así mejorar la eficiencia y la gestión de la infraestructura.

2.3. Inteligencia Artificial

La IA, y más específicamente el ML, está emergiendo como el paradigma tecnológico más transformador de la década y uno de los más importantes de la historia (*La historia completa de la IA se define en la definición 12*). Aunque desde sus inicios ha pasado por algunos “inviernos” (Cheok y Zhang, 2023), el lanzamiento de “ChatGPT” en 2022 catapultó la fama de esta tecnología (*figura A.3* del apéndice de definiciones).

Estudios del ONTSI (Observatorio Nacional de Tecnología y Sociedad, 2025) revelan que en 2024, el 11,4 % de las empresas españolas de 10 o más empleados usaba IA, un dato ligeramente inferior a la media de la UE (13,5 %), aunque por encima de potencias como EE.UU. (5,7 % según OECD, o 7,3 % del total de empresas según Business Trends and Outlook Survey (Encuesta de Tendencias y Perspectivas Empresariales)). En cuanto a la población general, en 2024 un 73,8 % de los españoles tenían conocimiento de la existencia de la IA generativa, y un 56,8 % la utilizó durante el año. Los datos de 2025 según la encuesta del INE (Instituto Nacional de Estadística, 2025) aumentan la cifra: el 21,1 % de las empresas españolas de 10 o más empleados utilizó tecnologías de IA en el primer trimestre de 2025.

Aunque la reciente fama de la IA viene dada por los modelos generativos basados en *transformers* (Vaswani et al., 2017), la aplicación de esta ciencia y sus tecnologías relacionadas va más allá de esto: el núcleo de esta revolución reside en el conjunto de herramientas algorítmicas para el análisis predictivo y la extracción de patrones en datos masivos, lo cual incluye los modelos generativos, pero no exclusivamente. En este proyecto se pretende utilizar ese potencial a través de plataformas cloud como Google Vertex AI, el uso de diferentes modelos de clasificación y clusterización o de detección de anomalías, con el propósito de intentar transformar el vasto volumen de datos públicos, a menudo infrautilizados, en “insights” o conclusiones de valor público.

También aclarar que, por acotar el alcance del proyecto, este trabajo no

tendrá en cuenta avances en IA que traten datos multimedia, como videos, audios e imágenes, aunque reconocemos el increíble avance que han tenido tecnologías de visión por computador o creación de multimedia y su utilidad en LLM multimodales. Con esto en mente, en las siguientes secciones vamos a ver cómo aplicar el ML al proyecto, revisando los modelos tradicionales, tecnologías que proporcionan las nubes para usarlos, como el AutoML. Igual que para los datos se han tenido en cuenta ideas de gobernanza de datos, para la aplicación de los modelos se tendrán en cuenta los principios de las Operaciones de aprendizaje automático (MLOps) *Definición 14*.

2.3.1. Modelos de ML

Vamos a estudiar los modelos de ML pertinentes para el análisis predictivo y la extracción de patrones en datos. Aunque se pueden clasificar de varias maneras, aquí se dividirán según dos tipos de categorías:

- Según tipos de aprendizaje según la disponibilidad y calidad de etiquetas (Definidos con detalle en la *definición 13*)
- Según la naturaleza de los datos (tabulares, no estructurados, etc.) [definidos en la *Sección 2.1.3*]

Debido a la utilización principal de datos estructurados y semiestructurados, se priorizarán los modelos adaptados mejor a este tipo de datos (Fowdur, 2021). Para la elección del modelo, seguiremos el esquema extraído del estudio (Brownlee, 2024b), con ejemplos para cada algoritmo:

Paso uno: ¿Se necesita predecir algo?

- Si (Aprendizaje Supervisado):
 - Si la predicción es sobre **categorías** → *Tarea de Clasificación*.
 - Si la predicción es sobre **datos temporales** → *Predicción de Series Temporales*.
 - Si la predicción es sobre **otras características** → *Tarea de Regresión*.
- No (Aprendizaje No Supervisado):
 - Si el objetivo es **encontrar grupos** → *Clusterización*.
 - Si el objetivo es **encontrar anomalías** → *Detección de Anomalías*.

Paso dos: ¿Qué tipo de datos tenemos?

- **Simple:** Datos Estructurados → Algoritmos ML Simples:
 - **Árboles de Decisión o k-Nearest Neighbors** (para clasificación / regresión)
 - **K-means** (para clusterización)
- **Intermedio:** Múltiples Características / Imágenes de Baja Resolución → Métodos de Ensemble:
 - **Random Forests, XGBoost** (ejemplos para clasificación / regresión)
 - **DBSCAN** (para clusterización)
- **Complejo:** Imágenes / Texto / Audio → Algoritmos más complejos:
 - Redes Neuronales Profundas
 - LLM

Para tomar mejor las decisiones, se han estudiado estos modelos para comprobar su valor dependiendo del tipo de datos *Definición 15*. Debido a que los modelos elegidos para cada conjunto de datos depende del tipo de los mismos (e incluso aún sabiendo el tipo de datos es difícil saber si cierto modelo funcionará mejor que otro), estos se detallarán para cada conjunto de datos en el apartado *Sección 3.2.4: Modelos de Aprendizaje automático*.

2.3.2. ML en la nube

Todos los modelos que se han comentado, particularmente los más complejos, tienen algo en común: son bastante exigentes en el consumo de procesamiento, tanto de CPU como sobre todo de GPU o TPU (Sze et al., 2017). Esta barrera de entrada hardware ha sido tradicionalmente un impedimento para investigadores, estudiantes y pequeñas organizaciones para ejecutar estos modelos. En este punto es donde puede ser muy útil el paradigma de la computación en la nube, sobre todo los grandes proveedores con sus capas gratuitas. Estas capas no solo proporcionan la infraestructura base para poder crear estos modelos, sino que además tienen herramientas especializadas para ello. Esto facilita la implementación de un ciclo de vida completo de ML con MLOps.

En este proyecto se utilizarán varias herramientas. En cuanto a los datos, los almacenaremos dependiendo de la nube utilizada para su procesamiento, pues cada una de las nubes puede comunicarse con un número limitado y específico de herramientas de almacenamiento. Los modelos entrenados se almacenarán también en la solución de almacenamiento de la propia nube (AWS S3, Azure Storage, etc.) cuando se requiera su uso. Para entrenamiento

o inferencia, además de las plataformas de MLOps comentadas, también merece la pena destacar opciones como “Kaggle notebooks” o “HuggingFace Spaces” que detallaremos en los siguientes apartados.

2.3.2.1. Plataformas MLOps en la Nube

Los principales proveedores de nube ofrecen plataformas completas diseñadas para gestionar el ciclo de vida de los modelos de ML (Böer, 2023):

- **Gemini Enterprise Agent Platform (Anteriormente Google Vertex AI):** Integra herramientas para todo el ciclo de vida del ML y la IA generativa: preparación de datos, entrenamiento, despliegue y monitoreo en su GUI / CLI. Abstrae gran parte de la gestión de infraestructura y ofrece comunicación con las herramientas de Google Cloud Platform (GCP) y ofrece varios modelos preentrenados, incluyendo modelos de Hugging Face, Stable Diffusion, etc. (Google, 2025b). Durante el desarrollo de este trabajo, la plataforma se reestructuró y evolucionó hacia una plataforma centrada en agentes autónomos, lo que ilustra la alta volatilidad en la interfaz y nomenclatura de los servicios en la nube.
- **AWS SageMaker:** Proporciona un conjunto completo de herramientas y servicios para construir, entrenar y desplegar modelos de ML a escala, incluyendo notebooks gestionados, algoritmos y entrenamiento distribuido. Soporta una amplia gama de fuentes de datos como S3, Athena, Redshift, Snowflake y Databricks (Amazon Web Services, 2025).
- **Azure ML:** Ofrece un entorno para el desarrollo y despliegue con herramientas para la preparación de datos, entrenamiento de modelos, gestión de experimentos y automatización de flujos de trabajo de ML, además de ofrecer modelos de Hugging Face y OpenAI. Sus fuentes de datos principales incluyen Azure Blob Storage, Azure File Share y Azure Data Lake (Microsoft, 2025).
- **OVHcloud (AI Notebook y AI Training):** Ofrece sus servicios “AI Notebook” y “AI Training”, con infraestructura gestionada, incluyendo acceso a GPUs, para el desarrollo y entrenamiento de modelos. No tiene un entorno tan potente como el resto de clouds, pero ofrece una capa gratuita generosa y localizada en Europa (OVHcloud, 2025).

2.3.2.2. Otras herramientas

Además de las plataformas comentadas, existen herramientas especializadas de gran utilidad y con capas gratuitas que ya se ha comentado en la *Sección de cloud 2.2.2*, pero merece la pena concretar:

- **Kaggle Kernels/Notebooks:** Es ideal para análisis exploratorio de datos, competiciones de ML y entrenamiento de modelos intensivos (Kaggle, 2025a) por el acceso a sus GPUs.
- **Google Colab:** Alternativa excelente para el entrenamiento de modelos complejos, funcionando como un entorno de desarrollo gratuito con Jupyter Notebooks que ofrece GPUs y TPUs, especialmente popular por su facilidad de uso y su integración con el ecosistema de Google y GCP (Google, 2025c).
- **Hugging Face Spaces:** Plataforma dedicada al despliegue, comparación y descubrimiento de modelos de ML ya creados, muy útil para pruebas de concepto, permitir la prueba de modelos o utilizar los que la comunidad ha creado (Hugging Face, 2025).

También vale la pena destacar los grandes modelos generativos, los cuales presentan una capacidad de adaptación enorme. Aunque no están diseñados para la ingesta de grandes volúmenes de datos, el aumento de las ventanas de contexto (número de tokens a los que el modelo “presta atención” (Vaswani et al., 2017)), ha hecho que tratar de utilizarlos para el tratamiento de datos tabulares **no sensibles** sea un caso que vale la pena considerar. Teniendo en cuenta, al utilizarlos, todas las consideraciones éticas y de privacidad correspondientes.

Teniendo en cuenta la ventana de contexto de los modelos disponibles en junio de 2026 según el leaderboard de LLM Stats (LLM Stats, 2026) y que un token son aproximadamente cuatro caracteres (Microsoft, 2026b), se ha elaborado una tabla con la cantidad de datos tabulares que los principales modelos de LLM podrían asumir. Se consideran dos escenarios realistas:

- Una fila simple, con un identificador y una etiqueta corta (aproximadamente 50 tokens por fila).
- Una fila compleja, con varias columnas o una descripción de unas 100 palabras (aproximadamente 150 tokens por fila).

Con estos datos se puede observar que los modelos más avanzados ya pueden procesar miles de filas tabulares simples en su ventana de contexto, lo que puede ser suficiente para muchos conjuntos de datos. Ya existen estudios que exploran estas capacidades (Fang et al., 2024).

Tabla 2.1: Ventanas de contexto en tokens de principales LLM (Junio 2026), con su cálculo de filas de datos posibles que entrarían dentro de esa ventana.

Modelo	Proveedor	Tokens	N.º filas (50 t/fila)	N.º filas (150 t/fila)
Grok 4 Fast	xAI	2.000.000	40.000	13.333
GPT-5.5	OpenAI	1.100.000	22.000	7.333
Gemini 3.1 Pro	Google	1.000.000	20.000	6.666
Claude Fable 5	Anthropic	1.000.000	20.000	6.666
DeepSeek-V4-Pro-Max	DeepSeek	1.000.000	20.000	6.666
Qwen3.7 Max	Alibaba	1.000.000	20.000	6.666
GLM-5.2 (pesos abiertos)	Zhipu AI	1.000.000	20.000	6.666

Fuente: Elaboración propia con datos de LLM Stats (2026) (actualizado a junio de 2026).

2.3.2.3. AutoML

Como colofón a las estrategias de construcción de modelos, el Aprendizaje Automático Automatizado (AutoML) representa un conjunto de técnicas y herramientas que simplifican y aceleran el proceso de desarrollo del ML, reduciendo la complejidad de la implementación. Lo consiguen automatizando una, varias o todas las siguientes tareas:

- **Preprocesamiento de datos:** Limpieza y preparación de datos antes de entrenar el modelo.
- **Ingeniería de características:** Creación y selección automática de “features” relevantes.
- **Selección de modelo:** Evaluación automática de varios modelos para escoger el más adecuado.
- **Ajuste de hiperparámetros:** Optimización automática de los parámetros del modelo.
- **Evaluación del modelo:** Cálculo de métricas y generación de informes de desempeño.
- **Ensamblado y “stacking”:** Combinación de múltiples modelos para mejorar la precisión.
- **Reportes y documentación:** Seguimiento automático de todo el proceso de ML.
- **Despliegue y producción:** Implementación del modelo entrenado en un entorno productivo.

Aunque esta tecnología es muy útil para tratar grandes volúmenes de datos de forma rápida, también es muy costosa en cuanto a computación, por lo que no todos los proveedores cloud ofrecen servicios de AutoML. A continuación se listan los principales que sí disponen de esta funcionalidad (Böer, 2023):

- **Google Vertex AI AutoML**
- **AWS SageMaker Autopilot**
- **Microsoft Azure AutoML**

Otra opción sería utilizar herramientas especializadas como “AutoKeras” (Jin et al., 2023) o “AutoSklearn” (Feurer et al., 2020) en la infraestructura que la nube proporciona. Estas librerías implementan soluciones interesantes de AutoML para clasificación.

2.3.3. IA, normativa y ética

El desarrollo de soluciones con IA debe enmarcarse en el nuevo Reglamento de Inteligencia Artificial de la Unión Europea (Unión Europea, 2024a, 2026), que constituye la base normativa de este proyecto. Además del cumplimiento de esta regulación, se han considerado otros principios éticos transversales (supervisión humana, transparencia, equidad y rendición de cuentas), que se detallan en la *Sección 3.2.3.2*. Cabe señalar que, aunque la mayor parte de la reflexión ética reciente se ha centrado en modelos de procesamiento del lenguaje natural (Gabriel et al., 2024, como los estudios de DeepMind), los principios aplicados son de carácter general y extensibles a cualquier dominio de la IA. En este aspecto, el presente trabajo se acoge tanto a la “Declaración Responsable sobre Autoría y Uso Ético de Herramientas de Inteligencia Artificial (IA) de la Universidad Complutense de Madrid” como a los siete estándares éticos definidos por el reglamento europeo.

Para terminar, anteriormente se ha hablado sobre la obtención de “insights” automáticos: es sabido que la IA acelera la identificación de patrones, pero para poder efectuar una interpretación estratégica se necesita el contexto de política pública y la validación humana experta. El principio HITL (“humano en el bucle”, del inglés *Human-In-The-Loop*) (Mosqueira-Rey et al., 2023) es un requisito metodológico y ético para convertir patrones en decisiones, por lo que se ha seguido en este proyecto.

2.3.4. Estudios anteriores y relacionados

Aunque ya se han nombrado varios trabajos en la *Historia sobre la IA - Definición 12*, se ha querido añadir algunas referencias más en este capítulo. El libro (Fowdur, 2021), que introduce en su capítulo 3 un profundo análisis

sobre diferentes modelos de IA. También el libro (Brownlee, 2016) y todo el trabajo del autor en general, el cual ha sido de gran ayuda para afianzar los conceptos de esta sección y todo el trabajo.

También nombrar un par de trabajos muy interesantes sobre AutoML, que al abordar este tema, tratan todas las fases del ciclo completo de los algoritmos de ML. El artículo (Salehin et al., 2024) desglosa cada etapa del flujo de trabajo y explica cómo AutoML automatiza cada una. Destaca la búsqueda de arquitecturas neuronales, que automatizan el proceso de diseño de la arquitectura de una red neuronal, como motor del crecimiento del AutoML. Por otro lado, (Barbudo et al., 2023) se centra más en el campo de investigación de AutoML, con una taxonomía que clasifica todo el campo en fases, tareas y técnicas.

También mencionar trabajos académicos de compañeros con ideas similares a la tratada en este estudio y que han ayudado a guiar el mismo:

- **“Análisis de datos de la ciudad de Madrid”** (Santos, 2023): Donde se realiza un análisis del impacto de la pandemia en la movilidad peatonal de Madrid con datos públicos del Ayuntamiento (2019-2021). El autor utiliza el modelo ARIMA (Autoregresivo) para las series temporales, y K-means para clusterización de datos. En este trabajo, se replicaron las técnicas de tratamiento de datos de este proyecto, aunque su análisis quedó fuera de alcance.
- **“Madrid, isla de calor”** (Meneses Vicente y García Ruíz, 2023): También analizando datos del Ayuntamiento de Madrid, esta vez del clima y la contaminación del año 2021. Los autores utilizaron clusterización, mayormente K-Means, para comprobar hipótesis sobre el clima en la ciudad. Este mismo trabajo se ha replicado y ampliado en este proyecto para comparar las diferentes tecnologías de las que hablamos en esta sección, replicando tanto la descarga y tratamiento de datos, como su uso y análisis en tecnologías cloud y locales.

De hecho, debido a la cercanía de estos trabajos, se ha contactado con sus autores para poder replicar y ampliar lo que hicieron en favor de poder desarrollar una metodología de tratamiento de datos públicos en la nube, y se utilizaron de base para el estudio posterior.

Por último, un estudio que utiliza métodos y sistemas similares a los tratados finalmente en este proyecto es el de Liu et al. (Liu et al., 2025). Los autores analizan puntos térmicos diurnos y nocturnos mediante técnicas de ML como “Random Forest” o “Gradient Boosting” sobre datos satelitales y de temperatura, estudiando la formación de islas de calor en zonas urbanas e industriales. Este enfoque y sus conclusiones sobre la influencia de la altura y densidad de los edificios resultan de gran utilidad para orientar el análisis de la ciudad de Madrid que se desarrolla en este trabajo.

2.4. Conclusiones del capítulo

En este capítulo se ha realizado un recorrido por el estado actual de las tres tecnologías que vertebran el proyecto: datos abiertos, computación en la nube e IA.

En el ámbito de los datos, se ha constatado que, pese a los avances normativos y técnicos, existe una brecha entre la apertura declarada y la reutilización efectiva. Los problemas de calidad, la documentación insuficiente y las barreras técnicas dificultan la automatización. La gobernanza de datos se presenta como un marco necesario para asegurar la calidad, seguridad y transparencia en ciclo de vida del dato.

En el ámbito de la nube, se ha analizado la oferta de los principales proveedores y de otras alternativas, destacando sus capas gratuitas y servicios especializados en IA y ML. Se ha mostrado que la elección de una plataforma no depende únicamente del coste, sino también de la curva de aprendizaje, la integración con otros servicios o la localización de los centros de datos, entre muchos otros factores.

En el ámbito de la IA, se ha revisado el panorama de modelos de ML, plataformas MLOps y herramientas de AutoML, así como el marco regulatorio y ético que debe guiar su aplicación. La irrupción de los grandes modelos generativos y el aumento de las ventanas de contexto abren nuevas posibilidades para el tratamiento de datos tabulares, siempre que se tengan en cuenta las consideraciones éticas y de privacidad.

Este estado de la cuestión sienta las bases para las decisiones metodológicas que se detallan en el siguiente capítulo, orientado a la implementación práctica del pipeline de datos sobre las plataformas cloud seleccionadas.

Capítulo 3

Materiales y métodos

“El primer 90 % del código consume el primer 90 % del tiempo de desarrollo. El 10 % restante consume el otro 90 % del tiempo.”

— Tom Cargill, Laboratorios Bell

-

En este capítulo describimos el proceso que se ha seguido en la realización del trabajo. Empezamos por los materiales: las distintas tecnologías, lenguajes de programación, conjuntos de datos y herramientas utilizados, incluyendo algunos de los valorados en el *capítulo 2*, pero descartados, así como los motivos para ello. También se han definido los métodos de desarrollo y el modelo de trabajo utilizados durante el proyecto. Por último se explica cómo se puede utilizar la misma solución para replicar las conclusiones con estos u otros datos.

3.1. Materiales

En esta sección se detallarán los programas, nubes y conjuntos de datos específicos que se han utilizado o estudiado, así como los descartados en el trabajo.

3.1.1. Conjuntos de Datos

Los conjuntos empleados proceden del portal de datos abiertos del Ayuntamiento de Madrid (Ayuntamiento de Madrid, 2026b) ¹, bajo licencia “Creative Commons Attribution 4.0 (CC BY 4.0)”. La ingesta se realizó de forma

¹<https://datos.madrid.es/portal/site/egob>

automatizada, registrando los metadatos de procedencia de cada fichero en el archivo `code/files/data/bronze/_metadatos.csv`. La tabla 3.1 los resume.

Conjunto	Cobertura	Uso
Calidad del aire (diario)	2019-2025	Isla de calor
Meteorología (diario)	2019-2025	Isla de calor
Masas arbóreas / distrito	2019-2025	Isla de calor
Aforos de peatones	2019-2024	Movilidad (datos analizados sin ML)
Aforos de bicicletas	2019-2024	
Estaciones de control	único	Georreferencia
Distritos (shapefile)	único	Cartografía

Tabla 3.1: Conjuntos de datos utilizados, su procedencia es (Ayuntamiento de Madrid, 2026b).

Los datos comienzan en 2019 debido a la disponibilidad del portal. La red meteorológica municipal se puso en marcha en 2018 y no existen registros anteriores, lo que limita los análisis que involucran meteorología a estas fechas, como se recoge en el propio portal (Ayuntamiento de Madrid, 2026c). Además de esta, hay más limitaciones conocidas de estos conjuntos:

- Los aforos de peatones y bicicletas presentan un hueco de publicación de catorce meses (julio de 2021 a agosto de 2022) y alcanzan hasta junio de 2024.
- En la cobertura de la red, no todas las estaciones miden todas las magnitudes, lo que introduce valores nulos.
- Los conjuntos de aforos (bicicletas y peatones) cambiaron de esquema a mitad de serie (columnas renombradas, traducidas al inglés y con errores de codificación en origen).
- Los datos del arbolado emplean tres denominaciones distintas para la misma magnitud de superficie según el año de publicación. El portal publica para 2019 la magnitud *Superficie Masa Forestal*, pero a partir de 2020 cambia a *Superficie Masa Arbórea*. La segunda magnitud calcula la masa arbórea, mientras que la primera se extiende a más vegetación. Como consecuencia, la serie temporal de superficie arbórea no es estrictamente continua y se ha restringido la serie comparable a 2020-2025.
- El fichero de meteorología de 2024 no incluye diciembre, y la cobertura de la red municipal se degradó notablemente entre 2021 y 2022, coincidiendo con cambios y actualizaciones en los sistemas de información municipales.

3.1.2. Nubes

En esta sección se listarán como materiales las nubes y sus aplicaciones y tecnologías que se han utilizado para el desarrollo del proyecto, así como las que se valoraron y descartaron.

3.1.2.1. Amazon Web Services

Amazon Web Services (AWS) es la plataforma líder mundial en computación en la nube, que proporciona recursos escalables y flexibles de todo tipo, lo que ha permitido construir, desplegar y gestionar aplicaciones. Se utilizó AWS como primera nube, debido a su capa gratuita de 6 meses, su popularidad a nivel global y sus capacidades de IA con SageMaker. Los primeros pasos fueron realizar los tutoriales de la web, lo que permite contar con 100\$ extra para la capa gratuita.

Dentro de su catálogo, se emplearon los siguientes servicios gestionados como herramientas e infraestructura técnica:

- **Amazon S3 (Simple Storage Service)**: servicio de almacenamiento de objetos distribuido, altamente disponible y escalable.
- **AWS Glue (Python Shell)**: servicio de integración de datos y creación de procesos de “Extraction, Transform and Load” (ETL) gestionado y *serverless*. Se utilizó la modalidad *Python Shell*, un entorno de ejecución ligero que incluye de forma nativa librerías para ciencia de datos (**pandas**, **numpy**, **scikit-learn**).
- **AWS Glue Data Catalog**: catálogo de metadatos unificado y rastreadores automáticos encargados de descubrir e inferir esquemas sobre archivos estructurados.
- **AWS IAM (Identity and Access Management)**: servicio de gestión de identidades y accesos para la administración de usuarios, grupos y roles de servicio.
- **AWS CloudShell**: entorno de terminal Linux basado en navegador con acceso autenticado y la interfaz de línea de comandos (**AWS CLI**) preconfigurada sobre la región activa.
- **AWS Budgets y Cost Explorer**: herramientas de monitorización y control financiero para el seguimiento de costes mediante etiquetas de asignación.

3.1.2.2. Google Cloud Platform

Google Cloud Platform (GCP) es la plataforma de computación en la nube gestionada por Google, que ofrece servicios de infraestructura, almacenamiento, análisis y ML, entre muchos otros. Se seleccionó como segunda nube por su programa de créditos gratuitos (300 dólares durante 90 días) y por su enfoque en ML e IA. Los servicios empleados fueron los siguientes:

- **Cloud Storage:** almacenamiento de objetos equivalente a Amazon S3. Se utilizó para alojar las capas *bronze*, *silver* y los resultados, replicando la misma estructura de directorios que en local y en AWS.
- **Cloud Shell:** terminal Linux basada en navegador con la Consola de comando (CLI, Command line interface) de GCP preconfigurada, utilizada para la ingesta inicial, la gestión de recursos y la creación del manual de usuario.
- **Vertex AI Workbench:** entorno gestionado de *JupyterLab*, integrado en la plataforma *Gemini Enterprise Agent Platform*, que permite ejecutar cuadernos y scripts de Python en VM. Se empleó para las fases de limpieza y análisis, unificando ambos procesos en un mismo entorno interactivo y evitando la complejidad de configurar servicios ETL desatendidos.

Durante la fase de diseño se evaluaron también dos servicios *serverless* para el procesamiento ETL: **Cloud Run Jobs** y **Cloud Functions**. Ambos se descartaron tras varias pruebas debido a problemas en la configuración y los accesos. Cloud Run Jobs presentó problemas con la detección del punto de entrada en procesos que no son servicios web (error **Application exec likely failed**), y Cloud Functions, aunque se desplegó correctamente, introdujo discrepancias en la resolución de rutas relativas y en la inyección de variables de entorno, lo que obligaba a modificar el código fuente. Se priorizó la simplicidad y la reproducibilidad, optando por ejecutar todo en *Gemini Enterprise Agent Platform*, dentro de un *Vertex AI Workbench*.

3.1.2.3. Otras plataformas descartadas

Además de AWS y GCP, se consideraron otras plataformas en la nube:

- **Microsoft Azure:** ofrece servicios análogos a las nubes utilizadas (Azure Blob Storage, Azure Functions y Azure ML). Se descartó por acotar el alcance del proyecto y por su similitud con las nubes ya tratadas.
- **OVHcloud:** proveedor europeo con entornos interactivos gestionados para modelado (*AI Notebooks*). Hubiera sido una opción interesante

debido a su localización europea y novedad, pero debido a su menor capa gratuita y variedad de servicios, se decidió dejar fuera de alcance como trabajo futuro.

3.1.3. Recursos para el desarrollo

3.1.3.1. Lenguajes

Los principales lenguajes utilizados para el desarrollo del proyecto han sido los siguientes:

- **Python:** lenguaje de programación interpretado, multiparadigma y centrado en la legibilidad del código. Se ha elegido como lenguaje principal por ser el estándar en ciencia de datos, dada su extensa comunidad y el amplio ecosistema de librerías orientadas al ML (detalladas en el apartado *Librerías especializadas*). Además, su alta adopción garantiza un soporte nativo en todas las nubes, facilitando la portabilidad del código, el despliegue de los modelos y la comparación de procesos entre plataformas.
- **Bash Script:** la interacción con las nubes se ha gestionado principalmente mediante la ejecución de *scripts* de Bash en AWS CloudShell y Google Cloud Shell, así como en local. De hecho, estos scripts son los que componen el manual de usuario para asegurar la reproducibilidad y automatizan la ejecución de los procesos (AWS Glue y demás scripts) y la creación de recursos (buckets, roles IAM, instancias, archivos, etc.). También se emplearon para la preparación de entornos virtuales y la instalación de dependencias.

También se planteó el uso de lenguajes como Javascript para la extracción de datos en diferentes páginas web, el uso de “Dockerfile” para la creación de contenedores en los entornos, o el uso de SQL para la explotación de los datos tabulares en entornos de bases de datos, pero finalmente fueron descartados.

Librerías especializadas

Para el tratamiento y modelado de la información en Python, se ha hecho uso de las siguientes librerías, agrupadas por función:

- **Análisis de datos:**
 - **Pandas:** para la limpieza, transformación y manipulación de los datos tabulares y estructuras *DataFrame* en memoria (The pandas development team, 2026).

- **NumPy**: para operaciones vectoriales y manejo de arrays numéricos, además de ser utilizado como base para muchas de las otras librerías que requieren de estas capacidades (NumPy developers, 2026).
 - **GeoPandas**: para el análisis de datos geoespaciales, empleada para las operaciones espaciales (*spatial joins*) y el cruce geométrico entre los puntos geográficos de las estaciones y los polígonos de los distritos de Madrid (GeoPandas developers, 2026).
- **Acceso a datos y almacenamiento en la nube:**
- **Requests**: para la comunicación web, específicamente la API REST de CKAN que permite la ingesta automatizada de datos desde el portal del Ayuntamiento de Madrid (Requests project, 2026).
 - **fsspec, s3fs y gcsfs**: interfaces para sistemas de archivos, tanto locales como en la nube, todas basadas en **fsspec** (fsspec developers, 2026). Unifica escrituras en disco local, en AWS o en GCP sin modificaciones de código, permitiendo mayor portabilidad.
- **Gestión de formatos de archivo:**
- **openpyxl**: para la lectura de archivos Excel (**.xlsx**) para los conjuntos de datos que se publican en ese formato (openpyxl developers, 2026).
 - **pyarrow**: para la lectura y escritura eficiente en formato **Parquet**, que se utiliza como formato de salida de la capa *silver* junto con CSV, para intentar mejorar el rendimiento en entornos cloud (Apache Software Foundation, 2026).
- **Otras: gráficos, ML y estadística:**
- **Matplotlib**: utilizada para la creación y visualización de todos los gráficos de resultados: diagramas del codo, dendrogramas de agrupamiento, gráficos de dispersión y mapas de cobertura temporal (The Matplotlib development team, 2026).
 - **SciPy y Scikit-learn**: para la implementación de algoritmos de ML (K-Means, agrupamiento jerárquico de Ward), estandarización de variables, cálculo de *clusters* y métricas de validación como el coeficiente de silueta (The SciPy community, 2026; scikit-learn developers, 2026).

3.1.3.2. Herramientas de desarrollo

Las siguientes herramientas y programas han sido esenciales para la elaboración del proyecto:

- **Visual Studio Code:** editor de código abierto desarrollado por Microsoft. Se ha utilizado como entorno de desarrollo por la gran comunidad que tiene detrás, la cual mantiene extensiones y tutoriales al día. Incluye soporte para la depuración, control integrado de Git, resaltado de sintaxis, finalización inteligente de código, fragmentos y refactorización de código, entre muchas otras funciones.
- **Git y GitHub:** GitHub es una plataforma para alojar proyectos utilizando el sistema de control de versiones Git, que se utiliza principalmente para la creación, almacenamiento y control de código fuente. El repositorio de este proyecto es: <https://github.com/crismo04/TFM-cloud-solutions-to-public-data/>. Sigue las recomendaciones de buenas prácticas de GitHub e incluye archivos como el `changelog` para poder ver los cambios y el `README.md` para resumir el proyecto. Además, se han usado varias herramientas como extensiones de VSCo-de para la gestión de repositorios y GitHub Desktop.
- **CLIs de nube (AWS CLI y Google Cloud CLI):** interfaces de línea de comandos que permiten interactuar con los servicios de AWS y GCP. Se utilizaron desde CloudShell y desde entornos locales para todo tipo de tareas.
- **L^AT_EX con TeXstudio:** se ha usado L^AT_EX para desarrollar este documento en la aplicación TeXstudio, así como para tomar las notas del proyecto.
- **Trello:** herramienta de gestión de proyectos basada en tableros Kanban que se empleó para la planificación y priorización de tareas y el seguimiento del progreso de las mismas a lo largo del desarrollo del trabajo.

3.2. Métodos

Para llegar al objetivo de diseño, se dividió la implementación en diferentes módulos conceptuales:

- **Búsqueda y almacenamiento de datos:** localización de fuentes públicas, captura de sus metadatos y elección del mecanismo de descarga y almacenamiento.

- **Tratamiento básico de los datos:** una vez almacenados, se procede a la depuración, resolución de inconsistencias, gestión de valores nulos, duplicados o atípicos y estandarización de esquemas. Las modificaciones se documentaron para poder ser replicadas.
- **Estudio con modelos de IA en diferentes nubes:** con los datos tratados, se pasa a la elección de modelos algorítmicos y extracción de patrones y clústeres a partir de estos datos para extraer conclusiones.
- **Comparación y estudio de resultados:** tras el análisis se procedió a la revisión de las hipótesis iniciales y las extraídas de los modelos para el contraste de los resultados frente a los datos o trabajos de referencia.
- **Revisión, automatización y generalización:** una vez finalizado el proceso, se refinó con un análisis de mejoras y costes para automatizar siguientes iteraciones y mejorar tanto en las siguientes iteraciones, como abaratar el proceso en recursos y tiempo.

Estos módulos se materializaron en el *pipeline* que se describe en la *Sección 3.2.2*. Para llegar a la solución, se han seguido las buenas prácticas del tratamiento de los datos, así como las de MLOps y las recomendadas por cada una de las nubes utilizadas. Estos conjuntos de buenas prácticas se detallan más adelante en este mismo capítulo.

Para empezar las primeras iteraciones, se optó por conjuntos de datos que ya habían sido estudiados previamente y disponían de algunas conclusiones públicas. Estos son los trabajos de “**Madrid, isla de calor**” (Meneses Vicente y García Ruíz, 2023) principalmente y, en menor medida, “**Análisis de datos de la ciudad de Madrid**” (Santos, 2023), compañeros de la UCM que trataron datos públicos del Ayuntamiento de Madrid y extrajeron conclusiones. Como primera toma de contacto, se replicaron las conclusiones del primer trabajo y se extendió el análisis a años posteriores, complementando así el estudio. En cuanto al segundo trabajo, se estudiaron y procesaron los datos, añadiendo datos de bicicletas para complementar, pero no se llegó a analizar con los modelos de ML que el trabajo detalla.

El detalle de los conjuntos se recoge en la *Sección 3.1.1*.

3.2.1. Marco metodológico

Este trabajo no propuso una metodología desde cero. Cada pieza del problema cuenta ya con un marco consolidado: la arquitectura de medalla [*Definición 11*] para la organización del dato, el modelo de tres capas de la OECD (OECD, 2019) para la gobernanza, las prácticas de MLOps (Kreuzberger et al., 2023) para la trazabilidad del análisis, los marcos de buenas prácticas de cada proveedor (Amazon Web Services, 2026a; Google Cloud, 2026b) para

el diseño en la nube y el marco normativo europeo para acotar qué datos y qué modelos son adecuados. Lo que se propuso fue la unión de todos ellos. El escenario es el de la reutilización automatizada de datos públicos sobre varias fuentes y sin presupuesto de infraestructura. Esa unión se dividió en cinco principios de diseño, independientes del dominio y transversales a todas las etapas:

1. **Portabilidad y abstracción del almacenamiento de datos:** el destino de la escritura se definió como un parámetro de configuración, de modo que la ejecución entre entornos fuera una comparación real.
2. **Configuración declarativa por patrón:** las reglas se declararon por tipo de fichero y no por conjunto de datos. Así, incorporar una fuente nueva que encaje en un patrón conocido no requiere modificaciones y facilita la ampliación del proyecto.
3. **Replicar antes de extender:** el proceso reprodujo las condiciones del trabajo de referencia, lo que permitió atribuir las diferencias observadas al criterio introducido y no al cambio de herramienta o de periodo. Esto solo se aplicó a los datos con estudio anterior.
4. **Ingesta como auditoría:** el proceso no solo descargó los datos, sino que registró metadatos de procedencia y calidad. Esto convirtió la automatización en una herramienta de evaluación del portal que los publica.
5. **El coste nulo como restricción de diseño:** la elección de servicios se basó en las capas gratuitas, de modo que cualquiera pueda replicarlo, dimensionando cada etapa al volumen del problema.

3.2.2. Desarrollo de la solución

Esta es la sección más extensa, ya que explica el proceso que se ha seguido para ingestar, procesar y analizar estos datos de forma automática, mientras que el resto de las secciones de datos, nube y ML se centran en las partes específicas de estas tecnologías. Para llevar a cabo el trabajo se creó un conjunto de procesos en Python que implementa los pasos del desarrollo, configurados por un único fichero `config.py`. El *pipeline* se ejecutó primero íntegramente en local con un doble propósito: validar la replicación de los trabajos originales en un entorno controlado antes de introducir la variable de la nube, y establecer una línea base para comparar posteriormente con las implementaciones en cada nube en términos de esfuerzo, tiempo de ejecución y coste. Se describen a continuación sus etapas, siguiendo el orden de los módulos.

Las fases y sus ficheros correspondientes en local y en el repositorio Git del proyecto han sido los mostrados en la tabla 3.2:

Fichero	Etapas	Salida
config.py	Parametrización	—
01_descarga.py	Ingesta automatizada de datos	Capa bronce
02_limpieza.py	Normalización y limpieza	Capa plata
03_analisis_isla_calor.py	Análisis y modelado	Resultados

Tabla 3.2: Correspondencia entre los procesos del *pipeline* y las etapas de la arquitectura de medalla ([Definición 11]).

Estas etapas se describen en más detalle a continuación.

3.2.2.1. Ingesta automatizada de datos

La descarga se estudió primero como descarga manual en los portales, pero se implementó como un proceso programático y reproducible para mayor facilidad a la hora de replicar resultados. El portal opera sobre la plataforma CKAN (Open Knowledge Foundation, 2026b) (API REST), versión 2.9.11, que está dos ramas por detrás de la versión estable disponible en el momento de redactar este trabajo, lo que ya es un dato sobre el mantenimiento de la infraestructura de publicación de estos datos. Sobre esta plataforma, el proceso resuelve el identificador de cada conjunto y consulta sus recursos mediante la acción `package_show`, como se muestra en la guía (Open Knowledge Foundation, 2026a). Esta automatización tuvo sus complicaciones.

El portal del Ayuntamiento y su API de descarga ², pese a declarar sus datos como abiertos, presenta dificultades en la automatización de la descarga, ya que incorpora protección anti-bot que penaliza descargas sucesivas, y su interfaz JavaScript no expone los enlaces en el HTML inicial. Para solucionarlo, el proceso incorpora pausas entre descargas y reintentos con espera creciente. Esta fricción entre la apertura que se supone que hay y la que realmente se aplica ilustra en la práctica las limitaciones en el estado real de los datos abiertos señaladas en el estado de la cuestión (Verhulst et al., 2020; OECD, 2023).

De todas formas, el proceso aporta tres propiedades relevantes para la gobernanza del dato: es **idempotente** (re-ejecutarlo no vuelve a descargar lo ya presente, permitiendo automatización periódica), registra **metadatos** de procedencia por fichero (origen, fecha, tamaño y licencia) y **abstrae el almacenamiento** mediante `fsspec` (fsspec developers, 2026), de modo que el mismo código escribe en local o en las nubes evaluadas sin cambios en su lógica. Además, los datos se organizan siguiendo el modelo *medallion*: la capa *bronze* almacena los datos en crudo, la capa *silver* contiene los datos

²API utilizada en la descarga de datos en el fichero `01_descarga.py`: `https://datos.madrid.es/api/3/action`

limpios y normalizados, y la capa *gold* (denominada *resultados* en el código) guarda los productos del análisis.

3.2.2.2. Normalización y limpieza

La limpieza se organizó por tipos de fichero en lugar de por conjunto aislado para facilitar la incorporación de ficheros similares. Los ocho conjuntos estudiados se reducen a cuatro patrones: series mensuales con columnas de validación, aforos horarios, tablas anuales y ficheros únicos. Las reglas para tratar estos ficheros se han declarado en el archivo de configuración y basta modificarlo para añadir más tipos de datos.

Para las series de calidad del aire y meteorología se replicó la lógica del trabajo original (Meneses Vicente y García Ruíz, 2023), donde solo se aceptaron valores marcados como verificados por el portal y se descartaron las fechas imposibles del formato mensual. El proceso tuvo que resolver varios problemas con los datos:

- **Formatos de fecha variables:** un mismo conjunto (aforos) presenta fechas en formato `dd/mm/yyyy` en unos años y `yyyy-mm-dd` en otros. Se implementó una función de detección automática del formato que prueba patrones y selecciona el que mejor convierte (`_parse_fechas`).
- **Decimales con coma:** los ficheros originales, al estar generados en entorno español, utilizan la coma como separador decimal y el punto como separador de miles. La función `_convertir_decimales` estandariza estos valores reemplazando comas por puntos y eliminando puntos de miles antes de la conversión a numérico.
- **Cambios de esquema en una misma serie:** en los aforos, las columnas cambiaron de nombre: `DIRECCION` → `NOMBRE_VIAL`, `LATITUDE` → `LATITUD`, además de campos que se tradujeron al inglés y aparecieron errores tipográficos: `NAOMERO_DISTrito` → `NUMERO_DISTrito`. El proceso de limpieza renombra estas columnas de forma unificada mediante un diccionario de mapeo, ya que estos cambios son difíciles de automatizar.
- **Nombres de entidades inconsistentes:** los distritos aparecen escritos de forma diferente dentro de un mismo fichero (`San Blas-Canillejas` → `San Blas - Canillejas`), o combinando nombres con tildes y sin ellas. En la limpieza se aplica una normalización que elimina tildes, convierte a mayúsculas y unifica los guiones.
- **Filas de totales y notas al pie:** los archivos CSV de arbolado anuales (2020–2022) incluyen filas con textos como “NOTA” o “TOTALES” destinadas a la lectura humana. La función `_quitar_filas_basura` las

identifica y elimina antes del procesamiento, ya que romperían cualquier automatismo.

Todas estas transformaciones quedaron registradas en el código publicado para garantizar su reproducibilidad.

3.2.2.3. Análisis y modelado

Sobre los datos limpios se implementó un módulo de análisis por cada caso de estudio, aplicando tanto las mismas técnicas que los trabajos de referencia, como técnicas propias que se detallan a continuación.

Para el trabajo de movilidad peatonal (Santos, 2023) se intentó replicar la predicción de series temporales con los datos ya tratados de peatones que tenía el estudio, añadiendo además los datos de bicicletas, los cuales parecían interesantes para ampliar las conclusiones, pero finalmente se sacó del alcance, quedando como línea de trabajo futuro.

En cambio, para el trabajo de la isla de calor (Meneses Vicente y García Ruíz, 2023), se replicaron las cinco aproximaciones de agrupamiento del trabajo original:

1. **Siete magnitudes meteorológicas:** velocidad y dirección del viento, temperatura, humedad relativa, presión barométrica, radiación solar y precipitación, sobre las estaciones que miden todas ellas.
2. **Temperatura y humedad relativa:** sobre las estaciones que disponen de ambas magnitudes.
3. **Temperatura y superficie arbórea:** sobre las estaciones con temperatura cuyo distrito publica datos de masas arbóreas. El trabajo original denomina a esta aproximación como “temperatura”, pero en realidad combina ambas variables (temperatura y superficie arbórea).
4. **Dióxido de nitrógeno (NO_2):** sobre todas las estaciones de la red de calidad del aire.
5. **Dióxido de nitrógeno y partículas:** NO_2 , $\text{PM}_{2.5}$ y PM_{10} , sobre las estaciones que miden las tres.

Sobre la media anual de cada estación estandarizada, se aplicó *k-means* y agrupamiento jerárquico de *Ward*, conservando el número de grupos y la semilla que se escogió en el trabajo original, de modo que las diferencias observadas se pudieran atribuir a los datos. Para fijar el número de grupos se utilizó el método del codo, al igual que en el estudio original, para representar la inercia (suma de distancias cuadráticas al centroide) del número de grupos considerado, localizando el punto a partir del cual deja de descender

de forma apreciable. Para la calidad de los agrupamientos se validó con el coeficiente de silueta, que se comenta más adelante, y también se incorporó un cruce geoespacial entre las estaciones y los distritos mediante el *shapefile* municipal para contrastar la hipótesis de relación entre superficie arbórea y temperatura.

Para facilitar la lectura de la prueba, se creó un resumen automático entre años que tabula las métricas de las ejecuciones y señala valores que se desvían, que sale tanto por pantalla como en el archivo:

`code/files/data/resultados/ejecucion.log`.

Para que la réplica funcionara correctamente y poder comparar con los resultados obtenidos, se han tenido que resolver algunas discrepancias entre la ejecución y la descripción del trabajo original:

- **Variable real de temperatura:** como ya se ha dicho, el trabajo original denomina a la tercera aproximación como “temperatura”, pero en realidad combina la temperatura de la estación con la superficie arbórea del distrito donde se ubica. Ambas variables residen en conjuntos distintos (meteorología diaria y masas arbóreas anuales) y con granularidad diferente (estación-día frente a distrito-año). Para resolverlo, se implementó un cruce geoespacial que asigna cada estación a su distrito mediante un *shapefile* municipal, y se incorporó la variable externa `superficie_ha` en el agrupamiento.
- **Criterio de selección de estaciones con superficie arbórea:** el trabajo original declara que selecciona las estaciones que “disponen de datos de masas arbóreas”, lo que en la práctica excluye a los distritos que publican una superficie de cero hectáreas. Esta interpretación se ha replicado. Sin embargo, en el análisis de correlación *Sección 4.2.2* se optó por conservar los distritos con superficie 0.

Para evaluar la réplica, se utilizó un índice de Rand por pares. Dado un conjunto de n estaciones comunes entre el trabajo original y la réplica, se consideran todos los $\frac{n(n-1)}{2}$ pares posibles. Para cada par de estaciones (A, B) , se verifica si ambos trabajos las clasifican en el mismo grupo o en grupos distintos (independientemente de la etiqueta numérica del grupo). El porcentaje de acuerdo se calcula como:

$$\text{Acuerdo} = \frac{\text{Nmero de pares en los que ambos trabajos coinciden}}{\text{Nmero total de pares}} \times 100$$

Este criterio evita el problema de que las etiquetas de grupo son arbitrarias y no tienen por qué coincidir entre dos ejecuciones.

Estos resultados de la réplica, lo más parecida posible al trabajo original, se guardan en la carpeta `code/files/data/resultados/isla_calor/replica`.

Para los cambios realizados como mejora metodológica y para extender las conclusiones, se añadieron dos aproximaciones y varias mejoras que se guardaron en la carpeta `code/files/data/resultados/isla_calor/propio`, ambas carpetas están en el repositorio de GitHub del proyecto y se controlan mediante el parámetro `MODULO_REPLICA` en la configuración.

A continuación se enumeran los cambios realizados para esta extensión:

1. **Dos nuevas aproximaciones:** tras estudiar la réplica y sus limitaciones, se decidió añadir dos nuevas aproximaciones:
 - **Temperatura y altitud:** incorpora la altitud de la estación como variable externa para evaluar el efecto de la orografía en los datos, ya que estaciones en el norte de Madrid pueden diferir de algunas como Vallecas por su altitud.
 - **Temperatura y superficie relativa:** utiliza la superficie arbórea dividida por el área total del distrito, en lugar del valor absoluto que publica el Ayuntamiento de Madrid, para controlar así el tamaño del distrito.
2. **Criterio de cobertura mínima:** la media anual de una estación solo se considera válida si supera un número mínimo de días con dato (configurable mediante `MIN_DIAS_ANIO` en `config.py`), ya que una estación que operó únicamente durante una pequeña parte del año produce una media sesgada hacia la estación climática en que estuvo activa. El valor por defecto es de 300 días como mínimo.
3. **Validación con coeficiente de silueta:** se calcula sistemáticamente para cada aproximación y año, midiendo en qué grado cada observación está más próxima a su propio grupo que al vecino más cercano. Esto permite comparar, independientemente de la escala, la calidad de los agrupamientos entre años, aproximaciones y plataformas (detalle en *Sección 3.2.4*).
4. **Variables dependientes del año:** los casos ya comentados de *Superficie Masa Forestal* $\rightarrow$ *Superficie Masa Arbórea* o variables que tenían errores en algunos años han requerido una limpieza que, lógicamente, en el trabajo original no era necesaria al contar con un único año.

3.2.3. Aplicados a Datos

Para tratar los datos del proyecto, se han seguido principios éticos y los principios de gobernanza de datos.

3.2.3.1. Aplicación de la gobernanza de datos como método

Como ya se introdujo en la *Sección 2.1.4: Estudios de datos y gobernanza*, la gobernanza de datos en este proyecto se implementó adoptando el modelo de tres capas (estratégica, táctica y operativa o de entrega) ³. El objetivo fue garantizar que el proceso de análisis, adquisición y almacenamiento de datos públicos, y la obtención de valor mediante IA, se ha realizado de forma ética, segura y en pleno cumplimiento del marco regulatorio actual. Aunque las tres capas cobran mayor importancia en proyectos grandes con múltiples equipos, se han adaptado a este trabajo por la estructura metodológica que proponen y la utilidad en la gestión de datos y procesos.

1. **Capa estratégica: liderazgo y visión.** En esta capa se definen los objetivos generales y principios de la gobernanza de datos en el proyecto:

- **Visión:** convertir los datos abiertos en generadores de conocimiento mediante técnicas de IA y tecnologías cloud.
- **Seguridad y soberanía:** aunque se utilizan servicios de nubes públicas por su acceso gratuito y capacidades en IA, se configuraron para operar dentro de la UE.
- **Transparencia y reproducibilidad:** todo el proceso (origen de datos, transformaciones, código y resultados de modelos) se documentó en esta memoria para garantizar la transparencia y la posibilidad de auditar o reproducir el análisis, de acuerdo con los principios de la Unión Europea: *ver Sección 3.2.3.2.*

2. **Capa táctica: capacidades de implementación y marco normativo.** Esta capa detalla cómo se implementa la estrategia a través de políticas, procesos, directrices, etc:

- **Uso del dato:** se priorizaron datos públicos abiertos de administraciones españolas, prestando especial atención a las licencias para asegurar la legalidad de su reutilización y evitando el uso de datos sensibles. Respecto a datos sensibles se aplicó un principio de precaución: cualquier conjunto de datos con riesgo de contener información sensible fue filtrado y descartado.
- **Gestión de accesos y credenciales:** como único usuario, se gestionan las credenciales de acceso a los servicios cloud con el máximo nivel de seguridad, evitando su filtración a repositorios públicos o terceros.

³no confundir con las capas de la arquitectura medallón

- **Competencias y coordinación:** todas las funciones fueron asumidas por un único investigador, lo que centralizó la toma de decisiones y facilitó el cumplimiento normativo y la trazabilidad de todo el proceso. De todas formas, se utilizan herramientas como Git o Trello para auto-organizarse.
 - **Selección de proveedores y servicios:** para la selección de plataformas cloud se evaluó la capacidad para proporcionar entornos de procesamiento seguro y la localización de sus centros de datos para asegurar el cumplimiento normativo. En cuanto a la IA, también se revisaron sesgos en los datos de entrenamiento.
3. **Capa operativa: infraestructura, integración del ciclo de valor y arquitectura.** Esta última capa corresponde a la implementación práctica de la estrategia, la gestión diaria del ciclo de valor de los datos para integrarlo con la infraestructura técnica:
- **Infraestructura:** se emplearon servicios en la nube principalmente para el almacenamiento, procesamiento y análisis de los datos. Los entornos se han configurado con los mecanismos de seguridad correspondientes. Aunque una de las ideas de este proyecto es el tratamiento de datos con el menor número de recursos posibles, también se usaron dispositivos *on-premise* (equipo personal) para la ingesta de datos y pruebas base, para su posterior almacenamiento en cloud.
 - **Arquitectura de datos y ciclo de valor:** se diseñó un flujo simple de trabajo centrado en cloud y basado en la ingesta de datos abiertos de fuentes oficiales que cubrió todo el ciclo de vida del dato:
 - **Adquisición:** se descargaron conjuntos de datos abiertos, registrando metadatos sobre origen, licencia, calidad, formato y condiciones de uso.
 - **Almacenamiento y gestión:** se organizaron en *buckets* con estructura clara siguiendo la arquitectura de medalla [Definición 11]. Este enfoque facilitó la exploración, el modelado y la generación de valor con herramientas nativas como SageMaker. El almacenaje depende de la herramienta propietaria de cada nube (S3 para Amazon, Cloud Storage para GCP, etc.).
 - **Procesamiento y transformación:** se realizó la limpieza y estandarización de los datos descargados, descartando fuentes sensibles. Se realizó *feature engineering* en entornos gestionados nativos en la nube, como Vertex AI Workbench, como se

detalla en la parte de prácticas de MLOps.

- **Uso/compartición:** se utilizaron diversas técnicas de IA para la identificación de patrones en los datos y se han publicado los resultados bajo licencias abiertas, priorizando la transparencia.
- **Optimización y sostenibilidad:** se monitorizó el uso de recursos en las diferentes nubes para mantener el proyecto dentro del coste cero. También se optimizaron las configuraciones de los servicios para asegurar la eficiencia tanto económica como ecológica del proyecto.

3.2.3.2. Principios éticos

Destacar también que en el proyecto se siguieron rigurosamente los siete principios éticos de la IA definidos por el reglamento de la Unión Europea (Unión Europea, 2024a, 2026):

- **Acción y supervisión humanas:** en este trabajo se supervisó tanto cada etapa del desarrollo como los resultados. Se descartaron aquellos que no cumplieran con los criterios éticos establecidos.
- **Solidez técnica y seguridad:** se veló por la mayor excelencia técnica y se definieron principios de seguridad tanto para los datos como para los modelos.
- **Gestión de la privacidad y de los datos:** se ha abordado todo el proyecto cumpliendo con los principios del RGPD, como se indica en la sección de datos.
- **Transparencia:** se documentaron los procesos, algoritmos utilizados y decisiones tomadas durante el desarrollo para asegurar que el proceso fuera comprensible y reproducible. También se documentaron los casos en los que se recurrió a la IA, indicando claramente las razones para ello, y cumpliendo con la declaración responsable sobre autoría y uso ético de herramientas de IA de la UCM. Los usos se detallan en el *apéndice B*.
- **Diversidad, no discriminación y equidad:** se comprobaron los sesgos de los datos y algoritmos utilizados, decisiones tomadas y resultados obtenidos, con el objetivo de identificar y mitigar potenciales discriminaciones o sesgos.
- **Bienestar social y ambiental:** el motivo último de este trabajo es el procesamiento de datos públicos para mejorar el valor de los mismos y, mediante su aplicación, el bienestar social en general.

- **Rendición de cuentas:** se mantuvo un registro detallado de las decisiones de diseño, preprocesamiento de datos y selección de modelos para permitir una auditoría clara y una rendición de cuentas transparente.

3.2.4. Aplicados a Aprendizaje Automático

Los fundamentos teóricos de los algoritmos y métricas empleados (K-Means, agrupamiento jerárquico de Ward, coeficiente de silueta y correlación de Pearson) se definieron en el *Capítulo 2.3* y sus definiciones. En esta sección se detallan los pasos del procesamiento, las técnicas empleadas y las métricas de validación que se llevaron a cabo tras la normalización de los datos, basadas en técnicas de aprendizaje no supervisado y estadística.

3.2.4.1. Preprocesamiento y construcción de características

Para cada año y aproximación, los datos diarios se agregaron calculando la media anual por estación para cada magnitud. Antes del agrupamiento, se aplicaron dos filtros ya explicados: el de cobertura mínima (300 días en el modo propio) y el de completitud de variables (eliminación de nulos). Posteriormente, todas las variables métricas se estandarizaron mediante `StandardScaler` (media nula y varianza unitaria) para evitar que magnitudes con escalas absolutas mayores dominen sobre otras de menor escala.

Además, en las aproximaciones que incluyen variables externas (altitud, superficie arbórea absoluta y superficie relativa), estas se añadieron al conjunto de características de cada estación. El procedimiento de cruce geoespacial y cálculo de la superficie relativa se detalló en el apartado de preprocesamiento. Para las variables que dependen del distrito, se asignó a cada estación el valor correspondiente mediante un cruce geoespacial (*spatial join*) con el *shapefile* de distritos, utilizando la librería `GeoPandas`. Este paso es común a los modos réplica y propio, y está implementado en la función `_estaciones_con_distrito()`.

3.2.4.2. Algoritmos de agrupamiento

Sobre la matriz de medias anuales estandarizadas se ejecutaron dos algoritmos de agrupamiento:

- **K-Means:** con un número de grupos fijo k (especificado para cada aproximación) y semilla aleatoria `random_state=100`, para garantizar la reproducibilidad y mantener la comparabilidad con el trabajo original. El número de iteraciones se fijó en 25.

- **Agrupamiento jerárquico de Ward:** se aplicó como método de validación cruzada, utilizando la distancia euclídea y el criterio de Ward, que minimiza la varianza intra-grupo en cada fusión. Los resultados se visualizan mediante dendrogramas, donde las hojas se etiquetan con el nombre de cada estación.

Ambos algoritmos se aplicaron para cada una de las siete aproximaciones (las cinco originales más las dos nuevas) y para cada año del rango temporal, aunque la réplica solo se aplica a 2021.

3.2.4.3. Métricas de validación y evaluación

Para evaluar la calidad de los agrupamientos y la robustez de los resultados se emplearon tres métricas:

- **Coeficiente de silueta:** se calculó para cada aproximación y año a partir de los resultados de K-Means. Su valor (entre -1 y 1) indica el grado de separación entre grupos y la cohesión interna, lo que permite comparar las distintas aproximaciones de forma independiente a la escala de las variables.
- **Comparación K-Means vs Ward:** para cada año y aproximación, se compararon las etiquetas asignadas por ambos algoritmos, verificando que producen particiones similares. Esta comprobación no estaba presente en el trabajo original y se introduce como medida de robustez.
- **Coeficiente de correlación de Pearson:** se empleó para evaluar relaciones lineales entre pares de magnitudes meteorológicas (temperatura vs humedad relativa, precipitación vs radiación solar) por estación, y para cuantificar la relación entre la temperatura media por distrito y la superficie arbórea (absoluta y relativa), como parte del análisis de arbolado.

Además, para cada aproximación se generó el diagrama del codo, que representa la inercia de K-Means para $k = 1, \dots, 10$, como herramienta de diagnóstico para confirmar la elección del número de grupos.

3.2.4.4. Prácticas de MLOps y DevOps

Además de los métodos comentados, todo el proceso de análisis se acompañó de prácticas de MLOps (incluidas las presentes en DevOps general) para garantizar la trazabilidad y reproducibilidad de los resultados:

- **Versionado de código:** el código fuente se gestiona con Git y se aloja en un repositorio público de GitHub.

- **Versionado de datos:** la capa *bronze* es inmutable y las capas posteriores se generan de forma reproducible.
- **Registro de experimentos:** cada ejecución genera un fichero de log (`ejecucion.log`) que registra los parámetros en ambos modos (réplica o propio): cobertura mínima, años procesados, y las métricas de salida (silueta y correlaciones). Las figuras y tablas de resultados se almacenan en carpetas organizadas por año y aproximación.
- **Infraestructura como código (IaC):** los roles y trabajos de AWS Glue, así como la instancia de Vertex AI Workbench, se definen mediante comandos CLI y plantillas, facilitando el despliegue en distintos entornos.

3.2.5. Aplicados a la Nube

El despliegue de las capas de almacenamiento, procesamiento y analítica sobre plataformas en la nube se ha abordado bajo una metodología común para evaluar la dificultad de implementación, viabilidad, rendimiento y coste de ejecutar un mismo *pipeline* de datos abiertos sobre diferentes proveedores. Esta estrategia reutiliza el enfoque de arquitectura por capas (*medallion architecture*) definido en la [Definición 11], el mismo explicado en datos y local. Se combinará con las buenas prácticas específicas de diseño y gobernanza generales del desarrollo en la nube y las específicas de cada proveedor, por lo que las siguientes secciones se centrarán en estas partes específicas únicamente.

3.2.5.1. Específicos de Amazon Web Services (AWS)

La especificación técnica paso a paso, la sintaxis completa de los comandos ejecutados en la CLI y el procedimiento de despliegue reproducible de cada uno de estos métodos se detallan en el manual de usuario disponible en la Sección 5.2. Aquí se define una arquitectura más a alto nivel de las decisiones tomadas, así como los métodos utilizados, pero se puede consultar todo el manual de arquitectura y buenas prácticas en la web de AWS (Amazon Web Services, 2026a).

1. **Arquitectura de medalla:** para las capas, se aplicó un bloqueo de acceso público para evitar la modificación externa, se activó el versionado para asegurar la inmutabilidad y trazabilidad, y se asignaron etiquetas (*labels*) para poder medir el coste en todas las capas del proceso.
2. **Procesamiento ETL serverless de bajo cómputo:** como método de transformación, se descartó el uso de clústeres distribuidos (*Apache*

Spark) debido a que el volumen de datos (272 MB en la capa bronce) no requería demasiada computación. Se optó por una ejecución mediante *AWS Glue Python Shell* y la propia *AWS CLI*, garantizando tiempos de arranque inmediatos y un consumo mucho menor por ejecución, gestionando el almacenamiento desde los contenedores de S3.

3. **Infraestructura como código (IaC) y gestión de dependencias:** para garantizar la reproducibilidad, el despliegue del trabajo ETL se definió de forma declarativa mediante comandos y plantillas JSON definidas en el manual 5.2. Los módulos propios de configuración (`config.py`) se empaquetaron en formato estándar de distribución de Python (*wheel*, `.whl`) para gestionar las dependencias junto al *requirements.txt*.
4. **Gobernanza de identidades (RBAC) y control financiero (*FinOps*):** implementación del principio de menor privilegio y control de costes mediante:
 - **Uso de credenciales temporales:** se utilizó *AWS CloudShell* para operar con las credenciales de la sesión web, evitando el almacenamiento de claves fijas (*Access Keys*) en local.
 - **Permisos para servicios:** se definieron roles IAM de servicio (`AWSGlueServiceRole-tfm`) con acceso restringido exclusivamente a las rutas necesarias de S3 para el procesamiento en *AWS Glue*.
 - **Control de gasto:** se desactivaron los reintentos automáticos (`max-retries 0`) y se establecieron tiempos máximos de ejecución en los trabajos de *AWS Glue*, además de la monitorización de gastos mediante *AWS Budgets*.

Se valoró el empleo de los modelos pre-entrenados de *AWS SageMaker*, pero se descartaron por ser una solución sobredimensionada para este problema. El conjunto de análisis está formado por unas pocas decenas de observaciones con menos de diez variables, un tamaño para el que los algoritmos de agrupamiento clásicos resultan más apropiados.

3.2.5.2. Específicos de Google Cloud Platform (GCP)

Al igual que en la sección anterior, la especificación técnica paso a paso y el procedimiento de despliegue por comandos de cada uno de estos métodos se detallan en el manual de usuario disponible en la *Sección 5.3*. La arquitectura general se rige también por las directrices y buenas prácticas de GCP (Google Cloud, 2026b), aplicando en concreto las siguientes decisiones de diseño:

1. **Arquitectura de medalla en Cloud Storage:** las capas se almacenaron en un contenedor (*bucket*) de Google Cloud Storage. Se aplicó la política *Public Access Prevention* de forma nativa para evitar la modificación externa de los ficheros, y se habilitó también el versionado y el etiquetado de recursos.
 2. **Servicios para el procesamiento ETL descartados:** para la fase de transformación se analizaron dos opciones, que se descartaron tras las pruebas iniciales.
 - **Cloud Run Jobs:** servicio para ejecutar procesos bajo demanda. Se preparó un fichero `Procfile` con la instrucción de arranque (`python3 02_limpieza.py`) y un `.gcloudignore` para excluir archivos locales. Sin embargo, surgió un problema relacionado con la detección del punto de entrada en procesos que no son servicios web: no se resolvía el comando de arranque para este tipo de tareas, y tras varias horas de intento no se logró un arranque exitoso.
 - **Cloud Functions:** como alternativa, se desplegó una función con el script original mediante `subprocess`. El despliegue y la llamada funcionaron, pero falló la resolución de rutas relativas, lo que impedía que el script descargara o guardara los ficheros de origen en el *bucket*, tras varios intentos, también se descartó.
- Ambas soluciones son técnicamente viables ⁴, pero se descartaron para priorizar la simplicidad, similitud y reproducibilidad del flujo de trabajo.
3. **Procesamiento y análisis en Vertex AI Workbench:** finalmente, se optó por unificar las fases de limpieza y análisis en *Vertex AI Workbench*, un entorno gestionado de *JupyterLab*, para simplificar la gestión de credenciales (al heredar las del usuario) y poder ejecutar los scripts originales sin modificaciones y sin creación de roles de servicio. El mismo entorno interactivo se utilizó tanto para la transformación como para el modelado, lo que redujo el coste y el esfuerzo de despliegue.
 4. **Aislamiento de proyecto:** aunque GCP crea varios proyectos en una organización al crear la cuenta, el entorno se desplegó fuera de la jerarquía de la organización principal para evitar heredar políticas de los proyectos creados y mantener la facturación separada del entorno corporativo.

⁴ Ambas soluciones son técnicamente viables con configuración adicional, como la definición explícita de un `Dockerfile` para Cloud Run o la creación de un `main.py` específico para Cloud Functions.

3.3. Conclusiones del capítulo

Frente a los desafíos identificados en el estado de la cuestión, este capítulo ha presentado una propuesta metodológica concreta y replicable, organizada también en los tres ejes del proyecto (datos, nube, y IA).

Para los datos, se han seleccionado conjuntos de datos abiertos procedentes del portal del Ayuntamiento de Madrid y se han caracterizado sus limitaciones: discontinuidades temporales, cambios de esquema no documentados y problemas de nomenclatura. Estas fallas detectadas durante la ingesta y limpieza, recalcan la necesidad de procesos automatizados que actúen como auditoría de la calidad del dato. En cuanto a métodos, la aplicación de principios de gobernanza y ética, junto con prácticas de MLOps y DevOps, ha permitido garantizar la trazabilidad y reproducibilidad de los tratamientos de datos.

En el ámbito de la nube, se han presentado las dos plataformas evaluadas finalmente en el proyecto (AWS y GCP), los servicios concretos empleados en cada una (S3 y Glue en AWS; Cloud Storage y Vertex AI Workbench en GCP) y las razones que llevaron a descartar otras opciones como Azure, o servicios *serverless* como Cloud Run o Cloud Functions en GCP. También se ha definido el proceso y la estrategia de almacenamiento mediante capas (bronce, plata y oro), que ha permitido mantener una estructura, facilitando la comparación y la reproducibilidad.

En cuanto a los métodos y materiales de ML y desarrollo del análisis, se ha detallado el proceso implementado en Python: desde la ingesta automatizada mediante la API de CKAN, pasando por la normalización y limpieza de los datos, hasta el análisis y modelado basado en técnicas de clustering no supervisado. Se han detallado las cinco aproximaciones del trabajo “Madrid, isla de calor” y dos nuevas incorporadas, así como las métricas de validación empleadas (coeficiente de silueta, índice de Rand por pares y correlación de Pearson).

La metodología aquí definida es la que ha permitido obtener los resultados que se exponen en el siguiente capítulo.

Capítulo 4

Resultados

“La respuesta a la gran pregunta sobre la vida, el universo y todo lo demás es... 42.”

— Pensamiento Profundo, *Guía del autoestopista galáctico*
(Douglas Adams)

En este capítulo se recogen los resultados obtenidos durante el proyecto, organizados en tres bloques, al igual que el resto de la memoria: los hallazgos relativos a la calidad y continuidad de los datos publicados, los resultados de los análisis realizados sobre ellos y los métodos de ML utilizados, y la comparación entre la ejecución local y las diferentes plataformas cloud evaluadas.

4.1. Hallazgos sobre la calidad de los datos publicados

El trabajo ha conseguido detectar problemas de calidad que no son visibles en un estudio de un solo año, como los trabajos de referencia (Meneses Vicente y García Ruíz, 2023; Santos, 2023), que usaron un único año de datos. Con esto, se pueden perder cambios como los que hay nombrados en el *apartado 3.2.2.2*. Por ejemplo, Meneses y García (2023) sí detectaron el problema de los meses con más días de los que corresponden y lo corrigieron en su limpieza en R; esta misma regla se ha heredado en este trabajo.

La principal conclusión es que la automatización no solo aporta eficiencia, sino que actúa como un instrumento de auditoría sobre la calidad de la información pública, evidenciando en la práctica las carencias que la literatura actual señala sobre la madurez de los portales de datos abiertos (Verhulst et

al., 2020; OECD, 2023; Melendrez Moreto, 2016). En los siguientes apartados se detallan los hallazgos más relevantes sobre los datos analizados, como la evolución no documentada y los problemas de continuidad y cobertura.

4.1.1. Evolución no documentada de los esquemas

La automatización del *pipeline* ha permitido identificar una serie de problemas de calidad en los conjuntos de datos, que se resumen en la tabla 4.1.

Problema	Manifestación	Efecto	Documentación
Nomenclatura	Tres denominaciones para la superficie arbórea	Pérdida de la variable en algunos años	No documentado
Unidades	2019 publica m ² , 2020 en adelante m ² y ha	Serie incompleta	No documentado
Formato numérico	Separador de millar solo desde 2022	Valores no convertibles a número	No documentado
Semántica	Masa forestal frente a masa arbórea	Serie no comparable entre años	No documentado
Entidades	Distritos escritos de forma distinta en el mismo fichero	Cruce vacío sin error	No documentado
Continuidad	Hueco de 14 meses en aforos (documentado) y diciembre 2024 ausente (no documentado)	Series discontinuas	Documentado (hueco aforos)
Cobertura	Estaciones que no miden todas las magnitudes	Análisis inviables	Mencionado en comentarios

Tabla 4.1: Patologías de calidad detectadas en los conjuntos publicados, su efecto sobre la reutilización automatizada y nivel de documentación.

Esta revela dos patrones: los cambios decididos por la administración (como el hueco en los aforos o mejoras de red) están documentados en la descripción del conjunto; en cambio, las derivas en el proceso de generación (cambios de nomenclatura, unidades, formato numérico, etc.) no aparecen documentadas. La información de los hilos de comentarios del portal (como la cobertura sensorial heterogénea o la corrección de unidades) existe, pero no es consumible por un proceso automático, lo que dificulta su reutilización.

4.1.2. Continuidad de la publicación y cobertura de la red

La *figura 4.1* muestra los días válidos de temperatura por estación y año. Se observa que la caída de cobertura entre 2021 y 2022 se concentra en la subred municipal con códigos 1xx, mientras que la red clásica, con números bajos, se mantiene. Este patrón coincide en el tiempo con el hueco de 14 meses en los aforos de peatones y bicicletas, lo que apunta a que no es un fallo general ni averías independientes (Ayuntamiento de Madrid, 2026a). Además, se detecta que diciembre de 2024 está ausente en toda la red (todas las estaciones se detienen en unos 335 días). Las estaciones 16 y 39 presentan cero datos hasta 2022, año en el que entran en la red. Por último, la estación 104 mide temperatura en 2019 aunque el inventario oficial indique que no tiene ese sensor, lo que evidencia una contradicción entre el maestro de datos y el dato real.

4.2. Resultados del análisis de ML: isla de calor

En esta sección se presentan los resultados del análisis de la isla de calor, que extiende el trabajo de (Meneses Vicente y García Ruíz, 2023) desde 2019 hasta 2025 (incluyendo 2019, aunque este año no es directamente comparable con el resto de la serie; véase la *Sección 4.2.6*). Se han evaluado cinco aproximaciones originales (basadas en magnitudes meteorológicas y de contaminación) y dos nuevas aproximaciones propias (temperatura y altitud; temperatura y superficie arbórea relativa). Además, se han aplicado criterios propios para aumentar el alcance del estudio, como la cobertura mínima de 300 días por estación y año. Cabe aclarar que, para las figuras de esta memoria, especialmente cuando se han analizado varios años, se ha utilizado 2021 como año de referencia, ya que es el año base del trabajo original. El resto de análisis (2019-2025) se pueden consultar en el repositorio de GitHub.

4.2.1. Replicación del trabajo de referencia

La réplica se ha evaluado comparando, para cada par de estaciones, si ambos trabajos las asignan al mismo grupo o a grupos distintos. Este criterio evita el problema de que las etiquetas de grupo son arbitrarias y no tienen por qué coincidir entre dos ejecuciones. Las asignaciones del trabajo original se extrajeron de sus figuras y tablas (Capítulo 6 de (Meneses Vicente y García Ruíz, 2023)), y se compararon con las obtenidas en la réplica. Los detalles por aproximación se recogen en la Tabla 4.2. Las fracciones entre paréntesis indican el número de pares de acuerdo sobre el total de pares posibles para las estaciones comunes de cada aproximación.




Figura 4.1: Días válidos de temperatura por estación y año. Se aprecia la degradación de la subred municipal (códigos mayores a 100) durante 2021 y 2022.

Aproximación	Original	Réplica	Comunes	Acuerdo
1. Siete magnitudes	8	7	6	87 % (13/15)
2. Temperatura y humedad	16	21	16	97 % (116/120)
3. Temperatura y arbolado	12	15	9	94 % (34/36)
4. NO ₂	24	24	24	80 % (220/276)
5. NO ₂ y partículas	7	8	7	100 % (21/21)
Total				86 % (404/468)

Tabla 4.2: Replicación del agrupamiento de (Meneses Vicente y García Ruíz, 2023) para 2021. El acuerdo se calcula sobre el total de pares posibles entre las estaciones comunes: para cada par se comprueba si ambos trabajos coinciden en agruparlas juntas o en grupos distintos, con independencia de la etiqueta numérica del grupo.

En la tabla se puede ver el acuerdo en las aproximaciones. Las diferencias se explican dependiendo de la aproximación, como se detalla a continuación:

1. En la **primera aproximación** (siete magnitudes meteorológicas), el trabajo original presenta una inconsistencia: su texto declara seis estaciones seleccionadas por disponer de todas las magnitudes, mientras que su figura muestra ocho, dos de las cuales no miden presión ni radiación solar según el inventario del portal. La réplica ha seguido el criterio declarado y ha añadido la estación de Peñagrande (código 108), que comenzó a registrar datos en 2021 y no estaba disponible en el trabajo original. Por tanto, la réplica utiliza 7 estaciones, de las cuales 6 son comunes con el original, y el acuerdo entre ellas es del 87 %.
2. En la **segunda aproximación** (temperatura y humedad), de las 16 estaciones comunes, solo una (El Pardo) cambia de grupo. En el trabajo original, El Pardo se agrupa con el Centro Municipal de Acústica; en la réplica, se agrupa con Casa de Campo y Juan Carlos I. El acuerdo es del 97 %.
3. En la **tercera aproximación** (temperatura y arbolado), el acuerdo alcanza el 94 % sobre 9 estaciones comunes.
4. En la **cuarta aproximación** (NO₂), que utiliza 24 estaciones comunes, el acuerdo es del 80 %. Ambas particiones coinciden en las estaciones con menor y mayor concentración de dióxido de nitrógeno, pero difieren en los puntos de corte intermedios.
5. En la **quinta aproximación** (NO₂ y partículas), la réplica replica la partición original de forma exacta, con un acuerdo del 100 % sobre 7 estaciones comunes.

4.2.2. Relación entre superficie arbórea y temperatura

La relación inversa entre superficie arbórea y temperatura media por distrito se mantuvo en los siete años analizados, con valores comprendidos entre $-0,26$ y $-0,47$ y una media de $-0,37$ (tabla 4.3). El trabajo original observaba esta relación en un único año y de forma cualitativa; la extensión temporal permite afirmar que no se trata de una particularidad de ese periodo, sino de un patrón sostenido, aunque de intensidad moderada, lo que sugiere factores no controlados, que se discuten en la *Sección 4.2.6*.

Año	Réplica		Criterio propio	
	Pearson r	Distritos	Pearson r	Distritos
2019	-0,686	14	-0,462	14
2020	-0,293	14	-0,392	12
2021	-0,215	14	-0,416	13
2022	-0,258	15	-0,471	9
2023	-0,049	15	-0,264	15
2024	-0,334	15	-0,285	14
2025	-0,315	15	-0,315	15
Media	-0,307		-0,372	

Tabla 4.3: Correlación de Pearson entre superficie arbórea y temperatura media por distrito (2019-2025), reproduciendo las condiciones del trabajo original, y aplicando el criterio de cobertura mínima propio.

En la *figura 4.2* se aprecia el patrón esperado: los distritos sin masas arbóreas (como el Centro o Arganzuela) registran las temperaturas más altas, mientras que los de mayor superficie arbórea (como Casa de Campo o El Retiro) presentan las medias más bajas. Destaca, sin embargo, Puente de Vallecas, que pese a disponer de una superficie arbórea comparable a la de los distritos más frescos resulta ser el más cálido del conjunto. Este comportamiento atípico se explica al observar el dendrograma de la *Figura 4.7*: los dos distritos de Vallecas caen en el bloque urbano denso, lo que sugiere que la ubicación y la densidad de edificación pesan más que la superficie arbórea en su régimen térmico.

4.2.3. Análisis de sensibilidad

La comparación entre ambas configuraciones mostradas en la *figura 4.3* indica que el criterio de cobertura mínima no debilita la relación, sino que la refuerza, ya que la correlación media pasa de $-0,31$ a $-0,37$ y desaparecen los años anómalos. El caso de 2023 resulta ilustrativo. Reproduciendo las condiciones originales, la correlación es prácticamente nula, con un valor de $-0,05$, lo que llevaría a concluir que ese año no existió relación alguna. El motivo es que un distrito con una única estación parcialmente operativa




Figura 4.2: Relación entre superficie arbórea y temperatura media por distrito, año 2021.

aportaba una media anual de 12,5 grados frente a los 18,4 grados del año anterior, recuperando el comportamiento esperado.

Resulta significativo que ambas configuraciones converjan en 2024 y 2025, precisamente los años en que la red operó con normalidad, y diverjan en los años afectados por la degradación de la red o por el cambio de definición de la variable. El criterio propuesto, por tanto, no altera los resultados cuando los datos son completos, únicamente corrige aquellos años en que la media anual no era representativa. En sentido contrario, el criterio reduce el número de distritos disponibles en los años de menor cobertura, hasta un mínimo de nueve en 2022, por lo que las correlaciones de esos años deben interpretarse con cautela.

4.2.4. Variables externas: altitud y superficie relativa

Además de la superficie arbórea absoluta, se ha explorado la relación entre temperatura y otras variables externas: la altitud de las estaciones (en metros) y la superficie arbórea relativa al área del distrito (hectáreas de masa arbórea divididas por la superficie total del distrito). Los resultados se resumen en la tabla 4.4.

La altitud muestra correlaciones muy débiles y cambiantes de signo, lo que sugiere que, dentro del término municipal de Madrid, el gradiente altitudinal no es un factor determinante en el régimen térmico. La superficie relativa




Figura 4.3: Evolución de la correlación entre superficie arbórea y temperatura media por distrito (2019-2025) en ambas configuraciones del análisis.

Año	Pearson r (altitud)	Pearson r (sup. relativa)
2019	0,185	-0,658
2020	-0,180	0,023
2021	0,038	0,198
2022	-0,074	-0,232
2023	-0,234	0,128
2024	-0,047	-0,159
2025	0,006	-0,113

Tabla 4.4: Correlación de Pearson entre temperatura media anual y altitud (por estación) y superficie arbórea relativa (por distrito).

presenta una relación más variable: en 2019 la correlación es fuertemente negativa ($-0,658$), probablemente debida al cambio en el término de superficie, pero en el resto de años los valores son moderados y cambian de signo. Este comportamiento, junto con el hecho de que en la aproximación de agrupamiento la superficie relativa obtiene una silueta media ($0,521$) superior a la absoluta ($0,500$), sugiere que la normalización por el tamaño del distrito puede tener efectos no lineales. La *figura 4.4* muestra el *scatter* para el año 2021, donde se aprecia la dispersión de los datos. El *scatter* 3D de temperatura, altitud y superficie relativa (*figura 4.5*) no muestra una tendencia clara, lo que refuerza que la vegetación absoluta es el factor más relevante entre los analizados.




Figura 4.4: Relación entre superficie arbórea relativa y temperatura media por distrito, año 2021.

4.2.5. Evaluación de los agrupamientos

Los agrupamientos revelaron una relación inversa y sistemática entre el número de variables empleadas y la calidad de los grupos obtenidos (tabla 4.5). La aproximación basada en una única magnitud, el dióxido de nitrógeno, alcanzó la mejor silueta media ($0,565$), seguida de las aproximaciones con dos variables (temperatura y humedad: $0,498$; temperatura y arbolado: $0,500$). La que emplea las siete magnitudes meteorológicas obtuvo sistemáticamente

Temperatura vs altitud y sup. relativa 2022




Figura 4.5: Scatter 3D de temperatura, altitud y superficie relativa para el año 2022.

los peores valores (0,146), hasta el punto de resultar inviable en 2022. Esto se debe a dos causas: al aumentar la dimensionalidad, las distancias entre observaciones tienden a igualarse y los grupos pierden definición; además, exigir que una estación disponga de todas las magnitudes reduce drásticamente la muestra, de las veinticuatro estaciones disponibles para el NO_2 a apenas cinco o siete para el conjunto meteorológico completo. La heterogeneidad de la cobertura sensorial de la red no solo introduce valores ausentes, sino que también condiciona qué análisis resultan viables. En cuanto a las aproximaciones propias, la que incorpora la altitud obtuvo una silueta media de 0,458, inferior a la de temperatura y humedad (0,498). La que utiliza la superficie arbórea relativa al área del distrito alcanzó una silueta media de 0,521, superior a la versión absoluta (0,500), lo que sugiere que normalizar por el tamaño del distrito mejora la separación entre grupos.

El diagrama del codo para la aproximación de temperatura y humedad (*figura 4.6*) muestra que la inercia cae de forma pronunciada hasta $k = 2$ ($21, 2 \rightarrow 5, 8$), luego se modera ($5, 8 \rightarrow 4, 5 \rightarrow 2, 6$) y a partir de $k = 5$ las reducciones son inferiores a 1. Este comportamiento valida la elección de cinco grupos del trabajo original. Además, el máximo de silueta para esta aproximación en 2021 es de 0,660, lo que confirma que dos criterios independientes señalan el mismo número de grupos. Un matiz honesto es que la caída más brusca se produce en $k = 2$, coherente con la primera división del dendrograma (*figura 4.7*), lo que indica que $k = 2$ captura la estructura dominante (periferia vs.

Año	7 magn.	T+HR	T+arb.	NO ₂	NO ₂ +PM	T+Altitud	T+Sup. Rel.
2019	0,097	0,510	0,458	0,601	0,377	0,399	0,564
2020	0,122	0,444	0,470	0,522	0,356	0,442	0,469
2021	0,078	0,660	0,438	0,554	0,309	0,472	0,486
2022	—	0,397	0,460	0,508	0,262	0,443	0,607
2023	0,014	0,505	0,531	0,682	0,254	0,480	0,491
2024	0,293	0,502	0,569	0,566	0,286	0,496	0,539
2025	0,269	0,470	0,577	0,522	0,376	0,471	0,494
Media	0,146	0,498	0,500	<u>0,565</u>	0,317	0,458	0,521

Tabla 4.5: Coeficiente de silueta por año y aproximación, aplicando el criterio de cobertura mínima. Se incluyen las cinco aproximaciones originales y las dos propias. En negrita, el mejor valor de cada año. “—” indica que la aproximación no reunió estaciones suficientes ese año.

núcleo urbano) y $k = 5$ es la subdivisión estable de esa estructura.




Figura 4.6: Diagrama del codo de la aproximación de temperatura y humedad relativa (2021).

Como comprobación de robustez se ejecutaron sobre los mismos datos dos algoritmos de agrupamiento independientes, *k-means* y el método jerárquico de Ward. En cuatro de las cinco aproximaciones originales ambos produjeron particiones idénticas, y en la restante difirieron en dos de veintiuna estaciones. Que dos procedimientos con fundamentos distintos converjan en la misma agrupación indica que la estructura detectada responde a los datos y no a las particularidades de un algoritmo concreto, comprobación que el trabajo original no realizaba de forma explícita. Estas etiquetas se registran en los archivos `clusters_*.csv` de cada ejecución. Para 2021, acuerdo agregado por pares entre ambos métodos fue del 96,6 % (797 de 825 pares).

El dendrograma (*figura 4.7*) muestra que la primera división del conjunto separa las estaciones situadas en la periferia y en grandes zonas verdes (Casa de Campo, El Pardo, Juan Carlos I) de las ubicadas en el núcleo urbano denso (Centro, Arganzuela, Puente de Vallecas), una partición que reproduce la estructura espacial del fenómeno estudiado sin haber sido impuesta al algoritmo.




Figura 4.7: Dendrograma del agrupamiento jerárquico de Ward sobre temperatura y humedad relativa (2021).

4.2.6. Limitaciones e interpretación

Todos los resultados obtenidos deben interpretarse a la luz de tres limitaciones principales.

En primer lugar, existen factores no controlados que pueden influir en la temperatura. Se han añadido aproximaciones que incorporan la altitud y la superficie relativa al área del distrito. La altitud, según el estudio, no es un factor distintivo. La superficie relativa obtiene una silueta media ligeramente superior, aunque la diferencia es modesta. Es posible que haya más variables no consideradas que expliquen la variabilidad de la temperatura, como la densidad de edificación, la orientación de las calles, la presencia de cuerpos de agua, entre otros. La disponibilidad de datos abiertos sobre estas variables es limitada, lo que restringe su inclusión en el análisis.

En segundo lugar, el año 2019 no es directamente comparable con el resto de la serie. El cambio de definición de “masa forestal” a “masa arbórea” supone un reinventariado, no un crecimiento vegetal real, como reflejan los saltos de ± 30 hectáreas en algunos distritos (San Blas pasa de 45 a 15 ha; Villa de Vallecas de 63 a 94 ha). Por este motivo, en el análisis de sensibilidad se ha tratado 2019 por separado y se ha restringido la serie comparable a 2020-2025.

En tercer lugar, el criterio de cobertura mínima propuesto (300 días por estación y año), aunque mejora la robustez de los agrupamientos al descartar estaciones con datos insuficientes, introduce una limitación importante: reduce drásticamente la muestra disponible en años con baja cobertura sensorial. En 2022, por ejemplo, solo quedan 9 distritos, lo que limita la generalización de las correlaciones de ese año ($r = -0,471$), que deben interpretarse con cautela. Este efecto es una consecuencia directa de la calidad de los datos publicados y no del criterio en sí, pero es una limitación que debe tenerse en cuenta al extender el análisis a años con cobertura incompleta.

4.3. Comparación entre la ejecución local y las plataformas cloud

Respecto a los entornos, los resultados son idénticos en los tres (local, AWS y GCP) dada la portabilidad del código, lo que confirma la reproducibilidad del análisis. El coste bruto estimado del proyecto en AWS fue de 0,93 \$. El análisis interactivo en SageMaker fue el componente más costoso, lo que indica que el coste no está en el cómputo, sino en mantener un entorno encendido. En GCP, el coste bruto fue de 13,14 €, concentrado casi íntegramente en el tiempo de instancia de Vertex AI Workbench (Notebooks). El resto de servicios (Cloud Storage, Cloud Run, etc.) tuvieron un coste marginal o nulo. En ambos casos, los créditos de las capas gratuitas cubrieron la totalidad de los costes, por lo que el coste neto fue de 0 euros.

La tabla 4.6 recoge el esfuerzo medido en horas dedicado a cada etapa y en cada entorno por el investigador. En este caso, el orden en que se abordaron los entornos condiciona el resultado, ya que con el conocimiento acumulado de etapas anteriores, las siguientes son mucho más ágiles. La implementación local fue la primera y llevó la mayor parte del trabajo de comprensión de las fuentes, diseño del proceso en código y resolución de las incidencias de calidad del dato. De igual manera, AWS fue la primera nube evaluada, y la que menos conocía el autor, por lo que el tiempo acumulado incluye el aprendizaje de la plataforma y el coste en tiempo del primer acercamiento a la nube. En cambio, GCP tiene un alto tiempo en limpieza por la evaluación de diferentes métodos que al final no se pudieron aplicar.

4.3.1. Comparación de costes en las diferentes nubes

La tabla 4.7 detalla los costes brutos y netos incurridos en las plataformas cloud durante el período de desarrollo, dividido por servicios de una manera más extensa a lo expuesto en el apartado anterior.

Etapas	Esfuerzo (h)			Ejecución (s)			Coste (\$)	
	Local	AWS	GCP	Local	AWS	GCP	AWS (bruto)	GCP (bruto)
Configuración	5	8	2	—	—	—	0,00	0,00
Ingesta	10	5	1	—	180	176	0,00	0,00
Limpieza	20	6	10	45	227	51	0,01	0,04
Análisis	35	5	5	120	300	115	0,92	12,87
Total	70 h	21 h	18 h	165	707	342	0,93	12,91

Tabla 4.6: Comparativa de esfuerzo de desarrollo, tiempo de ejecución y coste por etapa y entorno.

Servicio	AWS (USD)	GCP (EUR)
Almacenamiento (S3 / Cloud Storage)	0,021	0,00
Procesamiento ETL (Glue / Cloud Run)	0,011	0,04
Análisis interactivo (SageMaker / Vertex AI Notebooks)	0,811	12,87
Infraestructura y otros (DataZone, CloudWatch, etc.)	0,083	0,23
Coste bruto (antes de créditos)	0,926	13,14
Créditos aplicados	0,926	13,14
Coste neto (real)	0,00	0,00

Tabla 4.7: Comparativa de costes brutos y netos en AWS y GCP durante el período de ejecución del proyecto.

La principal diferencia radica en el modelo de facturación: AWS ofrece una capa gratuita generosa para servicios como Glue y SageMaker (hasta 6 meses), mientras que en GCP, aunque los créditos iniciales (300 \$) cubren el proyecto, el coste de mantener una instancia de Vertex AI Workbench encendida es el que genera el gasto principal. Si se detuviera la instancia entre sesiones, este coste podría reducirse drásticamente.

De todas formas, el precio de la nube no es el único factor a considerar. La facilidad de uso, la documentación, la integración con otros servicios y la experiencia previa son elementos que influyen en la elección de una plataforma sobre otra. En este caso, las diferencias de coste no son significativas, dado que ambos entornos ofrecieron créditos suficientes para cubrir la totalidad del proyecto, y Vertex AI Workbench podría haber sido detenido entre sesiones para reducir el coste.

4.4. Conclusiones del capítulo

Los resultados obtenidos en este capítulo confirman la utilidad del pipeline implementado y ofrecen evidencia empírica sobre las tres partes principales del proyecto.

En el ámbito de los datos, se han revelado problemas de calidad, ya descritos en *Sección 3.2.2.2*.

En el análisis de la isla de calor, se ha verificado la relación inversa entre superficie arbórea y temperatura, confirmando que se trata de un patrón estructural de la ciudad y no de una particularidad anual. El criterio de cobertura mínima ha demostrado reforzar esta relación, eliminando distorsiones introducidas por estaciones parcialmente operativas. Las aproximaciones con menos variables obtienen mejores agrupamientos, mientras que la altitud no resulta un factor determinante.

En la comparativa cloud, se ha constatado la reproducibilidad de los resultados en los tres entornos, con costes netos nulos gracias a los créditos gratuitos, y una generosa cantidad sobrante. El esfuerzo de desarrollo ha sido mayor en local que en las nubes, aunque el orden de ejecución condiciona estos tiempos. La principal diferencia de coste radica en el modelo de facturación, siendo el análisis interactivo el componente más costoso en ambas plataformas.

Las implicaciones de estos resultados, junto con las lecciones aprendidas y las líneas de trabajo abiertas, se discuten en el *Capítulo 6.1*.

Capítulo 5

Manual de usuario y casos de uso

“¡Es peligroso ir solo! Toma esto.”
— Anciano, *The Legend of Zelda* (1986)

-

En este capítulo, describiremos en detalle la guía operativa del proyecto, explicando los pasos necesarios para que cualquier usuario o investigador pueda replicar el entorno de trabajo, ejecutar el *pipeline* de datos y reproducir los análisis descritos en capítulos anteriores.

Para mantener la coherencia con el resto de capítulos, dividiremos este manual por plataforma (Local, AWS y GCP), y dentro de cada una de ellas, seguiremos las tres etapas del ciclo de vida del dato:

1. **Configuración, ingesta y almacenamiento de datos.**
2. **Despliegue, automatización y procesamiento ETL (Extract, Transform, Load).**
3. **Ejecución de modelos y evaluación de resultados.**

De este modo, intentaremos garantizar la trazabilidad del ciclo de vida del dato. Esto lo haremos para las tres plataformas donde hemos trabajado: Local, AWS y GCP, y al final, también estableceremos una comparativa lo más objetiva posible de qué entornos es mejor utilizar en cada caso, según lo estudiado en este trabajo. Los detalles de los métodos utilizados en las partes correspondientes se han detallado anteriormente en la *Sección 3.2.2*. La comparación cuantitativa entre entornos, en términos de esfuerzo, tiempo de ejecución y coste, se recopila en el *Capítulo 4*.

5.1. Manual de usuario en Local

Aunque esta sección va a tratar de cómo lanzar el proceso en local, muchos de los comentarios aplican a las nubes estudiadas, ya que parten de los mismos ficheros base que tenemos en el repositorio público de GitHub.

5.1.1. Despliegue y utilización del código en Local

La ejecución local no requiere infraestructura adicional más allá de un entorno de desarrollo como puede ser *VS Code*, que es el que se ha utilizado para este proyecto, o cualquier entorno con el que el lector se sienta más cómodo, y configurarlo de manera similar a como se describe en la siguiente *Sección 5.1.2*.

Los procesos se ejecutan secuencialmente y cada uno utiliza la salida del anterior como entrada. Aunque para este trabajo se ha utilizado un entorno local, se podrían usar herramientas como notebooks de Jupyter o los entornos de *Hugging Face* para ejecutar estos comandos sin la necesidad de un hardware personal.

5.1.2. Ingesta y descarga de datos

El proceso de ingesta requiere Python 3.12 o superior e instalar las dependencias de `requirements.txt` (preferiblemente en un entorno virtual). El comportamiento del *pipeline* se controla desde el fichero, `config.py`, que centraliza las rutas de las capas de almacenamiento, las direcciones web de los conjuntos en los portales de datos, los años a descargar, los filtros de formato, las reglas de limpieza y demás parámetros de entorno. Para incorporar un conjunto de datos nuevo solo habría que añadir una entrada en los diccionarios correspondientes, y modificar, si es necesario, la lógica de los procesos.

La ruta base del proyecto es la definida en la variable `TFM_BASE`. Si esta no existe, se utiliza el directorio local del proyecto. Aunque no se añada en este apartado, se recomienda configurarla tanto aquí como en otros entornos. Con esto, lo primero sería descargar el código y crear el entorno virtual, como se muestra en el bloque 5.1.

Después de esto, ya tendríamos los datos definidos, y ahora podemos pasar a ejecutar el proceso de limpieza (bloque 5.2). Este script consolida los datos y genera la capa *Silver* estructurada lista para el análisis.

El proceso es idempotente, es decir, puede relanzarse sin volver a descargar lo ya presente, y registra los metadatos de procedencia de cada fichero en


```
# Descarga de código
git clone https://github.com/crismo04/TFM-cloud-solutions-to-public-data.git
cd TFM-cloud-solutions-to-public-data/code/files

# Entorno virtual de python
python -m venv .venv
source .venv/bin/activate          # Windows: .venv\Scripts\Activate.ps1
pip install -r requirements.txt --quiet

# Descarga de datos
python 01_descarga.py --dry-run    # Comprueba enlaces sin
descargar                         # descargar
python 01_descarga.py              # Descarga completa y
metadatos                         # metadatos
```

Bloque de código 5.1: Preparación del entorno y ejecución de la ingesta

```
python 02_limpieza.py
```

Bloque de código 5.2: Ejecución local de limpieza

`_metadatos.csv`. Debido a la protección anti-automatización de los portales también incorpora pausas entre descargas y reintentos, por lo que una ingesta completa puede durar varios minutos, pero con esto ya deberíamos tener los datos en las carpetas correspondientes.

5.1.3. Ejecución de modelos y resultados

Una vez superada la fase ETL, el modelado se ejecuta mediante el bloque 5.3:


```
python 03_analisis_isla_calor.py
```

Bloque de código 5.3: Ejecución local del modelado analítico

Cada ejecución del análisis genera un directorio por cada año con los diagramas del codo, dendrogramas, gráficos de dispersión de correlaciones y tablas de grupos. El parámetro `MODO_REPLICA` determina si se reproducen las condiciones del trabajo original o se aplican los criterios metodológicos propios definidos en la *Sección 3.2.2.3*, y los resultados de cada modo se almacenan en directorios separados. La salida completa queda registrada en `ejecucion.log` para facilitar la trazabilidad de las ejecuciones y los parámetros elegidos. También se producen tres resúmenes: el coeficiente de silueta

por año y aproximación, la correlación entre superficie arbórea y temperatura por año, y un diagnóstico de cobertura de días válidos por estación. El árbol de directorios se puede ver en la figura 5.1 o en el propio GitHub, ya que se han subido también para dar transparencia y permitir su auditoría.

Figura 5.1: Árbol de archivos de resultados



Fuente: Propia

Los resultados y hallazgos interesantes que se extraen de estos archivos se pueden consultar en detalle en el *capítulo 4.2*.

5.2. Manual de usuario en AWS


5.2.1. Despliegue

Para desplegar la infraestructura en la nube de Amazon, lo primero que tenemos que hacer es registrarnos en la plataforma (Amazon Web Services, 2026b). El proceso de creación consta de cinco pasos y da acceso al plan gratuito, aunque requiere introducir una tarjeta de crédito de manera obligatoria. Además, por motivos de seguridad, el sistema exige configurar un segundo factor de autenticación (MFA). Para no alargar este capítulo, simplemente redirigimos al usuario al propio tutorial de AWS, donde se explica en detalle cómo crear la cuenta: (Amazon Web Services, 2026d). Con esto, AWS proporciona hasta 200 \$ en créditos gratuitos para realizar pruebas: 100 \$ iniciales y otros 100 \$ adicionales al completar una serie de actividades. Aunque han ido cambiando en las diferentes veces que hemos creado la cuenta, y lo más seguro es que cambiarán de nuevo en el futuro, a fecha de creación de esta memoria, las pruebas consistían en:

- Crear una VM.
- Establecer un límite de gasto (*Billing*).
- Crear una base de datos SQL.
- Crear una aplicación web.
- Probar un modelo de lenguaje (LLM) en el servicio Amazon Bedrock.

Con los 200 \$ disponibles, se dispone de créditos de sobra para poder realizar el proyecto, como hemos visto en la *Sección 4.3.1*. Todos los comandos y procedimientos nombrados a partir de aquí han sido realizados consultando la documentación técnica oficial de AWS (Amazon Web Services, 2026c). Debido a la extensión de esta documentación y para facilitar la lectura de la memoria, no se referencian las páginas de documentación individuales para cada comando, pero la misma cuenta con un buscador donde se puede consultar el comando o comandos específicos de esta memoria para ver su funcionamiento y las decisiones de diseño que se han tomado aquí. También para facilitar la reproducibilidad, se ha priorizado la utilización de los comandos de la CLI, aunque todos ellos tienen sus equivalentes en la web, que también se pueden consultar en la documentación y pueden ser más fáciles de ejecutar, y sobre todo más claros, en ciertos escenarios. Los comandos que vamos a lanzar se pueden escribir directamente en la **AWS CloudShell** como se muestra en la *figura 5.2*

Figura 5.2: Abrir terminal AWS en consola



Fuente: Propia

5.2.2. Configuración del entorno y autenticación

Aunque desde **AWS CloudShell** se gestionan las credenciales de acceso con el usuario que hemos registrado, es posible configurar credenciales de acceso externas para otros usuarios, para que los diferentes servicios en la nube los utilicen, o para ejecutar los comandos desde local. El proyecto se realizó siguiendo las mejores prácticas, mediante el modelo de control de acceso basado en roles y grupos (RBAC). Aunque se podrían establecer permisos más estrictos, este modelo tiene más sentido para manejar un número mayor de usuarios, pero se realizó para futuras extensiones del proyecto y para la utilización de herramientas y roles de servicio.

Lo primero para trabajar con la nube es seleccionar la región que más convenga al proyecto, que en este caso es la región **eu-west-1** (Irlanda), ya que es la que mayor número de servicios ofrece dentro de la Unión Europea. Con esto, en la propia **AWS CloudShell**, se puede obtener el código del proyecto, publicado bajo licencia abierta, como se muestra en el bloque 5.4.

```
cd ~
git clone https://github.com/crismo04/TFM-cloud-solutions-to-public-data.git
cd TFM-cloud-solutions-to-public-data/code/files
pip install -r requirements.txt --quiet
```

Bloque de código 5.4: Obtención del código fuente del proyecto

También conviene tener creadas las variables de entorno que vamos a utilizar en el proyecto (bloque 5.5). Además, al trabajar con la terminal, se conserva el directorio personal entre sesiones, pero no las variables de entorno definidas. Para no tener que volver a crearlas cada sesión, se pueden almacenar en

un fichero que se carga al comenzar cada sesión:

```
cat > ~/tfm-env.sh << 'EOF'
export BUCKET="tfm-ucm-datos-publicos"
export REGION="eu-west-1"
export CUENTA=$(aws sts get-caller-identity --query
    Account --output text)
export TFM_BASE="s3://$BUCKET"
EOF

source ~/tfm-env.sh
```

Bloque de código 5.5: Persistencia de las variables del proyecto

5.2.3. Infraestructura de Almacenamiento en Amazon S3

El almacenamiento en la nube se fundamenta en un *bucket* de Amazon S3 denominado `tfm-ucm-datos-publicos`. Su estructura replica exactamente la jerarquía de directorios local y de otras nubes: `data/bronze/`, `data/silver/`, `resultados/` (como capa Gold) y `scripts/`. Esto permite que el código de Python migre entre ambos entornos cambiando únicamente el prefijo de ruta de archivo. Se aplican también, mediante los comandos del bloque 5.6, bloqueo total de acceso público, versionado de objetos y etiquetado para el seguimiento de costes.

```
# Creacion del bucket
aws s3api create-bucket --bucket "$BUCKET" --region "
    $REGION" \
--create-bucket-configuration LocationConstraint="$REGION"

# Bloqueo de acceso publico
aws s3api put-public-access-block --bucket "$BUCKET" \
--public-access-block-configuration \
"BlockPublicAcls=true,IgnorePublicAcls=true,
    BlockPublicPolicy=true,RestrictPublicBuckets=true"

# Versionado y etiquetado
aws s3api put-bucket-versioning --bucket "$BUCKET" \
--versioning-configuration Status=Enabled

aws s3api put-bucket-tagging --bucket "$BUCKET" \
--tagging 'TagSet=[{Key=proyecto,Value=tfm}]'
```

Bloque de código 5.6: Creación y configuración del contenedor en S3

Una vez creado el contenedor, se puede ver en el apartado de S3 instantáneamente y ya podemos proceder a cargar los procesos de ingesta directamente

sobre el almacenamiento creado (bloque 5.7). Con esto, validamos la portabilidad, ya que el mismo proceso que se ejecutó en local escribe ahora en S3 sin ninguna modificación de su lógica, gracias a la abstracción del sistema de ficheros con *fsspec* descrita en la *Sección 3.2.2.1*.

```
# Carga de los scripts del pipeline
aws s3 cp . "s3://$BUCKET/scripts/" --recursive --exclude
    "*" --include "*.py"


# Ingesta escribiendo directamente en la capa bronze del
    bucket
python 01_descarga.py --destino "s3://$BUCKET/data/bronze/"
    ""

# Verificación del contenido cargado
aws s3 ls "s3://$BUCKET/data/bronze/" --recursive --
    summarize
```

Bloque de código 5.7: Carga de procesos e ingesta directa sobre S3

Con esto ya tendremos la estructura de carpetas y la ingesta completa en S3 con los datos definidos en el Python del repositorio, como se muestra en la *figura 5.3*.

Figura 5.3: Estructura de carpetas generada en S3



Fuente: Propia

En caso de querer descargar otros datos públicos, hay dos opciones. Se podría descargar directamente con un comando de descarga como el del bloque 5.8.

También, como opción más elegante, se podría integrar en el proceso y mo-

```
# SOLO PARA DESCARGAR NUEVOS DATOS! CAMBIANDO LA URL!  
wget -q0 - "$URL_DATOS" | aws s3 cp - "s3://$BUCKET/data/  
bronze/nombre_archivo.csv"
```

Bloque de código 5.8: Ingesta manual directa de un nuevo dataset a S3

dificar el repositorio descargable o el archivo, directamente en la consola de AWS o en local, contribuyendo así al desarrollo de este proyecto.

5.2.4. Orquestación y Procesamiento ETL con AWS Glue

Para el procesamiento de datos en la nube se ha optado por “AWS Glue Python Shell” en lugar de entornos distribuidos basados en “Apache Spark”. Dado que los conjuntos de datos tratados en este proyecto ocupan 272 MB en su capa bronce, el uso de *Spark* implicaría una sobrecarga innecesaria y un coste mínimo de 2 DPU (Data Processing Units), mientras que *Python Shell* permite ejecutar con un mínimo de 0,0625 DPU ($\approx 0,03$ \$/hora), incluyendo librerías como **pandas**, **numpy** y **scikit-learn** ya instaladas.

A diferencia de la ejecución en terminal del apartado anterior, Glue se ejecuta desde su propio apartado en AWS, puede programarse o encadenarse con otros, y es más fácil de automatizar, además de que nos permite explorar las posibilidades de la nube. El primer paso es crear la cuenta de servicio (bloque 5.9), siguiendo los principios que hemos comentado al principio de este capítulo.

Para utilizar *Python Shell* es necesario empaquetar los módulos propios que hemos creado, como el fichero de configuración. Durante el desarrollo se ha comprobado que un fichero comprimido en formato **zip** se descarga correctamente pero no llega a importarse, mientras que un paquete en formato *wheel* sí se instala como cualquier otra dependencia, por lo que lo hemos hecho de la manera mostrada en el bloque 5.10. Si posteriormente se modifica el fichero de configuración, es necesario regenerar el paquete e **incrementar su número de versión**, ya que en caso contrario el gestor de dependencias reutilizaría la copia previamente instalada.

Con el rol y los procesos disponibles solo falta crear la función. Para esto, fijaremos un tiempo máximo de ejecución, una capacidad máxima y desactivaremos los reintentos automáticos como medida de control de costes. También añadiremos etiquetas para poder desglosar el gasto. La definición se declara en JSON en lugar de como argumentos en línea, para mayor visibilidad de rutas y evitar el escapado de comillas, ya que ambas han dado problemas en la ejecución (bloque 5.11).

```

# Política para que solo Glue tenga el rol
cat > trust.json << 'EOF'
{"Version":"2012-10-17","Statement":[{"Effect":"Allow", "
  Principal":{"Service":"glue.amazonaws.com"},"Action":"
    sts:AssumeRole"}]}
EOF

aws iam create-role --role-name AWSGlueServiceRole-tfm \
--assume-role-policy-document file://trust.json \
--tags Key=proyecto,Value=tfm

aws iam attach-role-policy --role-name AWSGlueServiceRole-
tfm \
--policy-arn arn:aws:iam::aws:policy/service-role/
AWSGlueServiceRole

aws iam attach-role-policy --role-name AWSGlueServiceRole-
tfm \
--policy-arn arn:aws:iam::aws:policy/AmazonS3FullAccess

```

Bloque de código 5.9: Creación del rol de servicio de Glue

```

rm -rf /tmp/pkg && mkdir -p /tmp/pkg
cp ~/TFM-cloud-solutions-to-public-data/code/files/config.
py /tmp/pkg/

cat > /tmp/pkg/setup.py << 'EOF'
from setuptools import setup
setup(name="tfmconfig", version="1.0.0", py_modules=["
  config"])
EOF

cd /tmp/pkg && pip wheel . -w dist --no-deps --quiet
aws s3 cp dist/tfmconfig-1.0.0-py3-none-any.whl "s3://
$BUCKET/scripts/"

cd ~/TFM-cloud-solutions-to-public-data/code/files
aws s3 cp . "s3://$BUCKET/scripts/" --recursive --exclude
"*" --include "*.py"

```

Bloque de código 5.10: Empaquetado del módulo de configuración


```
source ~/tfm-env.sh
# Aborta si la variable esta vacia, evitando rutas del
# tipo s3:///
: "${BUCKET:?Variable BUCKET vacia, ejecutar source ~/tfm-
env.sh}"

cat > job-limpieza.json << EOF
{
  "Name": "tfm-02-limpieza",
  "Role": "AWSGlueServiceRole-tfm",
  "Command": {"Name": "pythonshell", "PythonVersion": "
    3.9",
    "ScriptLocation": "s3://$BUCKET/scripts/02
      _limpieza.py"},
  "DefaultArguments": {
    "--extra-py-files": "s3://$BUCKET/scripts/
      tfmconfig-1.0.0-py3-none-any.whl",
    "--additional-python-modules": "s3fs",
    "--TFM_BASE": "s3://$BUCKET"},
  "MaxCapacity": 0.0625,
  "Timeout": 15,
  "MaxRetries": 0,
  "Tags": {"proyecto": "tfm", "fase": "limpieza"}
}
EOF

cat job-limpieza.json      # comprobacion de las rutas
                           resueltas
aws glue create-job --cli-input-json file://job-limpieza.
json
```

Bloque de código 5.11: Definición y despliegue del trabajo de limpieza en Glue

Esto, de nuevo, es sencillo por tener los `.py` configurados. Para añadir más datos solo sería necesario incluir su entrada en `config.py`, actualizar el repositorio con las especificidades de estos, y volver a sincronizar los procesos con el almacenamiento mediante el ciclo descrito en este trabajo. Con esto ya podemos lanzar la ejecución y ver el resultado (bloque 5.12).

```

RUN=$(aws glue start-job-run --job-name tfm-02-limpieza \
--query JobRunId --output text)

aws glue get-job-run --job-name tfm-02-limpieza --run-id "
$RUN" \
--query "JobRun.[JobRunState,ExecutionTime,ErrorMessage]"
--output text

# Registro de la ejecucion
aws logs tail /aws-glue/python-jobs/output --since 10m

# La capa silver debe aparecer en el bucket al finalizar
aws s3 ls "s3://$BUCKET/data/silver/" --recursive --
summarize

```

Bloque de código 5.12: Ejecución, seguimiento y verificación del resultado

Aunque aquí lo ponemos en línea de comandos, AWS Glue es más fácil de ejecutar en la propia plataforma y, de hecho, ha sido la forma de trabajo utilizada para los pequeños errores que han aparecido durante la ejecución. Tras esta ejecución, la capa *silver* aparece en S3, con los mismos datos y estructura que la generada en el entorno local, como se puede apreciar en la *figura 5.4*.

Figura 5.4: Ejecuciones del trabajo ETL en AWS Glue

The screenshot shows the AWS Glue console interface. On the left is a navigation menu with options like 'Pegamento AWS', 'Primeros pasos', 'Estudio unificado SageMaker', 'Trabajos ETL', 'ETL visual', 'Cuadernos', 'Monitoreo de la ejecución del trabajo', 'Tablas de catálogo de datos', 'Conexiones de datos', 'Flujos de trabajo (orquestración)', 'Integraciones Zero-ETL', 'Catálogo de datos', 'Integración de datos y ETL', and 'Páginas heredadas'. The main panel displays the 'tfm-02-limpieza' job details. It includes a 'Runs' tab with a table of job executions. Below this, there's a 'Detalles de la ejecución' section showing job metadata and execution statistics.

Estado de ejecución	Reintentos	Hora de inicio (Local)	Hora de finalización (Local)	Duración	Capacidad (DPU)	Tipo de trabajador
✓ Sucedio	0	23/08/2026 23:24:39	23/08/2026 23:28:33	3 m 47 s	0,0625 DPU	-
○	0	23/08/2026 23:09:37	23/08/2026 23:13:35	3 m 50 s	0,0625 DPU	-
○	0	23/08/2026 23:07:28	23/08/2026 23:07:48	15 s	0,0625 DPU	-
○	0	23/08/2026 23:04:49	23/08/2026 23:05:15	Años 20	0,0625 DPU	-
○	0	23/08/2026 23:00:57	23/08/2026 23:01:20	16 s	0,0625 DPU	-
○	0	23/08/2026 22:57:42	23/08/2026 22:58:35	43 s	0,0625 DPU	-
○	0	23/08/2026 22:52:31	23/08/2026 22:52:55	17 s	0,0625 DPU	-

Detalles de la ejecución		Argumentos de entrada (6)		Registros		Ejecutar información		Métricas		Análisis de solución de problemas		Interfaz de usuario Spi	
Nombre del trabajo	tfm-02-limpieza	Hora de inicio (Local)	23/08/2026 23:24:39	Versión en pegamento	5.1	Última modificación el (Local)	23/08/2026 23:28:33	Nombre del grupo de registro	/aws-glue/python-jobs	Número de trabajadores	-		
Id	j_r_8fab70f5d20efb64ef3b4119b605b4569b194451c64d15	Hora de finalización (Local)	23/08/2026 23:28:33	Tipo de trabajador	-								
Estado de ejecución	✓ Sucedio	Estado de ejecución	6 segundos	Capacidad máxima	0,0625 DPU								

Fuente: Propia, traducido por Google


5.2.5. Modelos de ML y resultados con Amazon SageMaker

Para generar esta última capa de análisis en AWS, vamos a volver a cambiar de tecnología. Mientras que la etapa *Silver* se completó mediante *AWS Glue*, la etapa de análisis tiene otros requerimientos: ejecución de algoritmos, cálculo de siluetas, volumen elevado de figuras, librerías de tratamiento geo-espacial, etc. Todo esto se beneficia de una ejecución interactiva durante la interpretación de los resultados.

Por ello vamos a emplear **Amazon SageMaker**. Específicamente, el servicio de *Spaces* dentro de un dominio, que proporciona entornos de *Jupyter Notebooks*. Lo primero es la creación de este dominio, que se realiza desde la consola web ¹, con la configuración de inicio rápido en la región **eu-west-1**.

AWS aprovisionará automáticamente las redes virtuales (VPC, Virtual Private Cloud) y el almacenamiento (EFS, Elastic File System) con el dominio. Una vez creado, el espacio aprovisiona automáticamente el entorno de desarrollo **JupyterLab** mediante IDE (Integrated Development Environment), además de muchas otras funciones, que se pueden ver en la figura 5.5.

Figura 5.5: Consola de SageMaker



Fuente: Propia

Desde la terminal integrada en el entorno, se descarga el repositorio, se instalan librerías y se sincronizan *Silver* y datos descargados en el paso de ingesta. Todo esto debe instalarse en el mismo intérprete que ejecuta el proceso y hay que tener en cuenta que el explorador de ficheros del entorno se abre por defecto en un directorio distinto a donde clonamos el repositorio, por lo que es necesario ir hasta él para visualizar las figuras generadas. Los comandos para todo esto, y para sincronizar los resultados en S3, se muestran en el bloque 5.13.

¹<https://eu-west-1.console.aws.amazon.com/datazone/home?region=eu-west-1#/>

```
# Dentro de JupyterLab en SageMaker, creamos o
# actualizamos el repositorio
git clone https://github.com/crismo04/TFM-cloud-solutions-
to-public-data.git \
|| (cd TFM-cloud-solutions-to-public-data && git pull)
cd TFM-cloud-solutions-to-public-data/code/files
pip install -r requirements.txt --quiet
python -m pip install geopandas --quiet

# Descarga de las capas necesarias desde S3
aws s3 sync s3://tfm-ucm-datos-publicos/data/silver/ data/
silver/
aws s3 sync s3://tfm-ucm-datos-publicos/data/bronze/
distritos/ data/bronze/distritos/

# Ejecutamos el analisis y publicamos los resultados
python 03_analisis_isla_calor.py
aws s3 sync resultados/ s3://tfm-ucm-datos-publicos/
resultados/
```

Bloque de código 5.13: Ejecución del análisis en SageMaker.

Emplear **JupyterLab** para el trabajo analítico también facilita visualizar gráficos y tablas directamente en el entorno, y publicar después en el almacenamiento de objetos una vez estudiada la salida. El entorno de cuadernos incorpora además un conjunto amplio de librerías de aprendizaje automático con versiones fijadas por el proveedor, de modo que instalar las dependencias del proyecto podría generar conflictos de versión (pero en este caso no afectan a la ejecución).


El proyecto también tiene un archivo `.ipynb` ejecutable para poder ver los resultados directamente en la carpeta `code/files/analisis_isla_calor.ipynb`.

También advertir que, desde una perspectiva de control de costes, los espacios de trabajo facturan por tiempo de aprovisionamiento mientras permanecen encendidos, con independencia de que se esté utilizando el cuaderno o no. Conviene detenerlos manualmente desde la administración del dominio al finalizar cada sesión para interrumpir la facturación.

Un ejemplo de la ejecución de JupyterLab en SageMaker se puede ver en la figura 5.6.

Este manual ha empleado tres modalidades de ejecución dentro de AWS, cada una adecuada a una etapa distinta: un terminal interactivo para la ingesta, un servicio de procesamiento desatendido para la transformación, y un entorno de cuadernos para el análisis. Aunque la ingesta y la limpieza podrían ejecutarse indistintamente en cualquiera de las tres, la etapa de análisis requiere el entorno de cuadernos por sus dependencias gráficas y

Figura 5.6: Ejecucion de Jupyter en SageMaker



Fuente: Propia

geoespaciales. Esta división refleja la lógica del propio catálogo de servicios, en el que cada uno está optimizado para un perfil de carga concreto.

5.2.6. Consulta de costes en AWS

Los costes pueden consultarse desde la consola web de cada plataforma, pero para mantener la reproducibilidad, el siguiente comando de AWS Cost Explorer obtiene el coste no amortizado (*UnblendedCost*) desglosado por servicio para el periodo dado, y teniendo en cuenta los créditos de bienvenida (bloque 5.14).

```
aws ce get-cost-and-usage \
--time-period Start=2026-08-01,End=2026-09-01 \
--granularity MONTHLY \
--metrics "UnblendedCost" \
--filter '{"Not":{"Dimensions":{"Key":"RECORD_TYPE","Values":["Credit","Refund"]}}}' \
--group-by Type=DIMENSION,Key=SERVICE
```

Bloque de código 5.14: Consulta de costes históricos en AWS CLI

Este comando requiere que el usuario o rol tenga permisos para la acción `ce:GetCostAndUsage`. El resultado se devuelve en formato JSON y puede procesarse con herramientas como `jq` para extraer solo los valores relevantes.


5.3. Manual de usuario en GCP

5.3.1. Despliegue

Para desplegar la infraestructura en la nube de Google, lo primero que tenemos que hacer, al igual que en AWS, es registrarnos en la plataforma (Google Cloud Platform, 2026a). El proceso de creación es sencillo, en un solo paso está configurado y es gratuito, aunque también requiere introducir una tarjeta bancaria, y al momento de escribir la memoria, si la tarjeta es virtual, se puede requerir un prepago de 25 € que se devuelve al cerrar la cuenta, por lo que se recomienda el uso de una tarjeta física real.

Para no alargar este capítulo, simplemente redirigimos al usuario al propio tutorial de GCP, donde se explica en detalle las condiciones: (Google Cloud Platform, 2026c). GCP no tiene tutoriales obligatorios y disponemos de los 300 \$ (aproximadamente 263 €) disponibles desde el principio. Todos los comandos y procedimientos nombrados en este apartado también han sido realizados con la documentación técnica oficial de GCP (Google Cloud Platform, 2026b), y debido a la extensión de esta documentación y la facilidad para recorrer sus apartados y buscar comandos concretos, no se referencian las páginas de documentación individuales para cada comando. Se ha priorizado la utilización de los comandos de la CLI al igual que en AWS, y los comandos del manual se pueden escribir directamente en la **Google Cloud Shell**, o ejecutar su correspondiente acción en la consola web de GCP.

Figura 5.7: Abrir terminal GCP en consola



Fuente: Propia

5.3.2. Configuración del entorno y autenticación

A diferencia de AWS, GCP ya crea automáticamente una jerarquía de organización con varios proyectos al registrar la cuenta, pero crearemos un proyecto específico y aislado de la organización por defecto para este trabajo, para tener todo bajo un mismo entorno.

Todos los comandos se ejecutan en la *Google Cloud Shell*, que ya incluye la CLI de GCP configurada y con los permisos necesarios (bloque 5.15)² ³.

```
# Crear un proyecto y activarlo
gcloud projects create tfm-ucm-datos-publicos --name="TFM
UCM Datos Publicos"
gcloud config set project tfm-ucm-datos-publicos

# Le asignamos la cuenta de facturación
gcloud billing projects link tfm-ucm-datos-publicos \
--billing-account="$(gcloud billing accounts list --format
='value(ACCOUNT_ID)' | head -n1)"

# Definimos regiones
gcloud config set compute/region europe-west1
gcloud config set compute/zone europe-west1-b

# Comprobar la configuración
gcloud config list
```

Bloque de código 5.15: Creación del proyecto en GCP

Además, para un seguimiento detallado de los costes, es necesario habilitar desde la consola web la exportación de costes detallados (*Detailed usage cost*) a BigQuery. Esta configuración no puede realizarse mediante comandos de `gcloud`, ya que no hay una instrucción específica para ello. Una vez activada, los datos de facturación se almacenan en una tabla de BigQuery desde la que se pueden consultar.

Una vez creado y vinculado el proyecto, definimos las variables de entorno que usaremos en el resto del manual de GCP (bloque 5.16), al igual que en AWS. Aquí hay que tener en cuenta que los contenedores tienen nombres globales, por lo que si el nombre propuesto ya está en uso, habrá que cambiarlo, por lo que no sirve copiar y pegar del manual en este caso.

²*Nota sobre la visibilidad del proyecto:* Debido a este aislamiento en el proyecto, la consola web solo lo muestra en el selector de proyectos, en la opción “Sin organización” (*No organization*), o buscando el nombre directamente en la barra de búsqueda global.

³*Nota sobre la cuota de facturación:* Si al vincular el proyecto aparece el error `Cloud billing quota exceeded`, puede deberse a que la cuenta ya tiene demasiados proyectos asociados. En ese caso, se puede liberar cuota eliminando proyectos no utilizados con `gcloud projects delete <ID_PROYECTO>`, como el que Google crea por defecto.

```

cat > ~/tfm-env-gcp.sh << 'EOF'
export BUCKET="tfm-ucm-datos-publicos"    # Debe ser
cambiado
export REGION="europe-west1"
export PROJECT=$(gcloud config get-value project)
export TFM_BASE="gs://$BUCKET"
EOF

source ~/tfm-env-gcp.sh
echo $TFM_BASE    # Para comprobar

```

Bloque de código 5.16: Creación del archivo de variables de entorno

5.3.3. Infraestructura de almacenamiento en Cloud Storage

Como tecnología de almacenamiento para el proyecto, creamos un *bucket en Cloud Storage*, que alojará las capas del mismo, con la misma estructura de directorios que local y AWS (bloque 5.17).

```

# Crear el bucket en la region de europe-west1
gcloud storage buckets create gs://$BUCKET --location=
$REGION

# Bloquear acceso publico, activar versionado y etiquetar
gcloud storage buckets update gs://$BUCKET --public-access
-prevention
gcloud storage buckets update gs://$BUCKET --versioning
gcloud storage buckets update gs://$BUCKET --update-labels
=proyecto=tfm

```

Bloque de código 5.17: Creación y configuración del contenedor de Cloud Storage

Con el contenedor listo, el siguiente paso es obtener el código fuente del repositorio. En GCP, la propia terminal de *Cloud Shell* viene preconfigurada con las credenciales del usuario, por lo que la librería `gcsfs` (implementación de `fsspec` para Google) se autentica automáticamente (bloque 5.18).

Podemos comprobar que la ingesta se ha realizado correctamente en la *figura 5.8*.


Una vez finalizada la carga de datos, el siguiente paso del *pipeline* es su limpieza y transformación. Para esta fase se valoró e intentó inicialmente el uso de alternativas como **Cloud Run** o **Cloud Functions**, que si bien es técnicamente viable desplegar los procesos en estas plataformas, habría sido necesario crear una configuración de **Dockerfile** a medida y gestionar explícitamente los roles de acceso. Además, presentaban dificultades con la ejecución de procesos por lotes y la autenticación de acceso a *Cloud Storage*.


```
# Clonar el repositorio y situarse en la ruta de trabajo
git clone https://github.com/crismo04/TFM-cloud-solutions-to-public-data.git
cd TFM-cloud-solutions-to-public-data/code/files
pip install -r requirements.txt gcsfs --quiet

# Ejecutar la ingesta en el CLI
python 01_descarga.py --destino "gs://$BUCKET/data/bronze/"
```

Bloque de código 5.18: Descarga del código e ingesta en Cloud Storage

Figura 5.8: Conjuntos de datos cargados en Cloud Storage



Fuente: Propia

Esta vía se descartó para priorizar la agilidad metodológica y, en su lugar, se optó por centralizar tanto el procesamiento ETL como el modelado en un único entorno unificado.

5.3.4. Procesamiento y análisis en Vertex AI Workbench

Para esta fase de transformación (*Silver*) y análisis, se optó por **Vertex AI Workbench**, un entorno de *JupyterLab* con instancia de VM dedicada, equivalente directo a los *Amazon SageMaker Spaces* empleados en la *Sección 5.2.5*. Vertex AI simplifica la gestión de credenciales, al heredar las del proyecto activo, y permite ejecutar los *scripts* originales sin modificaciones. El primer paso es crear la instancia de trabajo (bloque 5.19).


La instancia tarda unos minutos en aprovisionarse; una vez que el estado indica **ACTIVE**, se puede abrir JupyterLab desde la consola web de Vertex AI. Se muestra como hacerlo en la *figura 5.9*.

```
# Activamos la API
source ~/tfm-env-gcp.sh
gcloud services enable notebooks.googleapis.com workbench.
  googleapis.com

# Creamos la instancia
gcloud workbench instances create tfm-notebook \
--location="$REGION-b" \
--machine-type=e2-standard-4
```

Bloque de código 5.19: Creación de la instancia de Vertex AI Workbench

Figura 5.9: Instancia de Vertex AI Workbench



Fuente: Propia

Para simplificar la gestión de rutas y credenciales, y dado el reducido volumen de datos (272 MB en la capa bronce), se decidió descargar de nuevo la capa bronce al disco local de la instancia y ejecutar el *pipeline* completo, evitando así el uso de `gcsfs` durante el procesamiento (bloque 5.20).

Ahora, para ejecutar el análisis no es necesario mover ni cargar datos, ya que están en el mismo entorno que el resto del proceso; simplemente se ejecuta el script de análisis (bloque 5.21).

Alternativa interactiva: Al igual que en AWS, el repositorio incluye un cuaderno `analisis_isla_calor.ipynb` que puede abrirse directamente en JupyterLab para ejecutar el análisis de forma incremental y visualizar las figuras en el propio entorno.

Control de costes: al igual que con SageMaker, las instancias de Vertex AI Workbench facturan por tiempo de aprovisionamiento mientras permanecen encendidas. Conviene detenerlas manualmente al finalizar cada sesión (bloque 5.22).

```
# Clonar el repositorio
git clone https://github.com/crismo04/TFM-cloud-solutions-to-public-data.git
cd TFM-cloud-solutions-to-public-data/code/files
pip install -r requirements.txt gcsfs geopandas --quiet

# Descargar la capa bronze del bucket al disco local
mkdir -p data/bronze
gsutil -m cp -r gs://$BUCKET/data/bronze/* data/bronze/

# Ejecutar limpieza usando la ruta base
unset TFM_BASE
python3 02_limpieza.py
```

Bloque de código 5.20: Ejecución de limpieza en Vertex AI Workbench

```
# Ejecutar analisis sin variable TFM_BASE (usa rutas locales)
python3 03_analisis_isla_calor.py

# Subir los resultados al bucket
gsutil -m cp -r resultados gs://$BUCKET/
```


Bloque de código 5.21: Ejecución del análisis en Vertex AI Workbench

```
gcloud workbench instances stop tfm-notebook --location="$REGION -b"
```

Bloque de código 5.22: Detención de la instancia de Vertex AI

La nube de Google cuenta además con servicios de AutoML que permiten estudiar directamente modelos de clasificación y regresión, como se muestra en la *figura 5.10*. No se han utilizado en este proyecto por dejarlos para futuras ampliaciones, ya que requieren un volumen de datos mayor para poder entrenar los modelos y obtener resultados fiables.

Figura 5.10: Consola para crear un estudio de regresión y clasificación en Vertex AI AutoML



Fuente: Propia

5.3.5. Consulta de costes en GCP

En GCP, la consulta de costes se realiza a través de la pestaña de **Billing**, o a través de BigQuery, una vez activada la exportación de costes detallados. La ruta de la tabla de facturación sigue el patrón `<proyecto>.<dataset>.<tabla>`, donde el nombre exacto depende de la configuración de exportación. El siguiente comando ejecuta una consulta SQL que agrupa los costes por servicio (bloque 5.23):

La variable `$PROJECT` debe sustituirse por el ID del proyecto GCP, y la ruta de la tabla debe ajustarse a la configuración real de exportación de costes del proyecto. Si la exportación no está activada, este comando devolverá un error.

```
bq query --use_legacy_sql=false --format=json \  
"SELECT service.description, SUM(cost) as total_cost \  
FROM \'$PROJECT.facturacion_tfm.  
    gcp_billing_export_resource_v1_*\' \  
WHERE DATE(usage_start_time) BETWEEN \'2026-07-01\' AND  
    \'2026-09-05\' \  
GROUP BY service.description ORDER BY total_cost DESC"
```

Bloque de código 5.23: Consulta de costes históricos en BigQuery

5.4. Conclusiones del capítulo

Este capítulo ha intentado recoger el procedimiento completo para reproducir el trabajo en los tres entornos evaluados. El ejercicio de escribir el mismo proceso tres veces permite extraer algunas conclusiones sobre las plataformas:

La primera es lo mucho que facilita el proceso enfocarse en la portabilidad. Los tres entornos ejecutan los mismos ficheros del repositorio cambiando mínimamente la configuración. Lo que varía entre plataformas es solamente el trabajo que rodea al código: roles, empaquetado de dependencias, regiones y credenciales.

La segunda es que cada etapa del ciclo de vida del dato encaja en varios servicios distintos, aunque algunos dan más facilidades que otros. La ingesta se resuelve bien desde los propios terminales gestionados, e incluso la transformación, aunque esta se beneficia de un servicio desatendido que pueda programarse (como *AWS Glue*). El análisis, en cambio, se beneficia de un entorno interactivo por sus dependencias gráficas y geoespaciales (como *Vertex AI Workbench*). La comparación cuantitativa de esfuerzo, tiempo y coste entre los tres entornos se ha recogido en la *Sección 4.3*.

La tercera, insistir en el aviso que aparece en las dos nubes: tanto los espacios de *SageMaker* como las instancias de *Vertex AI Workbench* facturan por tiempo de aprovisionamiento. Detener la instancia al terminar cada sesión es la medida de control de costes más relevante de todo el manual.

Capítulo 6

Conclusiones y Trabajo Futuro

Este capítulo cierra el trabajo recogiendo las reflexiones finales, las limitaciones encontradas y las líneas abiertas que podrían enriquecerlo en el futuro. Las conclusiones sintetizan los logros alcanzados en relación con los tres objetivos planteados al inicio del proyecto. El apartado de trabajo futuro, por su parte, invita a continuar explorando caminos que apenas han quedado esbozados, debido a la extensión de las tecnologías involucradas.

6.1. Conclusiones

Revisando los objetivos iniciales del proyecto, se pueden dar por cumplidos los tres objetivos planteados, demostrando que la combinación de datos abiertos, computación en la nube e IA puede generar valor cuando se superan las barreras de calidad y continuidad de los datos publicados.

Primer objetivo: análisis del panorama tecnológico. Se ha realizado un análisis exhaustivo del panorama actual de la computación en la nube, la IA y el estado de los datos públicos, identificando las metodologías, técnicas y servicios más relevantes. El *Capítulo 2* ha permitido contextualizar el proyecto y justificar las decisiones tecnológicas adoptadas, desde la selección de los conjuntos de datos hasta la elección de las plataformas cloud y los algoritmos de aprendizaje automático. También se han dejado constancia de trabajos y tendencias actuales sobre estas tecnologías, que pueden servir de guía para otros investigadores que quieran abordar problemas similares.

Segundo objetivo: desarrollo de una metodología replicable. Se ha desarrollado una metodología que permite el uso de los datos desde su origen hasta la generación de valor, basada en los cinco principios definidos en la *Sección 3.2.1* y complementada con un manual de usuario que facilita la reproducibilidad y la inclusión de nuevos conjuntos de datos de manera relativamente sencilla. El *pipeline* implementado (ingesta, limpieza y análisis) se ha demostrado portable entre entornos local, AWS y GCP gracias a la metodología aplicada. La automatización no solo ha aportado eficiencia, sino que ha actuado como un instrumento de auditoría sobre la calidad de la información pública, evidenciando carencias no documentadas en los portales de datos abiertos.

Tercer objetivo: aplicación a casos de estudio reales. Se ha aplicado la metodología propuesta a los conjuntos de datos del Ayuntamiento de Madrid, evaluando diferentes configuraciones para identificar las soluciones más eficientes a la hora de generar valor público. El análisis de la isla de calor ha extendido el trabajo de (Meneses Vicente y García Ruíz, 2023) desde 2019 hasta 2025, incorporando mejoras metodológicas como el criterio de cobertura mínima y la validación con coeficiente de silueta. Los resultados confirman una relación inversa sostenida entre superficie arbórea y temperatura media por distrito, con una correlación media de $-0,37$ mantenida a lo largo de los siete años analizados.

La evaluación de los agrupamientos ha revelado que la aproximación basada en una única magnitud (NO_2) alcanzó la mejor silueta media (0,565), lo que indica que los grupos formados están bien separados y son coherentes internamente. En cambio, la que emplea las siete magnitudes meteorológicas obtuvo los peores valores (0,146), señalando una estructura prácticamente aleatoria. Las dos aproximaciones propias (temperatura + altitud y temperatura + superficie relativa) han mostrado que la altitud no es un factor determinante (silueta 0,458) y que la superficie relativa mejora ligeramente la separación (0,521 frente a 0,500 de la versión absoluta).

Pero lo más importante es que el análisis ha demostrado la posibilidad y relativa facilidad con la que estos modelos se pueden utilizar para tratar los datos públicos en diferentes plataformas y extraer conclusiones de los mismos. En cuanto a la comparativa entre entornos, ha demostrado la reproducibilidad del análisis, con resultados idénticos en local, AWS y GCP. El coste neto ha sido de 0 USD y 0 € gracias a los créditos gratuitos, manteniendo un holgado margen de más de 150 € en cada plataforma. Esto permitiría repetir el estudio varias veces y valida el enfoque de las capas gratuitas de las nubes públicas para proyectos de investigación de tamaño moderado.

6.2. Limitaciones conocidas del proyecto

Los resultados obtenidos deben interpretarse a la luz de varias limitaciones conocidas.

En primer lugar, la discontinuidad de datos impide una serie temporal completamente homogénea, lo que limita la generalización de las correlaciones. Los cambios de definición de variables, los huecos en las publicaciones y la degradación de la cobertura sensorial afectan especialmente a los años 2019 y 2022, que han debido tratarse con cautela.

En segundo lugar, el análisis de movilidad peatonal y bicicletas, aunque se descargó y limpió, no se completó por restricciones de alcance. Queda como una línea abierta que habría aportado una perspectiva complementaria sobre el comportamiento urbano.

En tercer lugar, el trabajo se ha limitado a comparar un número reducido de modelos de datos, dos proveedores cloud y un conjunto acotado de algoritmos de ML. Sería mucho más enriquecedor poder comparar todas las tecnologías y herramientas nombradas en el *Capítulo 2*, para tener un espectro de elección más amplio al decidir cómo trabajar con estas tres tecnologías.

6.3. Trabajo futuro

Aunque el trabajo ha cumplido sus objetivos, inevitablemente, debido a la extensión de los temas tratados, quedan abiertas numerosas líneas que habría sido interesante explorar y que podrían enriquecerlo en el futuro. A continuación se recogen las más relevantes que se han quedado fuera del proyecto, ya sea por alcance o por imposibilidad. Están organizadas, de nuevo, en los tres bloques que han guiado este proyecto.

- **En el ámbito de los datos:**

- *Incluir más datos.* El análisis finalmente se ha centrado en un número limitado de conjuntos de datos de una única fuente. Sería de gran valor extenderlo a otras fuentes, incluyendo datos de gran volumen (petabytes), para exprimir las capacidades en la nube y hacer viable la comparación con tecnologías como Spark.
- *Simular o imputar datos para años con baja cobertura.* En el proyecto de isla de calor, habría sido interesante probar técnicas de generación sintética para años con pocos datos y evaluar su impacto en la calidad de los agrupamientos. O, en su defecto, incluir datos de temperatura superficial y vegetación procedentes de satélites (como los utilizados en (Liu et al., 2025)) para complementar

la red de estaciones terrestres y analizar las diferencias diurnas y nocturnas en el comportamiento térmico de la ciudad.

- *Contactar con los responsables de los portales de datos.* Una vez analizados los datos, sería muy útil establecer un puente con los equipos que mantienen los portales de datos abiertos para ayudarles a mejorar los datos ofrecidos y la documentación, facilitando así la reutilización automatizada a otros investigadores.
- *Llevar a cabo estudios con población.* También sería interesante, con los datos rescatados y tratados, realizar un estudio con diferentes poblaciones sobre el nivel de conocimiento de los datos, tanto de los públicos como de las conclusiones extraídas del estudio.

■ **En el ámbito de la nube:**

- *Evaluar más proveedores, especialmente europeos.* Habría sido muy interesante probar OVHcloud (con sus *AI Notebooks*) o plataformas abiertas como OpenNebula, así como extender el análisis a otras nubes, algo que se acotó por tiempo.
- *Añadir el coste ecológico al análisis comparativo.* Hubiera sido un complemento excelente medir la huella de carbono de las diferentes plataformas y compararla con el coste económico, para tener una visión más sostenible de la nube.
- *Probar procesamiento distribuido y en tiempo real.* Utilizar servicios como AWS Glue (Spark) o Dataproc en GCP, así como herramientas de análisis en tiempo real, para comprobar la utilidad de los datos en tiempo real sería un gran punto a ampliar en el proyecto.
- *Completar el despliegue serverless.* En este trabajo se descartaron tanto Cloud Run como Cloud Functions; con configuración adicional es técnicamente viable, y merecería la pena intentarlo en una siguiente iteración.
- *Construir un dashboard interactivo para los resultados.* Para que otros investigadores o el público general pudieran explorar los datos y conclusiones de forma visual e intuitiva, sería muy útil desarrollar una interfaz con herramientas nativas en la nube como un *Apache Superset* gestionado o *Looker Studio*.

■ **En el ámbito del análisis y ML:**

- *Completar el análisis de movilidad peatonal y bicicletas.* Con los datos ya tratados del trabajo de (Santos, 2023), añadiendo además nuevos datos y horizonte temporal, nos habría gustado poder

aplicar modelos de series temporales (ARIMA, Prophet, LSTM) a estos datos de aforos y estudiar el proyecto.

- *Usar Grandes Modelos de Lenguaje (LLMs) de forma exploratoria.* Sería fascinante emplear LLMs para analizar automáticamente la documentación de los conjuntos y para generar descripciones interpretativas de los grupos obtenidos en el clustering, mejorando así la explicabilidad de los resultados.
- *Probar AutoML en las plataformas cloud.* Durante el desarrollo se evaluó la posibilidad de emplear *Vertex AI AutoML* (definido en el manual de usuario) y *SageMaker Autopilot* para la fase de modelado. Estos servicios resuelven tareas supervisadas, no agrupamiento, por lo que para utilizarlos sería necesario reformular el problema como una regresión (p. ej. predecir la temperatura de una estación a partir del resto de variables). Haría falta además trabajar con granularidad diaria en vez de anual para aumentar el tamaño de la muestra. El interés no estaría tanto en la calidad de la predicción como en la importancia de variables, calculadas automáticamente, lo que daría una respuesta cuantitativa a qué factores importan y en qué proporción, algo que el agrupamiento no permite establecer.
- *Enumero también las mejoras estadísticas en el análisis que quedaron fuera del alcance.*
 - *Regresión multivariable.* Estimar el efecto de cada variable manteniendo las demás constantes, en lugar de correlaciones por pares.
 - *Modelos de panel con efectos fijos.* Aprovechar la estructura de panel de los siete años para controlar las variables de confusión y acercarse a una interpretación causal.
 - *Intervalos de confianza.* Acompañar los coeficientes de una medida de incertidumbre, mediante técnicas como la transformación z de Fisher o el remuestreo por *bootstrap*. Esto permitiría ir más allá de estimaciones puntuales y valorar la solidez estadística de las correlaciones observadas.
 - *Análisis geoespacial formal.* Contrastar la autocorrelación espacial entre distritos colindantes.
 - *Modelizar la discontinuidad como variable.* Incorporar la cobertura al modelo en lugar de usarla solo como criterio de exclusión.

6.4. Valoración final

El proyecto ha contribuido a demostrar que la combinación de computación en la nube, aprendizaje automático y datos públicos puede generar valor público tangible, siempre que se superen las barreras de calidad y continuidad de los datos publicados. La metodología desarrollada es extensible a otros conjuntos de datos y plataformas de manera relativamente sencilla, y sienta las bases para futuras líneas de trabajo.

El trabajo con datos reales, aún con sus imperfecciones, ha puesto de manifiesto la importancia de la calidad del dato como requisito previo para cualquier proceso automatizado de análisis. La automatización no es un lujo técnico, sino una necesidad para auditar la calidad de lo que se publica y para devolver a la ciudadanía un valor que muchas veces queda oculto (o en manos de unos pocos), por la falta de herramientas y conocimientos para procesar los datos abiertos.

A toque personal, el proyecto ha sido un reto apasionante que me ha permitido profundizar en el estado del arte de tres tecnologías apasionantes, y aplicar estos conocimientos a problemas reales de interés público. La experiencia adquirida y las lecciones aprendidas serán de gran valor para futuros proyectos.

Chapter 6

Conclusions and Future Work

This chapter closes the work by gathering the final reflections, the limitations encountered, and the open lines that could enrich it in the future. The conclusions synthesize the achievements attained in relation to the three objectives established at the beginning of the project. The future work section, for its part, invites us to continue exploring paths that have barely been outlined, due to the breadth of the technologies involved.

6.1. Conclusions

Reviewing the initial objectives of the project, the three proposed objectives can be considered fulfilled, demonstrating that the combination of open data, cloud computing, and AI can generate value when the barriers of quality and continuity of published data are overcome.

First objective: analysis of the technological landscape. An exhaustive analysis of the current landscape of cloud computing, AI, and the state of public data has been carried out, identifying the most relevant methodologies, techniques, and services. The *Chapter 2* has allowed contextualizing the project and justifying the technological decisions adopted, from the selection of datasets to the choice of cloud platforms and ML algorithms. Current works and trends on these technologies have also been documented, which can serve as a guide for other researchers wishing to address similar problems.

Second objective: development of a replicable methodology. A methodology has been developed that allows the use of data from its origin

to the generation of value, based on the five principles defined in *Section 3.2.1* and complemented by a user manual that facilitates reproducibility and the inclusion of new datasets in a relatively simple way. The implemented *pipeline* (ingestion, cleaning, and analysis) has proven to be portable across local, AWS, and GCP environments thanks to the applied methodology. Automation has not only provided efficiency but has also acted as an audit instrument on the quality of public information, evidencing undocumented shortcomings in open data portals.

Third objective: application to real case studies. The proposed methodology has been applied to the datasets of the Madrid City Council, evaluating different configurations to identify the most efficient solutions for generating public value. The heat island analysis has extended the work of (Meneses Vicente y García Ruíz, 2023) from 2019 to 2025, incorporating methodological improvements such as the minimum coverage criterion and validation with the silhouette coefficient. The results confirm a sustained inverse relationship between tree cover and average temperature per district, with a mean correlation of -0.37 maintained over the seven years analyzed.

The evaluation of the clustering has revealed that the approach based on a single magnitude (NO_2) achieved the best mean silhouette (0.565), indicating that the groups formed are well separated and internally coherent. In contrast, the one using the seven meteorological magnitudes obtained the worst values (0.146), pointing to a practically random structure. The two own approaches (temperature + altitude and temperature + relative tree cover) have shown that altitude is not a determining factor (silhouette 0.458) and that relative tree cover slightly improves separation (0.521 compared to 0.500 for the absolute version).

But most importantly, the analysis has demonstrated the possibility and relative ease with which these models can be used to process public data on different platforms and extract conclusions from them. Regarding the cross-environment comparison, it has demonstrated the reproducibility of the analysis, with identical results on local, AWS, and GCP. The net cost has been 0 USD and 0 € thanks to the free credits, maintaining a comfortable margin of more than 150 € on each platform. This would allow repeating the study several times and validates the approach of the free tiers of public clouds for moderate-sized research projects.

6.2. Known limitations of the project

The results obtained must be interpreted in light of several known limitations.

Firstly, the discontinuity of the data prevents a completely homogeneous time series, which limits the generalization of the correlations. The changes in variable definitions, gaps in publications, and the degradation of sensor coverage especially affect the years 2019 and 2022, which have had to be treated with caution.

Secondly, the analysis of pedestrian and bicycle mobility, although downloaded and cleaned, was not completed due to scope restrictions. It remains an open line that would have provided a complementary perspective on urban behavior.

Thirdly, the work has been limited to comparing a reduced number of data models, two cloud providers, and a limited set of ML algorithms. It would be much more enriching to be able to compare all the technologies and tools mentioned in the *Chapter 2*, to have a broader spectrum of choice when deciding how to work with these three technologies.

Future work

Although the work has fulfilled its objectives, inevitably, due to the breadth of the topics addressed, numerous lines remain open that would have been interesting to explore and that could enrich it in the future. Below are the most relevant ones that have been left out of the project, either due to scope or impossibility. They are organized, again, into the three blocks that have guided this project.

■ In the data domain:

- *Include more data.* The analysis has ultimately focused on a limited number of datasets from a single source. It would be of great value to extend it to other sources, including large-volume data (petabytes), to exploit cloud capabilities and make comparison with technologies like Spark viable.
- *Simulate or impute data for years with low coverage.* In the heat island project, it would have been interesting to test synthetic generation techniques for years with few data and evaluate their impact on the quality of clustering. Alternatively, include surface temperature and vegetation data from satellites (such as those used in (Liu et al., 2025)) to complement the terrestrial station network and analyze the diurnal and nocturnal differences in the city's thermal behavior.
- *Contact those responsible for data portals.* Once the data has been analyzed, it would be very useful to establish a bridge with

the teams that maintain the open data portals to help them improve the data offered and the documentation, thus facilitating automated reuse to other researchers.

- *Carry out studies with the population.* It would also be interesting, with the rescued and processed data, to carry out a study with different populations on the level of knowledge of the data, both public and the conclusions drawn from the study.

■ **In the cloud domain:**

- *Evaluate more providers, especially European ones.* It would have been very interesting to test OVHcloud (with its *AI Notebooks*) or open platforms like OpenNebula, as well as extend the analysis to other clouds, something that was limited by time.
- *Add the ecological cost to the comparative analysis.* Measuring the carbon footprint of the different platforms and comparing it with the economic cost would have been an excellent complement, to have a more sustainable vision of the cloud.
- *Test distributed and real-time processing.* Using services such as AWS Glue (Spark) or Dataproc in GCP, as well as real-time analysis tools, to check the usefulness of real-time data would be a great point to expand on in the project.
- *Complete the serverless deployment.* In this work, both Cloud Run and Cloud Functions were discarded; with additional configuration it is technically viable, and it would be worth trying in a next iteration.
- *Build an interactive dashboard for the results.* So that other researchers or the general public could explore the data and conclusions in a visual and intuitive way, it would be very useful to develop an interface with native cloud tools such as a managed *Apache Superset* or *Looker Studio*.

■ **In the analysis and ML domain:**

- *Complete the analysis of pedestrian and bicycle mobility.* With the data already processed from the work of (Santos, 2023), also adding new data and time horizon, we would have liked to apply time series models (ARIMA, Prophet, LSTM) to these flow data and study the project.
- *Use Large Language Models (LLMs) in an exploratory way.* It would be fascinating to use LLMs to automatically analyze the documentation of the datasets and to generate interpretative de-

scriptions of the groups obtained in the clustering, thus improving the explainability of the results.

- *Test AutoML on cloud platforms.* During development, the possibility of using *Vertex AI AutoML* (defined in the user manual) and *SageMaker Autopilot* for the modelling phase was evaluated. These services solve supervised tasks, not clustering, so using them would require reformulating the problem as a regression (e.g. predicting a station's temperature from the remaining variables). It would also be necessary to work with daily rather than annual granularity in order to increase the sample size. The interest would lie not so much in the quality of the prediction as in the automatically computed variable importance, which would give a quantitative answer as to which factors matter and in what proportion, something that clustering cannot establish.
- *Statistical improvements to the analysis that fell outside the scope:*
 - *Multivariate regression.* Estimating the effect of each variable while holding the others constant, instead of relying on pairwise correlations.
 - *Fixed-effects panel models.* Exploiting the panel structure of the seven years to control for confounding variables and move closer to a causal interpretation.
 - *Confidence intervals.* Reporting coefficients together with a measure of uncertainty, through techniques such as Fisher's z transformation or bootstrap resampling. This would go beyond point estimates and allow the statistical strength of the observed correlations to be assessed.
 - *Formal geospatial analysis.* Testing for spatial autocorrelation between neighbouring districts.
 - *Model discontinuity as a variable.* Including coverage in the model rather than using it only as an exclusion criterion.

6.3. Final reflections

The project has contributed to demonstrating that the combination of cloud computing, ML, and public data can generate tangible public value, provided that the barriers of quality and continuity of published data are overcome. The developed methodology is extensible to other datasets and platforms in a relatively simple way, and lays the foundations for future lines of work.

Working with real data, even with its imperfections, has highlighted the importance of data quality as a prerequisite for any automated analysis process. Automation is not a technical luxury, but a necessity to audit the quality of what is published and to return to citizens a value that often remains hidden (or in the hands of a few), due to the lack of tools and knowledge to process open data.

On a personal level, the project has been a fascinating challenge that has allowed me to delve into the state of the art of three exciting technologies, and to apply this knowledge to real problems of public interest. The experience gained and the lessons learned will be of great value for future projects.

Apéndice A

Apéndice A: Definiciones y acrónimos

“Saber dónde encontrar la información y cómo usarla. Ese es el secreto del éxito”

— Albert Einstein (Atribuida)

Dedicaremos este apéndice a la explicación de conceptos en más extensión, ya sea conceptos más generales o la explicación del significado de los acrónimos de esta memoria.

A.1. Definiciones

Separaremos este apartado, de la misma manera que se ha hecho en otras partes de la memoria, en los tres grandes elementos que conforman este trabajo: definiciones referentes a datos, a nubes y a Inteligencia Artificial. En cada uno de ellos enumeraremos las definiciones que se han ido incrustando en la memoria (ej. *Definición 1*).

La enumeración de las definiciones es independiente del apartado en el que se encuentra.

A.1.1. Referentes a datos

1. El Gobierno de España define los **Datos de alto valor** como “documentos cuya reutilización está asociada a considerables beneficios para la sociedad, el medio ambiente y la economía, en particular debido a

su idoneidad para la creación de servicios de valor añadido, aplicaciones y puestos de trabajo nuevos, dignos y de calidad, y al número de beneficiarios potenciales de los servicios de valor añadido y aplicaciones basados en tales conjuntos de datos”. Esta definición ofrece varias pistas sobre la manera en la que se prevé que se identifiquen esos conjuntos de datos de alto valor a través de una serie de indicadores que incluirían:

- Su potencial para generar beneficios sociales o medioambientales significativos.
 - Su potencial para generar beneficios económicos y nuevos ingresos.
 - Su potencial para generar servicios innovadores.
 - Su potencial en cuanto a número de usuarios beneficiados, con atención particular a las PYMEs.
 - Su capacidad para ser combinados con otros conjuntos de datos.
2. El **open government** o gobierno abierto es una forma de comunicación abierta, permanente y bidireccional entre la administración y los ciudadanos. Se basa en la transparencia por parte de la administración y la participación y colaboración con la sociedad civil y las empresas. Teniendo como punto clave el movimiento *open data* o datos abiertos, esta estructura y formatos abiertos permiten que los datos puedan reutilizarse proporcionando nuevos servicios a ciudadanos y empresas. En Europa sus orígenes se sitúan en la Directiva 2003/98/CE del Parlamento y del Consejo Europeos sobre el acceso y la reutilización de la información del sector público (Ferrer-Sapena et al., 2011).
3. El **Valor Público** se puede definir de muchas maneras y depende de la perspectiva de muchos autores:
- Para **Mark Moore**, su creador, consiste en conocer y satisfacer los deseos de la gente. Es un valor que lo público debe crear de forma análoga a como el sector privado crea valor económico (Moore, 1995).
 - **Bozeman** lo define desde una perspectiva ciudadana como el consenso sobre los derechos y obligaciones de los ciudadanos, así como los principios sobre los que debe basarse el gobierno (Bozeman, 2007). A menudo se refiere a “valores públicos”, en plural, para destacar su diversidad. Este tema sería llevado más en profundidad por **Talbot**, que sugiere que a veces estos son contradictorios entre sí, reflejando la combinación de las diversas y conflictivas preferencias del público (Talbot, 2011).

- **Benington** lo vincula directamente con la “esfera pública”, argumentando que el valor público no es solo lo que el público valora individualmente, sino también aquello que agrega valor a este espacio colectivo (Benington, 2009).
- Finalmente, **Timo Meynhardt** lo conceptualiza como un fenómeno relacional que surge de las percepciones. El valor público se crea en la relación entre el individuo y la sociedad. Depende de cómo las acciones de las organizaciones públicas impactan en la satisfacción de las necesidades básicas de las personas: morales, sociales, utilitarias y hedonistas (Meynhardt, 2009).

En un intento de resumirlo, el valor público surge de las evaluaciones y percepciones que los individuos y colectivos realizan sobre cómo las acciones, servicios o políticas de las organizaciones públicas (y otras entidades) impactan en la satisfacción de sus diversas necesidades básicas dentro de un marco relacional que involucra a la esfera pública. Es un valor creado para y por la sociedad.

4. Los **Datos Abiertos** se refieren a conjuntos de datos digitales que se publican bajo una filosofía de apertura. Garantizan y facilitan el libre acceso, uso, modificación, reutilización y redistribución por parte de cualquier persona o entidad, en cualquier momento, lugar y con cualquier finalidad. Una parte específica e importante para este trabajo son los Datos Abiertos de Gobierno: aquellos datos que se originan, producen, encargan o publican los gobiernos u organismos públicos en el ejercicio de sus funciones. Estos datos buscan, como fin último, fomentar la transparencia, la creación de valor público, la colaboración intersectorial y la resolución de problemas.

La materialización de esta filosofía de apertura se concreta en requisitos técnicos y jurídicos específicos, cuya interpretación puede variar ligeramente entre las entidades que los definen. Desde el Grupo de Trabajo sobre Datos Abiertos de la *Open Knowledge Foundation* (OKF), “el conocimiento está abierto si alguien tiene la libertad de acceder a él, usarlo, modificarlo y compartirlo, sujeto, como máximo, a medidas que preserven su procedencia y su apertura” (Open Knowledge Foundation, 2025). El Portal Europeo de Datos y el *Open Data Charter*, por su parte, enfatizan las condiciones de acceso y las libertades de uso, incluyendo la gratuidad y la ausencia de limitaciones. Detallan la necesidad de características técnicas y jurídicas para que los datos sean libremente reutilizables y redistribuibles (Portal Europeo de Datos, 2025; Open Data Charter, 2026). Todo esto subraya la complejidad y la multifuncionalidad de los Datos Abiertos como catalizador para la innovación y el desarrollo socioeconómico. Tienen implicaciones legales

y técnicas que deben ser gestionadas cuidadosamente para maximizar su potencial.

5. Las **Tres olas del “Open Data”** representan las diferentes etapas evolutivas por las que ha transitado el movimiento de apertura de datos. La **Primera Ola** (1990s-2000s) se fundamentó principalmente en Estados Unidos. Se dirigía a periodistas, abogados y activistas que solicitaban datos específicos bajo el modelo de “derecho a saber”, enfrentando riesgos de secretismo gubernamental y requiriendo auditores de información. La **Segunda Ola** (2000s-2010s) evolucionó hacia la apertura por defecto con alcance internacional. Expandió su audiencia a agencias gubernamentales, empresas tecnológicas y organizaciones comunitarias, pero generó desafíos de privacidad que impulsaron la creación de portales de datos abiertos y responsables. La **Tercera Ola** (2010s-presente) representa la madurez del movimiento con colaboración intersectorial y flujos transfronterizos. Se dirige a ONGs, instituciones académicas, pequeñas empresas y gobiernos, estableciendo marcos de responsabilidad en materia de datos. Esta evolución se visualiza en la tabla comparativa *tabla A.1*.
6. La **Teoría de la Ventana** (Matheus y Janssen, 2020) es un marco conceptual que analiza la transparencia generada por los Datos Abiertos de Gobierno. La concibe como una “ventana” que el gobierno abre para que el público vea su funcionamiento interno. Postula que la transparencia es una construcción diversa y continua, cuyo objetivo principal es facilitar la transferencia de información entre el gobierno y sus públicos. Su materialización está influenciada por factores que la facilitan o la impiden, clasificados en:
 - Características de los datos.
 - Características del sistema.
 - Características de la organización.
 - Características del uso individual.

Esto genera consecuencias (intencionadas o no) como la rendición de cuentas, la participación cívica, el aumento de la eficiencia o la afectación a la privacidad.

7. Un **“Datathon”** (Anslow et al., 2016) es un evento colaborativo o competitivo intensivo centrado en datos, derivado de los términos “data” y “maratón”. Equipos de expertos y otros individuos se reúnen para analizar grandes volúmenes de datos con el fin de encontrar soluciones innovadoras a problemas específicos. Esto va desde desarrollar aplicaciones para sacar partido a estos datos, hasta la optimización de

Tabla A.1: Resumen de las principales características de las denominadas olas de datos abiertos.

	Primera ola	Segunda ola	Tercera ola emergente
Concepto	Libertad de información	Datos públicos abiertos	Reutilización de datos públicos y privados
Propuesta de valor	Transparencia	Transparencia y resolución de problemas	• Elaboración de políticas basadas en pruebas • Innovación e iniciativa empresarial
Método	Datos a petición (derecho a saber)	Abierto por defecto (derecho a compartir)	Publicar con propósito
Enfoque	Enfoque de impulso	Enfoque de atracción	Asociaciones (colaboraciones con datos)
Énfasis geográfico	Nacional	Internacional y nacional	• Subnacional y local • Flujo transfronterizo de datos con fines específicos
Audiencia / Demanda	• Periodistas • Abogados y activistas • Tecnólogos cívicos y “data geeks”	• Agencias gubernamentales • Empresas, startups tecnológicas • Organizaciones comunitarias	• ONG, derechos humanos y justicia social • Instituciones académicas • Pequeñas empresas y startups • Gobierno
Riesgos y políticas	Secretismos y ofuscación	Privacidad – Efecto mosaico, información demográfica identificable (DII)	Marco de responsabilidad y derechos en materia de datos
Respuestas institucionales	Audidores de información	• Responsable de datos • Portales de datos abiertos	• Director de datos • Intermediarios

Fuente: Traducción propia de Verhulst et al. (2020).

procesos o la creación de modelos predictivos. Las posibilidades son amplias.

8. **“Data Governance”** (Gobierno del Dato) se define como un marco integral de políticas, estrategias, estándares, roles y procesos que rigen toda la gestión del ciclo de vida completo de los datos (desde su creación y recopilación hasta su almacenamiento, procesamiento, uso, compartición, archivado y, finalmente, eliminación). Su objetivo es garantizar su calidad, integridad, seguridad, accesibilidad, interoperabilidad y confiabilidad (Herrera Capriz, 2024) (pág. 241). La OECD propone que un modelo de *data governance* exitoso integra tres capas: una capa estratégica (liderazgo y visión); una capa táctica (capacidades de implementación y normativa: comités, formación, directrices, etc.); y una capa de entrega u operativa (de infraestructura y arquitectura: estándares, catálogos de datos, ciclo de valor, etc.) (OECD, 2019).

También vale la pena mencionar que hay más metodologías que hablan de las buenas prácticas del gobierno del dato, como es el caso de DAMA (de Datos Abiertos del Gobierno de España, 2021). Propone un marco de referencia (DAMA-DMBOK) donde el gobierno de datos coordina e integra otras diez áreas de conocimiento: la arquitectura de datos, modelado y diseño de datos, seguridad de datos, calidad de datos, gestión de metadatos y almacenamiento de datos y operaciones.

Figura A.1: Capas de gobierno del dato



Fuente: (OECD, 2019) traducida.

A.1.2. Referentes a Cloud

9. La “**Computación distribuida**” / “**Nube distribuida**” es un paradigma que aprovecha la capacidad de cálculo de miles o millones de dispositivos conectados a internet. Crea una red de computación masiva, paralela y descentralizada. Los usuarios solo necesitan instalar un cliente de software que, cuando su dispositivo no está en uso, se encarga de descargar un pequeño fragmento de datos, procesarlo y devolver el resultado a un servidor central que coordina todas las tareas y ensambla los resultados finales. Este es un enfoque especialmente adecuado para problemas altamente paralelizables. Uno de los primeros productos en llevar la idea a cabo fue BOINC (Anderson, 2004) para ayudar al cómputo de proyectos científicos. Actualmente, nubes como AWS o GCP se han apropiado del término *nube distribuida*, teniendo centros de datos en diferentes localizaciones para distribuir su trabajo a localizaciones más cercanas o llevar la propia infraestructura y servicios de la nube fuera de sus *data centers* (Google Cloud, 2026a). Esta idea evolucionó hasta la llamada **computación voluntaria** (Nov et al., 2010), donde dispositivos personales de voluntarios se usaban para este fin (ahora BOINC, cuyo software aún está disponible, sería considerado computación voluntaria). También se puede considerar que este paradigma se usa de forma malintencionada con varios casos famosos de ataques DDoS distribuidos (radwere, 2026; Danysoft, 2026) que usan dispositivos infectados para conseguir su propósito.

También han surgido modelos con estas ideas, paradigmas como el **dew computing** (Ray, 2018) donde los dispositivos personales se usan como almacenamiento. También plataformas de *fog computing* (que añade dispositivos intermedios en el cálculo centralizado) o *edge computing* (que ejecuta directamente en dispositivos finales) como SONM (SONM, 2026) u otros proyectos (Uriarte y De Nicola, 2018) que surgieron con el auge de las *blockchains* y las usaban para poner en contacto usuarios que quisieran proporcionar potencia de cálculo con quienes querían usarla. En la actualidad, hay nubes que siguen activas como (Golem Network, 2026; Akash, 2026; Render Network, 2026) y que permiten comprar y vender potencia de cómputo.

En resumen, todo lo englobado en la computación distribuida que se ha comentado se puede ver en esta tabla:

10. La **clasificación de la Computación en Nube** típicamente se puede dividir según dos dimensiones principales (Huawei Technologies Co., Ltd., 2023):

Por modelo de operación:

Modelo	Descripción	Ejemplo destacado
Nube distribuida	Infraestructura descentralizada, extendiendo servicios hacia el <i>edge</i> o centros locales.	Gestión centralizada con despliegue en <i>edge</i> /localización (AWS CloudFront, Google Cloud CDN).
Computación voluntaria	Uso de recursos ociosos de dispositivos personales para cómputo distribuido voluntario.	BOINC, SETI@home, HTCondor, Techila Grid.
<i>Dew Computing</i>	Combina almacenamiento local y en la nube, sincronizando datos y permitiendo disponibilidad offline.	Dropbox.
<i>Fog Computing</i>	Procesamiento intermedio entre dispositivos y la nube, reduciendo latencia y uso de ancho de banda.	Aplicaciones IoT y casos de baja latencia / vehículos autónomos.
<i>Edge Computing</i>	Procesamiento en dispositivos finales, priorizando latencia y seguridad.	Procesamiento de vídeo en tiempo real, reconocimiento facial en dispositivos móviles.
<i>BotNets</i>	Redes de dispositivos comprometidos que realizan tareas maliciosas de forma distribuida, usando el mismo principio de cómputo compartido pero con fines ilícitos.	Ataques DDoS (Mydoom), spam masivo, minería de criptomonedas no autorizada.

Tabla A.2: Comparación de modelos relacionados con la computación distribuida.

- **Nube Pública:** infraestructura compartida y gestionada por proveedores externos (ej. AWS, Azure, Google Cloud), que ofrece acceso universal mediante pago por uso.
- **Nube Privada:** infraestructura exclusiva para una organización, gestionada interna o externamente, y que tiene mayor control y seguridad.
- **Nube Comunitaria:** compartida por varias organizaciones con intereses comunes (ej. instituciones académicas), presentando un equilibrio entre control y costes.
- **Nube Híbrida:** combina nubes públicas y privadas, permitiendo mover cargas de trabajo según necesidades de seguridad, coste o escalabilidad.
- **Nube Industrial:** especializada en sectores específicos (sanidad, automoción), con componentes optimizados para casos de uso particulares.

Por modelo de servicio:

- **IaaS (Infraestructura como Servicio):** proporciona recursos fundamentales (VM, almacenamiento, redes). Ej: Amazon EC2, Google Compute Engine.
- **PaaS (Plataforma como Servicio):** ofrece entornos de desarrollo y ejecución para aplicaciones. Ej: Google App Engine, Microsoft Azure App Services.
- **SaaS (Software como Servicio):** software completo gestionado por el proveedor y accesible vía web. Ej: Gmail, Salesforce, Office 365.

En la *figura A.2* se puede observar una tabla que simplifica todos estos modelos de cloud por servicio.

11. La “**Arquitectura en medalla**” es un patrón de diseño utilizado para gestionar el ciclo de vida de los datos en plataformas de datos. Organiza y transforma datos en capas sucesivas: Bronce, Plata y Oro. Cada capa representa un nivel creciente de calidad y utilidad de los datos. Permite estructurar los datos para facilitar su ingestión, limpieza, enriquecimiento, análisis y consumo empresarial (Microsoft, 2026c). Aunque se ha definido este nombre, quizás al lector le sea más familiar otra forma de procesar datos en capas (Bobrov, 2025). La idea no es nueva en la ingeniería de datos y muchas otras metodologías introducen conceptos similares:

- **Arquitectura clásica de Data Warehouse (Inmon):**

Figura A.2: Distintos tipos de cloud



Fuente:

(Albert Barron, 2015).

- Staging Area (Etapas de Carga) $\approx$ Capa Bronze
- CIF (Corporate Information Warehouse) $\approx$ Capa Silver
- Data Marts (Almacenamiento de Industria) $\approx$ Capa Gold

■ **Data Vault:**

- Staging Layer para procesamiento de flujos crudos $\approx$ Capa Bronze
- Raw Vault (donde se almacenan los datos originales) $\approx$ Capa Silver
- Business Vault o Data Marts (transforman datos en métricas) $\approx$ Capa Gold

■ **Data Mesh (Concepto de Propiedad de Datos Distribuida):**

- Raw Domain Data $\approx$ Capa Bronze
- Aggregated Domain Data $\approx$ Capa Silver
- Consumer-Oriented Products $\approx$ Capa Gold

■ **Patrón “Write-Audit-Publish”:**

- Write (recolección de datos) $\approx$ Capa Bronze
- Audit (limpieza y procesamiento de datos) $\approx$ Capa Silver

- Publish (preparación para el uso) $\approx$ Capa Gold

A.1.3. Referentes a Inteligencia Artificial

12. La “**Historia de la Inteligencia Artificial**” se remonta a hace casi un siglo. Las ideas de matemáticos como Alan Turing sentaron las bases de la computación y propusieron el primer test para evaluar Inteligencia Artificial (Cheok y Zhang, 2023). A partir de ese punto, no han parado de surgir avances en métodos matemáticos y algoritmos impulsando la búsqueda e implementación de modelos prácticos. Hitos como el desarrollo del perceptrón (Rosenblatt, 1958), un modelo esencial para las redes neuronales; las cadenas de Markov, usadas como modelos estadísticos (Hidden Markov Model, HMM); o el desarrollo del *backpropagation* que sentó las bases para que el entrenamiento de redes neuronales profundas fuera efectivo (Werbos, 1974).

Los avances, junto con el aumento de la computación siguiendo la ley de Moore, permitieron el surgimiento y aumento de las redes neuronales recurrentes (Hopfield, 1984). También su uso para aplicaciones de procesamiento del lenguaje natural (Bengio et al., 2003). Otro punto de inflexión lo puso Google con su artículo “Attention Is All You Need” (Vaswani et al., 2017), donde definía que lo único que se necesitaba para procesar secuencias de forma eficaz era un mecanismo de atención. Eliminó la necesidad de recurrencia y convoluciones, lo que permitió entrenar modelos más potentes sobre conjuntos de datos masivos, sentando las bases técnicas para los Grandes Modelos de Lenguaje (LLMs) como BERT o la serie GPT (Transformadores Pre-entrenados Generativos).

Tomando esta tecnología de los *transformers*, OpenAI lanzó diferentes versiones de su modelo GPT hasta culminar con una interfaz conversacional basada en su modelo GPT-3: ChatGPT. Esta interfaz se convirtió en una revolución, impulsando un interés público sin precedentes y consolidando a la IA como una herramienta indispensable. En los últimos años han seguido surgiendo modelos con tecnologías como la multimodalidad, donde los agentes combinan el procesamiento de texto escrito con otras fuentes como audio y visión en tiempo real. También el *Mixture of Experts (MoE)* (Jiang et al., 2024), donde el modelo utiliza una combinación de múltiples redes neuronales (expertos), activando selectivamente un subconjunto de ellas para procesar cada entrada. Esta explosión en la presencia de la IA en la vida cotidiana también ha impulsado, sobre todo en Europa, el desarrollo de marcos regulatorios para garantizar un uso responsable y transparente de estas tecnologías (Unión Europea, 2024a).

Matiz: Si bien tecnologías de visión por computador o generación de multimedia son pilares fundamentales de la IA moderna y cruciales para los LLMs multimodales, es necesario acotar el alcance de este trabajo. Por lo tanto, esta definición se centra en los avances relacionados con el procesamiento de datos estructurados y texto. Deja fuera un análisis detallado del tratamiento específico de vídeo, audio e imagen, a pesar de reconocer su enorme relevancia e impacto.

Para facilitar la visualización de esta definición, resumiremos los hitos que consideramos importantes en orden cronológico:

Tabla A.3: Línea de tiempo de la IA


1936	Turing machines - Marco teórico para computación
1950	Turing test - Primera medida práctica de inteligencia máquina
1958	Perceptrón - Modelo base de las redes neuronales
1964	ELIZA - Primer chatbot conversacional
1966	Hidden Markov Model - Modelo estadístico temprano
1967	K-means - Algoritmo popular de clustering
1974	Backpropagation - Algoritmo fundamental para ANN multicapa
1982	RNN - Redes neuronales recurrentes
1997	LSTM - RNN con memoria a largo plazo
	Deep Blue vence a Kasparov
2003	NPLM - Aprendizaje de <i>embeddings</i> de palabras, base de LLM
2014	GAN - Generación de datos nuevos
2016	AlphaGo - Derrotó al campeón del mundo
2017	Transformers - Arquitectura basada en atención
2018	BERT, GPT-1 - Modelos de lenguaje grandes (LLM)
2020	GPT-3 - Aumento de las capacidades y parámetros
2021	DALL-E - Imágenes desde texto
2022	ChatGPT - Interfaz conversacional, aumenta el interés público
2023	GPT-4 - Modelo multimodal
	LLaMA - Modelo <i>open-source</i>
2024	GPT-4o - Modelo multimodal con voz y visión en tiempo real
	EU AI Act - Regulación integral sobre IA
2025	DeepSeek - LLM de bajo coste
	IA Agéntica y especializada - agentes autónomos, tareas específicas
2026	Fable y Astra - LLMs capaces de utilizar vulnerabilidades de día 0 y penetrar sistemas como <i>HuggingFace</i> .

Fuente: Adaptación y actualización de (Cheok y Zhang, 2023), complementada con información de (Sapkota et al., 2025), (bit2brain, 2020), (Campbell et al., 2002) y las referencias mencionadas en el texto.

Como frase final, y espero que esperanzadora, incluir que a pesar de

que esta tecnología ha pasado por algunas épocas de menor interés público, los datos de la web parecen mostrar que esta vez la tecnología viene para quedarse *figura A.3*. Ya que a pesar de que un último estudio del MIT anuncia que el 95 % de los proyectos con IA reciben retorno cero (Challapally et al., 2025), diversos analistas sostienen que esto no implica una burbuja vacía. Señalan que es más bien una fase inicial en la que muchos pilotos fracasarán por problemas de integración u organizativos y no por fallos tecnológicos. Al igual que ocurrió con la burbuja de las *dot.com*, de la cual emergieron gigantes como Amazon y Google, se espera que también en IA sobrevivan los proyectos con verdadero valor (AI Explained, 2025).

Figura A.3: Tendencias de búsqueda de IA



Fuente: (Google Trends, 2025), *destacar el pico de 2011 por el lanzamiento de Siri (Apple) y la tendencia desde 2022 por la salida de ChatGPT.*

13. Los tipos de **Técnicas de ML según aprendizaje** es la forma de clasificar estos modelos dependiendo de cómo los sistemas aprenden patrones, o del grado de supervisión que reciben. Se clasifican en cuatro tipos principales (Sarker, 2021):

- **Aprendizaje Supervisado:** utiliza datos etiquetados para aprender una función que mapea entradas a salidas. Está orientado a tareas concretas. Sus aplicaciones más comunes incluyen clasificación y regresión, como predecir la cantidad de ventas de un producto.
- **Aprendizaje No Supervisado:** analiza datos no etiquetados, buscando estructuras, patrones o relaciones ocultas. Es un enfoque

orientado al descubrimiento y exploración. Se aplica típicamente en clusterización, reducción de dimensionalidad o detección de anomalías.

- **Aprendizaje Semi-Supervisado:** combina datos etiquetados y no etiquetados. Aprovecha la abundancia de datos sin etiqueta para mejorar el rendimiento del modelo más allá de lo que se lograría solo con datos etiquetados. Es útil en contextos donde las etiquetas son costosas o escasas, como en detección de fraude o clasificación de texto.
 - **Aprendizaje por Refuerzo:** se basa en la interacción de un agente con un entorno. Aprende mediante recompensas o penalizaciones para optimizar su comportamiento. Se aplica en tareas de automatización compleja y optimización, como robótica o conducción autónoma.
14. **MLOps** u operaciones de ML, son un conjunto de prácticas y herramientas que busca automatizar y gestionar el ciclo de vida completo de un proyecto de *machine learning*. Abarca desde el desarrollo del modelo hasta su despliegue, monitorización y mantenimiento en producción. Se basa en principios de DevOps pero adaptados a las particularidades de los sistemas de ML (Kreuzberger et al., 2023). Los nueve principios son los siguientes:
- a) **Automatización CI/CD:** Integración, entrega y despliegue continuos que automatizan el desarrollo, prueba y puesta en producción de los modelos. Proporcionan información rápida sobre el éxito o fracaso de cada paso.
 - b) **Orquestación del flujo de trabajo (workflow):** Coordinación y gestión de las tareas de un *pipeline* o proceso de ML. Establece el orden de ejecución y dependencias, típicamente mediante DAGs.
 - c) **Reproducibilidad:** Capacidad fundamental de replicar el experimento de ML y obtener los mismos resultados.
 - d) **Control de versiones:** Implica la gestión y el seguimiento riguroso de los cambios en los datos, modelos y código. Es indispensable para la trazabilidad y el cumplimiento normativo.
 - e) **Colaboración:** Promueve el trabajo conjunto y una cultura comunicativa y abierta entre los diferentes roles del proyecto. Minimiza el aislamiento de datos e información.
 - f) **Entrenamiento y evaluación continuos:** Implica el reentrenamiento periódico y automático de los modelos con nuevos datos. Incluye una evaluación constante de su calidad para asegurar que

sigan siendo relevantes, precisos y óptimos en cuanto a rendimiento.

- g)* **Seguimiento y registro de metadatos:** Documentación detallada de la información relevante de cada ejecución del flujo. Asegura trazabilidad: parámetros utilizados, métricas, código, tiempo de ejecución y los datos utilizados.
- h)* **Monitorización continua:** Observación periódica de los datos, modelos, código, infraestructura y rendimiento del modelo desplegado. Detecta anomalías, errores o bajadas en la calidad.
- i)* **Bucles de retroalimentación:** Integrar los hallazgos y las lecciones aprendidas del monitoreo y la evaluación de calidad en el proceso de desarrollo.

15. **Modelos de ML** . Estas definiciones se basan en el curso de (Brownlee, 2026), el libro del mismo autor (Brownlee, 2024a) y en los libros (Fowdur, 2021) y (Sarker, 2021), así como en la asignatura “Desarrollo de aplicaciones y servicios inteligentes” impartida por la Universidad Complutense de Madrid. Aunque para estas definiciones **no** nos centraremos en cómo efectuar la selección de hiperparámetros (parámetros externos al modelo que lo configuran), señalar que el rendimiento y complejidad de estos modelos depende de la correcta elección de esta característica. También, por alcance, detallaremos solo los modelos que se han elegido para estudiar en este trabajo de entre la gran variedad de ellos que existe (Wikipedia, 2026). Estos son los siguientes:

- a)* **Árboles de Decisión (Decision Trees):** Son un método de aprendizaje **supervisado** no paramétrico utilizado para **clasificación y regresión**. Consiguen su objetivo dividiendo recursivamente el conjunto de datos de entrenamiento en subconjuntos más pequeños. Evalúan todas las posibles divisiones en cada característica de entrada para encontrar el punto de división óptimo que minimice la función de coste. El proceso continúa hasta alcanzar un criterio de detención, obteniendo los nodos terminales que contienen la predicción final (la clase más común o el promedio de valores).
- b)* **k-Nearest Neighbors (k-NN):** Es un algoritmo de aprendizaje **supervisado** de “aprendizaje perezoso” (no ejecuta hasta que no se le pida una predicción). Se utiliza para **clasificación y regresión**. Consigue su objetivo para nuevos datos calculando la distancia entre este y todos los ejemplos del conjunto de entrenamiento. Luego, selecciona los k ejemplos más parecidos (vecinos). Para clasificación, la predicción es la clase más común entre estos k vecinos. Para regresión, es el promedio de sus valores de salida.

- c) **K-means:** Es un algoritmo de aprendizaje **no supervisado** utilizado para la **clusterización**. Consigue su objetivo al identificar k centroides en el conjunto de datos. Luego asigna cada punto de datos al centroide más cercano durante varias iteraciones. Estos centroides se actualizan continuamente moviéndose al promedio de todos los puntos asignados a su clúster. Después de esto los puntos se reasignan, con el fin de minimizar la suma de las distancias cuadradas entre cada punto de datos y su centroide asignado.
- d) **Random Forests (Bosques Aleatorios):** Es un método de ensemble de aprendizaje supervisado utilizado para clasificación y regresión. Consigue su objetivo construyendo un “bosque” de múltiples árboles de decisión individuales. Cada árbol se entrena en una submuestra aleatoria del conjunto de datos con reemplazo (*bagging*). En cada punto de división se considera solo un subconjunto aleatorio de características. Las predicciones finales se obtienen combinando las predicciones de todos los árboles del bosque: por votación mayoritaria para clasificación o por promedio para regresión, lo que reduce la varianza y mejora la precisión.
- e) **XGBoost (Extreme Gradient Boosting):** Es una implementación optimizada y escalable de algoritmos de *gradient boosting*. Es un método de ensemble de aprendizaje **supervisado para clasificación y regresión**. Consigue su objetivo construyendo una serie de modelos individuales de forma secuencial (normalmente árboles de decisión). Cada nuevo modelo se entrena para corregir los errores residuales de los árboles previos. Para ello, minimiza una “función de pérdida” que cuantifica el error del modelo empleando aproximaciones de segundo orden. Esto significa que computa tanto la pendiente de la función de pérdida (como en el descenso de gradiente básico) como su curvatura para encontrar el mínimo. Esto resulta en una convergencia más rápida y una mayor exactitud. Además, aplica técnicas de regularización avanzadas (L1 y L2) para prevenir el sobreajuste y mejorar la generalización. La regularización L1 (Lasso) penaliza la suma de los valores absolutos de los coeficientes, pudiendo llevar algunos a cero y realizando selección de características. La regularización L2 (Ridge) penaliza la suma de los cuadrados de los coeficientes, reduciéndolos sin eliminarlos.
- f) **DBSCAN:** Es un algoritmo de aprendizaje **no supervisado para clusterización** basado en “densidad”. Consigue su objetivo identificando regiones densas de puntos de datos separadas por regiones de menor densidad. Clasifica los puntos como centrales,

frontera o de ruido. Forma cada clúster a partir de puntos que están densamente conectados. No requiere que se especifique el número de clústeres de antemano. Es capaz de descubrir clústeres de formas arbitrarias, además de identificar valores extremos.

- g)* **Redes Neuronales Profundas (Deep Neural Networks - DNN):** Brevemente, son modelos de aprendizaje **supervisado** que incluyen arquitecturas como los perceptrones multicapa (MLP). Consiguen su objetivo aprendiendo representaciones jerárquicas de los datos a través de múltiples capas ocultas de procesamiento. El proceso de entrenamiento implica la propagación hacia adelante de la entrada para calcular una salida. Luego, la retropropagación (*backpropagation*) del error ajusta iterativamente los pesos de las conexiones, minimizando la diferencia entre la salida predicha y la esperada. Son aptas para **clasificación y regresión en datos complejos**.
- h)* **Grandes Modelos de Lenguaje (Large Language Models - LLM):** Son un tipo avanzado de Redes Neuronales Profundas, frecuentemente basadas en la arquitectura de *transformers*. Consiguen su objetivo mediante un pre-entrenamiento masivo en vastos corpus de texto y código. Esto permite aprender patrones complejos de lenguaje, gramática, semántica y contextualización. Su mecanismo de atención les permite ponderar la importancia de diferentes partes de la entrada. Facilita una comprensión profunda y la generación de texto coherente y relevante. Se utilizan para una amplia gama de tareas de procesamiento de lenguaje natural (PLN).

A.2. Acrónimos

AI Inteligencia Artificial (Artificial Intelligence)

AI Act Ley de Inteligencia Artificial (Artificial Intelligence Act)

ANN Redes Neuronales Artificiales (Artificial Neural Network)

API Interfaz de Programación de Aplicaciones (Application Programming Interface)

ARIMA Modelo Autorregresivo Integrado de Medias Móviles (Autoregressive Integrated Moving Average)

AWS Amazon Web Services

BDTI Big Data Test Infrastructure

BERT Representaciones de Codificador Bidireccional de Transformadores
(Bidirectional Encoder Representations from Transformers)

BOINC Berkeley Open Infrastructure for Network Computing

BTOS Encuesta sobre Tendencias y Panorama Empresarial (Business Trends and Outlook Survey)

CCPA Ley de Privacidad del Consumidor de California (California Consumer Privacy Act)

CDN Red de Distribución de Contenidos (Content Delivery Network)

CI/CD Integración Continua/Entrega Continua (Continuous Integration/Continuous Delivery)

CIF Corporate Information Warehouse

CKAN Comprehensive Knowledge Archive Network

CLI Interfaz de Línea de Comandos (Command Line Interface)

CNN Red Neuronal Convolucional (Convolutional Neural Network)

CNMC Comisión Nacional de los Mercados y la Competencia

CPU Unidad Central de Procesamiento (Central Processing Unit)

CSV Valores Separados por Comas (Comma-Separated Values)

D1 D1 Database (Base de datos de Cloudflare)

DAGs Grafos Acíclicos Dirigidos (Directed Acyclic Graphs)

DAMA Asociación de Gestión de Datos (Data Management Association)

DBSCAN Clustering Espacial Basado en Densidad de Aplicaciones con Ruido (Density-Based Spatial Clustering of Applications with Noise)

DDoS Ataque de Denegación de Servicio Distribuido (Distributed Denial of Service)

DevOps Development and Operations

DNN Redes Neuronales Profundas (Deep Neural Networks)

DNS Sistema de Nombres de Dominio (Domain Name System)

DPU Unidad de Procesamiento de Datos (Data Processing Unit)

DSL Ley de Seguridad de Datos (Data Security Law) - China

EC2 Elastic Compute Cloud (Amazon EC2)

EEUU Estados Unidos

-
- EFS** Sistema de Archivos Elástico (Elastic File System)
- ETL** Extract, Transform, Load (Extraer, Transformar, Cargar)
- EU** European Union (Unión Europea)
- GAN** Red Generativa Antagónica (Generative Adversarial Network)
- GCP** Google Cloud Platform
- GPT** Transformador Pre-entrenado Generativo (Generative Pre-trained Transformer)
- GPU** Unidad de Procesamiento Gráfico (Graphics Processing Unit)
- HIPAA** Ley de Portabilidad y Responsabilidad de Seguros de Salud (Health Insurance Portability and Accountability Act)
- HITL** Human in the loop (humano en el proceso de IA)
- HMM** Modelo Oculto de Markov (Hidden Markov Model)
- HTML** Lenguaje de Marcado de Hipertexto (HyperText Markup Language)
- HTTP** Hypertext Transfer Protocol
- IA** Inteligencia Artificial (Artificial Intelligence)
- IaC** Infraestructura como Código (Infrastructure as Code)
- IaaS** Infraestructura como Servicio (Infrastructure as a Service)
- IAM** Gestión de Identidades y Accesos (Identity and Access Management)
- IBM** International Business Machines (empresa)
- IDE** Entorno de Desarrollo Integrado (Integrated Development Environment)
- INE** Instituto Nacional de Estadística
- IoT** Internet de las Cosas (Internet of Things)
- IP** Internet Protocol
- IPv4** Internet Protocol version 4
- JSON** Notación de Objetos de JavaScript (JavaScript Object Notation)
- k-NN** k-Nearest Neighbors (k-Vecinos Más Cercanos). Algoritmo de aprendizaje automático.
- KV** Key-Value (Almacenamiento Clave-Valor)
- LGD** Ley de Gobernanza de Datos

LLM	Modelo de Lenguaje a Gran Escala (Large Language Model)
LSTM	Memoria a Largo-Corto Plazo (Long Short-Term Memory)
MFA	Autenticación de Múltiples Factores (Multi-Factor Authentication)
MIT	Massachusetts Institute of Technology (Instituto de Tecnología de Massachusetts)
ML	Aprendizaje Automático (Machine Learning)
MLOps	Operaciones de Aprendizaje Automático (Machine Learning Operations)
MLP	Perceptrón Multicapa (Multi-layer Perceptron)
MoE	Mezcla de Expertos (Mixture of Experts)
NAS	Búsqueda de Arquitecturas Neuronales (Neural Architecture Search)
NLP	Procesamiento del Lenguaje Natural (Natural Language Processing)
NoSQL	Not only SQL
NPLM	Modelo de Lenguaje Neuronal Probabilístico (Neural Probabilistic Language Model)
OECD	Organización para la Cooperación y el Desarrollo Económicos (Organisation for Economic Co-operation and Development)
OGDA	Ley de Datos Abiertos del Gobierno (OPEN Government Data Act)
OKF	Open Knowledge Foundation
ONG	Organización No Gubernamental
ONTSI	Observatorio Nacional de Tecnología y Sociedad
PaaS	Plataforma como Servicio (Platform as a Service)
PIPL	Ley de Protección de Información Personal (Personal Information Protection Law) - China
PLN	Procesamiento del Lenguaje Natural (Natural Language Processing)
PYMEs	Pequeñas y Medianas Empresas
R2	R2 Storage (Almacenamiento de Cloudflare)
RAM	Memoria de Acceso Aleatorio (Random Access Memory)
RBAC	Control de Acceso Basado en Roles (Role-Based Access Control)
RDS	Servicio de Bases de Datos Relacionales (Relational Database Service)
RGPD	Reglamento General de Protección de Datos

RIA	Reglamento de Inteligencia Artificial
RL	Aprendizaje por Refuerzo (Reinforcement Learning)
RNN	Redes Neuronales Recurrentes (Recurrent Neural Network)
S3	Simple Storage Service (Amazon S3)
SaaS	Software como Servicio (Software as a Service)
SASE	Acceso Seguro al Borde del Servicio (Secure Access Service Edge)
SES	Simple Email Service (Amazon SES)
SIMPL	Smart Middleware Platform for Cloud-to-Edge (EU)
SNS	Simple Notification Service (Amazon SNS)
SQS	Simple Queue Service (Amazon SQS)
SQL	Lenguaje de Consulta Estructurado (Structured Query Language)
SSL	Capa de Conexión Segura (Secure Sockets Layer)
SSD	Disco de Estado Sólido (Solid State Drive)
TPU	Unidad de Procesamiento Tensorial (Tensor Processing Unit)
TURN	Traversal Using Relays around NAT (Network Address Translation)
UE	Unión Europea
VM	Máquina Virtual (Virtual Machine)
VPC	Nube Privada Virtual (Virtual Private Cloud)
XML	Lenguaje de Marcado Extensible (eXtensible Markup Language)
XLSX	Excel Open XML Spreadsheet

Apéndice B

Apéndice B: Uso ético de herramientas de IA

“La IA es como la Nutella para desayunar: si te pasas, te va a sentar mal.”

— Ryan Reynolds, *Keynote en WebexOne*, octubre de 2025

Este apéndice complementa la “Declaración responsable sobre autoría y uso ético de herramientas de IA” proporcionada por la UCM y que se adjunta con esta memoria. En cumplimiento de los principios de transparencia y ética académica, además del cumplimiento de las normativas europeas sobre el uso de IA en los textos de interés público (Unión Europea, 2024b), declaramos aquí el uso de herramientas y algoritmos basados en Inteligencia Artificial durante el desarrollo de este trabajo:

- **Accesibilidad y transcripción:** Debido a un problema médico personal del autor, diagnosticado durante el desarrollo del proyecto, la cual limitaba severamente la capacidad de escritura manual prolongada mediante teclado, se emplearon herramientas de reconocimiento de voz a texto (concretamente, el servicio de dictado nativo de Windows, atajo *Windows + H*) para la redacción de los borradores de esta memoria o texto completo que en todo momento fue supervisado.
- **Revisión y corrección de estilo:** Se utilizaron herramientas de asistencia a la redacción para corregir errores tipográficos y depurar la gramática del texto, así como la revisión del texto a través de LLMs para revisar huecos o frases incompletas que se hubieran pasado por alto, sin que estas herramientas alteraran en ningún momento la originalidad de las ideas o el contenido intelectual del autor.

- **Modelado analítico y tratamiento de datos:** Tal y como se detalla en el Capítulo 3.2.4, el núcleo analítico del trabajo se basa en la aplicación de algoritmos de ML. Se han utilizado herramientas de IA orientadas al análisis de datos (como *K-Means* o agrupamiento jerárquico) para extraer conclusiones, identificar patrones y generar los resultados de los casos de estudio.
- **Asistente de GCP:** *Google Cloud* cuenta con un asistente de IA integrado en la consola para el análisis de logs (*Cloud Assist*), el cual se utilizó para intentar solucionar las incidencias durante los despliegues iniciales en *Cloud Run* y *Cloud Functions*. Aunque aportó pistas sobre el comportamiento de los contenedores, no se terminó de encontrar una solución viable y el trabajo se orientó hacia el uso de *Vertex AI Workbench* para unificar de forma fluida el procesamiento y el análisis.
- **Modelos de lenguaje y motores de búsqueda avanzados:** Se emplearon modelos de lenguaje de grandes dimensiones (*LLMs*) integrados en buscadores y plataformas oficiales de documentación técnica, como una evolución avanzada de foros de consultas tipo *Stack Overflow*. Su uso en este ámbito se limitó a la resolución de incidencias puntuales, validación de parámetros de las CLI de AWS y GCP, y la solución puntual de errores durante las fases de despliegue.
- **Otros usos de modelos de lenguaje:** También se utilizaron para dar forma a la memoria sin alterar su contenido, como por ejemplo, ordenar la lista de acrónimos, o maquetar algunas de las referencias que no venían por defecto en formato bibtex.

Bibliografía

- AI EXPLAINED. An ai bubble? what altman actually said, the facts and nano banana. 2025.
- AKASH. The decentralized cloud built for ai's next frontier. 2026.
- ALBERT BARRON, T. P. C. M. Pizza as a service. 2015.
- AMAZON. Datos abiertos en aws. 2025.
- AMAZON WEB SERVICES. Amazon sagemaker. 2025.
- AMAZON WEB SERVICES. Aws well-architected framework. 2026a.
- AMAZON WEB SERVICES. Creación de cuenta en AWS Console. 2026b.
- AMAZON WEB SERVICES. Documentación general de AWS. 2026c.
- AMAZON WEB SERVICES. Tutorial de AWS: Creación y activación de una cuenta de AWS. 2026d.
- ANDERSON, D. Boinc: a system for public-resource computing and storage. 2004.
- ANSLOW, C., BROSZ, J., MAURER, F. y BOYES, M. Datathons: An experience report of data hackathons for data science education. página 615–620, 2016.
- APACHE SOFTWARE FOUNDATION. Apache arrow pyarrow documentation. 2026.
- ARELLANO BRUNO, J. B. Uso de geolocalización y de fuentes de datos abiertas para la creación de servicios turísticos por la ciudad de madrid. 2019.
- AWESOME DATA. Awesome public datasets. 2025.

- AYUNTAMIENTO DE MADRID. Portal de datos abiertos del ayuntamiento de madrid. 2025.
- AYUNTAMIENTO DE MADRID. Aforos de peatones y bicicletas: nota explicativa sobre la interrupción de datos. 2026a. Portal de Datos Abiertos del Ayuntamiento de Madrid.
- AYUNTAMIENTO DE MADRID. Portal de datos abiertos del ayuntamiento de madrid. 2026b.
- AYUNTAMIENTO DE MADRID. Sistema integral de la calidad del aire: interpretación de los datos de calidad del aire y meteorología. 2026c. Portal de Datos Abiertos del Ayuntamiento de Madrid, documentación asociada a los conjuntos de datos diarios.
- BARBUDO, R., VENTURA, S. y ROMERO, J. R. Eight years of automl: categorisation, review and trends. *Knowledge and Information Systems*, vol. 65(12), páginas 5097–5149, 2023.
- BENGIO, Y., DUCHARME, R., VINCENT, P. y JAUVIN, C. A neural probabilistic language model. *Journal of Machine Learning Research*, vol. 3(Feb), páginas 1137–1155, 2003.
- BENINGTON, J. Creating the public in order to create public value? *International Journal of Public Administration*, vol. 32(3-4), 2009.
- BIT2BRAIN. Historia de la IA Inteligencia Artificial. 2020.
- BOBROV, K. Data engineering: Now with 30 % more bull****. 2025.
- BÖER, J. Self-service ai for everyone? a comparison of automl services. 2023.
- BOMMALA, H. ET AL. Cloud verse: mapping the new frontiers of cloud computing. vol. 392, página 01081, 2024.
- BOZEMAN, B. *Public Values and Public Interest: Counterbalancing Economic Individualism*. Georgetown University Press, 2007. ISBN 9781589011779.
- BROWN, B., CHUI, M. y MANYIKA, J. Are you ready for the era of big data. *McKinsey Quarterly*, vol. 4(1), páginas 24–35, 2011.
- BROWNLEE, J. *Master Machine Learning Algorithms: Discover How They Work and Implement Them From Scratch*. Machine Learning Mastery, 2016.
- BROWNLEE, J. *Machine Learning Algorithms From Scratch*. Machine Learning Mastery, 2024a.

- BROWNLEE, J. A practical guide to choosing the right algorithm for your problem: From regression to neural networks. 2024b.
- BROWNLEE, J. Machine learning mastery. 2026.
- CAMPBELL, M., HOANE JR., A. J. y HSU, F.-H. Deep Blue. *Artificial Intelligence*, vol. 134(1-2), páginas 57–83, 2002.
- CANONICAL LTD. Microcloud: Your open source cloud platform. 2026. 2026-09-01.
- CARSANIGA, G., DOGGER, J. y REGECZI, D. The use case observatory a 3-year monitoring of 30 reuse cases to understand the economic, governmental, social and environmental impact of open data volume i. *Publications Office of the European Union*, 2022.
- CHALLAPALLY, A., PEASE, C., RASKAR, R. y CHARI, P. State of ai in business 2025: The genai divide. 2025. Preliminary findings from AI Implementation Research, Research Period: January–June 2025.
- CHEOK, A. y ZHANG, E. From turing to transformers: A comprehensive review and tutorial on the evolution and applications of generative transformer models. 2023.
- CLOUDING.IO. clouding.io, infraestructura cloud a tu servicio. 2026.
- COMISIÓN NACIONAL DE LOS MERCADOS Y LA COMPETENCIA. Informe económico sectorial de telecomunicaciones y audiovisual 2025. 2026.
- CONCEPCIÓN DE LINARES, J. B. Open food facts. 2025a.
- CONCEPCIÓN DE LINARES, J. B. Planttes. 2025b.
- CONGRESO DE LOS ESTADOS UNIDOS DE AMÉRICA. Health insurance portability and accountability act of 1996 (hipaa). 1996.
- CONGRESO DE LOS ESTADOS UNIDOS DE AMÉRICA. Foundations for evidence-based policymaking act of 2018, title ii: Open government data act. 2019.
- CORNELLA, A. Conferencia - cómo sobrevivir a la infoxicación. 2000.
- DANYSOFT. El ataque de los botnets. 2026.
- DE DATOS ABIERTOS DEL GOBIERNO DE ESPAÑA, P. El potencial uso de la metodología de dama en la gestión de los datos abiertos. 2021.
- ESRI ESPAÑA. Portal de datos abiertos de esri españa. 2025.
- ESTADO DE CALIFORNIA. California consumer privacy act (ccpa). 2018.

- EUROPEAN COMMISSION. Simpl: Cloud-to-edge federations empowering eu data spaces. 2024.
- EUROPEAN COMMISSION. Cloud computing. 2026a.
- EUROPEAN COMMISSION. From hype to action using the big data test infrastructure (bdti). 2026b.
- EUROPEAN PARLIAMENT, C. Regulation (eu) 2022/868 of the european parliament and of the council of 30 may 2022 on european data governance and amending regulation (eu) 2018/1724 (data governance act). Official Journal of the European Union, L 152, pp. 1-44, 2022. Accessed: 2026-09-01.
- EUROSTAT. 53 % of eu enterprises used paid cloud services in 2025. 2026.
- FANG, X., XU, W., TAN, F. A., ZHANG, J., HU, Z., QI, Y., NICKLEACH, S., SOCOLINSKY, D., SENGAMEDU, S. y FALOUTSOS, C. Large language models (llms) on tabular data: Prediction, generation, and understanding – a survey. *arXiv preprint arXiv:2402.17944*, 2024. Version 4, last revised 21 June 2024.
- FERRER-SAPENA, A., PESET, F. y ALEIXANDRE-BENAVENT, R. Acceso a los datos públicos y su reutilización: Open data y open government. *El Profesional de la Información*, páginas 260–269, 2011.
- FEURER, M., EGGENSBERGER, K., FALKNER, S., LINDAUER, M. y HUTTER, F. Auto-sklearn 2.0: Hands-free automl via meta-learning. *arXiv:2007.04074 [cs.LG]*, 2020.
- FOWDUR, T. P. *Real-Time Cloud Computing and Machine Learning Applications*. Computer Science, Technology and Applications. Nova Science Publishers, Incorporated, New York, 2021. ISBN 978-1536198133. Description based upon print version of record.
- FSSPEC DEVELOPERS. fsspec: Filesystem interfaces for python. 2026.
- GABRIEL, I., MANZINI, A., KEELING, G., HENDRICKS, L. A., RIESER, V., IQBAL, H., TOMAŠEV, N., KTEA, I., KENTON, Z., RODRIGUEZ, M., EL-SAYED, S., BROWN, S., AKBULUT, C., TRASK, A., HUGHES, E., BERGMAN, A. S., SHELBY, R., MARCHAL, N., GRIFFIN, C., MATEOS-GARCIA, J., WEIDINGER, L., STREET, W., LANGE, B., INGERMAN, A., LENTZ, A., ENGER, R., BARAKAT, A., KRAKOVNA, V., SIY, J. O., KURTH-NELSON, Z., MCCROSKERY, A., BOLINA, V., LAW, H., SHANAHAN, M., ALBERTS, L., BALLE, B., DE HAAS, S., IBITOYE, Y., DAFUE, A., GOLDBERG, B., KRIER, S., REESE, A., WITHERSPOON, S., HAWKINS, W., RAUH, M., WALLACE, D., FRANKLIN, M., GOLDSTEIN,

- J. A., LEHMAN, J., KLENK, M., VALLOR, S., BILES, C., MORRIS, M. R., KING, H., Y ARCAS, B. A., ISAAC, W. y MANYIKA, J. The ethics of advanced ai assistants. 2024.
- GEOPANDAS DEVELOPERS. Geopandas: Python tools for geographic data. 2026.
- GIGAS. Gigas - cloud hosting solutions. 2026.
- GMBH, N. Nextcloud - your own private cloud. 2026.
- GOBIERNO DE ESPAÑA. Big data test infrastructure: Un entorno gratuito para que las aa.pp experimenten con sus datos abiertos. 2021a.
- GOBIERNO DE ESPAÑA. Plan de digitalización de las administraciones públicas 2021-2025. 2021b.
- GOBIERNO DE ESPAÑA. Eventos datathon gobierno de españa. 2025a.
- GOBIERNO DE ESPAÑA. Eventos datos abiertos gobierno de españa. 2025b.
- GOBIERNO DE ESPAÑA. Portal de datos abiertos. 2025c.
- GOBIERNO DE ESPAÑA. Nubesara. 2026a.
- GOBIERNO DE ESPAÑA. Plan de precios de nubesara. 2026b.
- GOLEM NETWORK. Golem network. 2026.
- GÓMEZ-OBREGÓN, J. Jaime gómez-obregón. 2025a.
- GÓMEZ-OBREGÓN, J. La donación - jaime gómez-obregón. 2025b.
- GÓMEZ-OBREGÓN, J. Subvenciones - jaime gómez-obregón. 2025c.
- GOOGLE. Data commons. 2025a.
- GOOGLE. Google vertex ai platform. 2025b.
- GOOGLE. Welcome to colab! 2025c.
- GOOGLE CLOUD. Amplía la infraestructura y la ia de google cloud on-premise. 2026a.
- GOOGLE CLOUD. Google cloud architecture framework. 2026b.
- GOOGLE CLOUD PLATFORM. Creación de cuenta en Google Cloud Console. 2026a.
- GOOGLE CLOUD PLATFORM. Documentación general de GCP. 2026b.

- GOOGLE CLOUD PLATFORM. Tutorial de GCP: Creación y activación de una cuenta de GCP. 2026c.
- GOOGLE TRENDS. Google trends artificial intelligence. 2025. Se puede observar un pico en 2011, posiblemente por la salida de Siri, y la tendencia creciente desde 2022 debido a chatGPT. Las cifras representan el interés de búsqueda en relación con el punto más alto del gráfico para la región y el momento determinados. Un valor de 100 es el pico de popularidad del término. Un valor de 50 significa que el término es la mitad de popular. Una puntuación de 0 significa que no había datos suficientes para este término.
- HERRERA CAPRIZ, M. E. El valor intangible de la transparencia: un análisis de los datos abiertos de España en el marco de la corriente “valor público”. 2024. Tesis inédita de la Universidad Complutense de Madrid, Facultad de Ciencias de la Información, leída el 08/05/2024.
- HOPFIELD, J. J. Neurons with graded response have collective computational properties like those of two-state neurons. *Proc Natl Acad Sci U S A*, vol. 81(10), páginas 3088–3092, 1984.
- HUAWEI TECHNOLOGIES CO., LTD. *Cloud Computing Technology*. Springer and Posts & Telecom Press, Singapore and Beijing, 2023. ISBN 978-981-19-3026-3. Open access book.
- HUGGING FACE. Hugging face spaces. 2025.
- INSTITUTO NACIONAL DE ESTADÍSTICA. Encuesta sobre el uso de TIC y del comercio electrónico en las empresas. año 2024 - primer trimestre 2025. 2025.
- JIANG, A. Q., SABLAYROLLES, A., ROUX, A., MENSCH, A., SAVARY, B., BAMFORD, C., CHAPLOT, D. S., DE LAS CASAS, D., HANNA, E. B., BRESSAND, F., LENGUEL, G., BOUR, G., LAMPLE, G., LAVAUD, L. R., SAULNIER, L., LACHAUX, M.-A., STOCK, P., SUBRAMANIAN, S., YANG, S., ANTONIAK, S., LE SCAO, T., GERVET, T., LAVRIL, T., WANG, T., LACROIX, T. y EL SAYED, W. Mixtral of Experts. *arXiv preprint arXiv:2401.04088*, 2024.
- JIN, H., CHOLLET, F., SONG, Q. y HU, X. Autokeras: An automl library for deep learning. *Journal of Machine Learning Research*, vol. 24(6), páginas 1–6, 2023.
- JORGE, R. y HERRERA, R. Aumenta la negativa a abrir datos públicos: Informa Inai tendencia de 4t a opacidad. llama presidenta a ciudadanos a iniciar defensa de ente autónomo. 2023. Copyright - Copyright Editora El Sol, S.A. de C.V. Mar 24, 2023; Última actualización - 2023-03-24.

- KAGGLE. Kaggle code notebook. 2025a.
- KAGGLE. Kaggle datasets. 2025b.
- KHAN, S. y ALAM, M. File formats for big data storage systems. *International Journal of Engineering and Advanced Technology (IJEAT) Volume-9 Issue-1*, 2019.
- KREUZBERGER, D., KÜHL, N. y HIRSCHL, S. Machine learning operations (mlops): Overview, definition, and architecture. *IEEE Access*, vol. 11, páginas 31866–31879, 2023.
- KUMAR, R., ADWANI, L., KUMAWAT, S. y JANGIR, S. K. Opennebula: Open source IaaS cloud computing software platforms. 2014.
- LEONIDAS, T., ALEXANDRA, T. y YANNIS, S. A state-of-the-art review in big data management engineering: Real-life case studies, challenges, and future research directions. *Eng*, vol. 5(3), página 1266, 2024. Copyright - © 2024 by the authors. Licensee MDPI, Basel, Switzerland. This article is an open access article distributed under the terms and conditions of the Creative Commons Attribution (CC BY) license (<https://creativecommons.org/licenses/by/4.0/>). Notwithstanding the ProQuest Terms and Conditions, you may use this content in accordance with the terms of the License; Última actualización - 2024-09-27.
- LISDORF, A. *Cloud Computing Basics: A Non-Technical Introduction*. Apress, 2021. ISBN 978-1-4842-6921-3. Accessed: 2026-09-01.
- LIU, H., LI, M., ZHAN, Q., MA, Z. y HE, B.-J. Homogeneity and heterogeneity of diurnal and nocturnal hotspots and the implications for synergetic mitigation in heat-resilient urban planning. *Computers Environment and Urban Systems*, 2025.
- LLAMOCCA PORTELA, P. Integración y visualización de datos abiertos medioambientales. 2016. Máster en Ingeniería Informática, curso 2015-2016.
- LLM STATS. Llm leaderboard. 2026.
- MATHEUS, R. y JANSSEN, M. A systematic literature study to unravel transparency enabled by open government data: The window theory. *Public Performance & Management Review*, vol. 43(3), páginas 503–534, 2020.
- MELENDREZ MORETO, I. Auditoría y metodología de implantación de open data para smart cities. 2016. Máster en Ingeniería Informática, curso 2015-2016, a destacar: gran compilación de datasets, conceptos interesantes como cinco estrellas del Open Data, manual de CKAN.
- MENESES VICENTE, G. y GARCÍA RUÍZ, J. F. Madrid, isla de calor. 2023. Trabajo de Fin de Máster en Ingeniería Informática.

- MEYNHARDT, T. Public value inside: What is public value creation? *International Journal of Public Administration*, vol. 32(3-4), páginas 192–219, 2009.
- MICROSOFT. microsoft azure machine learning. 2025.
- MICROSOFT. Cloud computing terminology. 2026a.
- MICROSOFT. ¿qué es la tokenización? 2026b.
- MICROSOFT. What is the medallion lakehouse architecture? 2026c.
- MOORE, M. Creating public value: Strategic management in government. 1995.
- MOSQUEIRA-REY, E., HERNÁNDEZ-PEREIRA, E., ALONSO-RÍOS, D., BOBES-BASCARÁN, J. y FERNÁNDEZ-LEAL, Á. Human-in-the-loop machine learning: a state of the art. *Artificial Intelligence Review*, vol. 56(4), páginas 3005–3054, 2023. ISSN 1573-7462.
- NIGRO, H. Cloud computing: Retos y oportunidades. *Rev. Ingeniería, Matemáticas y Ciencias de la Información*, vol. 9(18), páginas 11–16, 2022.
- NIJSEN, D. The use case observatory a 3-year monitoring of 30 reuse cases to understand the economic, governmental, social and environmental impact of open data volume ii. *Publications Office of the European Union*, 2022.
- NOV, O., ANDERSON, D. y ARAZY, O. Volunteer computing: A model of the factors determining contribution to community-based scientific research. *Proceedings of the 19th International Conference on World Wide Web, WWW '10*, páginas 741–750, 2010.
- NUMPY DEVELOPERS. Numpy documentation. 2026.
- OBSERVATORIO NACIONAL DE TECNOLOGÍA Y SOCIEDAD. Indicadores de uso de inteligencia artificial en las empresas españolas. edición 2025 - datos 2024. 2025. NIPO: 230250053, DOI: 10.30923/230250053.
- OECD. *The Path to Becoming a Data-Driven Public Sector*. OECD Digital Government Studies. OECD Publishing, 2019.
- OECD. 2023 oecd open, useful and re-usable data “ourdata” index: Results and key findings. *OECD Public Governance Policy Papers, No. 43, OECD Publishing, Paris*, 2023.
- OPEN DATA CHARTER. ¿qué son los datos abiertos? 2026.
- OPEN KNOWLEDGE FOUNDATION. Open definition. 2025.

- OPEN KNOWLEDGE FOUNDATION. Ckan 2.9 api guide: Action api and `package_show`. 2026a. Documentación oficial de CKAN, versión 2.9.11.
- OPEN KNOWLEDGE FOUNDATION. Ckan: open-source data management system. 2026b. Plataforma sobre la que opera el Portal de Datos Abiertos de Madrid.
- OPENPYXL DEVELOPERS. `openpyxl` - a python library to read/write excel 2010 xlsx/xlsm files. 2026.
- OVHcloud. Ovhcloud ai training. 2025.
- OVHcloud. Public cloud free trial ovhcloud. 2026.
- PANGARKAR, T. Big data statistics 2025 by patterns in the dimensions. 2025.
- SÁNCHEZ DE PAZ, M. Optimización de infraestructuras de cloud computing basadas en máquinas virtuales. 2023. Trabajo de Fin de Máster en Ingeniería Informática, Curso 2022/2023.
- PORTAL EUROPEO DE DATOS. ¿qué son los datos abiertos? 2025.
- PREPARATIC. Servicio nubeara. casos prácticos y ejemplos de aplicación. 2026.
- PRESS, G. A very short history of big data. 2013.
- RADWERE. What is mydoom malware? 2026.
- RAMOS-SIMÓN, L. F. El uso de las licencias libres en los datos públicos abiertos. *Revista Española de Documentación Científica*, vol. 40(3), páginas 1–16, 2017. Copyright - Copyright Consejo Superior de Investigaciones Científicas Jul/Sep 2017; Última actualización - 2017-10-04.
- RAY, P. P. An introduction to dew computing: Definition, concept and implications. *IEEE Access*, vol. 6, páginas 723–737, 2018.
- REGISTRADORES DE ESPAÑA. Portal de datos abiertos de los registradores de españa. 2025.
- RENDER NETWORK. The distributed gpu render network. 2026.
- REQUESTS PROJECT. Requests: Http for humans. 2026.
- R.I.PIENAAR. Free for devs. 2025.
- ROSENBLATT, F. The perceptron: A probabilistic model for information storage and organization in the brain. *Psychological Review*, vol. 65(6), páginas 386–408, 1958.

- SALEHIN, I., ISLAM, M. S., SAHA, P., NOMAN, S., TUNI, A., HASAN, M. M. y BATEN, M. A. Automl: A systematic review on automated machine learning with neural architecture search. *Journal of Information and Intelligence*, vol. 2(1), páginas 52–81, 2024. ISSN 2949-7159.
- SANTOS, J. S. Análisis de datos de la ciudad de madrid. 2023. Trabajo de Fin de Grado en Ingeniería Informática.
- SAPKOTA, R., ROUMELIOTIS, K. I. y KARKEE, M. Ai agents vs. agentic ai: A conceptual taxonomy, applications and challenges. *Information Fusion*, vol. 126, 2025. ISSN 1566-2535.
- SARKER, I. H. Machine learning: Algorithms, real-world applications and research directions. *SN Computer Science*, vol. 2(3), página 160, 2021.
- SCIKIT-LEARN DEVELOPERS. scikit-learn: Machine learning in python. 2026.
- SONM. Sonm whitepaper. 2026.
- STANDING COMMITTEE OF THE NATIONAL PEOPLE’S CONGRESS. Data security law of the people’s republic of china. 2021a.
- STANDING COMMITTEE OF THE NATIONAL PEOPLE’S CONGRESS. Personal information protection law of the people’s republic of china. 2021b.
- SZE, V., CHEN, Y.-H., EMER, J., SULEIMAN, A. y ZHANG, Z. Hardware for machine learning: Challenges and opportunities. 2017.
- TALBOT, C. Paradoxes and prospects of public value. *Public Money & Management*, vol. 31(1), 2011.
- TALLIN UNIVERSITY (TLU). Data mining without coding. 2024.
- TAYLOR, P. Big data - statistics and facts. 2025.
- TELEFÓNICA. Telefónica tech cloud platform. 2026.
- THE MATPLOTLIB DEVELOPMENT TEAM. Matplotlib documentation. 2026.
- THE PANDAS DEVELOPMENT TEAM. pandas documentation. 2026.
- THE SCIPY COMMUNITY. Scipy: Hierarchical clustering. 2026.
- DE LA TORRE, S. y NÚÑEZ, S. Transparencia en la administración pública municipal del ecuador. *Estudios de la Gestión*, (14), páginas 53–73, 2023. Copyright - Copyright null 2023; Última actualización - 2024-12-12; SubjectsTermNotLitGenreText - Ecuador.
- UNIÓN EUROPEA. Data protection under gdpr. 2016.

- UNIÓN EUROPEA. Explicación de la ley de gobernanza de datos. 2023.
- UNIÓN EUROPEA. Reglamento de inteligencia artificial. 2024a.
- UNIÓN EUROPEA. Reglamento (ue) 2024/1689, artículo 50: obligaciones de transparencia para determinados sistemas de ia. 2024b.
- UNIÓN EUROPEA. European alternatives for popular services. 2025a.
- UNIÓN EUROPEA. Portal de datos abiertos. 2025b.
- UNIÓN EUROPEA. Reglamento ómnibus digital sobre ia. 2026.
- UNIVERSIDATA. Análisis de desplazamientos interurbanos en estudiantes. 2020.
- UNIVERSIDATA. Ii datathon universidata. 2024.
- UNIVERSIDATA. Universidata. 2025.
- UNIVERSITAT AUTÒNOMA DE BARCELONA. infoparticipa. 2025.
- URIARTE, R. B. y DE NICOLA, R. Blockchain-based decentralised cloud/fog solutions: Challenges, opportunities and standards. *IEEE Communications Standards Magazine*, 2018.
- VALERO TORRIJOS, J. y MARTÍNEZ GUTIÉRREZ, R. *DATOS ABIERTOS Y REUTILIZACIÓN DE LA INFORMACIÓN DEL SECTOR PÚBLICO*. CRC Press, 2022. ISBN 978-84-1369-269-2.
- VASWANI, A., SHAZEER, N., PARMAR, N., USZKOREIT, J., JONES, L., GOMEZ, A. N., KAISER, Ł. y POLOSUKHIN, I. Attention is all you need. páginas 5998–6008, 2017.
- VERHULST, S., YOUNG, A., ZAHURANEC, A., CALDERON, A., GEE, M. y AARONSON, S. The emergence of a third wave of open data: How to accelerate the re-use of data for public interest purposes while ensuring data rights and community flourishing. *International Journal of Public Administration*, página 8, 2020.
- VOGEL, A., GRIEBLER, D., MARON¹, C., SCHEPKE, C. y FERNANDES, L. Private iaas clouds: A comparative analysis of opennebula, cloudstack and openstack. páginas 672–679, 2016.
- WERBOS, P. Beyond regression: New tools for prediction and analysis in the behavioral science. thesis (ph. d.). appl. math. harvard university. 1974.
- WIKIPEDIA. Information age. 2025.
- WIKIPEDIA. List of machine learning methods. 2026.

