
Implementación de soluciones en la nube para el análisis de datos públicos a través de modelos de inteligencia artificial

-

Implementation of cloud solutions for public data analysis through artificial intelligence models



Trabajo de Fin de Master
Curso 2025–2026

Autor

Cristian Molina Muñoz

Director

Jose Luis Vazquez-Poletti

Rubén Fuentes-Fernández

Máster en Ingeniería Informática

Facultad de Informática

Universidad Complutense de Madrid

Implementación de soluciones en la nube para el análisis de datos públicos a través de modelos de inteligencia artificial

-

Implementation of cloud solutions for public data analysis through artificial intelligence models

Trabajo de Fin de máster en Ingeniería Informática

Autor

Cristian Molina Muñoz

Director

Jose Luis Vazquez-Poletti

Rubén Fuentes-Fernández

Convocatoria: *Septiembre 2026*

Calificación:

Máster en Ingeniería Informática

Facultad de Informática

Universidad Complutense de Madrid

28 de agosto de 2026

Autorización de difusión

El abajo firmante, matriculado en el Master en Ingeniería en Informática de la Facultad de Informática, autoriza a la Universidad Complutense de Madrid (UCM) a difundir y utilizar con fines académicos, no comerciales y mencionando expresamente a sus autores el presente Trabajo Fin de Master: “Implementación de soluciones en la nube para el análisis de datos públicos a través de modelos de inteligencia artificial“, realizado durante el curso académico 2025-2026 bajo la dirección de Jose Luis Vazquez-Poletti y Rubén Fuentes-Fernández, y a la Biblioteca de la UCM a depositarlo en el Archivo Institucional E-Prints Complutense con el objeto de incrementar la difusión, uso e impacto del trabajo en Internet y garantizar su preservación y acceso a largo plazo.

Cristian Molina Muñoz

28 de agosto de 2026

Dedicatoria

A mis padres, por hacer posible todo esto. Por su esfuerzo

Agradecimientos

Agradecer a todas las personas que han aportado su granito de arena a la persona que soy, y por extensión, a este mismo trabajo. Sobre todo a profesores y compañeros de estudio y trabajo, de los que tanto he aprendido.

Resumen

La computación en la nube, la Inteligencia artificial y el tratamiento de grandes volúmenes de datos se revelaron como tres tecnologías profundamente disruptivas en el panorama tecnológico de los últimos años. En este trabajo se estudió el estado de la cuestión de estas tecnologías en profundidad, analizando su utilidad intrínseca y explorando las distintas metodologías, técnicas y servicios existentes, aportando también una implementación práctica para examinar su capacidad de aportar un beneficio público tangible.

Se examinó la disponibilidad de conjuntos de datos públicos a nivel europeo como base para el proyecto, cumpliendo con los nuevos marcos legales que este impone. A partir de ello, se elaboró una metodología replicable que describió el recorrido de los datos desde su origen hasta la generación de valor público, haciendo uso de la computación en la nube y las capacidades avanzadas de los algoritmos de Aprendizaje automático, así como los entornos gestionados de aprendizaje automático que las grandes nubes públicas proporcionan. Esto permitió identificar las configuraciones más eficientes y óptimas para la construcción de estas soluciones, comparando con el resto de opciones disponibles. De igual manera, permitió desarrollar un enfoque general del estado actual de las tecnologías estudiadas.

Los ficheros de GitHub se encuentran en el siguiente repositorio: <https://github.com/crismo04/TFM-cloud-solutions-to-public-data/>

Palabras clave

Big Data, Computación en la nube, Inteligencia Artificial, Machine Learning, Open Data, Tratamiento de datos, Valor público

Abstract

Cloud computing, artificial intelligence, and big data processing emerged as profoundly disruptive technologies in the technological landscape of recent years. In this work, the state of the art of these technologies was studied in depth, analyzing their intrinsic utility and exploring the different methodologies, techniques, and services available, while also providing a practical implementation to examine their ability to deliver tangible public benefit.

The availability of public datasets at the European level was examined as the foundation of the project, in compliance with the new legal frameworks imposed in this area. Based on this, a replicable methodology was developed that described the journey of data from its origin to the generation of public value, making use of cloud computing and the advanced capabilities of machine learning algorithms, as well as the managed machine learning environments provided by the major public cloud providers. This made it possible to identify the most efficient and optimal configurations for building such solutions, in comparison with other available options. Likewise, it enabled the development of a general overview of the current state of the three technologies under study.

The project files can be found in the following repository: <https://github.com/crismo04/TFM-cloud-solutions-to-public-data/>

Keywords

Artificial Intelligence, Big Data, Cloud Computing, Data Processing, Machine Learning, Open Data, Public Value

Índice

1. Introducción	1
1.1. Motivación	1
1.2. Objetivos y alcance	2
1.3. Plan de trabajo	2
1.4. Estructura de esta memoria	3
1. Introduction	5
1.1. Motivation	5
1.2. Objectives and Scope	6
1.3. Work Plan	6
1.4. Structure of this Thesis	7
2. Estado de la Cuestión	9
2.1. Datos	10
2.1.1. Obtención de datos públicos	11
2.1.2. Trabajos anteriores y relacionados	12
2.1.3. Conjuntos de datos	14
2.1.4. Gobierno de los datos	16
2.2. Nubes	17
2.2.1. Principales Proveedores de Nube y sus Capas Gratuitas	18
2.2.2. Otras herramientas de interes	23
2.2.3. Trabajos anteriores y relacionados	26
2.3. Inteligencia Artificial	28
2.3.1. Modelos de ML	29
2.3.2. ML en la nube	30
2.3.3. IA, normativa y ética	34
2.3.4. IA, normativa y ética	34
2.3.5. Trabajos anteriores y relacionados	34
3. Materiales y métodos	37

3.1.	Materiales	37
3.1.1.	Conjuntos de Datos	37
3.1.2.	Nubes	39
3.1.3.	Materiales para el desarrollo	40
3.2.	Métodos	42
3.2.1.	Desarrollo de la solución	43
3.2.2.	Métodos utilizados: Datos	47
3.2.3.	Métodos utilizados: Aprendizaje automático	51
3.2.4.	Métodos utilizados: Cloud	52
4.	Resultados	57
4.1.	Hallazgos sobre la calidad de los datos publicados	57
4.1.1.	Evolución no documentada de los esquemas	57
4.1.2.	Continuidad de la publicación y cobertura de la red	57
4.2.	Resultados del análisis de aprendizaje automático: isla de calor	57
4.2.1.	Replicación del trabajo de referencia	57
4.2.2.	Relación entre superficie arbórea y temperatura	59
4.2.3.	Análisis de sensibilidad	60
4.2.4.	Evaluación de los agrupamientos	61
4.2.5.	Limitaciones e interpretación	63
4.3.	Comparación entre la ejecución local y las plataformas cloud	63
4.3.1.	Comparación de costes en las diferentes nubes	63
5.	Manual de usuario y casos de uso	65
5.1.	Manual de usuario en Local	65
5.1.1.	Despliegue y utilización del código en Local	66
5.1.2.	Ingesta y descarga de datos	66
5.1.3.	Modelos y resultados	67
5.2.	Manual de usuario en Amazon Web Services (AWS)	68
5.2.1.	Despliegue	68
5.2.2.	Configuración del entorno y autenticación	69
5.2.3.	Infraestructura de Almacenamiento en Amazon S3	70
5.2.4.	Orquestación y Procesamiento ETL con AWS Glue	72
5.2.5.	Modelos de ML y resultados con Amazon SageMaker	75
5.3.	Manual de usuario en Google Cloud Platform (GCP)	78
5.3.1.	Despliegue	78
5.3.2.	Configuración del entorno y autenticación	79
5.3.3.	Infraestructura de almacenamiento en Cloud Storage	80
5.3.4.	Procesamiento y análisis en Vertex AI Workbench	81
6.	Conclusiones y Trabajo Futuro	83
6.	Conclusions and Future Work	85

A. Apéndice A: Definiciones y acrónimos	87
A.1. Definiciones	87
A.1.1. Referente a datos	88
A.1.2. Referente a Cloud	93
A.1.3. Referente a Inteligencia Artificial	98
A.2. Acrónimos	105
B. Apéndice B: Uso ético de herramientas de IA	109
B.1. Análisis de la gestión de datos mediante LLMs	111
Bibliografía	113

Índice de figuras

4.1. Días válidos de temperatura por estación y año. Se aprecia la degradación de la subred municipal (códigos 1xx) durante 2021 y 2022.	58
4.2. Relación entre superficie arbórea y temperatura media por distrito, año 2021.	60
4.3. Evolución de la correlación entre superficie arbórea y temperatura media por distrito (2019-2025) en ambas configuraciones del análisis.	61
4.4. Diagrama del codo de la aproximación de temperatura y humedad relativa (2021).	62
4.5. Dendrograma del agrupamiento jerárquico de Ward sobre temperatura y humedad relativa (2021).	63
5.1. Árbol de archivos de resultados	68
5.2. Abrir terminal AWS en consola	69
5.3. Estructura de carpetas generada en S3	72
5.4. Ejecuciones del trabajo ETL en AWS Glue	75
5.5. Consola de SageMaker	76
5.6. Abrir terminal GCP en consola	78
A.1. Capas de gobierno del dato	93
A.2. Distintos tipos de cloud	96
A.3. Tendencias de búsqueda de IA	100

Índice de tablas

2.1. Ventanas de contexto en tokens de principales LLM (Junio 2026), con su calculo de filas de datos posibles que entrarían dentro de esa ventana.	32
3.1. Conjuntos de datos utilizados, su procedencia es (Ayuntamiento de Madrid, 2026a).	38
3.2. Correspondencia entre los procesos del <i>pipeline</i> y las etapas de la arquitectura de medalla.	43
4.1. Patologías de calidad detectadas en los conjuntos publicados y su efecto sobre la reutilización automatizada.	58
4.2. Replicación del agrupamiento de (Meneses Vicente y García Ruíz, 2023) para 2021. Las tres primeras columnas indican el número de estaciones empleadas en cada trabajo y las comunes a ambos, y la última el porcentaje de pares de estaciones agrupados de igual forma.	59
4.3. Correlación de Pearson entre superficie arbórea y temperatura media por distrito (2019-2025), reproduciendo las condiciones del trabajo original, y aplicando el criterio de cobertura mínima propio.	60
4.4. Coeficiente de silueta por año y aproximación, aplicando el criterio de cobertura mínima. Las columnas corresponden a las cinco aproximaciones descritas en la Sección 3.2.1.3, es decir siete magnitudes meteorológicas, temperatura y humedad relativa, temperatura y superficie arbórea, dióxido de nitrógeno, y dióxido de nitrógeno con partículas. El guion indica que la aproximación no reunió estaciones suficientes ese año. .	62
4.5. Comparativa de esfuerzo de desarrollo, tiempo de ejecución y coste por etapa y entorno.	64

A.1. Resumen de las principales características de las denominadas olas de datos abiertos.	91
A.2. Comparación de modelos relacionados con la computación dis- tribuida.	94
A.3. Línea de tiempo de la IA	99

Capítulo 1

Introducción

“We can only see a short distance ahead, but we can see plenty there that needs to be done.”

— Alan Turing

Este proyecto se basa en tres tecnologías: La computación en la nube, la cual se entiende como el suministro de servicios informáticos (servidores, almacenamiento, bases de datos, redes, software, análisis y más) a través de internet, permitiendo un acceso flexible y escalable a recursos sin la necesidad de poseer ni gestionar la infraestructura física; la inteligencia artificial, que abarca el desarrollo de sistemas que demuestran la capacidad de aprender, adaptarse, razonar y resolver problemas complejos, así como de percibir y comprender su entorno (virtual o físico), a menudo a través del análisis y la inferencia a partir de grandes volúmenes de datos (más específicamente, en este proyecto se emplearán las metodologías del aprendizaje automático, una rama de la IA centrada en la mejora del rendimiento en tareas específicas a través de algoritmos); Finalmente, los grandes volúmenes de datos se refieren a colecciones masivas y heterogéneas de información generada o recopilada por entidades gubernamentales u organizaciones, accesible al público. El proyecto estudia la manera en la que estas tres tecnologías se pueden combinar para aportar un valor tangible.

1.1. Motivación

La motivación de este proyecto surge debido al enorme auge que han tenido las tres tecnologías estudiadas, así como de su capacidad para crear sinergias

y aportar valor público. En el marco de la Unión Europea, se están tomando medidas para la liberalización de grandes volúmenes de datos públicos y promoviendo su uso por entidades públicas, así como poniendo el foco en la inteligencia artificial y su potencial transformador. La sociedad es cada vez más consciente del potencial de modelos del lenguaje, pero aun falta camino para que estos sean capaces de generar beneficios sociales de la manera más automatizada posible. Este trabajo pretende centrarse en eso, en estudiar cual es la mejor manera de que los distintos actores (individuales, públicos y privados) pueda generar valor a través de estas tecnologías.

1.2. Objetivos y alcance

El objetivo y alcance de este proyecto es triple:

- Realizar un análisis exhaustivo del panorama actual de la computación en la nube, la inteligencia artificial y el estado de los datos públicos, identificando las metodologías, técnicas y servicios más relevantes.
- Desarrollar una metodología replicable que permita el uso de estos datos, desde su origen, hasta la generación de valor. Afinando esta metodología a través de la puesta en práctica de la misma.
- Aplicar la metodología propuesta a diversos conjuntos de datos disponibles a nivel europeo y/o nacional, evaluando diferentes modelos y configuraciones para identificar las soluciones más eficientes y efectivas para generar valor público a partir de la información analizada.

1.3. Plan de trabajo

Una vez definido el alcance, destacaremos las seis fases en las que se ha dividido el proyecto, que se han ido iterando en un esquema ágil para la creación de varias versiones funcionales:

1. **Fase de investigación académica:** Búsqueda de estudios o trabajos acerca del estado actual de las tres tecnologías y las últimas innovaciones para establecer el marco teórico y contextualizar las bases del proyecto.
2. **Fase de investigación técnica:** Búsqueda de información acerca de diferentes fuentes públicas de datos, tecnologías en la nube y modelos o herramientas de IA que nos ayuden a tratar, filtrar y entender todos los datos públicos recopilados.

3. **Fase de análisis de requisitos:** A partir del conocimiento adquirido, se diseñó la arquitectura de la solución, se seleccionaron los conjuntos de datos públicos objetivo y se planificó la metodología concreta a seguir, estableciendo las métricas para evaluar el éxito del proyecto.
4. **Fase de implementación:** Fase central para materializar la solución. Esta aplica la metodología definida para llevar a la práctica e integrar todos los elementos: la configuración del entorno en la nube, la adquisición y limpieza de los datasets seleccionados, el entrenamiento de los modelos de aprendizaje automático y su despliegue y el uso del resto de tecnologías.
5. **Fase de pruebas y evaluación:** Valoración de los prototipos desarrollados y resultados obtenidos, así como del rendimiento de los modelos y la calidad del valor público generado, teniendo en cuenta el aspecto ético de los mismos.
6. **Fase de documentación:** Etapa transversal al resto, documentando los pasos seguidos y hallazgos en la elaboración de este documento, plasmando también los resultados obtenidos, las conclusiones y las posibles líneas de trabajo futuras.

1.4. Estructura de esta memoria

Toda esta memoria se ha construido con L^AT_EX [3.1.3.2] y ayuda de la plantilla T_EX_{IS}, El resto de la memoria se estructurará por capítulos de esta manera:

Capítulo 2: Estado de la cuestión, donde se plasmaran las conclusiones de las primeras dos fases de investigación: estudios, trabajos, marcos, tecnologías, conjuntos de datos y demás herramientas encontradas. También estudiará el panorama actual en la sociedad con respecto a estas.

Capítulo 3: Materiales y métodos, donde se plasmaran las siguientes dos fases de análisis e implementación, concretando las tecnologías y conjuntos de datos utilizados finalmente en el proyecto, al igual que la metodología y pasos que se han seguido durante el proyecto para obtener resultados.

Capítulo 4: Resultados y trabajo futuro En este capítulo se redactarán en detalle los resultados obtenidos en el proyecto, teniendo en cuenta todas las plataformas estudiadas y modelos usados.

Manual de usuario 5: Se centrará en la especificación técnica paso a paso de la solución, aportando la sintaxis completa de los comandos ejecutados tanto en local como en la nube, para que el trabajo sea lo mas facil posible de reproducir.

Anexo A “Definiciones y acrónimos”: Para evitar la excesiva longitud de ciertos apartados, **algunas definiciones se han movido a este apartado, apareciendo en el texto de la siguiente manera: [Definición 1]**. Aquí también se podrán encontrar los Acrónimos que aparecen durante todo el trabajo [A.2].

Conclusiones y Trabajo Futuro 6: Donde se definirá (también en ingles), mas resumidamente que en el capitulo de resultados, las conclusiones que se han podido sacar de este estudio, así como las líneas de investigación que inevitablemente quedan abiertas debido a la extensión de los temas tratados.

Aclarar que esta memoria utilizará las palabras en español o sus anglicismos correspondientes indistintamente, debido a su popularización y uso en la rama de la computación. Esto es palabras tales como “machine learning” o “aprendizaje automático”, “dataset” o “conjunto de datos”, “cloud” o “nube”, etc.

Chapter 1

Introduction

“We can only see a short distance ahead, but we can see plenty there that needs to be done.”

— Alan Turing

This project is based on three main technologies: Cloud computing, which is understood as the provision of computing services (servers, storage, databases, networking, software, analytics, and more) over the internet, allowing flexible and scalable access to resources without the need to own or manage physical infrastructure; artificial intelligence, which encompasses the development of systems that demonstrate the ability to learn, adapt, reason, and solve complex problems, as well as perceive and understand their environment (either virtual or physical), often through analysis and inference from large volumes of data (More specifically, this project will employ machine learning methodologies, a branch of AI focused on improving performance in specific tasks through algorithms); finally, public big data refers to massive and heterogeneous collections of information generated or collected by governmental or organizational entities, publicly accessible. This project studies the way in which these three technologies can combine to improve the social value.

1.1. Motivation

The motivation for this project arises from the enormous growth of the three studied technologies, as well as their capacity to create synergies and deliver public value. Within the framework of the European Union, measures are being taken to liberalize large volumes of public data and promote their

use by public entities, while also focusing on artificial intelligence and its transformative potential. Society is increasingly aware of the potential of language models, but there is still a long way to go before these can generate social benefits in the most automated way possible. This work aims to focus precisely on that: studying the best way for different actors (individuals, public and private entities) to generate value using these technologies.

1.2. Objectives and Scope

The objective and scope of this project are triple:

- Conduct a comprehensive analysis of the current landscape of cloud computing, artificial intelligence, and the state of public data, identifying the most relevant methodologies, techniques, and services.
- Develop a replicable methodology that allows the use of these data, from their origin to the generation of value, refining this methodology through practical implementation.
- Apply the proposed methodology to various datasets available at the European and national levels, evaluating different models and configurations to identify the most efficient and effective solutions for generating public value from the analyzed information.

1.3. Work Plan

Once the scope has been defined, we will highlight the six phases into which the project has been divided, which have been iterated in an agile framework for the creation of several functional releases:

1. **Academic research phase:** Search for studies or works about the current state of the three technologies and the latest innovations to establish the theoretical framework and contextualize the foundations of the project.
2. **Technical research phase:** Search for information about different public data sources, cloud technologies, and AI models or tools that help process, filter, and understand all the collected public data.
3. **Requirements analysis phase:** Based on the knowledge acquired, the solution architecture was designed, target public datasets were selected, and a concrete methodology was planned, establishing metrics to evaluate the project's success.

4. **Implementation phase:** Central phase to materialize the solution. This applies the defined methodology to practically integrate all elements: cloud environment configuration, acquisition and cleaning of selected datasets, training of machine learning models, their deployment, and the use of the other technologies.
5. **Testing and evaluation phase:** Assessment of developed prototypes and obtained results, as well as model performance and the quality of the public value generated, taking ethical aspects into account.
6. **Documentation phase:** Cross-cutting stage documenting the steps followed and findings in the preparation of this document, also reflecting the obtained results, conclusions, and future lines of work.

1.4. Structure of this Thesis

This thesis has been built using L^AT_EX [3.1.3.2] with the help of the T_EX_{IS} template. The rest of the thesis is structured in chapters as follows:

Chapter 2: State of the Art, which will present the conclusions of the first two research phases: studies, works, frameworks, technologies, datasets, and other tools found. It will also study the current landscape in society regarding these topics.

Chapter 3: Materials and Methods, which will cover the next two phases of analysis and implementation, specifying the technologies and datasets finally used in the project, as well as the methodology and steps followed to obtain results.

Chapter 4: Results and Future Work In this chapter, all the results obtained in the project will be explained in detail, taking in account all the platforms and machine learning methods that has been used.

User manual 5: This chapter is focus on the technical specification, step by step, of the solution's syntax with all the commands used in the project, to provide to the reader the way to reproduce the full process.

Appendix A “Definitions and Acronyms”: To avoid excessive length in certain sections, some definitions have been moved to this appendix, appearing in the text as follows: [Definition 1]. Here, the acronyms used throughout the work can also be found [A.2].

Conclusions and Future Work 6: In this last chapter (which will also be available in English), the results obtained in the project will be concluded, as well as the research lines that inevitably remain open due to the breadth of the topics covered.

Capítulo 2

Estado de la Cuestión

“Somos una generación frontera. La única que ha conocido la vida antes y después de la hiperconectividad y los dispositivos móviles. [...] La última que pudo abarcar toda la tecnología de su tiempo.”
— Jaime Gómez-Obregón

En este apartado expondremos el estado actual de los puntos principales de este proyecto, así como los artículos relacionados con los temas a tratar: trabajos relacionados con los principales proveedores Cloud y su comparación, trabajos que traten con grandes volúmenes de datos públicos o que estudien los datos públicos, o trabajos que utilicen diferentes IAs para el tratamiento de datos y la obtención de conclusiones a partir de estos. No es una tarea fácil, ya que los artículos relacionados en “Google Scholar” se cuentan por millones al buscar “data”, “Artificial Intelligence” o “cloud computing”, por lo que, aunque también se estudiaran conjuntos de datos, artículos y aplicaciones de otras partes del globo, la parte práctica del proyecto se intentará centrar en datos del territorio español, de esta manera acotaremos el alcance del proyecto y contribuiremos a aprovechar datos que no han sido tan explotados y explorados como pueden ser los datos abiertos de Google (Google, 2025a) o Amazon (Amazon, 2025).

También dividiremos esta sección en los tres elementos que componen el trabajo, y estudiaremos las posibilidades y estado de la cuestión de cada uno.

2.1. Datos

Llevamos mucho tiempo escuchando que vivimos en la era de la información, o de los datos, desde la invención del transistor en 1947 (Wikipedia, 2025), pasando la primera vez que se acuñó en 2005 el termino “web 2.0” y “Big data” (Press, 2013), así como su rápido crecimiento y adopción en todas las esferas (Brown et al., 2011), hasta el presente, donde los datos y su tratamiento a través de múltiples herramientas, incluyendo la recientemente omnipresente Inteligencia Artificial, llegarán a generar, según proyecciones, la asombrosa cifra de 149 Zettabytes de datos creados, capturados, copiados y consumidos en 2024, cifra estimada en 181 Zettabytes para 2025 y que las proyecciones sitúan en torno a los 394 Zettabytes en 2028 (Taylor, 2025; Pangarkar, 2025) (numero impresionante a pesar de la naturaleza especulativa de estas proyecciones).

Esta evolución no ha sido lineal ni uniforme, sino que ha estado marcada por distintos enfoques, motivaciones y metodologías en todo el mundo en lo que se denominan las tres olas de datos abiertos [Definición 5], diferentes etapas evolutivas por las que ha transitado el movimiento de apertura de datos.

En España, los datos también muestran un aumento significativo. Según el informe económico de telecomunicaciones y audiovisual de la CNMC (Comisión Nacional de los Mercados y la Competencia, 2026), en 2025 el tráfico de banda ancha y datos móviles creció hasta los 0.095 Zettabytes, que aunque estas cifras miden el tráfico cursado por las redes de las principales operadoras y no es directamente comparable con las estimaciones globales de datos generados, permiten observar ambas mediciones son elevadas, y con tendencia común de crecimiento sostenido año tras año.

Aún con estas discrepancias en cuanto a números, lo que está claro es que el mercado de los datos no para de crecer año tras año y cada vez resulta más difícil separar la información relevante del ruido, evitando la “infoxicación” o sobrecarga informativa (Cornella, 2000). En este escenario, tecnologías como la computación en la nube e inteligencia artificial pueden ser claves para encontrar los patrones o llegar a conclusiones.

Mencionar también brevemente que los “datos” no suelen aparecer en formatos consistentes, y para este trabajo se han tratado diferentes formatos: CSV, JSON, bases de datos diversas, excel, APIs, etc. (Khan y Alam, 2019). Esto es así porque queríamos que las fuentes de datos fueran heterogéneas y no excluir datos porque su extracción o tratamiento fueran complejos, ya que este es el caso para la mayoría de aplicaciones en el mundo real. Esto se explicará más en detalle en la Sección 3.2.1.2: Normalización y limpieza

2.1.1. Obtención de datos públicos

Lo primero para la realización de este proyecto es la obtención de datos públicos, o datos abiertos [Definición 4]. Esto presenta tres grandes complicaciones a tener en cuenta:

La primera es que, aunque existe un consenso creciente sobre la importancia de la apertura de datos, la realidad muestra que **muchos datos de alto valor aún no son accesibles, lo son de forma limitada o su uso es complejo**, ya sea a conciencia o por indolencia. Según la OECD (OECD, 2023), sólo el 48 % de los conjuntos de datos de gran valor están disponibles como datos abiertos en los países estudiados, datos que bajan al 30 % cuando se trata de datos financieros. y estudios de otras partes del mundo también avalan esta reticencia a la correcta apertura de información pública (De la Torre y Núñez, 2023; Jorge y Herrera, 2023).

La segunda causa es **la regulación**, el tratamiento de datos en Europa debe seguir la RGPD de 2016 y las regulaciones propias de cada estado (Ramos-Simón, 2017) & (Union Europea, 2016), así como la más reciente Ley de Gobernanza de Datos (Union Europea, 2023; Valero Torrijos y Martínez Gutierrez, 2022). Para cumplir con estas normativas, en este proyecto nos centraremos en el uso de datos oficiales abiertos, evitando técnicas como el “scraping” que pueden estar sujetas a controversia a la vista de estas regulaciones. También se verificarán las licencias de todos los datos y modelos utilizados para asegurarnos de que no incumplimos ninguna de las regulaciones existentes.

En cuanto a datos de otros países fuera de la Unión Europea, tenemos panoramas diversos los cuales vale la pena mencionar, desde una regulación más laxa en Estados Unidos, hasta un control estricto en países como China. Estos datos no se utilizarán en este trabajo por temas de alcance, ya que se prefiere dar prioridad a fuentes de datos nacionales, pero las herramientas desarrolladas serían aplicables a estos mismos datos cumpliendo sus normativas.

En Estados Unidos, el panorama es sobre todo abierto, pero fragmentado. Cuentan con regulaciones sectoriales, como la “Health Insurance Portability and Accountability Act” (HIPAA) para datos médicos (Congreso de los Estados Unidos de America, 1996) y regulaciones estatales como la “California Consumer Privacy Act” (CCPA) (Estado de California, 2018) para proteger derechos individuales. También existe una legislación nacional que promueve los datos abiertos, la “OPEN Government Data Act” (2019) (Congreso de los Estados Unidos de America, 2019), que establece que los datos gubernamentales deben ser abiertos y utilizables.

Por su parte, China ha establecido un marco regulatorio estricto con leyes

como la “Personal Information Protection Law” (PIPL) (Standing Committee of the National People’s Congress, 2021b), que habla de principios de consentimiento y derechos del individuo, y la “Data Security Law” (DSL) (Standing Committee of the National People’s Congress, 2021a), que prioriza la seguridad nacional y el control sobre los datos generados en el país.

Por último, la tercera causa es **la tecnología**, como ya se ha hablado, los datos pueden estar en formatos diferentes, y la cantidad de herramientas para su tratamiento va en aumento, y hay que tener en cuenta también la integración, el procesamiento escalable a la cantidad de datos en aumento y el gobierno de los flujos de datos y modelos en un entorno “cloud” que está en evolución constante. Por ello, en este trabajo se ha optado por emplear herramientas ampliamente extendidas, soportadas, y principalmente abiertas, así como intentar hacer del conjunto de ellas lo más amplio posible, para estudiar y comparar un amplio abanico de soluciones.

2.1.2. Trabajos anteriores y relacionados

A parte de todas las referencias ya incluidas en esta sección, nos gustaría destacar todo el trabajo de Jaime Gómez-Obregón para liberar y hacer accesibles los datos de España (Gómez-Obregón, 2025a), con acciones como publicar las subvenciones a las empresas en España a través del portal ministerial y hacerlas accesibles (Gómez-Obregón, 2025c), o estudios sobre donaciones sospechosas de corrupción (Gómez-Obregón, 2025b). Todo este trabajo ha guiado también a este proyecto hacia un uso ético de los datos.

Sobre “Big data” y datos públicos, han surgido trabajos en España desde los inicios del *Open government* ([Definición 2]) desde 2011 (Ferrer-Sapena et al., 2011), y desde diversos campos como las Ciencias de la Información. Uno de los más completos que se han podido encontrar en nuestro territorio es: (Herrera Capriz, 2024), un reciente y extenso trabajo sobre los datos abiertos en España donde, partiendo de una extensa experiencia en la administración pública, la autora busca combinar dos campos con demandas complementarias bajo el marco teórico de la “Teoría de la Ventana” [Definición 6] y estudios anteriores de valor público (Meynhardt, 2009):

- Los Estudios de **Valor Público** [Definición 3]: Carecen de una extensa evidencia empírica sólida.
- La **transparencia y los Datos Abiertos** [Definición 4]: Carecen de medición del valor final que generan para los ciudadanos.

La autora trata de medir el valor real que la transparencia y los datos abiertos generan para los ciudadanos, más allá de su mera publicación. Para ello

propone un marco metodológico que permite cuantificar el valor de los datos abiertos a través de la percepción de los usuarios. Este enfoque consigue identificar que las dimensiones utilitaria y hedonista (relacionadas con la funcionalidad y la experiencia de usuario) reciben puntuaciones altas, mientras que las dimensiones político-social y moral-ética (relacionadas con la generación de comunidad, equidad y trato justo) lastran el valor potencial, y detectando también que determinantes clave como la frecuencia de uso y el tipo de datos (geoespacial, movilidad, turismo) son factores condicionantes para maximizar el valor.

Se quiere destacar también la gran labor de investigación sobre datos abiertos del trabajo, que ha sido clave como base para la realización de este mismo proyecto y la utilidad de los resultados, que influenciará en la utilización de los datos públicos de este proyecto.

En cuanto a trabajos más práctico-tecnológicos, hay muchos de ellos donde destacar, la Unión Europea en sus estudios de casos de uso sobre datos públicos, tiene más de 600 casos estudiados, 150 con impacto significativo, 30 participaron en el estudio del volumen 1 (Carsaniga et al., 2022) y finalmente 13 en el volumen dos del mismo (Nijssen, 2022), de los cuales nos gustaría destacar 3 españoles y uno Francés:

- **UniversiDATA:** Un portal que integra seis universidades españolas para el análisis avanzado y dinámico de datos abiertos con el objetivo de crear resultados interactivos y en tiempo real, facilitando el uso compartido de recursos y mejorando la comprensión de datos abiertos (UniversiDATA, 2025). El equipo también fomentaba el uso de sus datos con diferentes análisis propios (UniversiDATA, 2020) o el lanzamiento de eventos centrados en datos (o “Datathones” [Definición 7] (UniversiDATA, 2024) de los cuales hablaremos a continuación). También resuelven dudas de usuarios e investigadores en los conjuntos de datos o análisis a través de comentarios, fomentando aún más la comprensión de los datos
- **Tangible Data:** Transforma datos espaciales digitales en esculturas físicas accesibles.
- **Planttes:** Aplicación que informa sobre la floración de plantas y su impacto en las alergias al polen, combinando datos abiertos con aportaciones de usuarios, fomentando la concienciación, información y educación sobre alergias (Concepción De Linares, 2025b).
- **Open Food Facts:** Aplicación que informa sobre detalles de productos de supermercado, queriendo nombrarla por la enorme cantidad de datos que ha conseguido recopilar de usuarios de todo el mundo y lo intuitiva que es a la hora de usar toda esta cantidad de datos (más de 4.6 millones de productos). (Concepción De Linares, 2025a).

Como ya se ha comentado otra fuente importante de proyectos relacionados con datos serían los “Datathones” [Definición 7], de los cuales pueden salir decenas de proyectos relacionados con datos abiertos en muy poco tiempo y que sería inabarcable mencionar en este proyecto debido a los más de 20 Datathones diferentes encontrados y los múltiples proyectos que hay en cada uno, pero si que nos gustaría mencionar iniciativas como la del gobierno de España (Gobierno de España, 2025b,a) con centenares de eventos sobre datos a fecha de publicación de este trabajo.

Por último, también mencionaremos trabajos académicos de compañeros que han implementado soluciones con datos públicos, que aunque son algo anti-guós siguen aportando valor:

- **“Auditoría y metodología de implantación de open data para smart cities”** (Melendrez Moreto, 2016): Donde el autor hace un análisis extensivo de los datos abiertos, de los índices y métricas para evaluar el valor de estos datos y de herramientas como “CKAN” para la gestión de los datos. Audita diversas fuentes de datos nacionales dejando todas dentro del umbral de datos abiertos según AENOR.
- **“Uso de geolocalización y de fuentes de datos abiertas para la creación de servicios turísticos por la ciudad de Madrid”** (LLamocca Portela, 2016): El cual utiliza datos abiertos de geolocalización en Madrid para buscar sitios cercanos en una app móvil.
- **“Integración y visualización de datos abiertos medioambientales”** (Arellano Bruno, 2019): También hace un análisis extensivo de los datos abiertos, de las definiciones para evaluar estos datos y de herramientas como “CKAN”. Además, comenta iniciativas de limpieza de datos interesantes como “Data Tamer” o “Data Wrangler”. Finalmente, crea una aplicación para el uso de datos medioambientales en tiempo real.

2.1.3. Conjuntos de datos

Para embarcarse en el tema de los conjuntos de datos, primero tenemos que saber qué tipos de datos hay en el mundo real (Sarker, 2021) dependiendo de formato y forma, estos pueden ser:

- **Estructurados:** Datos con un formato definido, siguiendo un modelo de datos estándar como tablas o bases de datos relacionales (fechas, direcciones, geolocalización).
- **No estructurados:** Datos sin un formato o estructura predefinida, mas difíciles de procesar y analizar, principalmente texto y multimedia

(correos electrónicos, blogs, PDFs, audio, videos, etc.).

- **Semi-estructurados (Semi-structured):** Datos que no se almacenan en bases de datos relacionales, pero tienen cierta organización (HTML, XML, JSON o bases de datos NoSQL).
- **Metadatos (Metadata):** Datos sobre otros datos, que describen información relevante para dar significado a los datos (autor de un documento, tamaño de archivo, fecha de creación palabras clave, etc.).

Teniendo esto en cuenta, para el desarrollo de este proyecto donde pretendemos obtener valor de los mismos de la forma más automática y escalable, se elegirán principalmente datos estructurados, semiestructurados y los metadatos que proporcionen los portales. También, recalando la prioridad de este proyecto en conjuntos de datos cercanos, destacamos algunos de los conjuntos de datos e iniciativas más interesantes encontrados durante el estudio:

- **Internacionales:** Iniciativas individuales como “Awesome public datasets” (Awesome data, 2025), que recopila fuentes de datos fiables (aunque principalmente de Estados Unidos).
- **Europeos:** Europa cuenta con su propio portal para acceder a datos públicos (Union Europea, 2025b) con datasets sobre población, educación y ciencia.
- **Españoles:**
 - El Instituto Nacional de Estadística (INE) y la Agencia Tributaria han sido actores clave en la liberación de datos abiertos y el fomento de su reutilización para investigación e innovación.
 - Proyectos como el Portal de Transparencia del Gobierno de España y las iniciativas de datos abiertos de comunidades autónomas y ayuntamientos (Gobierno de España, 2025c; Ayuntamiento de Madrid, 2025; Registradores de España, 2025), los cuales se esfuerzan por hacer públicos datos de “alto valor” [Definición 1].
 - Famosas iniciativas como “Kaggle” cuentan con datos de todo tipo sobre España, muchos recopilados de otras fuentes públicas ya nombradas, pero otros interesantes (Kaggle, 2025b).
 - Iniciativas que fomentan la transparencia, como InfoParticipa (Universitat Autònoma de Barcelona, 2025).
 - Iniciativas privadas para la recolección de datos públicos (Esri España, 2025).
 - Iniciativas ya mencionadas como UniversiDATA (UniversiDATA, 2025).

Todos estos portales y aplicaciones son de gran importancia y constituyen la base material sobre la que se sustentan trabajos como el presente. Los conjuntos de datos escogidos se detallan en el apartado Sección 3.1.1: Materiales y datos.

2.1.4. Gobierno de los datos

Por último, y teniendo claro todo explicado sobre los datos, destacaremos la importancia de la gobernanza [Definición 8] de los mismos como uno de los desafíos fundamentales al manejarlos (Leonidas et al., 2024). En el marco europeo llevamos años promulgando mecanismos para aumentar la confianza para un mayor y mejor intercambio de datos (European Parliament, 2022). El reglamento presenta tres vías principales: la reutilización segura de datos protegidos del sector público, la intermediación neutral de datos y la cesión altruista de datos para el interés general. Estos mecanismos operativos materializan los principios de la gobernanza: calidad, seguridad, interoperabilidad y confianza.

Para la gestión de datos en este proyecto, adoptaremos un marco de gobernanza de datos basado en el modelo de tres capas propuesto por la OECD (Estratégica, Táctica y Operativa) (OECD, 2019), integrado con el resto de normativas europeas vigentes, (como “Data Governance Act” (European Parliament, 2022) o el Reglamento General de Protección de Datos (Union Europea, 2016)). La aplicación de este marco se articulara en la Sección 3.2.2.1: Métodos de Gobernanza.

2.2. Nubes

La capacidad real de extraer valor de los volúmenes masivos de datos abiertos detallados en la sección anterior está intrínsecamente ligada a la disponibilidad de recursos computacionales potentes, escalables y económicamente accesibles. Y aunque se lleva años hablando de soluciones como las nubes distribuidas [Definición 9], el paradigma de la computación en la nube gestionada (o publica, que no abierta) (*cloud computing*), con planes gratuitos, es muy relevante para democratizar este acceso, permitiendo a investigadores, startups e instituciones públicas superar las limitaciones del hardware local.

Estas nubes gestionadas nos proporcionan unidades de procesamiento gráfico (GPUs) y tensorial (TPUs) bajo demanda, además de un ecosistema completo de servicios gestionados diseñados específicamente para el ciclo de vida completo de los datos y la IA. También nos brindan mecanismos de seguridad que junto a la implementación diligente por parte del usuario (modelo de responsabilidad compartida) aporta la seguridad necesaria para el proyecto. Para este trabajo se ha optado por esta solución. Otra opción posible sería la nube híbrida, que combina el control de una infraestructura privada (“On premise”) con la escalabilidad y economía de la nube pública. Esto es ideal para cargas con datos sensibles, pero complicaría el enfoque de este proyecto. Para ayudarnos mejor a valorar todas las opciones, vamos a listar la oferta gratuita de algunas de las nubes estudiadas (Microsoft, s.f.a; Lisdorf, 2021).

En el panorama nacional, la encuesta del INE sitúa en un 44,3 % las empresas españolas de diez o más empleados que utilizaron servicios de computación en la nube de pago en el primer trimestre de 2025, 6,6 puntos porcentuales más que el año anterior (Instituto Nacional de Estadística, 2025). La cifra se mantiene por debajo de la media europea, que Eurostat sitúa en el 52,7 % para ese mismo año, con un crecimiento de 7,4 puntos respecto a la edición anterior de la encuesta (Eurostat, 2026). De cara al futuro, mientras la estrategia europea prioriza el “edge computing” frente a la cloud privada para ganar autonomía tecnológica y soberanía de datos (European Commission, s.f.a), el enfoque del Plan de Digitalización español (Gobierno de España, 2021b) no se aleja de la nube pública, sino que aboga por un modelo híbrido soberano usando NubeSARA (plataforma híbrida que, por sus precios (Gobierno de España, s.f.b), e información encontrada (Gobierno de España, s.f.a; PreparaTIC, s.f.) no vamos a utilizar en este estudio).

Matiz sobre “edge computing”: Aunque es especialmente importante en el uso de aplicaciones de IA [Tabla A.2], debido a la importancia de la privacidad en escenarios con datos tratados automáticamente, pero al ser esto una investigación y no una tecnología dirigida a un usuario final (el cual requeriría velocidad y privacidad), se optara por ejecutar los modelos en la nube en vez

en edge, aunque se reconoce su potencial para aplicaciones prácticas.

También hay alternativas para usar cloud en el territorio europeo y español, como pueden ser: (clouding.io, s.f.; GmbH, s.f.; Gigas, s.f.), en las cuales se podría desplegar máquinas virtuales para la ejecución de modelos y tratamiento de datos, pero que al no tener infraestructura especializada en Inteligencia artificial y carecer en su mayoría de capa gratuita, se han excluido del estudio. Resultaba interesante, por ejemplo, la iniciativa europea BD-TI (European Commission, s.f.b; Gobierno de España, 2021a), que ofrecía infraestructura gratuita a organismos públicos y trabajos como este, pero el proyecto concluyó en marzo de 2025 y sus recursos quedaron archivados. También SIMPL (European Commission, 2024), un framework tecnológico, un middleware para construir sobre diferentes proveedores cloud y edge. Telefónica Tech también vende una especie de nube pública basada en VMware, pero principalmente son servicios gestionados multi-cloud (Telefónica, s.f.). Por último, nombrar dos herramientas europeas que si pueden resultar útiles, y que analizaremos en la próxima sección, “OVHcloud” (proveedor de cloud francés) y “OpenNebula” (plataforma española open-source para gestionar clouds).

2.2.1. Principales Proveedores de Nube y sus Capas Gratuitas

A continuación detallaremos las pruebas gratuitas de los principales proveedores de servicios en la nube, información crucial para la selección tecnológica de este proyecto. (R.I.Pienaar, 2025). Estas cifras se verificaron por última vez en agosto de 2026, pero al ser ofertas comerciales sujetas a cambios (como evidenció el propio desarrollo de este trabajo entre la redacción inicial de esta sección y su revisión final, varios de los servicios consultados modificaron sus límites) se genera una volatilidad que hay que considerar en proyectos que dependan de estos recursos.

Google Cloud Platform

Ecosistema de servicios en la nube Google con infraestructura escalable, herramientas de análisis y soluciones de inteligencia artificial gestionadas que cubre todo el ciclo de vida de los datos y aplicaciones. A parte de las aplicaciones listadas y muchas más que se pueden encontrar en su **Lista completa**: <https://cloud.google.com/free>, Google también ofrece 300€ para exceder estos límites los primeros 3 meses de prueba, lo cual puede ayudar enormemente a proyectos de tamaño medio.

Servicios específicos:

- **App Engine:** 28 horas/día de ejecución “frontend”, 9 horas/día de ejecución “backend”.
- **Cloud Firestore:** 1GB almacenamiento, 50.000 lecturas, 20.000 escrituras, 20.000 borrados por día.
- **Compute Engine:** 1 e2-micro no susceptible de interrupción, 30GB disco duro, 5GB de instantáneas, con regiones restringidas.
- **Cloud Storage:** 5GB, 1GB de tráfico de salida de red.
- **Cloud Shell:** Terminal Linux basado en web con 5GB de almacenamiento persistente. Límite de 60 horas/semana.
- **Cloud Pub/Sub:** 10GB de mensajes por mes.
- **Cloud Functions:** 2 millones de invocaciones por mes.
- **Cloud Run:** 2M de peticiones por mes, 360.000 GB/segundos de memoria, 180.000 segundos de CPU virtual.
- **Google Kubernetes Engine:** Sin tarifa de gestión de clústeres para un clúster zonal.
- **BigQuery:** 1 TB de consultas por mes, 10 GB de almacenamiento.
- **Cloud Build:** 120 minutos de construcción por día.
- **Cloud Source Repositories:** Hasta 5 usuarios, 50 GB de almacenamiento, 50 GB de tráfico de salida.
- **Google Colab:** Entorno gratuito de desarrollo con “Jupyter Notebooks”.

Amazon Web Services

Plataforma de cloud computing más usada a nivel empresarial, con una enorme cantidad de servicios, desde cómputo básico hasta servicios de IA, aprendizaje automático, IoT, etc. Tiene una capa gratuita de 6 meses y 100 dolares de gastos + 100 adicionales al completar tareas. Aquí se puede consultar la **Lista completa** de servicios: <https://aws.amazon.com/free/>

Servicios específicos:

- **CloudFront:** 1TB de tráfico de salida por mes y 2M invocaciones de funciones.
- **CloudWatch:** 10 métricas personalizadas y 10 alarmas.

- **CodeBuild**: 100min de tiempo de ejecución por mes.
- **CodeCommit**: 5 usuarios activos, 50GB almacenamiento, 10000 peticiones por mes.
- **CodePipeline**: 1 pipeline activo por mes.
- **DynamoDB**: 25GB base de datos NoSQL.
- **EC2**: 750 horas/mes de t2.micro o t3.micro, 6 meses.
- **EBS**: 30GB por mes de SSD propósito general o magnético, 6 meses.
- **Elastic Load Balancing**: 750 horas por mes, 6 meses.
- **RDS**: 750 horas/mes de db.t2.micro, 20GB almacenamiento SSD, 6 meses.
- **S3**: 5GB almacenamiento estándar, 20K peticiones Get, 2K peticiones Put, 6 meses.
- **Glacier**: 10GB almacenamiento a largo plazo.
- **Lambda**: 1 millón de peticiones por mes.
- **SNS**: 1 millón de publicaciones por mes.
- **SES**: 3.000 mensajes por mes, 6 meses.
- **SQS**: 1 millón de peticiones de colas de mensajería.

Microsoft Azure

Ecosistema cloud de Microsoft, muy integrado con todas sus herramientas empresariales y de desarrollo, como la suite de DevOps, copilot y más soluciones de IA, enfoque en el lenguaje .NET. También tiene una capa gratuita de 12 meses. Aquí se puede consultar la **Lista completa** de servicios: <https://azure.microsoft.com/free/>

Servicios específicos:

- **Virtual Machines**: 1 B1S Linux VM, 1 B1S Windows VM, 12 meses.
- **App Service**: 10 aplicaciones web, móviles o de API, con 60 minutos CPU/día.
- **Functions**: 1 millón de peticiones por mes.
- **DevTest Labs**: Entornos de desarrollo y pruebas.
- **Active Directory**: 500.000 objetos.

- **Azure DevOps:** 5 usuarios activos, repositorios Git privados ilimitados.
- **Azure Pipelines:** 10 trabajos paralelos con minutos ilimitados para código abierto.
- **Microsoft IoT Hub:** 8.000 mensajes por día.
- **Load Balancer:** 1 IP pública con balanceo de carga gratuita.
- **Notification Hubs:** 1 millón de notificaciones “push”.
- **Ancho de banda:** 15GB de entrada y 5GB de salida por mes, 12 meses.
- **Cosmos DB:** 25GB almacenamiento y 1000 unidades de solicitud de rendimiento
- **Static Web Apps:** Aplicaciones estáticas con SSL, autenticación y dominios personalizados
- **Storage:** 5GB almacenamiento de archivos o “blobs” con redundancia local, 12 meses.
- **Cognitive Services:** APIs de IA/ML con transacciones limitadas.
- **Cognitive Search:** Búsqueda basada en IA, para 10.000 documentos.
- **Azure Kubernetes Service:** Servicio Kubernetes gestionado, gestión de clústeres.
- **Event Grid:** 100K operaciones/mes.

Oracle Cloud

Nube especializada en bases de datos de alto rendimiento (Oracle Database), aplicaciones Java, y soluciones de analytics. Ofrece una capa gratuita con recursos que no expiran, aquí se puede consultar la **Lista completa** de servicios: <https://www.oracle.com/cloud/free/>

Servicios específicos:

- **Compute:** 2 máquinas virtuales AMD con 1/8 OCPU y 1 GB memoria cada una.
- **Block Volume:** 2 volúmenes, 200 GB total para computación.
- **Object Storage:** 10 GB.
- **Load Balancer:** 1 instancia con 10 Mbps.
- **Databases:** 2 bases de datos, 20 GB cada una.

- **Monitoring:** 500 millones de puntos de ingesta de datos, 1 millardo de recuperación.
- **Ancho de banda:** 10 TB de tráfico de salida por mes, velocidad limitada a 50 Mbps.
- **IP Pública:** 2 IPv4 para máquinas virtuales, 1 IPv4 para balanceador de carga.
- **Notifications:** 1 millón de opciones de entrega por mes, 1000 emails enviados por mes.

IBM Cloud

Plataforma centrada en la transformación digital de grandes empresas con necesidades híbridas y multicloud, aunque también con una capa gratuita. Se puede consultar la **Lista completa** de servicios aquí: <https://www.ibm.com/cloud/free/>

Servicios específicos:

- **Cloudant database:** 1 GB de almacenamiento de datos.
- **Db2 database:** 100MB de almacenamiento de datos.
- **API Connect:** 50.000 llamadas API por mes.
- **Availability Monitoring:** 3 millones de puntos de datos por mes.
- **Log Analysis:** 500MB de registros diarios.

Cloudflare

Plataforma especializada en rendimiento web, seguridad y confiabilidad. Aunque no es una nube generalista, sino más bien una red global que acelera y protege sitios web, APIs y aplicaciones mediante su CDN, DNS, servicios de seguridad, etc. De todas formas también tiene capa gratuita, la **Lista completa** se encuentra en: <https://www.cloudflare.com/plans/free/>

- **Application Services:** DNS, Protección DDoS, CDN con SSL, Firewall de aplicaciones web.
- **Zero Trust & SASE:** Hasta 50 usuarios, 24 horas de registro de actividad.
- **Cloudflare Tunnel:** Exponer puertos HTTP locales a través de túnel.
- **Workers:** Desplegar código sin servidor - 100k peticiones diarias.

- **Workers KV:** 100k lecturas diarias, 1000 escrituras diarias, 1 GB datos almacenados.
- **R2:** 10 GB por mes, 1 millón operaciones por mes.
- **D1:** 5 millones de filas leídas por día, 100k filas escritas por día, 1 GB almacenamiento.
- **Pages:** Desplegar aplicaciones web - 500 despliegues mensuales, 100 dominios personalizados.
- **Queues:** 1 millón de operaciones por mes.
- **TURN:** 1TB de tráfico saliente por mes.

OVHcloud

Proveedor de cloud francés con un fuerte compromiso con la soberanía de los datos y el RGPD. Ofrece una gama completa de servicios de infraestructura (IaaS) y plataforma (PaaS) desde sus centros de datos. Ofrece 200 euros en créditos para probar el servicio durante un mes, aunque tiene una **Lista completa** de servicios: <https://www.ovhcloud.com/en/public-cloud/prices/>, los disponibles en el plan gratuito son los siguientes (OVHCloud, s.f.):

- **Despliegue de un e-commerce:** con 2 servidores B2-7, 1 base de datos MySQL, 1 IP adicional, 1 Balanceador de Carga y 10 GB de Almacenamiento de Objetos.
- **Prueba de Kubernetes y escalado:** 3 servidores B2-15 durante 1 mes y 12 horas de picos de tráfico en 10 servidores C2-30.
- **Desarrollo y Entrenamiento de IA:** 1 TB de Almacenamiento de Objetos, 35 horas de IA Notebook (AI1-1-GPU) y 5 horas de entrenamiento de IA en 4 nodos AI1-1-GPU.

2.2.2. Otras herramientas de interes

También, aunque no son nubes propiamente dichas, se ha querido añadir en esta sección otras herramientas que tienen interés para el proyecto:

Hugging Face Spaces

- **Tipo:** Plataforma para desplegar, compartir y descubrir modelos de Aprendizaje Automático (MLOps). Esencial para proyectos de IA. Per-

mite desplegar demostraciones de modelos con interfaz web de forma sencilla.

■ **Capa Gratuita - CPU:**

- 2 CPUs virtuales por espacio.
- 16 GB de RAM.
- Espacio de almacenamiento: 50 GB (para modelos, datos y código).
- Ancho de banda: 100 MB/hora para CPUs.
- **Apagado automático:** Los espacios se suspenden tras 48 horas de inactividad para ahorrar recursos, reactivándose con la siguiente visita.

■ **Capa Gratuita - GPU (T4):**

- Acceso a una GPU NVIDIA T4 por espacio.
- 16 GB de RAM.
- Espacio de almacenamiento: 50 GB.
- Ancho de banda: 30 MB/hora para GPUs.
- Uso: Hasta 30 horas de uso de GPU por mes, pero sujeto a disponibilidad.
- **Apagado automático:** Las GPU se apagan automáticamente tras 1 hora de inactividad.

■ **Enfoque:** Despliegue, demostración y compartición de modelos de IA. Integración nativa con el Hub de modelos y conjuntos de datos.

■ **URL:** <https://huggingface.co/spaces>

Kaggle Kernels/Notebooks

■ **Tipo:** Entorno de ejecución para cuadernos “Jupyter” en la nube. Proporciona acceso gratuito a aceleradores hardware de gama alta, eliminando la barrera de entrada para entrenar modelos complejos.

■ **Capa Gratuita - Sesiones de Ejecución:**

- **GPU (NVIDIA Tesla P100):** Hasta 30 horas por semana (4.3h/día aprox.).
- **TPU (v3):** Hasta 20 horas por semana (2.8h/día aprox.).

- **CPU:** 20 horas de tiempo total por semana, sin límite de sesiones concurrentes.
- **Límites por Sesión:**
 - **Tiempo máximo de ejecución:** 12 horas por sesión. Tras este tiempo, el kernel se detiene automáticamente.
 - **Internet:** Los cuadernos deben tener la opción de Internet activada manualmente para acceder a datos externos o instalar librerías.
 - **Almacenamiento Volátil:** 20 GB de espacio temporal de disco. Los datos no persisten entre sesiones, aunque se puede usar el sistema de conjuntos de datos de Kaggle para almacenamiento persistente.
- **Enfoque:** Análisis exploratorio de datos, competiciones de ML y, crucialmente, **entrenamiento de modelos** que requieran GPU/TPU.
- **URL:** <https://www.kaggle.com/code>

Open Data Editor

Herramienta de código abierto <https://okfn.org/en/projects/open-data-editor/> diseñada para la gestión y publicación de datos abiertos. Desarrollada por la “Open Knowledge Foundation”, facilita la creación, validación y limpieza de conjuntos de datos en formatos abiertos, con un enfoque en la usabilidad para usuarios no técnicos, para garantizar la calidad y accesibilidad de los datos públicos. Funcionalidades clave:

- Creación y edición tabular de datos.
- Validación de esquemas y meta datos.
- Integración con plataformas de datos abiertos (CKAN, S3, etc.).
- Exportación a formatos estandarizados (CSV, JSON, XLSX).

RapidMiner Studio (actualmente Altair AI Studio)

Aunque sin ser una cloud, tiene relevancia por ser una plataforma de software para el ciclo de vida completo de la ciencia de datos y el aprendizaje automático (ML), abarcando desde la preparación de datos hasta la creación y despliegue de modelos, centrándose en la automatización y la facilidad de uso mediante una interfaz gráfica de usuario con modelo de “cajas” (university, 2024).

- **Tipo:** Plataforma integral de Data Science y Machine Learning (desde ETL hasta MLOps básicos).
- **Capa Gratuita - RapidMiner Studio Free:**
 - **Funcionalidades:** Acceso a algoritmos de ML (clasificación, regresión, clustering, etc.), herramientas de preparación de datos, evaluación y visualización. Incluye capacidades de AutoML para la selección de modelos y optimización de hiperparámetros.
 - **Limitaciones:** Generalmente restringido en el número de filas de datos procesables en memoria y el número de operadores por proceso, adecuado para aprendizaje y proyectos de tamaño pequeño a mediano.
- **URL:** <https://altair.com/altair-rapidminer>

Nubes descentralizadas

Herramientas como estas: (Golem Network, s.f.; Akash, s.f.; Render Network, s.f.) podrían ser útiles en proyectos con exceso de potencia de computación, ya que se podría alquilar esta a cambio de tokens que más tarde se podría usar para las tareas intensivas cuando fuera necesario [Definición 9].

OpenNebula

Plataforma de código abierto con origen en España y EE.UU <https://openebula.io/>, la cual se centra en virtualización de centros de datos y gestión de nubes privadas, híbridas y públicas. Permite construir y gestionar infraestructuras IaaS (Infraestructura como Servicio) para cloud sobre la infraestructura de tecnología existente. Ofrece funcionalidades para el aprovisionamiento automático, es independiente del proveedor y soporta diversas interfaces de nube, proporcionando flexibilidad, control y soberanía de datos (Kumar et al., 2014; Vogel et al., 2016). Sin embargo, pese a ser una opción interesante, es posible que no se tenga en cuenta para este proyecto, que prioriza el acceso inmediato a hardware y servicios de IA gestionados sin coste inicial de infraestructura ni tiempo.

2.2.3. Trabajos anteriores y relacionados

La literatura referente a la computación en la nube es muy extensa, a parte de toda la literatura ya citada hasta ahora, citare algunos ejemplos mas, como el libro “**Cloud Computing Technology**” (Huawei Technologies Co.,

Ltd., 2023), aunque su traducción al inglés no es excelente, agrupa todos los conceptos del panorama cloud actual, así como los elementos que todas las nubes comparten entre sí, y da un panorama de la situación cloud en China, lo cual amplía los horizontes del conocimiento cloud. Otro libro: (Fowdur, 2021), cuyo capítulo 2 tiene interesantes definiciones sobre cloud. También el trabajo de (Nigro, 2022), que estudia las oportunidades, desafíos y antecedentes de la computación en la nube, o el trabajo de (Bommala et al., 2024), que tiene un enfoque muy interesante, denominando al ecosistema “cloud verde” y enfocándose en las innovaciones de los últimos años (infraestructuras de nube híbrida, modelos de computación sin servidor o “serverless”, “edge computing”, integración de IA, etc.) con un interesante enfoque en seguridad y cumplimiento de normativas, la integración de “blockchain” y el énfasis en la computación en la nube “verde sostenible”.

Aunque no únicamente dirigido a cloud, también vale la pena destacar portales o iniciativas que buscan opciones de código abierto o de fácil acceso a las tecnologías sobre las que trata el artículo y las cuales han sido de mucha ayuda, como la iniciativa de la Unión Europea (Union Europea, 2025a) o compilaciones como (R.I.Pienaar, 2025).

Por último, querría destacar trabajos de compañeros como **“Optimización de infraestructuras de Cloud Computing basadas en máquinas virtuales”** (Sánchez de Paz, 2023), el cual hace una excelente labor de investigación de todo lo relacionado con la computación en la nube para predecir el consumo futuro de recursos en máquinas virtuales de Azure (con sus datos públicos), y así mejorar la eficiencia y la gestión de la infraestructura.

2.3. Inteligencia Artificial

La Inteligencia Artificial (IA), y más específicamente el aprendizaje automático (ML), esta emergiendo como el paradigma tecnológico más transformador de la década y uno de los más importante de la historia [Definición 12]. Aunque desde sus inicios ha pasado por algunos “inviernos” (Cheok y Zhang, 2023), el lanzamiento de “ChatGPT” en 2022 catapulto la fama de esta tecnología [Figura A.3]. Estudios del ONTSI (Observatorio Nacional de Tecnología y Sociedad, 2025) revelan que en 2024, el 11,4 % de las empresas españolas de 10 o más empleados usaba IA, un dato ligeramente inferior a la media de la UE (13,5 %), aunque por encima de potencias como EE.UU. (5,7 % según OECD, o 7,3 % del total de empresas según BTOS). En cuanto a la población general, en 2024 un 73,8 % de los españoles tenían conocimiento de la existencia de la IA generativa, y un 56,8 % de la utilizó durante el año. Los datos de 2025 segun la encuesta del INE (Instituto Nacional de Estadística, 2025) aumentan aun más la cifra: el 21,1 % de las empresas españolas de 10 o más empleados utilizó tecnologías de Inteligencia Artificial en el primer trimestre de 2025.

Aunque esta fama viene dada por los modelos generativos basados en “transformers” y modelos generativos (Vaswani et al., 2017), la aplicación de esta tecnología va más allá de esto, el núcleo de esta revolución reside en el conjunto de herramientas algorítmicas para el análisis predictivo y la extracción de patrones en datos masivos, lo cual incluye los modelos generativos, pero no exclusivamente. En este proyecto se pretende utilizar ese potencial a través de plataformas cloud como Google Vertex AI, el uso de diferentes modelos de clasificación y clusterización o de detección de anomalías, con el propósito de intentar transformar el vasto volumen de datos públicos, a menudo infrautilizados, en “insights” o conclusiones de valor público.

También aclarar que, por acotar el alcance del proyecto, este trabajo no destacará avances en IA que traten datos multimedia, como vídeos, audios y imágenes, aunque reconocemos el increíble avance que han tenido tecnologías de visión por computador o creación de multimedia y su utilidad en LLMs multimodales, los cuales si entran en el “scope” del proyecto. Con esto en mente, en las siguientes secciones vamos a ver como aplicar el aprendizaje automático al proyecto, revisando los modelos tradicionales, tecnologías que proporcionan las nubes para usarlos, como el AutoML. Igual que para los datos se han tenido en cuenta ideas de gobernanza de datos, para la aplicación de los modelos se tendrán en cuenta los principios de las Operaciones de aprendizaje automático (MLOps) [Definición 14].

K-means (MacQueen, 1967)

2.3.1. Modelos de ML

Vamos a estudiar los modelos de aprendizaje automático pertinentes para el análisis predictivo y la extracción de patrones en datos. Aunque se pueden clasificar de varias maneras, clasificaremos los modelos por:

- Tipos de aprendizaje según la disponibilidad y calidad de etiquetas (supervisado, no supervisado ,por refuerzo, etc.) [Definición 13]
- La naturaleza de los datos (tabulares, no estructurados, etc.) [2.1.3]

Debido a la utilización principal de datos estructurados y semiestructurados, se priorizaran los modelos adaptados mejor a este tipo de datos (Fowdur, 2021).

Para la elección del modelo, seguiremos el siguiente esquema (Brownlee, 2024b):

Paso uno: ¿Se necesita predecir algo?

- **Si (Aprendizaje Supervisado):**
 - Si la predicción es sobre **categorías** → *Tarea de Clasificación*.
 - Si la predicción es sobre **datos temporales** → *Predicción de Series Temporales*.
 - Si la predicción es sobre **otras características** → *Tarea de Regresión*.
- **No (Aprendizaje No Supervisado):**
 - Si el objetivo es **encontrar grupos** → *Clusterización*.
 - Si el objetivo es **encontrar anomalías** → *Detección de Anomalías*.

Paso dos: ¿Qué tipo de datos tenemos?

- **Simple:** Datos Estructurados → Algoritmos ML Simples:
 - **Árboles de Decisión o k-Nearest Neighbors** (para clasificación / regresión)
 - **K-means** (para clusterización)
- **Intermedio:** Múltiples Características / Imágenes de Baja Resolución → Métodos de Ensemble:
 - **Random Forests, XGBoost** (para clasificación / regresión)
 - **DBSCAN** (para clusterización)

- **Complejo:** Imágenes / Texto / Audio $\rightarrow$ Algoritmos más complejos:
 - Redes Neuronales Profundas
 - Grandes modelos de Lenguaje (LLM)

Para tomar mejor las decisiones, se han estudiado estos modelos para comprobar su valor dependiendo del tipo de datos [Definición 14j]. Pero debido a que los modelos elegidos para cada conjunto de datos depende del tipo de los mismos (e incluso aun sabiendo el tipo de datos es difícil saber si cierto modelo funcionara mejor que otro), estos se detallaran para cada conjunto de datos en el apartado Sección 3.1.1: Materiales y datos.

2.3.2. ML en la nube

Todos los modelos que se han comentado, particularmente los más complejos, tienen algo en común, son bastante exigentes en el consumo de procesamiento, tanto de CPU, como sobre todo de GPU o TPU (Sze et al., 2017) Esta barrera de entrada hardware ha sido tradicionalmente un impedimento para investigadores, estudiantes y pequeñas organizaciones para ejecutar estos modelos, y en este punto es donde puede ser muy útil el paradigma de la computación en la nube y, sobre todo, los grandes proveedores con sus capas gratuitas, las cuales no solo proporcionan la infraestructura base para poder crear estos modelos, sino que además tienen herramientas especializadas para ello, facilitando la implementación de un ciclo de vida completo de Machine Learning (MLOps).

En este proyecto utilizaremos varias herramientas. En cuanto a los datos, los almacenaremos dependiendo de la nube utilizada para su procesamiento, pues cada una de las nubes puede comunicarse con un numero limitado y especifico de herramientas de almacenamiento. Los modelos entrenados se almacenaran también en la solución de almacenamiento de la propia nube (AWS S3, Azure Storage, etc.) cuando se requiera su uso, pero para entrenamiento o inferencia, a parte de las plataformas de MLOps comentadas, también merece la pena destacar opciones como “Kaggle notebooks” o “HuggingFace Spaces” que detallaremos en los siguientes apartados.

2.3.2.1. Plataformas MLOps en la Nube

Los principales proveedores de nube ofrecen plataformas completas diseñadas para gestionar el ciclo de vida de los modelos de ML (Böer, 2023):

- **Google Vertex AI:** Integra herramientas para todo el ciclo de vida del ML: preparación de datos, entrenamiento, despliegue y monitoreo en su GUI / CLI. Abstrae gran parte de la gestión de infraestructura

y ofrece comunicación con las principales herramientas de GCP como Bigquery. Además, ofrece una gran selección de modelos preentrenados de ML para diversos problemas, incluyendo modelos de Hugging Face, Stable Diffusion, etc. (Google, 2025b) .

- **AWS SageMaker:** Proporciona un conjunto completo de herramientas y servicios para construir, entrenar y desplegar modelos de ML a escala, incluyendo notebooks gestionados, algoritmos y entrenamiento distribuido. Soporta una amplia gama de fuentes de datos como S3, Athena, Redshift, Snowflake y Databricks(Amazon Web Services, 2025).
- **Azure Machine Learning:** Ofrece un entorno para el desarrollo y despliegue con herramientas para la preparación de datos, entrenamiento de modelos, gestión de experimentos y automatización de flujos de trabajo de ML, además de ofrecer modelos de Hugging Face y OpenAI. Sus fuentes de datos principales incluyen Azure Blob Storage, Azure File Share y Azure Data Lake, (microsoft, 2025).
- **OVHcloud (AI Notebook y AI Training):** Ofrece sus servicios "AI Notebookz" y "AI Training", con infraestructura gestionada, incluyendo acceso a GPUs, para el desarrollo y entrenamiento de modelos. No tiene un entorno tan potente como el resto de clouds, pero ofrece una capa gratuita generosa y localizada en Europa, (ovhcloud, 2025).

2.3.2.2. Otras herramientas

Además de las plataformas comentadas, existen herramientas especializadas de gran utilidad y con capas gratuitas que ya se ha comentado en [la sección de cloud 2.2.2], pero merece la pena concretar:

- **Kaggle Kernels/Notebooks:** Es ideal para análisis exploratorio de datos, competiciones de ML y entrenamiento de modelos intensivos (Kaggle, 2025a) por el acceso a sus GPUs.
- **Google Colab:** Alternativa excelente para el entrenamiento de modelos complejos, funcionando como un entorno de desarrollo gratuito con Jupyter Notebooks que ofrece GPUs y TPUs, especialmente popular por su facilidad de uso y su integración con el ecosistema de Google y GCP (Google, 2025c).
- **Hugging Face Spaces:** Plataforma dedicada al despliegue, compartición y descubrimiento de modelos de ML ya creados, muy útil para pruebas de concepto, permitir la prueba de modelos o utilizar los que la comunidad ha creado (huggingface, 2025).

También vale la pena destacar los grandes modelos generativos, los cuales presentan una capacidad de adaptación enorme, y aunque no están diseñados para la ingesta de grandes volúmenes de datos, el aumento de las ventanas de contexto (numero de tokens a los que el modelo “presta atención” (Vaswani et al., 2017)) ha hecho que tratar de utilizarlos para el tratamiento de datos tabulares **no sensibles** sea un caso que vale la pena considerar, siempre teniendo en cuenta estas consideraciones éticas y de privacidad.

Teniendo en cuenta la ventana de contexto de los modelos disponibles en junio de 2026 según el leaderboard de LLM Stats (LLM Stats, s.f.) y que un token son aproximadamente cuatro caracteres (Microsoft, s.f.c), se ha elaborado una tabla con la cantidad de datos tabulares que los principales modelos de LLM podrían asumir. Se consideran dos escenarios realistas:

- Una fila simple, con un identificador y una etiqueta corta (aproximadamente 50 tokens por fila).
- Una fila compleja, con varias columnas o una descripción de unas 100 palabras (aproximadamente 150 tokens por fila).

Tabla 2.1: Ventanas de contexto en tokens de principales LLM (Junio 2026), con su cálculo de filas de datos posibles que entrarían dentro de esa ventana.

Modelo	Proveedor	Tokens	nº filas a 50t	nº filas a 150t
Grok 4 Fast	xAI	2.000.000	40.000	13.333
GPT-5.5	OpenAI	1.100.000	22.000	7.333
Gemini 3.1 Pro	Google	1.000.000	20.000	6.666
Claude Fable 5	Anthropic	1.000.000	20.000	6.666
DeepSeek-V4-Pro-Max	DeepSeek	1.000.000	20.000	6.666
Qwen3.7 Max	Alibaba	1.000.000	20.000	6.666
GLM-5.2 (pesos abiertos)	Zhipu AI	1.000.000	20.000	6.666

Fuente: Elaboración propia con datos de LLM Stats (s.f.) (actualizado a junio de 2026).

Con estos datos se puede observar que los modelos más avanzados ya pueden procesar miles de filas tabulares simples en su ventana de contexto, lo que puede ser suficiente para muchos conjuntos de datos. Ya existen estudios que exploran estas capacidades (Fang et al., 2024).

2.3.2.3. AutoML

Como colofón a las estrategias de construcción de modelos, el Aprendizaje Automático Automatizado (AutoML) representa un conjunto de técnicas y herramientas que simplifican y aceleran el proceso de desarrollo del ML, reduciendo la complejidad de la implementación. Lo consiguen automatizando una, varias o todas las siguientes tareas:

- **Preprocesamiento de datos:** Limpieza y preparación de datos antes de entrenar el modelo.
- **Ingeniería de características:** Creación y selección automática de “features” relevantes.
- **Selección de modelo:** Evaluación automática de varios modelos para escoger el más adecuado.
- **Ajuste de hiperparámetros:** Optimización automática de los parámetros del modelo.
- **Evaluación del modelo:** Cálculo de métricas y generación de informes de desempeño.
- **Ensamblado y “stacking”:** Combinación de múltiples modelos para mejorar la precisión.
- **Reportes y documentación:** Seguimiento automático de todo el proceso de ML.
- **Despliegue y producción:** Implementación del modelo entrenado en un entorno productivo.

Aunque esta tecnología es muy útil para tratar grandes volúmenes de datos de forma rápida, también es muy costosa en cuanto a computación. por lo que no todas las nubes ofrecen sus herramientas propias, de todas formas las listaremos brevemente (Böer, 2023):

- **Google Vertex AI AutoML**
- **AWS SageMaker Autopilot**
- **Microsoft Azure AutoML**

Otra opción sería utilizar herramientas especializadas como “AutoKeras” (Jin et al., 2023) o “AutoSklearn” (Feurer et al., 2020) en la infraestructura que la nube proporciona. Estas librerías implementan soluciones interesantes de AutoML para clasificación.

2.3.3. IA, normativa y ética

También hay que tener en cuenta la nueva normativa que la Unión Europea ha establecido con el Reglamento de Inteligencia Artificial (Union Europea, 2024, 2026), así como el marco en el que este proyecto se engloba. Este reglamento se ha usado de base para el uso de IA en este proyecto, y aunque la mayor parte de las consideraciones éticas desarrolladas en los últimos años, se centran en modelos de procesamiento del lenguaje natural, (como los estudios conducidos por DeepMind) (Gabriel et al., 2024). En Este aspecto, el presente trabajo se compromete con la “Declaración Responsable sobre Autoría y Uso Ético de Herramientas de Inteligencia Artificial (IA) de la Universidad Complutense de Madrid” adjunta en el repositorio de este mismo proyecto. Pero además se compromete a seguir los siete estándares definidos por el reglamento de la Unión Europea en principios éticos de de la Unión Europea: Sección 3.2.2.2.

Para terminar, anteriormente se ha hablado sobre la obtención de “insights” automáticos: Es sabido que la IA acelera la identificación de patrones, pero para poder efectuar una interpretación estratégica se necesita el contexto de política pública y la validación humana experta. El principio HITL “humano en el bucle” (Mosqueira-Rey et al., 2023) es un requisito metodológico y ético para convertir patrones en decisiones, por lo que sera un requisito que seguiremos en este proyecto.

2.3.4. IA, normativa y ética

2.3.5. Trabajos anteriores y relacionados

Aunque ya se han nombrado varios anteriormente y en las [Definiciones 12], querría añadir algunas referencias mas, para empezar, el libro (Fowdur, 2021), cuyo capítulo 3 hace un profundo análisis sobre diferentes modelos de inteligencia artificial. También el libro (Brownlee, 2016) y todo el trabajo del autor en general, el cual ha sido de gran ayuda para afianzar los conceptos de esta sección.

También nombrar un par de trabajos muy interesantes sobre AutoML, que al abordar este tema, tratan todas las fases del ciclo completo de los algoritmos de aprendizaje automático. (Salehin et al., 2024) desglosa cada etapa del flujo de trabajo y explica cómo AutoML automatiza cada una. Destaca la búsqueda de arquitecturas neuronales (NAS), que automatiza el proceso de diseño de la arquitectura de una red neuronal, como motor del crecimiento del AutoML. Por otro lado, (Barbudo et al., 2023) se centra más en el campo de investigación de AutoML, con una taxonomía que clasifica todo el campo en fases, tareas y técnicas.

Por último, mencionar trabajos académicos de compañeros con ideas similares a la tratada en este estudio y que han ayudado a guiar el mismo:

- **“Análisis de datos de la ciudad de Madrid”** (Santos, 2023): Donde se realiza un análisis del impacto de la pandemia en la movilidad peatonal de Madrid con datos públicos del ayuntamiento (2019-2021). El autor utiliza el modelo ARIMA (Autoregresivo) para las series temporales, o K-means para clusterización de datos.
- **“Madrid, isla de calor”** (Meneses Vicente y García Ruíz, 2023): También analizando datos del Ayuntamiento de Madrid, esta vez del clima y la contaminación (2021). Los autores utilizaron clusterización, mayormente K-Means, para comprobar hipótesis sobre el clima en la ciudad.

De hecho, debido a la cercanía de estos trabajos, se ha contactado con sus autores para poder replicar y ampliar lo que hicieron en favor de poder desarrollar una metodología de tratamiento de datos públicos en la nube, y se utilizarán de base para el estudio posterior.

Capítulo 3

Materiales y métodos

En este capítulo describimos el proceso que se ha seguido en la realización del trabajo, empezando por los materiales: las distintas tecnologías, lenguajes de programación, conjuntos de datos y herramientas utilizados e incluso algunos de los valorados en el “capítulo 2: Estado de la cuestión”, pero descartados, así como los motivos para ello.

También se han definido los métodos de desarrollo y modelo de trabajo utilizados durante el proyecto, y por ultimo se explica como se puede utilizar la misma solución para replicar las conclusiones con estos u otros datos.

3.1. Materiales

3.1.1. Conjuntos de Datos

Los conjuntos empleados proceden del Portal de Datos Abiertos del Ayuntamiento de Madrid (Ayuntamiento de Madrid, 2026a), bajo licencia Creative Commons Attribution 4.0 (CC BY 4.0).

La ingesta se realizó de forma automatizada, registrando los metadatos de procedencia de cada fichero. La siguiente tabla 3.1 los resume.

El límite temporal inferior situado en 2019 responde a la disponibilidad real del dato, ya que la red meteorológica municipal se puso en marcha en 2018 y no existen registros anteriores (Ayuntamiento de Madrid, 2026b), limitando análisis que involucre meteorología a estas fechas.

Como limitaciones conocidas de estos conjuntos:

Conjunto	Cobertura	Uso
Calidad del aire (diario)	2019-2025	Isla de calor
Meteorología (diario)	2019-2025	Isla de calor
Masas arbóreas/distrito	2019-2025	Isla de calor
Estaciones de control	único	Georreferencia
Aforos de peatones	2019-2024	Movilidad
Aforos de bicicletas	2019-2024	Caso propio
Distritos (shapefile)	único	Cartografía

Tabla 3.1: Conjuntos de datos utilizados, su procedencia es (Ayuntamiento de Madrid, 2026a).

- No existen datos de arbolado de 2018 ni meteorológicos anteriores a 2019.
- Los aforos de peatones y bicicletas presentan un hueco de publicación de catorce meses (julio de 2021 a agosto de 2022) y alcanzan hasta junio de 2024.
- En la cobertura sensorial de las redes de medición, no todas las estaciones miden todas las magnitudes, lo que introduce valores ausentes.
- Los conjuntos de aforos cambiaron de esquema a mitad de serie (columnas renombradas, traducidas al inglés y con errores de codificación en origen), y el arbolado emplea tres denominaciones distintas para la misma magnitud de superficie según el año de publicación.
- El fichero de meteorología de 2024 no incluye diciembre, y la cobertura de la red municipal se degradó notablemente entre 2021 y 2022, coincidiendo con cambios en los sistemas de información municipales.

3.1.2. Nubes

3.1.2.1. Amazon Web Services

Amazon Web Services (AWS) es la plataforma líder mundial en computación en la nube, que proporciona recursos escalables y flexibles de todo tipo, lo que ha permitido construir, desplegar y gestionar aplicaciones sin la necesidad de poseer infraestructura física. Hemos utilizado AWS como primera nube, debido a la capa gratuita de 6 meses y su popularidad. Los primeros pasos han sido realizar los tutoriales de la web, lo cual permite contar con 100\$ extra para la capa gratuita.

Dentro de su catálogo, se emplearon los siguientes servicios gestionados como herramientas e infraestructura técnica:

- **Amazon S3 (Simple Storage Service):** Servicio de almacenamiento de objetos distribuido, altamente disponible y escalable.
- **AWS Glue (Python Shell):** Servicio de integración de datos (ETL) gestionado y *Serverless*. Se utilizó la modalidad *Python Shell*, un entorno de ejecución ligero que incluye de forma nativa librerías para ciencia de datos (**pandas**, **numpy**, **scikit-learn**).
- **AWS Glue Data Catalog** Catálogo de metadatos unificado y rastreadores automáticos encargados de descubrir e inferir esquemas sobre archivos estructurados.
- **AWS IAM (Identity and Access Management):** Servicio de gestión de identidades y accesos para la administración de usuarios, grupos y roles de servicio.
- **AWS CloudShell:** Entorno de terminal Linux basado en navegador con acceso autenticado y la interfaz de línea de comandos (*AWS CLI*) preconfigurada sobre la región activa.
- **AWS Budgets y Cost Explorer:** Herramientas de monitorización y control financiero para el seguimiento de costes mediante etiquetas de asignación.

3.1.2.2. Google Cloud Platform

3.1.3. Materiales para el desarrollo

3.1.3.1. Lenguajes

Los principales lenguajes utilizados para el desarrollo del proyecto han sido los siguientes:

- **Python:** Lenguaje de programación interpretado, multiparadigma y centrado en la legibilidad del código. Se ha elegido como lenguaje principal del proyecto por ser el estándar en ciencia de datos, dada su extensa comunidad y el amplio ecosistema de librerías orientadas al aprendizaje automático (detalladas en el apartado *Librerías especializadas*). Además, su alta adopción garantiza un soporte nativo en todas las nubes, facilitando la portabilidad del código, el despliegue de los modelos y la comparación de procesos entre plataformas.
- **Bash Script:** La interacción con las nubes se ha gestionado, en gran medida, mediante la ejecución de *scripts* de Bash en sus CLI con los comandos que estas mismas facilitan. También, se han desarrollado scripts específicos para tareas como la creación y preparación de los entornos.

Librerías especializadas

Para el tratamiento y modelado de la información en Python, se ha hecho uso intensivo de:

- **Pandas:** Para la limpieza, transformación y manipulación eficiente de datos tabulares y estructuras *DataFrame* en memoria (The pandas development team, 2026).
- **SciPy y Scikit-learn:** Para la implementación de algoritmos de aprendizaje automático (*Machine Learning*), estandarización de variables, cálculo de *clusters* y métricas de validación (The SciPy community, 2026; scikit-learn developers, 2026).
- **GeoPandas:** Extensión analítica empleada para las operaciones espaciales (*Spatial Joins*) y el cruce geométrico entre los puntos geográficos de las estaciones y los polígonos de los distritos de Madrid (GeoPandas developers, 2026).

3.1.3.2. Herramientas de desarrollo

Las siguientes herramientas y programas han sido esenciales para la elaboración del proyecto:

- **Visual Studio Code:** Visual Studio Code es un editor de código abierto desarrollado por Microsoft. Se ha utilizado Visual Studio Code como entorno de desarrollo software por la gran comunidad que tiene detrás, la cual mantiene extensiones y tutoriales al día. Incluye soporte para la depuración, control integrado de Git, resaltado de sintaxis, finalización inteligente de código, fragmentos y refactorización de código entre muchas otras funciones.
- **GitHub:** GitHub es una plataforma para alojar proyectos utilizando el sistema de control de versiones Git, que se utiliza principalmente para la creación, almacenamiento y control de código fuente. El de este proyecto en concreto es el siguiente: <https://github.com/crismo04/TFM-cloud-soliutions-to-public-data/>. Este sigue todas las recomendaciones de buenas practicas de github e incluye archivos como el changelog para poder ver los cambios y el Readme.md para resumir el proyecto.
- **L^AT_EXcon TeXstudio y MiKTeX:** Se ha usado L^AT_EX para desarrollar este documento en la aplicación de TeXstudio (como editor de L^AT_EX) y el compilador MikTeX (gestor de paquetes integrado). L^AT_EX es un sistema de composición tipográfica que incluye funcionalidades diseñadas para la producción de documentación técnica y científica. Es el estándar de facto para la comunicación y publicación de documentos científicos, el cual ha permitido desarrollar una memoria profesional y facilitar el diseño mientras se desarrollaba el proyecto.

3.2. Métodos

Para llegar a nuestro objetivo de diseño, se ha dividido la implementación en diferentes módulos conceptuales:

- **Búsqueda y almacenamiento de datos:** Localización de fuentes públicas, captura de sus metadatos y elección del mecanismo de descarga y almacenamiento.
- **Tratamiento básico de los datos:** Una vez almacenados, se procede a la depuración, resolución de inconsistencias, gestión de valores nulos, duplicados o atípicos y estandarización de esquemas. Las modificaciones se documentaron para poder ser replicadas.
- **Estudio con modelos de IA en diferentes nubes:** Con los datos tratados, se pasa a la elección de modelos algorítmicos y extracción de patrones y clústeres a partir de estos datos, para extraer conclusiones.
- **Comparación y estudio de resultados:** Tras el análisis se procede a la revisión de las hipótesis iniciales o extraídas de los modelos, y contraste de los resultados frente a los datos o trabajos de referencia.
- **Revisión, automatización y generalización del proceso:** Una vez finalizado el proceso, se refina con un análisis de mejoras y costos, para automatizar para siguientes iteraciones y mejorar tanto en los apartados, como abaratar en recursos y en tiempo.

Estos módulos se materializaron en el *pipeline* que se describe en la Sección 3.2.1. Para llegar a la solución, se han seguido las buenas prácticas del tratamiento de los datos, así como las de MLOps y las recomendadas por cada una de las nubes utilizadas. Estos conjuntos de buenas prácticas se detallarán más adelante en este mismo capítulo.

Para empezar las primeras iteraciones, se optó por conjuntos de datos que ya habían sido estudiados previamente y a los que se tenía acceso a conclusiones. Estos son los trabajos de “**Madrid, isla de calor**” (Meneses Vicente y García Ruíz, 2023) y “**Análisis de datos de la ciudad de Madrid**” (Santos, 2023), compañeros de la UCM que trataron datos públicos del Ayuntamiento de Madrid y extrajeron conclusiones. Como primera toma de contacto, se replicaron sus conclusiones y se extendió el análisis a años posteriores a los que estos trabajos estudiaron, complementando así sus estudios.

Tras esta primera fase, se incorporaron también otros conjuntos del mismo

portal, aumentando la cobertura temporal de ambos trabajos hasta 2025, y ampliándolo con un conjunto no tratado por estos: los aforos de bicicletas, para comprobar que la metodología generaliza a datos nuevos sin problemas.

El detalle de los conjuntos se recoge en la Sección 3.1.1.

3.2.1. Desarrollo de la solución

Para poder ingestar y procesar estos datos de forma automática, se creó un conjunto de procesos en Python que implementa los pasos del desarrollo, configurados por un único fichero “config.py”. El *pipeline* se ejecutó primero íntegramente en local con un doble propósito: validar la replicación de los trabajos originales en un entorno controlado antes de introducir la variable de la nube, y establecer una línea base para comparar posteriormente con las implementaciones en cada nube en términos de esfuerzo, tiempo de ejecución y coste. Se describen a continuación sus etapas, siguiendo el orden de los módulos.

Las fases y sus ficheros correspondientes en local y el GIT del proyecto han sido:

Fichero	Etapas	Salida
config.py	Parametrización	—
01_descarga.py	Ingesta automatizada de datos	Capa bronce
02_limpieza.py	Normalización y limpieza	Capa plata
03_analisis_isla_calor.py	Análisis y modelado	Resultados

Tabla 3.2: Correspondencia entre los procesos del *pipeline* y las etapas de la arquitectura de medalla.

Estas etapas se describen en más detalle a continuación.

3.2.1.1. Ingesta automatizada de datos

La descarga, se estudio primero como descarga manual en los portales, pero se implementó como un proceso programático y reproducible. El portal opera sobre la plataforma CKAN (Open Knowledge Foundation, 2026b) (API REST), versión 2.9.11, dos ramas por detrás de la versión estable disponible en el momento de redactar este trabajo, lo que ya es un dato sobre el mantenimiento de la infraestructura de publicación de estos datos. Sobre esta, el proceso resuelve el identificador de cada conjunto y consulta sus recursos mediante la acción `package_show` (Open Knowledge Foundation, 2026a), descargando los datos que cumplen los criterios configurados (año, formato y subserie).

El diseño aporta tres propiedades relevantes para la gobernanza del dato: es **idempotente** (re-ejecutarlo no vuelve a descargar lo ya presente, permitiendo automatización periódica), registra **metadatos** de procedencia por fichero (origen, fecha, tamaño y licencia) y abstrae el destino de almacenamiento mediante fsspec (fsspec developers, 2026), de modo que el mismo código escribe en disco local o en el almacenamiento de cualquiera de las nubes evaluadas sin cambios en su lógica.

Esta automatización tuvo sus complicaciones. El portal, pese a declarar sus datos como abiertos, dificulta la automatización de la descarga, ya que incorpora protección anti-bot que penaliza descargas sucesivas, y su interfaz JavaScript no expone los enlaces en el HTML inicial.

El proceso incorpora pausas entre descargas y re-intentos con espera creciente para consumir de forma fiable la API. Esta fricción entre apertura declarada y reutilización efectiva ilustra en la práctica las limitaciones que la literatura señala sobre el estado real de los datos abiertos (Verhulst et al., 2020; OECD, 2023).

3.2.1.2. Normalización y limpieza

La limpieza se organizó por tipos de fichero en lugar de por conjunto aislado. Los ocho conjuntos estudiados se reducen a cuatro patrones: series mensuales con columnas de validación, aforos horarios, tablas anuales y ficheros únicos. Las reglas para tratar estos ficheros se han declarado en configuración para facilitar el añadir más tipos de datos a futuro. Para las series de calidad del aire y meteorología se replicó la lógica del trabajo original (Meneses Vicente y García Ruíz, 2023), donde solo se aceptaron valores marcados como verificados por el portal, y se descartaron las fechas imposibles del formato mensual. El proceso tuvo que resolver, además, varias inconsistencias de los ficheros publicados, como formatos de fecha distintos entre años en el mismo conjunto que obligaron a detectar el formato de estos, decimales con coma (varios, ya que es la convención española), cambios de esquema a mitad de serie (con columnas renombradas, en inglés e incluso corrompidas por errores de codificación en origen), y ficheros CSV que incorporan filas de totales y notas al pie destinadas a lectura humana.

Todas estas transformaciones quedaron registradas en el código publicado para garantizar su reproducibilidad.

3.2.1.3. Análisis y modelado

Sobre los datos limpios se implementó un módulo de análisis por cada caso de estudio, aplicando tanto las mismas técnicas que los trabajos de referencia,

como técnicas propias que se detallan a continuación.

Para la isla de calor se replicaron las cinco aproximaciones de agrupamiento del trabajo original (Meneses Vicente y García Ruíz, 2023):

1. **Siete magnitudes meteorológicas:** velocidad y dirección del viento, temperatura, humedad relativa, presión barométrica, radiación solar y precipitación, sobre las estaciones que miden todas ellas.
2. **Temperatura y humedad relativa:** sobre las estaciones que disponen de ambas magnitudes.
3. **Temperatura y superficie arbórea:** sobre las estaciones con temperatura cuyo distrito publica datos de masas arbóreas.
4. **Dióxido de nitrógeno (NO₂):** sobre todas las estaciones de la red de calidad del aire.
5. **Dióxido de nitrógeno y partículas:** NO₂, PM_{2,5} y PM₁₀, sobre las estaciones que miden las tres.

Sobre la media anual de cada estación estandarizada, se aplicó *k-means* y agrupamiento jerárquico de *Ward*, conservando el número de grupos y la semilla que se escogió en el trabajo original, de modo que las diferencias observadas se pudieran atribuir a los datos. Para fijar el número de grupos se utilizó el método del codo, al igual que en el estudio original, para representar la inercia (suma de distancias cuadráticas al centroide) del número de grupos considerado. Se localizó el punto a partir del cual deja de descender de forma apreciable. Para la calidad de los agrupamientos se validó con el coeficiente de silueta, que se comentará más adelante. También se incorporó un cruce geoespacial entre las estaciones y los distritos, mediante el *shapefile* municipal, para contrastar la hipótesis de relación entre superficie arbórea y temperatura.

Para facilitar la prueba, se creó un resumen automático entre años que tabula las métricas de las ejecuciones y señala valores que se desvían.

Durante la replica, se ha tenido que resolver ciertas discrepancias entre la ejecución y la descripción del trabajo original: La primera, es que su tercera aproximación agrupa las estaciones por temperatura y superficie arbórea del distrito, y no solo por temperatura como definen. Ambas variables residen en conjuntos distintos y con granularidad diferente (estación-día frente a distrito-año), hemos resuelto la discrepancia mediante el cruce geoespacial. La segunda, es que el criterio declarado para seleccionar las estaciones (es decir, disponer de datos de masas arbóreas) excluye a los distritos que publican una superficie nula, interpretación que se adoptó al reproducir esa aproximación. Esto se conserva en la replica, pero en el análisis de correlación, los distritos sin superficie arbórea se conservan, ya que un distrito sin

masas arbóreas y con temperatura elevada es precisamente una observación que sostiene la hipótesis.

Sobre esta base se introdujeron tres mejoras metodológicas propias: La primera es un criterio de cobertura mínima: la media anual de una estación solo se considera válida si supera un número mínimo de días con dato, ya que una estación que operó únicamente durante una pequeña parte del año produce una media sesgada hacia la estación climática en que estuvo activa. La segunda, armonización de la superficie arbórea, que el portal publica con denominaciones y unidades distintas según el año, derivando las hectáreas de los metros cuadrados cuando la primera magnitud no se publica. La tercera, se validó la calidad con el coeficiente de silueta, que mide en qué grado cada observación está más próxima a su propio grupo que al vecino más cercano, sin depender de escala o variables, lo que hace comparables los resultados entre años, aproximaciones y plataformas cloud.

El criterio de cobertura se controla mediante un parámetro de configuración que permite ejecutar el análisis con las condiciones del trabajo original o aplicando los criterios propios, lo que hizo posible el análisis de sensibilidad recogido en el Capítulo 4.

Para la movilidad peatonal se replicó la predicción de series temporales del segundo trabajo (Santos, 2023),

El detalle de cada técnica y su fundamento se recoge en la Sección 3.2.3.

3.2.2. Métodos utilizados: Datos

Para tratar los datos a través del método principal de desarrollo, se ha seguido principios de gobernanza de datos:

3.2.2.1. Aplicación de la gobernanza de datos como método

Como ya se ha definido en la Sección 2.1.4: Estudios de datos y gobernanza, La gobernanza de datos en este proyecto se implementó adoptando este modelo de tres capas (Estratégica, Táctica y Operativa o de entrega). El objetivo fue garantizar que el proceso de análisis, adquisición y almacenamiento de datos públicos y la obtención de valor mediante IA, se ha realizado de forma ética, segura, y en pleno cumplimiento del marco regulatorio actual. En cuanto a las tres capas, aunque cobran mayor importancia en proyectos grandes con múltiples equipos y no en trabajos de una sola persona, se han adaptado a este trabajo por la estructura metodológica que proponen y la utilidad en cuanto a la gestión de datos y procesos:

1. Capa Estratégica: Liderazgo y Visión

En esta capa se definieron los objetivos generales y principios de la gobernanza de datos en el proyecto.

- **Visión:** Convertir los datos abiertos en generadores de conocimiento mediante técnicas de inteligencia artificial y tecnologías cloud.
- **Seguridad y soberanía:** Aunque se utilizan servicios de nubes públicas por su acceso gratuito, capas de seguridad y capacidades en IA, se configuraron para operar dentro de la UE.
- **Transparencia y reproducibilidad:** Todo el proceso (origen de datos, transformaciones, código, y resultados de modelos) se documentó en esta misma memoria para garantizar la transparencia y la posibilidad de auditar o reproducir el análisis, de acuerdo a los principios de la Unión Europea: Sección 3.2.2.2.

2. Capa Táctica: Capacidades de Implementación y Marco Normativo

Esta capa detalla cómo se implementa la estrategia a través de políticas, procesos, directrices, etc:

- **Uso del dato:** Se priorizaron datos públicos abiertos de administraciones españolas y de la Unión Europea, prestando especial atención a

las licencias para asegurar la legalidad de su reutilización y evitando el uso de datos sensibles. Respecto a datos sensibles se aplicó un principio de precaución: cualquier conjunto de datos con riesgo de contener información sensible fue filtrado y descartado.

- **Gestión de accesos y credenciales:** Como único usuario, se gestionan las credenciales de acceso a los servicios cloud con el máximo nivel de seguridad, evitando su filtración a repositorios públicos o terceros.
- **Competencias y coordinación:** Todas las funciones fueron asumidas por un único investigador, esto centralizó la toma de decisiones y facilitó el cumplimiento normativo y la trazabilidad de todo el proceso. De todas formas se utilizan herramientas como “Git” o “Trello” para auto-organizarse.
- **Selección de proveedores y servicios:** Para la selección de plataformas cloud se evaluó la capacidad para proporcionar entornos de procesamiento seguro, y la localización de sus centros de datos para asegurar el cumplimiento normativo. En cuanto a la IA, también se revisaron sesgos en los datos de entrenamiento.

3. Capa Operativa: Infraestructura, Integración del Ciclo de Valor y Arquitectura

Esta última capa corresponde a la implementación práctica de la estrategia, la gestión diaria del ciclo de valor de los datos para integrarlo con la infraestructura técnica.

- **Infraestructura:** Se emplearon servicios en la nube principalmente para el almacenamiento, procesamiento y análisis de los datos. Los entornos se han configurado con mecanismos de seguridad estándar. Aunque una de las ideas de este proyecto es el tratamiento de datos con el menor número de recursos posibles, también se usaron dispositivos on-premise (computador personal) para la ingesta de datos y posterior almacenamiento en cloud cuando esto facilitó el proceso, aunque se priorizaron tecnologías en la nube.
- **Arquitectura de datos y ciclo de valor:** Se diseñó un flujo simple de trabajo centrado en cloud y basado en la ingesta de datos abiertos de fuentes oficiales que cubrió todo el ciclo de vida del dato:
 - **Adquisición:** Se descargaron conjuntos de datos abiertos, registrando metadatos sobre origen, licencia, calidad, formato y condiciones de uso.
 - **Almacenamiento y gestión:** Se organizaron en buckets con es-

estructura clara siguiendo la arquitectura de medalla [Definición 11]. Este enfoque facilitó la exploración, el modelado y la generación de valor con herramientas nativas como BigQuery. El almacenaje depende de la herramienta propietaria de cada nube (S3 para amazon, cloud storage para GCP, etc.).

- **Procesamiento y transformación:** Se realizó la limpieza y estandarización de los datos descargados, descartando fuentes sensibles. [TODO] Se realizó feature engineering en entornos gestionados como nativos en la nube como Vertex AI Workbench. Se mantuvo un registro de los experimentos realizados (hipótesis, parámetros, versiones de modelos) para asegurar reproducibilidad y transparencia.
- **Uso/compartición:** Se utilizaron diversas técnicas de IA para la identificación de patrones en los datos y se han publicado los resultados bajo licencias abiertas, priorizando la transparencia.
- **Optimización y sostenibilidad:** Se monitorizó el uso de recursos en las diferentes nubes para mantener el proyecto dentro del coste cero, también se optimizaron las configuraciones de los servicios para asegurar la eficiencia tanto económica como ecológica del proyecto.

3.2.2.2. Principios éticos

Destacar también que en el proyecto, se siguieron rigurosamente los siete principios éticos de la IA definidos por el reglamento de la Unión Europea (Union Europea, 2024, 2026):

- **Acción y supervisión humanas:** En este trabajo se supervisó tanto cada etapa del desarrollo, como los resultados. Se descartaron aquellos que no cumplieran con los criterios éticos establecidos.
- **Solidez técnica y seguridad:** Se veló por la mayor excelencia técnica y se definieron principios de seguridad tanto para los datos como para los modelos.
- **Gestión de la privacidad y de los datos:** Se ha abordado todo el proyecto cumpliendo con los principios del RGPD, como se indica en la sección de datos.
- **Transparencia:** Se documentaron los procesos, algoritmos utilizados y decisiones tomadas durante el desarrollo para asegurar que el proceso fuera comprensible y reproducible. También se documentaron los casos en los que se recurrió a la Inteligencia Artificial, indicando claramente las razones para esto, y cumpliendo con la declaración responsable

sobre autoría y uso ético de herramientas de IA de la UCM. Los usos se detallan en el apéndice B.

- **Diversidad, no discriminación y equidad:** Se comprobaron los sesgos de los datos y algoritmos utilizados, decisiones tomadas y resultados obtenidos, con el objetivo de identificar y mitigar potenciales discriminaciones o sesgos.
- **Bienestar social y ambiental:** El motivo último de este trabajo es el procesamiento de datos públicos para mejorar el valor de los mismos y, mediante su aplicación, el bienestar social en general.
- **Rendición de cuentas:** Se mantuvo un registro detallado de las decisiones de diseño, preprocesamiento de datos y selección de modelos, para permitir una auditoría clara y una rendición de cuentas transparente.

3.2.3. Métodos utilizados: Aprendizaje automático

Para la fase de extracción de valor se emplearon las siguientes técnicas de aprendizaje no supervisado y estadística, adecuando cada una a la naturaleza de los datos:

- **K-Means:** Algoritmo de agrupamiento no supervisado (*clustering*) que particiona el espacio de datos en un número k de grupos basándose en la distancia geométrica a sus centroides. Se seleccionó por su eficiencia para descubrir zonas térmicas diferenciadas sin necesidad de etiquetas previas.
- **Agrupamiento Jerárquico (Método de Ward):** Algoritmo aglomerativo que minimiza la varianza intra-clúster en cada iteración de agrupación. Método idóneo para generar dendrogramas, permitiendo visualizar la jerarquía y las asociaciones climatológicas de las estaciones de control.
- **Coefficiente de correlación de Pearson:** Métrica estadística utilizada para evaluar la fuerza y dirección de la relación lineal entre dos variables continuas. Se aplicó para validar numéricamente hipótesis espaciales, como la relación inversa entre la temperatura media y la superficie arbórea.
- **Modelado de Series Temporales:** Para los datos de aforos de movilidad (peatones y bicicletas), se aplicaron técnicas de predicción secuencial comparando el error sobre tramos de validación.

Previo a la aplicación de los algoritmos basados en distancias (como K-Means o el método de Ward), se aplicó una **estandarización** a las variables métricas, asegurando una media nula y varianza unitaria. Esto previene que las magnitudes con escalas absolutas mayores (como presión atmosférica) dominen matemáticamente sobre las menores (como velocidad del viento) en el cálculo iterativo de las distancias.

3.2.4. Métodos utilizados: Cloud

El despliegue de las capas de almacenamiento, procesamiento y analítica sobre plataformas en la nube se ha abordado bajo una metodología común para evaluar la dificultad de implementación, viabilidad, rendimiento y coste de ejecutar un mismo *pipeline* de datos abiertos sobre diferentes proveedores. Esta estrategia reutiliza el enfoque de arquitectura por capas (*Medallion Architecture*) definido en la [Definición 11], que es el mismo que se ha seguido en local. Este se combinara con las buenas prácticas específicas de diseño y gobernanza generales del desarrollo en la nube y las específicas de cada proveedor.

3.2.4.1. Métodos utilizados en Amazon Web Services (AWS)

La especificación técnica paso a paso, la sintaxis completa de los comandos ejecutados en la CLI y el procedimiento de despliegue reproducible de cada uno de estos métodos se detallan en el manual de usuario disponible en la Sección 5.2.1. Aquí, definiremos una arquitectura más a alto nivel de las decisiones tomadas, así como los métodos utilizados, pero se puede consultar todo el manual de arquitectura y buenas practicas en la web de AWS (Amazon Web Services, 2026a).

1. **Arquitectura de medalla:** Aunque no es única de la nube, hay aspectos particulares que merece la pena comentar para el almacenamiento específico en Amazon S3 dividida en las capas: Se aplicó un bloqueo de acceso público para evitar la modificación externa, se activó el versionado para asegurar la inmutabilidad y trazabilidad, y se asignaron etiquetas para poder medir el coste en todas las capas del proceso.
2. **Procesamiento ETL Serverless de bajo cómputo:** Como método de transformación, se descartó el uso de clústeres distribuidos (*Apache Spark*) debido a que el volumen de datos (272 MB en la capa bronce) no requería demasiada computación. Se optó por una ejecución mediante *AWS Glue Python Shell* y la propia *AWS CLI*, garantizando tiempos de arranque inmediatos y un consumo mucho menor por ejecución, gestionando el almacenamiento desde los contenedores de S3.
3. **Infraestructura como Código (IaC) y Gestión de Dependencias:** Para garantizar la reproducibilidad, el despliegue del trabajo ETL se definió de forma declarativa mediante comandos y plantillas JSON definidas en el 5.2.1. Los módulos propios de configuración (*config.py*) se empaquetaron en formato estándar de distribución de Python (*Wheel*, *.whl*), para gestionar las dependencias junto al *requirements.txt*

4. **Gobernanza de identidades (RBAC) y control financiero (*FinOps*):** Implementación del principio de menor privilegio y control de costes mediante:

- **Uso de credenciales temporales:** Se utilizó *AWS CloudShell* para operar con las credenciales de la sesión web, evitando el almacenamiento de claves fijas (*Access Keys*) en local.
- **Segregación de permisos:** Se definieron roles IAM de servicio (*AWSGlueServiceRole-tfm*) con acceso restringido exclusivamente a las rutas necesarias de S3 para el procesamiento en *AWS Glue*.
- **Mecanismos de contención de gasto:** Se desactivaron los reintentos automáticos (`max-retries 0`) y establecimiento de tiempos máximos de ejecución (`timeout`) en los trabajos de *AWS Glue*, además de la monitorización presupuestaria mediante *AWS Budgets*.

Se valoró el empleo de los modelos pre-entrenados de *AWS SageMaker*, pero se descartaron por ser una solución sobre-dimensionada a este problema. El conjunto de análisis está formado por unas pocas decenas de observaciones con menos de diez variables, un tamaño para el que los algoritmos de agrupamiento clásicos resultan más apropiados.

3.2.4.2. Métodos utilizados en Google Cloud Platform (GCP)

Al igual que en la sección anterior, toda la especificación técnica paso a paso y el procedimiento de despliegue por comandos de cada uno de estos métodos aquí descritos, se detallan en el manual de usuario disponible en la Sección 5.3.1. La arquitectura general se rige también por las directrices y buenas practicas de GCP (Google Cloud, 2026), aplicando en concreto las siguientes decisiones de diseño:

1. **Arquitectura de medalla en Cloud Storage:** La jerarquía de almacenamiento (*Bronze*, *Silver*, *Gold*) se replicó utilizando un contenedor (*bucket*) de Google Cloud Storage. Como mecanismo de seguridad moderno, se aplicó la política de Prevención de Acceso Público (*Public Access Prevention*) de forma nativa, bloqueando cualquier exposición a internet. También se habilitó el versionado y el etiquetado de recursos.
2. **Evaluación de servicios serverless para el procesamiento ETL:** Para la fase de transformación se analizaron dos opciones de cómputo desatendido, ambas descartadas tras las pruebas iniciales.
 - **Cloud Run Jobs:** Este servicio permite ejecutar procesos por lotes en contenedores sin necesidad de escribir un `Dockerfile` explícito, gracias a la integración con *Cloud Build* y los *Buildpacks* de Google. Se preparó un fichero `Procfile` con la instrucción de arranque (`python3 02_limpieza.py`) y un `.gcloudignore` para excluir archivos locales. Sin embargo, el despliegue resultó fallido: el contenedor se construía correctamente pero la ejecución terminaba con el error “`Application exec likely failed`”, sin registros de aplicación. Se comprobó que el problema estaba relacionado con la detección del punto de entrada en procesos que no son servicios web, y que los *Buildpacks* no resolvían adecuadamente el comando de arranque para este tipo de tareas. Aunque se intentó forzar el comando con `-command python3` y ajustar la memoria, no se logró un arranque exitoso.
 - **Cloud Functions:** Como alternativa, se desplegó una función HTTP (2ª generación) que ejecutaba el script de limpieza mediante `subprocess`. El despliegue fue correcto y la función respondía a las invocaciones, pero al intentar acceder a los datos en *Cloud Storage* mediante la librería `gcsfs`, el sistema no autenticaba las credenciales de forma automática desde el entorno serverless. Como resultado, la función no encontraba los ficheros de entrada a pesar de que las rutas y los permisos del *bucket* eran correctos. Se añadieron permisos adicionales a la cuenta de servicio y se ajustó la variable de entorno `TFM_BASE`, sin éxito.

Ambas soluciones son técnicamente viables con configuración adicional (como la definición explícita de un **Dockerfile** o la gestión manual de claves de servicio), pero se descartaron para priorizar la simplicidad y la reproducibilidad del flujo de trabajo, dado el reducido volumen de datos del proyecto.

3. Procesamiento y análisis integrados en Vertex AI Workbench:

Finalmente, se optó por unificar las fases de limpieza y análisis en *Vertex AI Workbench*, un entorno gestionado de *JupyterLab*. Esta decisión simplificó la gestión de credenciales (al heredar las del usuario), evitó la configuración de identidades adicionales y permitió ejecutar los scripts originales sin modificaciones. El mismo entorno interactivo se utilizó tanto para la transformación como para el modelado, lo que redujo el coste y el esfuerzo de despliegue.

4. Gobernanza de recursos y aislamiento (*Sandbox*):

- **Aislamiento de proyecto:** El entorno se desplegó de forma deliberada fuera de la jerarquía de la organización principal (*No organization*) para evitar heredar políticas restrictivas (como bloqueos de red) y mantener la facturación separada del entorno corporativo.
- **Gestión de identidades:** Se aprovechó la pre-autenticación de *Google Cloud Shell* y la librería **gcsfs** para acceder al almacenamiento sin necesidad de exportar ni gestionar claves de cuentas de servicio (*Service Account Keys*) localmente, minimizando los riesgos de seguridad.

Capítulo 4

Resultados

En este capítulo se recogen los resultados obtenidos con el proyecto, organizados en tres bloques, al igual que el resto de la memoria: los hallazgos relativos a la calidad y continuidad de los datos publicados, los resultados de los análisis realizados sobre ellos y los métodos de aprendizaje automático utilizados, y la comparación entre la ejecución local y las diferentes plataformas cloud evaluadas.

4.1. Hallazgos sobre la calidad de los datos publicados

4.1.1. Evolución no documentada de los esquemas

4.1.2. Continuidad de la publicación y cobertura de la red

4.2. Resultados del análisis de aprendizaje automático: isla de calor

4.2.1. Replicación del trabajo de referencia

La replica se evaluó comparando, para cada par de estaciones, si ambos trabajos las asignan al mismo grupo o a grupos distintos. Este criterio evita el problema de que las etiquetas de grupo son arbitrarias y no tienen por qué coincidir entre dos ejecuciones. El acuerdo global alcanzó el 86 % de los pares evaluados, con el detalle por aproximación que recoge la Tabla 4.2. Para el caso de esta memoria, el año utilizado, sobretodo en los diagramas,

Problema	Manifestación	Efecto
Nomenclatura	Tres denominaciones para la superficie arbórea	Pérdida de la variable en algunos años
Unidades	2019 publica m ² , 2020 en adelante m ² y ha	Serie incompleta
Formato numérico	Separador de millar solo desde 2022	Valores no convertibles a número
Semántica	Masa forestal frente a masa arbórea	Serie no comparable entre años
Entidades	Distritos escritos de forma distinta en el mismo fichero	Cruce vacío sin error
Continuidad	Hueco de 14 meses en aforos y diciembre de 2024 ausente	Series discontinuas
Cobertura	Estaciones que no miden todas las magnitudes	Análisis inviables

Tabla 4.1: Patologías de calidad detectadas en los conjuntos publicados y su efecto sobre la reutilización automatizada.




Figura 4.1: Días válidos de temperatura por estación y año. Se aprecia la degradación de la subred municipal (códigos 1xx) durante 2021 y 2022.

es el 2021, ya que es el año que tiene de base el trabajo original. Pero el resto de análisis se pueden encontrar publicados en github

Aproximación	Original	Réplica	Comunes	Acuerdo
1. Siete magnitudes	8	7	6	87 %
2. Temperatura y humedad	16	21	16	97 %
3. Temperatura y arbolado	12	15	9	94 %
4. NO ₂	24	24	24	80 %
5. NO ₂ y partículas	7	8	7	100 %
Total				86 %

Tabla 4.2: Replicación del agrupamiento de (Meneses Vicente y García Ruíz, 2023) para 2021. Las tres primeras columnas indican el número de estaciones empleadas en cada trabajo y las comunes a ambos, y la última el porcentaje de pares de estaciones agrupados de igual forma.

La quinta aproximación replicó la partición original de forma exacta y la segunda difirió en una de dieciséis estaciones. En la segunda aproximación la única estación que cambia de grupo es El Pardo, que en el trabajo original se agrupa con el Centro Municipal de Acústica y en la réplica con Casa de Campo y Juan Carlos I. En la cuarta aproximación, que agrupa las estaciones por una única variable, ambas particiones coinciden en las estaciones con menor y mayor concentración de dióxido de nitrógeno, y difieren en los puntos de corte intermedios. En la primera aproximación se detectó una inconsistencia interna del trabajo replicado, ya que su texto declara seis estaciones seleccionadas por disponer de las siete magnitudes, mientras que su figura muestra ocho, dos de las cuales no miden presión ni radiación solar según el propio inventario de estaciones del portal. La réplica siguió el criterio declarado y añadió la estación de Peñagrande, que comenzó a registrar datos en el año analizado y no estaba disponible cuando se realizó el trabajo original.

4.2.2. Relación entre superficie arbórea y temperatura

La relación inversa entre superficie arbórea y temperatura media por distrito se mantuvo en los siete años analizados, con valores comprendidos entre $-0,26$ y $-0,47$ y una media de $-0,37$ (Tabla 4.3). El trabajo original observaba esta relación en un único año y de forma cualitativa, la extensión temporal permite afirmar que no se trata de una particularidad de ese periodo, sino de un patrón sostenido, aunque de intensidad moderada, lo que sugiere factores no controlados, que discutiremos en la Sección 4.2.5.

En la Figura 4.2 se aprecia el patrón esperado, ya que los distritos sin masas arbóreas registran las temperaturas más altas, mientras que los de mayor superficie arbórea presentan las medias más bajas. Destaca sin embargo Puente

Año	Réplica		Criterio propio	
	Pearson r	Distritos	Pearson r	Distritos
2019	-0,686	14	-0,462	14
2020	-0,293	14	-0,392	12
2021	-0,215	14	-0,416	13
2022	-0,258	15	-0,471	9
2023	-0,049	15	-0,264	15
2024	-0,334	15	-0,285	14
2025	-0,315	15	-0,315	15
Media	-0,307		-0,372	

Tabla 4.3: Correlación de Pearson entre superficie arbórea y temperatura media por distrito (2019-2025), reproduciendo las condiciones del trabajo original, y aplicando el criterio de cobertura mínima propio.

de Vallecas, que pese a disponer de una superficie comparable a la de los distritos más frescos resulta ser el más cálido del conjunto, lo que apunta a la influencia de factores no considerados en el análisis.




Figura 4.2: Relación entre superficie arbórea y temperatura media por distrito, año 2021.

4.2.3. Análisis de sensibilidad

La comparación entre ambas configuraciones (Figura 4.3) muestra que el criterio de cobertura mínima no debilita la relación, sino que la refuerza, ya que la correlación media pasa de $-0,31$ a $-0,37$ y desaparecen los años

anómalos. El caso de 2023 resulta ilustrativo. Reproduciendo las condiciones originales la correlación es prácticamente nula, con un valor de $-0,05$, lo que llevaría a concluir que ese año no existió relación alguna. El motivo es que un distrito con una única estación parcialmente operativa aportaba una media anual de $12,5$ grados frente a los $18,4$ grados del año anterior, recuperando el comportamiento esperado.

Resulta significativo que ambas configuraciones converjan en 2024 y 2025, precisamente los años en que la red operó con normalidad, y diverjan en los años afectados por la degradación de la red o por el cambio de definición de la variable. El criterio propuesto, por tanto, no altera los resultados cuando los datos son completos, únicamente corrige aquellos años en que la media anual no era representativa. En sentido contrario, el criterio reduce el número de distritos disponibles en los años de menor cobertura, hasta un mínimo de nueve en 2022, por lo que las correlaciones de esos años deben interpretarse con cautela.




Figura 4.3: Evolución de la correlación entre superficie arborea y temperatura media por distrito (2019-2025) en ambas configuraciones del análisis.

4.2.4. Evaluación de los agrupamientos

Los agrupamientos revelaron una relación inversa y sistemática entre el número de variables empleadas y la calidad de los grupos obtenidos (Tabla 4.4). La aproximación basada en una única magnitud, el dióxido de nitrógeno, alcanzó la mejor silueta media, seguida de las dos aproximaciones con dos variables, mientras que la que emplea las siete magnitudes meteorológicas obtuvo sistemáticamente los peores valores, hasta el punto de resultar inviable en 2022 por varias causas: Por un lado, al aumentar la dimensionalidad las distancias entre observaciones tienden a igualarse y los grupos pierden definición. Por otro, exigir que una estación disponga de todas las

magnitudes reduce drásticamente la muestra, de las veinticuatro estaciones disponibles para el dióxido de nitrógeno a apenas cinco o siete para el conjunto meteorológico completo. La heterogeneidad de la cobertura sensorial de la red no solo introduce valores ausentes, también condiciona qué análisis resultan viables.

Año	7 magn.	T + HR	T + arb.	NO ₂	NO ₂ + PM
2019	0,097	0,510	0,458	0,601	0,377
2020	0,122	0,444	0,470	0,522	0,356
2021	0,078	0,660	0,438	0,554	0,309
2022	—	0,397	0,460	0,508	0,262
2023	0,014	0,505	0,531	0,682	0,254
2024	0,293	0,502	0,569	0,566	0,286
2025	0,269	0,470	0,577	0,522	0,376
Media	0,146	0,498	0,500	0,565	0,317

Tabla 4.4: Coeficiente de silueta por año y aproximación, aplicando el criterio de cobertura mínima. Las columnas corresponden a las cinco aproximaciones descritas en la Sección 3.2.1.3, es decir siete magnitudes meteorológicas, temperatura y humedad relativa, temperatura y superficie arbórea, dióxido de nitrógeno, y dióxido de nitrógeno con partículas. El guion indica que la aproximación no reunió estaciones suficientes ese año.

En cuanto al numero de grupos validados por el diagrama del codo....




Figura 4.4: Diagrama del codo de la aproximación de temperatura y humedad relativa (2021).

Como comprobación de robustez se ejecutaron sobre los mismos datos dos algoritmos de agrupamiento independientes, *k-means* y el método jerárquico de Ward. En cuatro de las cinco aproximaciones ambos produjeron particiones idénticas, y en la restante difirieron en dos de veintiuna estaciones. Que dos procedimientos con fundamentos distintos converjan en la misma agrupación indica que la estructura detectada responde a los datos y no a

las particularidades de un algoritmo concreto, comprobación que el trabajo original no realizaba de forma explícita.

El dendrograma (Figura 4.5) muestra además que la primera división del conjunto separa las estaciones situadas en la periferia y en grandes zonas verdes de las ubicadas en el núcleo urbano denso, una partición que reproduce la estructura espacial del fenómeno estudiado sin haber sido impuesta al algoritmo




Figura 4.5: Dendrograma del agrupamiento jerárquico de Ward sobre temperatura y humedad relativa (2021).

4.2.5. Limitaciones e interpretación

4.3. Comparación entre la ejecución local y las plataformas cloud

La Tabla 4.5 recoge el esfuerzo medido en horas dedicado a cada etapa y en cada entorno. En este caso, el orden en que se abordaron los entornos, condiciona el resultado, ya que con el conocimiento acumulado de etapas anteriores, las siguientes son mucho mas ágiles. La implementación local fue la primera y llevo la mayor parte del trabajo de comprensión de las fuentes, diseño del proceso en código, y resolución de las incidencias de calidad del dato. De igual manera, AWS fue la primera nube evaluada, y la que menos conocía el autor, por lo que el tiempo acumulado incluye el aprendizaje de la plataforma y el coste en tiempo del primer acercamiento a la nube.

4.3.1. Comparación de costes en las diferentes nubes

Etapas	Esfuerzo (h)		Ejecución (s)		Coste (\$)	
	Local	AWS	Local	AWS	Local	AWS
Configuración	5	10	—	—	0	0
Ingesta	10				0	0
Limpieza	20			227	0	< 0,01
Análisis	35				0	
Total	70 h				0	

Tabla 4.5: Comparativa de esfuerzo de desarrollo, tiempo de ejecución y coste por etapa y entorno.

Capítulo 5

Manual de usuario y casos de uso

En este capítulo, describiremos en detalle la guía operativa del proyecto, detallando los pasos necesarios para que cualquier usuario o investigador pueda replicar el entorno de trabajo, ejecutar el *pipeline* de datos y reproducir los análisis descritos en capítulos anteriores.

Para mantener la coherencia con el resto de capítulos, dividiremos el manual en sus tres componentes:

- **Configuración, ingesta y almacenamiento de datos.**
- **Despliegue y automatización de la solución.**
- **Uso de modelos y evaluación de resultados.**

De este modo, intentaremos garantizar la trazabilidad del ciclo de vida del dato. Esto lo haremos para las tres plataformas donde hemos trabajado: Local, AWS y GCP; y al final, también estableceremos una comparativa lo más objetiva posible de que entornos es mejor utilizar en cada caso, según lo estudiado en este trabajo. Los detalles de los métodos utilizados en las partes correspondientes se han detallado anteriormente en la Sección 3.2.1. La comparación cuantitativa entre entornos, en términos de esfuerzo, tiempo de ejecución y coste, se recopila en el Capítulo 4.

5.1. Manual de usuario en Local

Aunque esta sección va a tratar de cómo lanzar el proceso en local, muchos de los comentarios aplican a las nubes estudiadas, ya que parten de los mismos ficheros base que tenemos en el repositorio público de github.

5.1.1. Despliegue y utilización del código en Local

La ejecución local no requiere infraestructura adicional más allá de un entorno de desarrollo como puede ser VScode, que es el que se ha utilizado para este proyecto, y configurarlo como se describe en la siguiente sección 5.1.2. Los procesos se ejecutan secuencialmente y cada uno utiliza la salida del anterior como entrada. Aunque para este trabajo se ha utilizado un entorno local de VSCode, se podrían usar herramientas como notebooks de Jupyter o los entornos de *Hugging Face* para ejecutar estos comandos sin la necesidad de un hardware personal.

Esta línea base local cumple con el propósito de validar los datos de los trabajos originales en un entorno controlado antes de introducir la variable de la nube, y de servir de referencia frente a la que comparar las implementaciones en cada proveedor.

5.1.2. Ingesta y descarga de datos

El proceso de ingesta requiere Python 3.12 o superior e instalar las dependencias de `requirements.txt` (preferiblemente en un entorno virtual). El comportamiento del *pipeline* se controla desde el fichero, `config.py`, que centraliza las rutas de las capas de almacenamiento, las direcciones web de los conjuntos en los portales de datos, los años a descargar, los filtros de formato, las reglas de limpieza y demás parámetros de entorno. Para incorporar un conjunto de datos nuevo solo habría que añadir una entrada en los diccionarios correspondientes, y modificar, si es necesario, la lógica de los procesos.

La ruta base del proyecto es la definida en la variable `TFM_BASE`, si esta no existe, se utiliza el directorio local del proyecto, aunque no se añada en este apartado, se recomienda configurarla tanto aquí como en otros entornos. Con esto, lo primero sería descargar el código y crear el entorno virtual.

```
# Entorno virtual de python
python -m venv .venv
source .venv/bin/activate          # o en Windows: .venv\
Scripts\Activate.ps1

# Descarga de código
git clone https://github.com/crismo04/TFM-cloud-soliutions
-to-public-data.git
cd TFM-cloud-soliutions-to-public-data/code/files
pip install -r requirements.txt --quiet

# Descarga de datos
python 01_descarga.py --dry-run    # comprueba que los
datos existen, sin descargar
```



```
python 01_descarga.py # descarga completa
```

Bloque de código 5.1: Preparación del entorno y ejecución de la ingesta


El proceso es idempotente, es decir, puede relanzarse sin volver a descargar lo ya presente, y registra los metadatos de procedencia de cada fichero en `_metadatos.csv`. Debido a la protección anti-automatización de los portales también incorpora pausas entre descargas y reintentos, por lo que una ingesta completa puede durar varios minutos, pero con esto ya deberíamos tener los datos en las carpetas correspondientes.

5.1.3. Modelos y resultados

Cada ejecución del análisis genera un directorio por cada año con los diagramas del codo, dendrogramas, gráficos de dispersión de correlaciones y tablas de grupos. El parámetro `MODO_REPLICA` determina si se reproducen las condiciones del trabajo original o se aplican los criterios metodológicos propios definidos en la sección 3.2.1.3, y los resultados de cada modo se almacenan en directorios separados. La salida completa queda registrada en `ejecucion.log` para facilitar la trazabilidad de las ejecuciones y los parámetros elegidos. También se producen tres resúmenes: el coeficiente de silueta por año y aproximación, la correlación entre superficie arbórea y temperatura por año, y un diagnóstico de cobertura de días válidos por estación. El árbol de directorio se puede ver en la figura 5.1 o en el propio github, ya que se han subido también para dar transparencia y permitir que se auditen.

Los resultados y hallazgos interesantes que se extraen de estos archivos se pueden consultar en detalle en el capítulo 4.2

Figura 5.1: Árbol de archivos de resultados



Fuente: Propia

5.2. Manual de usuario en Amazon Web Services (AWS)

5.2.1. Despliegue


Para desplegar la infraestructura en la nube de Amazon, lo primero que tenemos que hacer es registrarnos en la plataforma (Amazon Web Services, 2026b). El proceso de creación consta de cinco pasos y da acceso al plan gratuito, aunque requiere introducir una tarjeta de crédito de manera obligatoria. Además, por motivos de seguridad, el sistema exige configurar un segundo factor de autenticación (MFA). Para no alargar este capítulo, simplemente redirigimos al usuario al propio tutorial de AWS, donde se explica en detalle cómo crear la cuenta: (Amazon Web Services, 2026d). Con esto, AWS proporciona hasta 200\$ en créditos gratuitos para realizar pruebas: 100\$ iniciales y otros 100\$ adicionales al completar una serie de actividades. Aunque han ido cambiando en las diferentes veces que hemos creado la cuenta, y lo más seguro es que cambiaran de nuevo en el futuro, a fecha de creación de esta memoria, las pruebas consistían en:

- Crear una máquina virtual.
- Establecer un límite de gasto (*Billing*).
- Crear una base de datos SQL.

- Crear una aplicación web.
- Probar un modelo de lenguaje (LLM) en el servicio Amazon Bedrock.

Con los 200\$ disponibles, se disponen de créditos de sobra para poder realizar el proyecto, como hemos visto en 4.3.1. Todos los comandos y procedimientos nombrados a partir de aquí, han sido realizados consultando la documentación técnica oficial de AWS (Amazon Web Services, 2026c). Debido a la extensión de esta documentación y para facilitar la lectura de la memoria, no se referencia las paginas de documentación individuales para cada comando, pero la misma cuenta con un buscador donde se puede consultar el comando o comandos específicos de esta memoria para poder ver su funcionamiento y las decisiones de diseño que se han tomado aquí. También para facilitar la reproducibilidad, se ha priorizado la utilización de los comandos del CLI, aunque todas ellos tienen su equivalente en la web que también se pueden consultar en la documentación y pueden ser más fáciles de ejecutar, y sobre todo, mas claros, en ciertos escenarios. Los comandos que vamos a lanzar se pueden escribir directamente en la **AWS CloudShell** como se muestra en la figura 5.2.

Figura 5.2: Abrir terminal AWS en consola



Fuente: Propia

5.2.2. Configuración del entorno y autenticación

Aunque desde **AWS CloudShell** se gestionan las credenciales de acceso con el usuario que hemos registrado, es posible configurar credenciales de acceso externas para otros usuarios, para que los diferentes servicios en la nube los utilicen, o para ejecutar los comandos desde local. El proyecto se realizó siguiendo las mejores prácticas, mediante el modelo de control de acceso basado en roles y grupos (RBAC), y aunque se podrían establecer permisos más estrictos, y este modelo tiene más sentido para manejar un

numero mayor de usuarios, se realizó para futuras extensiones del proyecto y para la utilización de herramientas y roles de servicio.

Lo primero para trabajar con la nube, es seleccionar la región que más convenga al proyecto, que en este caso es la región **eu-west-1** (Irlanda), ya que es la que mayor número de servicios ofrece dentro de la Unión Europea. Con esto, en la propia **AWS CloudShell**, se puede obtener el código del proyecto, publicado bajo licencia abierta, de la siguiente manera:

```
cd ~
git clone https://github.com/crismo04/TFM-cloud-soliutions
-to-public-data.git
cd TFM-cloud-soliutions-to-public-data/code/files
pip install -r requirements.txt --quiet
```

Bloque de código 5.2: Obtención del código fuente del proyecto

También conviene tener creadas las variables de entorno que vamos a utilizar en el proyecto. Además, al trabajar con la terminal, se conserva el directorio personal entre sesiones, pero no las variables de entorno definida. Para no tener que volver a crearlas cada sesión, se pueden almacenar en un fichero que se carga al comenzar cada sesión:

```
cat > ~/tfm-env.sh << 'EOF'
export BUCKET="tfm-ucm-datos-publicos"
export REGION="eu-west-1"
export CUENTA=$(aws sts get-caller-identity --query
Account --output text)
export TFM_BASE="s3://$BUCKET"
EOF

source ~/tfm-env.sh
```

Bloque de código 5.3: Persistencia de las variables del proyecto

5.2.3. Infraestructura de Almacenamiento en Amazon S3

El almacenamiento en la nube se fundamenta en un *bucket* de Amazon S3 denominado **tfm-ucm-datos-publicos**. Su estructura replica exactamente la jerarquía de directorios local, y de otras nubes: (**data/bronze/**, **data/silver/**, **resultados/** (como capa Gold) y **scripts/**). Permitiendo así que el código de Python migre entre ambos entornos cambiando únicamente el prefijo de ruta de archivo. Se aplican también, mediante los siguientes comandos, bloqueo total de acceso público, versionado de objetos y etiquetado para el seguimiento de costes.

```
# Creacion del bucket
aws s3api create-bucket --bucket "$BUCKET" --region "
$REGION" \
```

```
--create-bucket-configuration LocationConstraint="$REGION"

# Bloqueo de acceso publico
aws s3api put-public-access-block --bucket "$BUCKET" \
--public-access-block-configuration \
"BlockPublicAcls=true,IgnorePublicAcls=true,
  BlockPublicPolicy=true,RestrictPublicBuckets=true"

# Versionado y etiquetado
aws s3api put-bucket-versioning --bucket "$BUCKET" \
--versioning-configuration Status=Enabled

aws s3api put-bucket-tagging --bucket "$BUCKET" \
--tagging 'TagSet=[{Key=proyecto,Value=tfm}]'
```

Bloque de código 5.4: Creación y configuración de seguridad del contenedor en S3

Una vez creado el contenedor, se puede ver en el apartado de S3 instantáneamente y ya podemos proceder a cargar los procesos de ingesta directamente sobre el almacenamiento creado. Con esto, validamos la portabilidad, ya que el mismo proceso que se ejecutó en local escribe ahora en S3 sin ninguna modificación de su lógica, gracias a la abstracción del sistema de ficheros con `fsspec` descrita en la Sección 3.2.1.1.

```
# Carga de los scripts del pipeline
aws s3 cp . "s3://$BUCKET/scripts/" --recursive --exclude
  "*" --include "*.py"

# Ingesta escribiendo directamente en la capa bronze del
  bucket
python 01_descarga.py --destino "s3://$BUCKET/data/bronze/"
  ""

# Verificacion del contenido cargado
aws s3 ls "s3://$BUCKET/data/bronze/" --recursive --
  summarize
```


Bloque de código 5.5: Carga de los procesos e ingesta directa sobre S3

Con esto ya tendremos la estructura de carpetas y la ingesta completa en S3 con los datos definidos en el Python del repositorio como se muestra en 5.3.

En caso de querer descargar otros datos públicos, hay dos opciones, se podría descargar directamente con un comando de descarga como este:

También, como opción más elegante, se podría integrar en el proceso y modificar el repositorio descargable o el archivo, directamente en la consola de AWS o en local, contribuyendo así en el desarrollo de este proyecto.

Figura 5.3: Estructura de carpetas generada en S3



Fuente: Propia

```
# SOLO PARA DESCARGAR NUEVOS DATOS! CAMBIANDO LA URL!
wget -qO- "$URL_DATOS" | aws s3 cp - "s3://$BUCKET/data/
bronce/nombre_archivo.csv"
```

Bloque de código 5.6: Ingesta manual directa de un nuevo conjunto de datos a S3

5.2.4. Orquestación y Procesamiento ETL con AWS Glue

Para el procesamiento de datos en la nube se ha optado por “AWS Glue Python Shell” en lugar de entornos distribuidos basados en “Apache Spark”. Dado que los conjuntos de datos tratados en este proyecto ocupan 272 MB en su capa bronce, el uso de *Spark* implicaría una sobrecarga innecesaria y un coste mínimo de 2 DPU (Data Processing Units), mientras que *Python Shell* permite ejecutar con un mínimo de 0,0625 DPU ($\approx 0,03$ \$/hora), incluyendo librerías como *pandas*, *numpy* y *scikit-learn* ya instaladas.

A diferencia de la ejecución en terminal del apartado anterior, Glue se ejecuta desde su propio apartado en AWS, puede programarse o encadenarse con otros, y es más fácil de automatizar, a parte de que nos permite explorar las posibilidades de la nube. El primer paso es crear la cuenta de servicio, siguiendo los principios que hemos comentado al principio de este capítulo:

```
# Política de confianza: solo el servicio Glue puede
asumir este rol
cat > trust.json << 'EOF'
```

```
{
  "Version": "2012-10-17",
  "Statement": [
    {
      "Effect": "Allow",
      "Principal": {
        "Service": "glue.amazonaws.com"
      },
      "Action": "sts:AssumeRole"
    }
  ]
}
```

EOF

```
aws iam create-role --role-name AWSGlueServiceRole-tfm \
--assume-role-policy-document file://trust.json \
--tags Key=proyecto,Value=tfm

aws iam attach-role-policy --role-name AWSGlueServiceRole-tfm \
--policy-arn arn:aws:iam::aws:policy/service-role/AWSGlueServiceRole

aws iam attach-role-policy --role-name AWSGlueServiceRole-tfm \
--policy-arn arn:aws:iam::aws:policy/AmazonS3FullAccess
```

Bloque de código 5.7: Creación del rol de servicio de Glue

Para utilizar *Python Shell* es necesario empaquetar los módulos propios que hemos creado, como el fichero de configuración. Durante el desarrollo se ha comprobado que un fichero comprimido en formato `zip` se descarga correctamente pero no llega a importarse, mientras que un paquete en formato *wheel* sí se instala como cualquier otra dependencia, por lo que lo hemos hecho de la siguiente manera:

```
rm -rf /tmp/pkg && mkdir -p /tmp/pkg
cp ~/TFM-cloud-solutions-to-public-data/code/files/config.py /tmp/pkg/

cat > /tmp/pkg/setup.py << 'EOF'
from setuptools import setup
setup(name="tfmconfig", version="1.0.0", py_modules=["config"])
EOF

cd /tmp/pkg && pip wheel . -w dist --no-deps --quiet
aws s3 cp dist/tfmconfig-1.0.0-py3-none-any.whl "s3://$BUCKET/scripts/"

cd ~/TFM-cloud-solutions-to-public-data/code/files
aws s3 cp . "s3://$BUCKET/scripts/" --recursive --exclude "*" --include "*.py"
```

Bloque de código 5.8: Empaquetado del módulo de configuración

Si posteriormente se modifica el fichero de configuración, es necesario regenerar el paquete e **incrementar su número de versión**, ya que en caso contrario el gestor de dependencias reutilizaría la copia previamente instalada.

Con el rol y los procesos disponibles solo falta crear la función, para esto, fijaremos un tiempo máximo de ejecución, una capacidad máxima y desactivaremos los reintentos automáticos como medida de control de costes. También añadiremos etiquetas para poder desglosar el gasto. La definición se declara en JSON en lugar de como argumentos en línea, para mayor visibilidad de rutas y evitar el escapado de comillas, ya que ambas han dado problemas en la ejecución:

```
source ~/tfm-env.sh
# Aborta si la variable esta vacia, evitando rutas del
# tipo s3:///
: "${BUCKET:?Variable BUCKET vacia, ejecutar source ~/tfm-
env.sh}"

cat > job-limpieza.json << EOF
{
  "Name": "tfm-02-limpieza",
  "Role": "AWSGlueServiceRole-tfm",
  "Command": {"Name": "pythonshell", "PythonVersion": "
3.9",
    "ScriptLocation": "s3://$BUCKET/scripts/02
_limpieza.py"},
  "DefaultArguments": {
    "--extra-py-files": "s3://$BUCKET/scripts/
tfmconfig-1.0.0-py3-none-any.whl",
    "--additional-python-modules": "s3fs",
    "--TFM_BASE": "s3://$BUCKET"},
  "MaxCapacity": 0.0625,
  "Timeout": 15,
  "MaxRetries": 0,
  "Tags": {"proyecto": "tfm", "fase": "limpieza"}
}
EOF

cat job-limpieza.json      # comprobacion de las rutas
resueltas
aws glue create-job --cli-input-json file://job-limpieza.
json
```

Bloque de código 5.9: Definición y despliegue del trabajo de limpieza (02) en AWS Glue

Esto de nuevo, es sencillo por tener los .py configurados, pero para añadir más datos solo seria necesario incluir su entrada en `config.py`, actualizar el repositorio con las especificidades de estos, y volver a sincronizar los procesos con el almacenamiento mediante el ciclo descrito en este trabajo. Con esto ya podemos lanzar la ejecución y ver el resultado:

```
RUN=$(aws glue start-job-run --job-name tfm-02-limpieza \
--query JobRunId --output text)
```



```
aws glue get-job-run --job-name tfm-02-limpieza --run-id "$RUN" \
--query "JobRun.[JobRunState,ExecutionTime,ErrorMessage]"
--output text

# Registro de la ejecucion
aws logs tail /aws-glue/python-jobs/output --since 10m

# La capa silver debe aparecer en el bucket al finalizar
aws s3 ls "s3://$BUCKET/data/silver/" --recursive --
summarize
```

Bloque de código 5.10: Ejecución, seguimiento y verificación del resultado

Figura 5.4: Ejecuciones del trabajo ETL en AWS Glue

The screenshot shows the AWS Glue console for a job named 'tfm-02-limpieza'. The 'Runs' tab is selected, displaying a table of job execution records. The table has columns for 'Estado de ejecución' (Execution Status), 'Reintentos' (Retries), 'Hora de inicio (Local)' (Start Time), 'Hora de finalización (Local)' (End Time), 'Duración' (Duration), 'Capacidad (DPU)' (Capacity), and 'Tipo de trabajador' (Worker Type). All listed runs show a status of 'Sucedido' (Succeeded) with 0 retries. Below the table, the 'Detalles de la ejecución' (Execution Details) tab is active, providing more information about the job, including its ID, start and end times, and execution status.

Fuente: Propia, traducido por Google

Aunque aquí lo ponemos en línea de comandos, AWS Glue es más fácil de ejecutar en la propia plataforma y de hecho ha sido la forma de trabajo utilizada para los pequeños errores que han aparecido durante la ejecución. Tras esta ejecución, la capa *silver* aparece en el S3, con los mismos datos y estructura que la generada en el entorno local.

5.2.5. Modelos de ML y resultados con Amazon SageMaker

Para generar esta última capa de análisis en AWS, vamos a volver a cambiar de tecnología. Mientras que la etapa *Silver* se completó mediante *AWS Glue*, la etapa de análisis tiene otros requerimientos: ejecución de algoritmos,

cálculo de siluetas, volumen elevado de figuras, librerías de tratamiento geoespacial, etc. Todo esto se beneficia de una ejecución interactiva durante la interpretación de los resultados.

Por ello vamos a emplear **Amazon SageMaker**. Específicamente, el servicio de *Spaces* dentro de un dominio, que proporciona entornos de *Jupyter Notebooks*. Lo primero es la creación de este dominio, que se realiza desde la consola web ¹, con la configuración de inicio rápido en la región **eu-west-1**.

AWS aprovisionará automáticamente las redes virtuales (VPC) y el almacenamiento (EFS) con el dominio. Una vez creado, el espacio aprovisiona automáticamente el entorno de desarrollo **JupyterLab** mediante IDE, además de muchas otras funciones, que se pueden ver en la figura 5.5.

Figura 5.5: Consola de SageMaker



Fuente: Propia

Desde la terminal integrada en el entorno, se descarga el repositorio, se instalan librerías y se sincronizan *Silver* y datos descargados en el paso de ingesta. Todo esto debe instalarse en el mismo intérprete que ejecuta el proceso y hay que tener en cuenta que el explorador de ficheros del entorno se abre por defecto en un directorio distinto a donde clonamos el repositorio, por lo que es necesario ir hasta él para visualizar las figuras generadas. Los comandos para todo esto, y para sincronizar los resultados en S3 son los siguientes:

```
# Dentro del terminal de JupyterLab en SageMaker, creamos
# o actualizamos el repositorio
git clone https://github.com/crismo04/TFM-cloud-solutions
-to-public-data.git \
|| (cd TFM-cloud-solutions-to-public-data && git pull)
cd TFM-cloud-solutions-to-public-data/code/files
pip install -r requirements.txt --quiet
python -m pip install geopandas --quiet
python -c "import geopandas"
```

¹SageMaker disponible en: <https://eu-west-1.console.aws.amazon.com/datazone/home?region=eu-west-1/>

```
# Descarga de las capas necesarias desde S3 que ya se han
    creado antes
aws s3 sync s3://tfm-ucm-datos-publicos/data/silver/ data/
    silver/
aws s3 sync s3://tfm-ucm-datos-publicos/data/bronze/
    distritos/ data/bronze/distritos/

# Tambien se pueden crear volviendo a ejecutar los
    archivos 01 y 02 en el mismo proceso

# Ejecutamos el analisis y publicamos los resultados
python 03_analisis_isla_calor.py
aws s3 sync resultados/ s3://tfm-ucm-datos-publicos/
    resultados/
```

Bloque de código 5.11: Ejecución del análisis en el entorno de SageMaker

Emplear **JupyterLab** para el trabajo analítico también facilita visualizar gráficos y tablas directamente en el entorno, y publicar después en el almacenamiento de objetos una vez estudiada la salida. El entorno de cuadernos incorpora además un conjunto amplio de librerías de aprendizaje automático con versiones fijadas por el proveedor, de modo que instalar las dependencias del proyecto podría generar conflictos de versión (pero que en este caso no afectan a la ejecución).

El proyecto también tiene un archivo `.ipynb` ejecutable para poder ver los resultados directamente en la carpeta `code/files/analisis_isla_calor.ipynb`

También advertir que, desde una perspectiva de control de costes, los espacios de trabajo facturan por tiempo de aprovisionamiento mientras permanecen encendidos, con independencia de que se esté utilizando el cuaderno o no. Conviene detenerlos manualmente desde la administración del dominio al finalizar cada sesión para interrumpir la facturación.

Este manual ha empleado tres modalidades de ejecución dentro de AWS, cada una adecuada a una etapa distinta: un terminal interactivo para la ingesta, un servicio de procesamiento desatendido para la transformación, y un entorno de cuadernos para el análisis. Aunque la ingesta y la limpieza podrían ejecutarse indistintamente en cualquiera de las tres, la etapa de análisis requiere el entorno de cuadernos por sus dependencias gráficas y geoespaciales. Esta división refleja la lógica del propio catálogo de servicios, en el que cada uno está optimizado para un perfil de carga concreto.


5.3. Manual de usuario en Google Cloud Platform (GCP)

5.3.1. Despliegue

Para desplegar la infraestructura en la nube de Google, lo primero que tenemos que hacer, al igual que en AWS, es registrarnos en la plataforma (Google Cloud Platform, 2026a). El proceso de creación es sencillo, en un solo paso esta configurado y es gratuito, aunque también requiere introducir una tarjeta bancaria, y al momento de escribir la memoria, si la tarjeta es virtual, se puede requerir un pre-pago de 25€ que se devuelve al cerrar la cuenta, por lo que se recomienda el uso de una tarjeta física real.

Para no alargar este capítulo, simplemente redirigimos al usuario al propio tutorial de GCP, donde se explica en detalle las condiciones: (Google Cloud Platform, 2026c). GCP no tiene tutoriales obligatorios y disponemos de los 300\$ (aproximadamente 263€) disponibles desde el principio. Todos los comandos y procedimientos nombrados en este apartado también han sido realizados con la documentación técnica oficial de GCP (Google Cloud Platform, 2026b), y debido a la extensión de esta documentación y la facilidad para recorrer sus apartados y buscar comandos concretos, no se referencia las paginas de documentación individuales para cada comando. Se ha priorizado la utilización de los comandos del CLI al igual que en AWS, y los comandos del manual se pueden escribir directamente en la **Google Cloud Shell**, o ejecutar su correspondiente acción en la consola web de GCP.

Figura 5.6: Abrir terminal GCP en consola



Fuente: Propia

5.3.2. Configuración del entorno y autenticación

A diferencia de AWS, GCP ya crea automáticamente una jerarquía de organización con varios proyectos al registrar la cuenta, pero crearemos un proyecto específico y aislado de la organización por defecto para este trabajo, para tener todo bajo un mismo entorno.

Todos los comandos se ejecutan en la *Google Cloud Shell*, que ya incluye la CLI de GCP configurada y con los permisos necesarios:

```
# Crear un proyecto nuevo (sin organization) y activarlo
gcloud projects create tfm-ucm-datos-publicos --name="TFM
    UCM Datos Publicos"
gcloud config set project tfm-ucm-datos-publicos

# Le asignamos la cuenta de facturación
gcloud billing projects link tfm-ucm-datos-publicos \
--billing-account="$(gcloud billing accounts list --format
    ='value(ACCOUNT_ID)' | head -n1)"

# Definimos regiones
gcloud config set compute/region europe-west1
gcloud config set compute/zone europe-west1-b

# Comprobar la configuración
gcloud config list
```

Bloque de código 5.12: Creación del proyecto en GCP

Nota sobre la visibilidad del proyecto: Debido a este aislamiento en el proyecto, la consola web solo lo muestra en el selector de proyectos, en la opción “Sin organización” (*No organization*), o buscando el nombre directamente en la barra de búsqueda global.

Nota sobre la cuota de facturación: Si al vincular el proyecto aparece el error `Cloud billing quota exceeded`, puede deberse a que la cuenta ya tiene demasiados proyectos asociados. En ese caso, se puede liberar cuota eliminando proyectos no utilizados con `gcloud projects delete <ID_PROYECTO>`, como el que Google crea por defecto.

Una vez creado y vinculado el proyecto, definimos las variables de entorno que usaremos en el resto del manual de GCP, al igual que en AWS. Aquí hay que tener en cuenta que los contenedores tienen nombres globales, por lo que si el nombre propuesto ya está en uso, habrá que cambiarlo, por lo que no sirve copiar y pegar del manual en este caso::

```
cat > ~/tfm-env-gcp.sh << 'EOF'
export BUCKET="tfm-ucm-datos-publicos"    # Debe ser
    cambiado
export REGION="europe-west1"
export PROJECT=$(gcloud config get-value project)
```

```
export TFM_BASE="gs://$BUCKET"
EOF

source ~/tfm-env-gcp.sh
echo $TFM_BASE      # Para comprobar
```

Bloque de código 5.13: Creación del archivo de variables de entorno

5.3.3. Infraestructura de almacenamiento en Cloud Storage

Como tecnología de almacenamiento para el proyecto, creamos un *bucket* en *Cloud Storage*, que alojara las capas del mismo, con la misma estructura de directorios que local y AWS:

```
# Crear el bucket en la region de europe-west1
gcloud storage buckets create gs://$BUCKET --location=
$REGION

# Bloquear acceso publico, activar versionado y etiquetar
gcloud storage buckets update gs://$BUCKET --public-access
-prevention
gcloud storage buckets update gs://$BUCKET --versioning
gcloud storage buckets update gs://$BUCKET --update-labels
=proyecto=tfm
```

Bloque de código 5.14: Creación y configuración del contenedor de *Cloud Storage*

Con el contenedor listo, el siguiente paso es obtener el código fuente del repositorio. En GCP, la propia terminal de *Cloud Shell* viene pre-configurada con las credenciales del usuario, por lo que la librería *gcsfs* (implementación de *fsspec* para Google) se autentica de forma automática:

```
# Clonar el repositorio y situarse en la ruta de trabajo
git clone https://github.com/crismo04/TFM-cloud-soliutions
-to-public-data.git
cd TFM-cloud-soliutions-to-public-data/code/files
pip install -r requirements.txt gcsfs --quiet

# Ejecutar la ingesta escribiendo directamente en la capa
bronze del bucket
python 01_descarga.py --destino "gs://$BUCKET/data/bronze/"
"
```

Bloque de código 5.15: Descarga del código e ingesta en Cloud Storage

5.3.4. Procesamiento y análisis en Vertex AI Workbench

Para la fase de transformación (*Silver*) y análisis, se optó por **Vertex AI Workbench**, un entorno gestionado de *JupyterLab*. Se descartaron los servicios serverless *Cloud Run Jobs* y *Cloud Functions* por presentar dificultades con la ejecución de procesos por lotes y la autenticación de acceso a *Cloud Storage* en el entorno de pruebas. Vertex AI simplifica la gestión de credenciales y permite ejecutar los scripts originales sin modificaciones.

El primer paso es crear la instancia de trabajo:

```
gcloud services enable notebooks.googleapis.com

gcloud notebooks instances create tfm-notebook \
--location=$REGION \
--machine-type=n1-standard-4 \
--vm-image-project=deeplearning-platform-release \
--vm-image-family=common-cpu-notebooks
```

Bloque de código 5.16: Creación de la instancia de Vertex AI Workbench

Una vez aprovisionada, se abre JupyterLab desde la consola de GCP y se ejecutan los siguientes comandos en la terminal integrada:

```
# Clonar el repositorio y situarse en el directorio de
# trabajo
git clone https://github.com/crismo04/TFM-cloud-soliutions
-to-public-data.git
cd TFM-cloud-soliutions-to-public-data/code/files
pip install -r requirements.txt gcsfs --quiet

# Definir la ruta base del bucket
export TFM_BASE="gs://tfm-ucm-datos-publicos"

# Ejecutar limpieza y analisis de resultados
python 02_limpieza.py
python 03_analisis_isla_calor.py

# Subir los resultados al bucket
gsutil cp -r resultados gs://tfm-ucm-datos-publicos/
```

Bloque de código 5.17: Ejecución de limpieza y análisis en Vertex AI Workbench

Control de costes: Al igual que con SageMaker, las instancias de Vertex AI Workbench facturan mientras están encendidas. Conviene detenerla al finalizar:

```
gcloud notebooks instances stop tfm-notebook --location=
$REGION
```

Bloque de código 5.18: Detención de la instancia de Vertex AI

Capítulo 6

Conclusiones y Trabajo Futuro

[TODO, importante a tener en cuenta: Señalar los principios y relaciones que indican los resultados (qué es lo que se ha sacado en claro con la investigación, futuras implicaciones que se pueden extraer, etc.). · Relacionar los resultados con otros trabajos publicados. · Hay que mencionar también las excepciones, faltas de correlación o aspectos no resueltos. · Indicar futuras líneas de trabajo]

Trabajo futuro

Añadir al estudio un coste ecológico de las tecnologías.

Contactar con responsables de algunos de los estudios citados y conducir una encuesta a los usuarios para comprender la utilidad de los datos.

Contactar con las nubes privadas europeas y españolas, ya que aunque es normal que en su mayoría no ofrezcan planes gratuitos para evitar su abuso, es posible que contactando como entidad investigadora dieran acceso a las cloud para poder comprobar su utilidad en este estudio.

Construir interfaz de usuario para visualizar los datos de una manera más optima, ya sea con Firebase, o una instancia de Superset.

Chapter 6

Conclusions and Future Work

[TODO]

Apéndice A

Apéndice A: Definiciones y acrónimos

“Saber dónde encontrar la información y cómo usarla. Ese es el secreto del éxito”

— Albert Einstein (Atribuida)

-

Dedicaremos este apéndice a la explicación de conceptos en más extensión, ya sea conceptos más generales o la explicación del significado de los acrónimos de esta memoria.

A.1. Definiciones

Separaremos este apartado, de la misma manera que se ha hecho en otras partes de la memoria, en los tres grandes elementos que conforman esta memoria, definiciones referentes a datos, a nubes y a Inteligencia artificial. En cada uno de ellos enumeraremos las definiciones que se han ido incrustando en la memoria de la manera: [Definición 1].

La enumeración de las definiciones es independiente del apartado en el que se encuentra

A.1.1. Referente a datos

1. El gobierno de España define los **Datos de alto valor** como “documentos cuya reutilización está asociada a considerables beneficios para la sociedad, el medio ambiente y la economía, en particular debido a su idoneidad para la creación de servicios de valor añadido, aplicaciones y puestos de trabajo nuevos, dignos y de calidad, y al número de beneficiarios potenciales de los servicios de valor añadido y aplicaciones basados en tales conjuntos de datos” Esta definición nos ofrece varias pistas sobre la manera en la que se prevé que se identifiquen esos conjuntos de datos de alto valor a través de una serie de indicadores que incluirían:
 - Su potencial para generar beneficios sociales o medioambientales significativos.
 - Su potencial para generar beneficios económicos y nuevos ingresos.
 - Su potencial para generar servicios innovadores.
 - Su potencial en cuanto a número de usuarios beneficiados, con atención particular a las PYMEs.
 - Su capacidad para ser combinados con otros conjuntos de datos.
2. El **open government** o gobierno abierto es una forma de comunicación abierta, permanente y bidireccional entre la administración y los ciudadanos, basada en la transparencia por parte de la administración y la participación y colaboración con la sociedad civil y las empresas. Teniendo como punto clave el movimiento open data o datos abiertos, esta estructura y formatos abiertos permiten que los datos puedan reutilizarse proporcionando nuevos servicios a ciudadanos y empresas. En Europa sus orígenes se sitúan en la Directiva 2003/98/CE del Parlamento y del Consejo Europeos sobre el acceso y la reutilización de la información del sector público. (Ferrer-Sapena et al., 2011).
3. El **Valor Público** se puede definir de muchas maneras y depende de la perspectiva de muchos autores:
 - Para **Mark Moore**, su creador, consiste en conocer y satisfacer los deseos de la gente, un valor que lo público debe crear de forma análoga a como el sector privado crea valor económico. (Moore, 1995)
 - **Bozeman** lo define desde una perspectiva ciudadana como el consenso sobre los derechos y obligaciones de los ciudadanos, así como

los principios sobre los que debe basarse el gobierno (Bozeman, 2007). A menudo se refiere a “valores públicos”, en plural, para destacar su diversidad, tema que sería llevado más en profundidad por **Talbot**, que sugiere que a veces estos son contradictorios entre sí, reflejando la combinación de las diversas y conflictivas preferencias del público (Talbot, 2011).

- **Benington** lo vincula directamente con la “esfera pública”, argumentando que el valor público no es solo lo que el público valora individualmente, sino también aquello que agrega valor a este espacio colectivo. (Benington, 2009)
- Finalmente, **Timo Meynhardt** lo conceptualiza como un fenómeno relacional que surge de las percepciones. El valor público se crea en la relación entre el individuo y la sociedad, y depende de cómo las acciones de las organizaciones públicas impactan en la satisfacción de las necesidades básicas de las personas: morales, sociales, utilitarias y hedonistas (Meynhardt, 2009).

En un intento de resumirlo, el valor público surge de las evaluaciones y percepciones que los individuos y colectivos realizan sobre cómo las acciones, servicios o políticas de las organizaciones públicas (y otras entidades) impactan en la satisfacción de sus diversas necesidades básicas dentro de un marco relacional que involucra a la esfera pública. Valor creado para y por la sociedad.

4. Los **Datos Abiertos** se refieren a conjuntos de datos digitales que se publican bajo una filosofía de apertura, garantizando y facilitando el libre acceso, uso, modificación, reutilización y redistribución por parte de cualquier persona o entidad, en cualquier momento, lugar y con cualquier finalidad. Una parte específica y importante para este trabajo son los Datos Abiertos de Gobierno, aquellos datos que se originan, producen, encargan o publican los gobiernos u organismos públicos en el ejercicio de sus funciones. Estos datos buscan, como fin último, fomentar la transparencia, la creación de valor público, la colaboración intersectorial y la resolución de problemas.

La materialización de esta filosofía de apertura se concreta en requisitos técnicos y jurídicos específicos, cuya interpretación puede variar ligeramente entre las entidades que los definen. Desde el Grupo de Trabajo sobre Datos Abiertos “Open Knowledge Foundation” (OKF), “El conocimiento está abierto si alguien tiene la libertad de acceder a él, usarlo, modificarlo y compartirlo, sujeto, como máximo, a medidas que preserven su procedencia y su apertura” (Open Knowledge Foundation, 2025). El Portal Europeo de Datos y el “Open Data Charter”,

por su parte, enfatizan las condiciones de acceso y las libertades de uso, incluyendo la gratuidad y la ausencia de limitaciones, detallando la necesidad de características técnicas y jurídicas para que los datos sean libremente reutilizables y redistribuibles (Portal Europeo de Datos, 2025), (Open Data Charter, s.f.). Todo esto subraya la complejidad y la multifuncionalidad de los Datos abiertos como catalizador para la innovación y el desarrollo socioeconómico, con implicaciones legales y técnicas que deben ser gestionadas cuidadosamente para maximizar su potencial.

5. Las **Tres olas del “Open Data”** representan las diferentes etapas evolutivas por las que ha transitado el movimiento de apertura de datos. La **Primera Ola** (1990s-2000s) se fundamentó principalmente en Estados Unidos, dirigido a periodistas, abogados y activistas que solicitaban datos específicos bajo el modelo de “derecho a saber”, enfrentando riesgos de secretismo gubernamental y requiriendo auditores de información. La **Segunda Ola** (2000s-2010s) evolucionó hacia la apertura por defecto con alcance internacional, expandiendo su audiencia a agencias gubernamentales, empresas tecnológicas y organizaciones comunitarias, pero generando desafíos de privacidad que impulsaron la creación de portales de datos abiertos y responsables. La **Tercera Ola** (2010s-presente) representa la madurez del movimiento con colaboración intersectorial y flujos transfronterizos, dirigiéndose a ONGs, instituciones académicas, pequeñas empresas y gobiernos, estableciendo marcos de responsabilidad en materia de datos. Esta evolución se visualiza en la tabla comparativa [Tabla A.1].

6. La **Teoría de la Ventana** (Matheus y Janssen, 2020) es un marco conceptual que analiza la transparencia generada por los Datos Abiertos de Gobierno, concibiéndola como una “ventana” que el gobierno abre para que el público vea su funcionamiento interno. Postulando que la transparencia es una construcción diversa y continua, cuyo objetivo principal es facilitar la transferencia de información entre el gobierno y sus públicos. Su materialización está influenciada por factores que la facilitan o la impiden, clasificados en:
 - Características de los datos.
 - Características del sistema.
 - Características de la organización.
 - Características del uso individual.

Esto genera consecuencias (intencionadas o no) como la rendición de

Tabla A.1: Resumen de las principales características de las denominadas olas de datos abiertos.

	Primera ola	Segunda ola	Tercera ola emergente
Concepto	Libertad de información	Datos públicos abiertos	Reutilización de datos públicos y privados
Propuesta de valor	Transparencia	Transparencia y resolución de problemas	■ Elaboración de políticas basadas en pruebas ■ Innovación e iniciativa empresarial
Método	Datos a petición (derecho a saber)	Abierto por defecto (derecho a compartir)	Publicar con propósito
Enfoque	Enfoque de impulso	Enfoque de atracción	Asociaciones (colaboraciones con datos)
Énfasis geográfico	Nacional	Internacional y nacional	■ Subnacional y local ■ Flujo transfronterizo de datos con fines específicos
Audiencia / Demanda	■ Periodistas ■ Abogados y activistas ■ Tecnólogos cívicos y “data geeks”	■ Agencias gubernamentales ■ Empresas, start-up tecnológicas ■ Organizaciones comunitarias	■ ONG, derechos humanos y justicia social ■ Instituciones académicas ■ Pequeñas empresas y start-ups ■ Gobierno
Riesgos y políticas	Secretismos y ofuscación	Privacidad – Efecto mosaico, información demográfica identificable (DII)	Marco de responsabilidad y derechos en materia de datos
Respuestas institucionales	Audidores de información	■ Responsable de datos ■ Portales de datos abiertos	■ Director de datos ■ Intermediarios

Fuente: Traducción propia de Verhulst et al. (2020).

cuentas, la participación cívica, el aumento de la eficiencia o la afectación a la privacidad.

7. Un **“Datathon”** (Anslow et al., 2016) es un evento colaborativo o competitivo intensivo centrado en datos, y derivado de los términos “data” y “maratón”, donde equipos de expertos y otros individuos se reúnen para analizar grandes volúmenes de estos datos con el fin de encontrar soluciones innovadoras a problemas específicos. Esto va desde desarrollar aplicaciones para sacar partido a estos datos, hasta la optimización de procesos o la creación de modelos predictivos, las posibilidades son amplias.
8. **“Data Governance ”** (Gobierno del Dato) se define como un marco integral de políticas, estrategias, estándares, roles y procesos que rigen toda la gestión del ciclo de vida completo de los datos (desde su creación y recopilación hasta su almacenamiento, procesamiento, uso, compartición, archivado y ,finalmente, eliminación) con el objetivo de garantizar su calidad, integridad, seguridad, accesibilidad, interoperabilidad y confiabilidad (Herrera Capriz (2024), pg 241). La OECD propone que un modelo de “Data Governance” exitoso integra tres capas: una capa estratégica (liderazgo y visión); una capa táctica (capacidades de implementación y normativa: comités, formación, directrices, etc.); y una capa de entrega o operativa (de infraestructura y arquitectura: estándares, catálogos de datos, ciclo de valor, etc.) (OECD, 2019).

También vale la pena mencionar que hay más metodologías que hablan de las buenas practicas del Gobierno del dato, como es el caso de DAMA (de Datos Abiertos del Gobierno de España, 2021), que propone un marco de referencia (DAMA-DMBOK) donde el gobierno de datos coordina e integra otras diez áreas de conocimiento: la arquitectura de datos, modelado y diseño de datos, seguridad de datos, calidad de datos, gestión de metadatos y almacenamiento de datos y operaciones.

Figura A.1: Capas de gobierno del dato



Fuente: (OECD, 2019) traducida.

A.1.2. Referente a Cloud

- La **“Computación distribuida”** / **“Nube distribuida”** es un paradigma que aprovecha la capacidad de cálculo de miles o millones de dispositivos conectados a internet, creando una red de computación masiva, paralela y descentralizada. Los usuarios solo necesitan instalar un cliente de software que, cuando su dispositivo no está en uso, se encarga de descargar un pequeño fragmento de datos, procesarlo y devolver el resultado a un servidor central que coordina todas las tareas y ensambla los resultados finales. Este es un enfoque especialmente adecuado para problemas altamente paralelizables. Uno de los primeros productos en llevar la idea a cabo fue BOINC (Anderson, 2004) para ayudar al cómputo de proyectos científicos. Actualmente, nubes como AWS o GCP se han apropiado del termino Nube distribuida, teniendo centros de datos en diferentes localizaciones para distribuir su trabajo a localizaciones más cercanas o llevar la propia infraestructura y servicios de la nube fuera de sus data centres (Google Cloud, s.f.). Esta idea evolucionó hasta la llamada **“Computación Voluntaria”** (Nov et al., 2010), donde dispositivos personales de voluntarios se usaban para este fin (ahora BOINC, cuyo software aún está disponible sería considerado computación voluntaria), y también se puede considerar que este paradigma se usa de forma malintencionada con varios casos famosos de ataques DDoS distribuidos (radwere, s.f.), (Danysoft, s.f.)

que usan dispositivos infectados para conseguir su propósito.

También han surgido modelos con estas ideas paradigmas como el “Dew computing” (Ray, 2018) donde los dispositivos personales se usan como almacenamiento, o plataformas de “fog computing” (que añade dispositivos intermedios en el cálculo centralizado) o “edge computing” (Que ejecuta directamente en dispositivos finales) como SONM (SONM, s.f.) o otros proyectos (Uriarte y De Nicola, 2018) que surgieron con el auge de las “Blockchains” y las usaban para poner en contacto usuarios que quisieran proporcionar potencia de cálculo con quienes querían usarla. En la actualidad, hay nubes que siguen activas como (Golem Network, s.f.), (Akash, s.f.) ó (Render Network, s.f.) y que permiten comprar y vender potencia de cómputo.

En resumen, todo lo englobado a la computación distribuida que se ha comentado se puede ver en esta tabla:

Modelo	Descripción	Ejemplo destacado
Nube distribuida	Infraestructura descentralizada, extendiendo servicios hacia el edge o centros locales.	Gestión centralizada con despliegue en edge/localización (AWS CloudFront, Google Cloud CDN).
Computación voluntaria	Uso de recursos ociosos de dispositivos personales para cómputo distribuido voluntario.	BOINC, SETI@home, HTCCondor, Techila Grid.
“Dew Computing”	Combina almacenamiento local y en la nube, sincronizando datos y permitiendo disponibilidad offline.	Dropbox.
“Fog Computing”	Procesamiento intermedio entre dispositivos y la nube, reduciendo latencia y uso de ancho de banda.	Aplicaciones IoT y casos de baja latencia / Vehículos autónomos.
“Edge Computing”	Procesamiento en dispositivos finales, priorizando latencia y seguridad.	Procesamiento de vídeo en tiempo real, reconocimiento facial en dispositivos móviles.
“BotNets”	Redes de dispositivos comprometidos que realizan tareas maliciosas de forma distribuida, usando el mismo principio de cómputo compartido pero con fines ilícitos.	Ataques DDoS (Mydoom), spam masivo, minería de criptomonedas no autorizada.

Tabla A.2: Comparación de modelos relacionados con la computación distribuida.

10. La **clasificación de la Computación en Nube** típicamente se puede dividir según dos dimensiones principales (Huawei Technologies Co., Ltd., 2023):

Por modelo de operación:

- **Nube Pública:** Infraestructura compartida y gestionada por proveedores externos (ej. AWS, Azure, Google Cloud), la cual ofrece acceso universal mediante pago por uso.
- **Nube Privada:** Infraestructura exclusiva para una organización, gestionada interna o externamente, y que tiene mayor control y seguridad.
- **Nube Comunitaria:** Compartida por varias organizaciones con intereses comunes (ej. instituciones académicas), y que presenta un equilibrio entre control y costes.
- **Nube Híbrida:** Combina nubes públicas y privadas, permitiendo mover cargas de trabajo según necesidades de seguridad, coste o escalabilidad.
- **Nube Industrial:** Especializada en sectores específicos (sanidad, automoción), con componentes optimizados para casos de uso particulares.

Por modelo de servicio:

- **IaaS (Infraestructura como Servicio):** Proporciona recursos fundamentales (máquinas virtuales, almacenamiento, redes). Ej: Amazon EC2, Google Compute Engine.
- **PaaS (Plataforma como Servicio):** Ofrece entornos de desarrollo y ejecución para aplicaciones. Ej: Google App Engine, Microsoft Azure App Services.
- **SaaS (Software como Servicio):** Software completo gestionado por el proveedor y accesible vía web. Ej: Gmail, Salesforce, Office 365.

En la Figura A.2 se pueden observar una tabla que simplifica todos estos modelos de cloud por servicio.

Figura A.2: Distintos tipos de cloud



Fuente: (Albert Barron, 2015).

11. La “**Arquitectura en medalla**” es un patrón de diseño utilizado para gestionar el ciclo de vida de los datos en plataformas de datos, esta organiza y transforma datos en capas sucesivas: Bronce, Plata y Oro, y cada capa representa un nivel creciente de calidad y utilidad de los datos. Permite estructurar los datos para facilitar su ingestión, limpieza, enriquecimiento, análisis y consumo empresarial (Microsoft, s.f.b). Aunque se ha definido este nombre, quizás al lector le sea más familiar otra forma de procesar datos en capas (Bobrov, 2025), ya que la idea no es nueva en la ingeniería de datos y muchas otras metodologías introducen conceptos similares:

- **Arquitectura Clásica de Data Warehouse (Inmon):**
 - Staging Area (Etapa de Carga) $\approx$ Capa Bronze
 - CIF (Corporate Information Warehouse) $\approx$ Capa Silver
 - Data Marts (Almacenamiento de Industria) $\approx$ Capa Gold
- “**Data Vault**”:
 - Staging Layer para procesamiento de flujos crudos $\approx$ Capa

Bronze

- Raw Vault (donde se almacenan los datos originales) $\approx$ Capa Silver
- Business Vault o Data Marts (transforman datos en métricas) $\approx$ Capa Gold
- **Data Mesh (Concepto de Propiedad de Datos Distribuida):**
 - Raw Domain Data $\approx$ Capa Bronze
 - Aggregated Domain Data $\approx$ Capa Silver
 - Consumer-Oriented Products $\approx$ Capa Gold
- **Patrón “Write-Audit-Publish”:**
 - Write (recolección de datos) $\approx$ Capa Bronze
 - Audit (limpieza y procesamiento de datos) $\approx$ Capa Silver
 - Publish (preparación para el uso) $\approx$ Capa Gold

A.1.3. Referente a Inteligencia Artificial

12. La “**Historia de la Inteligencia Artificial**” se remonta a hace casi un siglo, con la ideas de matemáticos como Alan Turing, que sentó las bases de la computación y propuso el primer test para evaluar inteligencia artificial (Cheok y Zhang, 2023). A partir de ese punto, no han parado de surgir avances en métodos matemáticos y algoritmos impulsando la búsqueda e implementación de modelos prácticos. Hitos como el desarrollo del perceptrón (Rosenblatt, 1958), un modelo esencial para las redes neuronales; las cadenas de Markov, usadas como modelos estadísticos (Hidden Markov Model (HMM)); o el desarrollo del “backpropagation” que sentó las bases para que el entrenamiento de redes neuronales profundas fuera efectivo (Werbos, 1974).

Los avances, junto con el aumento de la computación siguiendo la ley de Moore, permitió el surgimiento y aumento de las redes neuronales recurrentes (Hopfield, 1984), así como su uso para aplicaciones de procesamiento del lenguaje natural (Bengio et al., 2003). Otro punto de inflexión lo puso Google con su artículo “Attention Is All You Need” (Vaswani et al., 2017), donde definía que lo único que se necesitaba para procesar secuencias de forma eficaz era un mecanismo de atención, eliminando la necesidad de recurrencia y convoluciones, lo que permitió entrenar modelos más potentes sobre conjuntos de datos masivos, sentando las bases técnicas para los Grandes Modelos de Lenguaje (LLMs) como BERT o la serie GPT (Transformadores Pre-entrenados Generativos).

Tomando esta tecnología de los transformers, “OpenAI” lanzo diferentes versiones de su modelo GPT hasta culminar con una una interfaz conversacional basada en su modelo GPT-3,; ChatGPT. Esta interfaz se convirtió en una revolución, impulsando un interés público sin precedentes y consolidado a la IA como una herramienta indispensable. En los últimos años han seguido surgiendo modelos con tecnologías como la multimodalidad, donde los agentes combinan el procesamiento de texto escrito con otras fuentes como audio y visión en tiempo real, o el “Mixture of experts (MoE)” (Jiang et al., 2024) donde el modelo utiliza una combinación de múltiples redes neuronales (expertos), activando selectivamente un subconjunto de ellas para procesar cada entrada. Esta explosión en la presencia de la IA en la vida cotidiana, también ha impulsado, sobre todo en Europa, el desarrollo de marcos regulatorios para garantizar un uso responsable y transparente de estas tecnologías (Union Europea, 2024).

Matiz: Si bien tecnologías de visión por computador o generación de multimedia son pilares fundamentales de la IA moderna y cruciales

para los LLMs multimodales, es necesario acotar el alcance de este trabajo. Por lo tanto, esta definicion se centra en los avances relacionados con el procesamiento de datos estructurados y texto, dejando fuera un análisis detallado del tratamiento específico de vídeo, audio e imagen, a pesar de reconocer su enorme relevancia e impacto.

Para facilitar la visualización de esta definición, resumiremos los hitos que consideramos importantes en orden cronológico:


Tabla A.3: **Línea de tiempo de la IA**

1936	Turing machines - Marco teórico para computación
1950	Turing test - Primera medida práctica de inteligencia máquina
1958	Perceptrón - Modelo base de las redes neuronales
1964	ELIZA - Primer chatbot conversacional
1966	Hidden Markov Model - Modelo estadístico temprano
1967	K-means - Algoritmo popular de clustering
1974	Backpropagation - Algoritmo fundamental para ANN multicapa
1982	RNN - Redes neuronales recurrentes
1997	LSTM - RNN con memoria a largo plazo
	Deep Blue vence a Kasparov
2003	NPLM Aprendizaje de "embeddings" de palabras, base de LLM
2014	GAN - Generación de datos nuevos
2016	AlphaGo - Derroto al campeón del mundo
2017	Transformers - Arquitectura basada en atención
2018	BERT, GPT-1 - Modelos de lenguaje grandes (LLM)
2020	GPT-3 - aumento de las capacidades y parámetros
2021	DALL-E - Imágenes desde texto
2022	ChatGPT - Interfaz conversacional, aumenta el interés público
2023	GPT-4 - Modelo multimodal
	LLaMA Modelo Open-Source
2024	GPT-4o - Modelo multimodal con voz y visión en tiempo real
	EU AI Act - Regulación integral sobre IA
2025	DeepSeek - LLM de bajo costo
	IA Agéntica y especializada - agentes autónomos, tareas específicas

Fuente: Adaptación y actualización de (Cheok y Zhang, 2023), complementada con información de (Sapkota et al., 2025), (bit2brain, 2020), (Campbell et al., 2002) y las referencias mencionadas en el texto.

Como frase final, y espero que esperanzadora, incluir que a pesar de que esta tecnología ha pasado por algunas épocas de menor interés público, los datos de Web parecen mostrar que esta vez la tecnología viene para quedarse [Figura A.3]. Ya que a pesar de que un ultimo estudio del MIT anuncia que el 95 % de los proyectos con IA reciben retorno cero (Challapally et al., 2025), diversos analistas sostienen que esto no implica una burbuja vacía, sino más bien una fase inicial en la que muchos pilotos fracasaran por problemas de integración o organizativos y no por fallos tecnológicos. Al igual que ocurrió con la burbuja de las dot.com, de la cual emergieron gigantes como Amazon y Google, se espera que también en IA sobrevivan los proyectos con verdadero valor (AI Explained, 2025).

Figura A.3: Tendencias de búsqueda de IA



Fuente: (Google Trends, 2025), *Destacar el pico de 2011 por el lanzamiento de Siri (Apple) y la tendencia desde 2022 por la salida de chatGPT.*

13. Los tipos de **Técnicas de ML según aprendizaje** es la forma de clasificar estos modelos dependiendo de la forma en la que los sistemas aprenden patrones, o del grado de supervisión que reciben. Se clasifican en cuatro tipos principales (Sarker, 2021):

- **Aprendizaje Supervisado:** utiliza datos etiquetados para aprender una función que mapea entradas a salidas. Esta orientada a tareas concretas, y sus aplicaciones más comunes incluyen clasificación y regresión, como predecir la cantidad de ventas de un producto.
- **Aprendizaje No Supervisado:** analiza datos no etiquetados,

buscando estructuras, patrones o relaciones ocultas. Es un enfoque orientado al descubrimiento y exploración, y se aplica típicamente en clusterización, reducción de dimensionalidad o detección de anomalías.

- **Aprendizaje Semi-Supervisado:** combina datos etiquetados y no etiquetados, aprovechando la abundancia de datos sin etiqueta para mejorar el rendimiento del modelo más allá de lo que se lograría solo con datos etiquetados. Es útil en contextos donde las etiquetas son costosas o escasas, como en detección de fraude o clasificación de texto.
- **Aprendizaje por Refuerzo:** se basa en la interacción de un agente con un entorno, aprendiendo mediante recompensas o penalizaciones para optimizar su comportamiento. Se aplica en tareas de automatización compleja y optimización, como robótica o conducción autónoma.

14. **MLOps** u operaciones de aprendizaje automático, son un conjunto de prácticas y herramientas que busca automatizar y gestionar el ciclo de vida completo de un proyecto de machine learning, desde el desarrollo del modelo hasta su despliegue, monitoreo y mantenimiento en producción, basándose en principios de DevOps pero adaptados a las particularidades de los sistemas de ML (Kreuzberger et al., 2023). Los nueve principios son los siguientes:

- a) **Automatización CI/CD:** Integración, entrega y despliegue continuos que automatizan el desarrollo, prueba y puesta en producción de los modelos, proporcionando información rápida sobre el éxito o fracaso de cada paso.
- b) **Orquestación del flujo de trabajo (workflow):** Coordinación y gestión de las tareas de un “pipeline” o proceso de ML, estableciendo el orden de ejecución y dependencias, típicamente mediante DAGs.
- c) **Reproducibilidad:** Capacidad fundamental de replicar el experimento de ML y obtener los mismos resultados.
- d) **Control de versiones:** Implica la gestión y el seguimiento riguroso de los cambios en los datos, modelos y código (indispensable para la trazabilidad y el cumplimiento normativo).
- e) **Colaboración:** Promueve el trabajo conjunto y una cultura comunicativa y abierta entre los diferentes roles del proyecto para minimizar aislamiento de datos e información.

- f*) **Entrenamiento y evaluación continuos:** Implica el retrenamiento periódico y automático de los modelos con nuevos datos, incluyendo una evaluación constante de su calidad para asegurar que sigan siendo relevantes, precisos y óptimos en cuanto a rendimiento.
- g*) **Seguimiento y registro de metadatos:** Documentación detallada de la información relevante de cada ejecución del flujo para asegurar trazabilidad: parámetros utilizados, métricas, código, tiempo de ejecución y los datos utilizados.
- h*) **Monitoreo continuo:** Observación periódica de los datos, modelos, código, infraestructura y rendimiento del modelo desplegado, con el objetivo de detectar anomalías, errores o bajadas en la calidad.
- i*) **Bucles de retroalimentación:** Integrar los hallazgos y las lecciones aprendidas del monitoreo y la evaluación de calidad en el proceso de desarrollo.

- j*) **Modelos de Machine learning.** Estas definiciones se basan en el curso de (Brownlee, s.f), el libro del mismo autor (Brownlee, 2024a) y en los libros (Fowdur, 2021) y (Sarker, 2021), así como en la asignatura “desarrollo de aplicaciones y servicios inteligentes” impartida por la Universidad Complutense de Madrid. Aunque para estas definiciones **no** nos centraremos en como efectuar la selección de hiperparámetros (parámetros externos al modelo que lo configuran), nombrar que el rendimiento y complejidad de estos modelos depende de la correcta elección de esta característica. También, por alcance, detallaremos solo los modelos que se han elegido para estudiar en este de entre la gran variedad de ellos que existe (Wikipedia, s.f), estos son los siguientes:
 - 1) **Árboles de Decisión (Decision Trees):** Son un método de aprendizaje **supervisado** no paramétrico utilizado para **clasificación y regresión**. Consiguen su objetivo dividiendo recursivamente el conjunto de datos de entrenamiento en subconjuntos más pequeños, evaluando todas las posibles divisiones en cada característica de entrada para encontrar el punto de división óptimo que minimice la función de coste. El proceso continúa hasta alcanzar un criterio de detención, obteniendo los nodos terminales que contienen la predicción final (la clase más común o el promedio de valores).
 - 2) **k-Nearest Neighbors (k-NN):** Es un algoritmo de apren-

dizaje **supervisado** de "aprendizaje perezoso" (no ejecuta hasta que no se le pida una predicción), utilizado para **clasificación y regresión**. Consigue su objetivo para nuevos datos calculando la distancia entre este y todos los ejemplos del conjunto de entrenamiento. Luego, selecciona los k ejemplos más parecidos (vecinos). Para clasificación, la predicción es la clase más común entre estos k vecinos; para regresión, es el promedio de sus valores de salida.

- 3) **K-means**: Es un algoritmo de aprendizaje **no supervisado** utilizado para la **clusterización**. Consigue su objetivo al identificar k centroides en el conjunto de datos y luego asigna cada punto de datos al centroide más cercano durante varias iteraciones, estos centroides se actualizan continuamente moviéndose al promedio de todos los puntos asignados a su cluster, y después de esto los puntos se reasignan, con el fin de minimizar la suma de las distancias cuadradas entre cada punto de datos y su centroide asignado.
- 4) **Random Forests (Bosques Aleatorios)**: Es un método de ensamble de aprendizaje supervisado utilizado para clasificación y regresión. Consigue su objetivo construyendo un "bosque" de múltiples árboles de decisión individuales. Cada árbol se entrena en una submuestra aleatoria del conjunto de datos con reemplazo (bagging), y en cada punto de división se considera solo un subconjunto aleatorio de características. Las predicciones finales se obtienen combinando las predicciones de todos los árboles del bosque: por votación mayoritaria para clasificación o por promedio para regresión, lo que reduce la varianza y mejora la precisión.
- 5) **XGBoost (Extreme Gradient Boosting)**: Es una implementación optimizada y escalable de algoritmos de "gradient boosting", un método de ensamble de aprendizaje **supervisado para clasificación y regresión**. Consigue su objetivo construyendo una serie de modelos individuales de forma secuencial (normalmente árboles de decisión), donde cada nuevo modelo se entrena para corregir los errores residuales de los árboles previos. Para ello, minimiza una "función de pérdida" que cuantifica el error del modelo empleando aproximaciones de segundo orden. Esto significa que, computa tanto la pendiente de la función de pérdida (como en el descenso de gradiente básico) como su curvatura para encontrar el mínimo, lo que resulta en una convergencia más rápida y una mayor exactitud. Además, aplica técnicas de regularización

avanzadas (L1 y L2) para prevenir el sobre-ajuste y mejorar la generalización. La regularización L1 (Lasso) penaliza la suma de los valores absolutos de los coeficientes, pudiendo llevar algunos a cero y realizando selección de características; la regularización L2 (Ridge) penaliza la suma de los cuadrados de los coeficientes, reduciéndolos sin eliminarlos.

- 6) **DBSCAN:** Es un algoritmo de aprendizaje **no supervisado para clusterización** basado en “densidad”. Consigue su objetivo identificando regiones densas de puntos de datos separadas por regiones de menor densidad, clasificando los puntos como centrales, frontera o de ruido, y forma cada clúster a partir de puntos que están densamente conectados. No requiere que se especifique el número de clústeres de antemano y es capaz de descubrir clústeres de formas arbitrarias, además de identificar valores extremos.
- 7) **Redes Neuronales Profundas (Deep Neural Networks - DNN):** Brevemente, son modelos de aprendizaje **supervisado** que incluyen arquitecturas como los perceptrones multicapa (MLP). Consiguen su objetivo aprendiendo representaciones jerárquicas de los datos a través de múltiples capas ocultas de procesamiento (capas ocultas). El proceso de entrenamiento implica la propagación hacia adelante de la entrada para calcular una salida, seguida de la retropropagación ("Backpropagation") del error para ajustar iterativamente los pesos de las conexiones, minimizando la diferencia entre la salida predicha y la esperada. Son aptas para **clasificación y regresión en datos complejos**.
- 8) **Grandes Modelos de Lenguaje (Large Language Models - LLM):** Son un tipo avanzado de Redes Neuronales Profundas, frecuentemente basadas en la arquitectura de “transformers”. Consiguen su objetivo mediante un pre-entrenamiento masivo en vastos corpus de texto y código, permitiendo aprender patrones complejos de lenguaje, gramática, semántica y contextualización. Su mecanismo de atención les permite ponderar la importancia de diferentes partes de la entrada, facilitando una comprensión profunda y la generación de texto coherente y relevante. Se utilizan para una amplia gama de tareas de procesamiento de lenguaje natural (PNL).

k)

A.2. Acrónimos

AI Inteligencia Artificial (Artificial Intelligence)

AI Act Ley de Inteligencia Artificial (Artificial Intelligence Act)

ANN Redes Neuronales Artificiales (Artificial Neural Network)

API Interfaz de Programación de Aplicaciones (Application Programming Interface)

ARIMA Modelo Autorregresivo Integrado de Medias Móviles (Autoregressive Integrated Moving Average)

AWS Amazon Web Services

BDTI Big Data Test Infrastructure

BERT Representaciones de Codificador Bidireccional de Transformadores (Bidirectional Encoder Representations from Transformers)

BOINC Berkeley Open Infrastructure for Network Computing

BTOS Encuesta sobre Tendencias y Panorama Empresarial (Business Trends and Outlook Survey)

CCPA Ley de Privacidad del Consumidor de California (California Consumer Privacy Act)

CDN Red de Distribución de Contenidos (Content Delivery Network)

CI/CD Integración Continua/Entrega Continua (Continuous Integration/Continuous Delivery)

CIF Corporate Information Warehouse

CKAN Comprehensive Knowledge Archive Network

CNN Red Neuronal Convolucional (Convolutional Neural Network)

CNMC Comisión Nacional de los Mercados y la Competencia

CPU Unidad Central de Procesamiento (Central Processing Unit)

CSV Valores Separados por Comas (Comma-Separated Values)

D1 D1 Database (Base de datos de Cloudflare)

DAGs Grafos Acíclicos Dirigidos (Directed Acyclic Graphs)

DAMA Asociación de Gestión de Datos (Data Management Association)

DBSCAN Clustering Espacial Basado en Densidad de Aplicaciones con Ruido (Density-Based Spatial Clustering of Applications with Noise)

DDoS Ataque de Denegación de Servicio Distribuido (Distributed Denial of Service)

DevOps Development and Operations

DNN Redes Neuronales Profundas (Deep Neural Networks)

DNS Sistema de Nombres de Dominio (Domain Name System)

DSL Ley de Seguridad de Datos (Data Security Law) - China

EC2 Elastic Compute Cloud (Amazon EC2)

EEUU Estados Unidos

ETL Extract, Transform, Load (Extraer, Transformar, Cargar)

EU European Union (Unión Europea)

GAN Red Generativa Antagónica (Generative Adversarial Network)

GCP Google Cloud Platform

GPT Transformador Pre-entrenado Generativo (Generative Pre-trained Transformer)

GPU Unidad de Procesamiento Gráfico (Graphics Processing Unit)

HIPAA Ley de Portabilidad y Responsabilidad de Seguros de Salud (Health Insurance Portability and Accountability Act)

HITL Human in the loop (humano en los procesos (de IA))

HMM Modelo Oculto de Markov (Hidden Markov Model)

HTTP Hypertext Transfer Protocol

HTML Lenguaje de Marcado de Hipertexto (HyperText Markup Language)

IA Inteligencia Artificial (Artificial Intelligence)

IaaS Infraestructura como Servicio (Infrastructure as a Service)

IBM International Business Machines (empresa)

IDE Entorno de Desarrollo Integrado (Integrated Development Environment)

INE Instituto Nacional de Estadística

IoT Internet de las Cosas (Internet of Things)

IP Internet Protocol

IPv4 Internet Protocol version 4

-
- JSON** Notación de Objetos de JavaScript (JavaScript Object Notation)
- k-NN** k-Nearest Neighbors (k-Vecinos Más Cercanos). Algoritmo de aprendizaje automático.
- KV** Key-Value (Almacenamiento Clave-Valor)
- LGD** Ley de Gobernanza de Datos
- LLM** Modelo de Lenguaje a Gran Escala (Large Language Model)
- LSTM** Memoria a Largo-Corto Plazo (Long Short-Term Memory)
- MIT** Massachusetts Institute of Technology (Instituto de Tecnología de Massachusetts)
- ML** Aprendizaje Automático (Machine Learning)
- MLOps** Operaciones de Aprendizaje Automático (Machine Learning Operations)
- MLP** Perceptrón Multicapa (Multi-layer Perceptron)
- MoE** Mezcla de Expertos (Mixture of Experts)
- NAS** Búsqueda de Arquitecturas Neuronales (Neural Architecture Search)
- NLP** Procesamiento del Lenguaje Natural (Natural Language Processing)
- NoSQL** Not only SQL
- NPLM** Modelo de Lenguaje Neuronal Probabilístico (Neural Probabilistic Language Model)
- OECD** Organización para la Cooperación y el Desarrollo Económicos (Organisation for Economic Co-operation and Development)
- OGDA** Ley de Datos Abiertos del Gobierno (OPEN Government Data Act)
- OKF** Open Knowledge Foundation
- ONG** Organización No Gubernamental
- ONTSI** Observatorio Nacional de Tecnología y Sociedad
- PaaS** Plataforma como Servicio (Platform as a Service)
- PIPL** Ley de Protección de Información Personal (Personal Information Protection Law) - China
- PLN** Procesamiento del Lenguaje Natural (Natural Language Processing)
- PYMEs** Pequeñas y Medianas Empresas
- R2** R2 Storage (Almacenamiento de Cloudflare)

RAM	Memoria de Acceso Aleatorio (Random Access Memory)
RDS	Servicio de Bases de Datos Relacionales (Relational Database Service)
RGPD	Reglamento General de Protección de Datos
RIA	Reglamento de Inteligencia Artificial
RL	Aprendizaje por Refuerzo (Reinforcement Learning)
RNN	Redes Neuronales Recurrentes (Recurrent Neural Network)
S3	Simple Storage Service (Amazon S3)
SaaS	Software como Servicio (Software as a Service)
SASE	Acceso Seguro al Borde del Servicio (Secure Access Service Edge)
SES	Simple Email Service (Amazon SES)
SIMPL	Smart Middleware Platform for Cloud-to-Edge (EU)
SNS	Simple Notification Service (Amazon SNS)
SQS	Simple Queue Service (Amazon SQS)
SQL	Lenguaje de Consulta Estructurado (Structured Query Language)
SSL	Capa de Conexión Segura (Secure Sockets Layer)
SSD	Disco de Estado Sólido (Solid State Drive)
TPU	Unidad de Procesamiento Tensorial (Tensor Processing Unit)
TURN	Traversal Using Relays around NAT (Network Address Translation)
UE	Unión Europea
VM	Máquina Virtual (Virtual Machine)
XML	Lenguaje de Marcado Extensible (eXtensible Markup Language)
XLSX	Excel Open XML Spreadsheet

Apéndice B: Uso ético de herramientas de IA

Este apéndice complementa la “Declaración responsable sobre autoría y uso ético de herramientas de IA” proporcionada por la UCM y que se adjunta con esta memoria. En cumplimiento de los principios de transparencia y ética académica, además del cumplimiento de las normativas europeas sobre el uso de inteligencia artificial en los textos de interés público (?). Declaramos aquí el uso de herramientas y algoritmos basados en inteligencia artificial durante el desarrollo de este trabajo:

- **Accesibilidad y transcripción:** Debido a un problema médico personal del autor, diagnosticado durante el desarrollo del proyecto, la cual limitaba severamente la capacidad de escritura manual prolongada mediante teclado, se emplearon herramientas de reconocimiento de voz a texto (concretamente, el servicio de dictado nativo de Windows, atajo *Windows + H*) para la redacción de los borradores de esta memoria o texto completo que en todo momento fue supervisado.
- **Revisión y corrección de estilo:** Se utilizaron herramientas de asistencia a la redacción para corregir errores tipográficos y depurar la gramática del texto, así como la revisión del texto a través de LLMs para revisar huecos o frases incompletas que se hubieran pasado por alto, sin que estas herramientas alteraran en ningún momento la originalidad de las ideas o el contenido intelectual del autor.
- **Modelado analítico y tratamiento de datos:** Tal y como se detalla en el Capítulo ??, el núcleo analítico del trabajo se basa en la aplicación de algoritmos de aprendizaje automático (*Machine Learning*). Se han utilizado herramientas de IA orientadas al análisis de datos (como

K-Means o agrupamiento jerárquico) para extraer conclusiones, identificar patrones y generar los resultados de los casos de estudio.

- **Asistente de GCP:** *Google Cloud* cuenta con un asistente de inteligencia artificial para el análisis de logs que se utilizó para analizar los errores al intentar desplegar en *Cloud Run* y *Cloud Functions*, pero que no fue de mucha ayuda para dar con la solución, ya que al final se acabó usando el entorno de Vertex IA para implementar el proceso en esta nube.
- :

B.1. Análisis de la gestión de datos mediante LLMs

Bibliografía

- AI EXPLAINED. An ai bubble? what altman actually said, the facts and nano banana. 2025.
- AKASH. The decentralized cloud built for ai's next frontier. s.f.
- ALBERT BARRON, T. P. C. M. Pizza as a service. 2015.
- AMAZON. Datos abiertos en aws. 2025.
- AMAZON WEB SERVICES. Amazon sagemaker. 2025.
- AMAZON WEB SERVICES. Aws well-architected framework. 2026a.
- AMAZON WEB SERVICES. Creación de cuenta en AWS Console. 2026b.
- AMAZON WEB SERVICES. Documentacion general de AWS. 2026c.
- AMAZON WEB SERVICES. Tutorial de AWS: Creación y activación de una cuenta de AWS. 2026d.
- ANDERSON, D. Boinc: a system for public-resource computing and storage. 2004.
- ANSLOW, C., BROSZ, J., MAURER, F. y BOYES, M. Datathons: An experience report of data hackathons for data science education. página 615–620, 2016.
- ARELLANO BRUNO, J. B. Uso de geolocalización y de fuentes de datos abiertas para la creación de servicios turísticos por la ciudad de madrid. 2019.
- AWESOME DATA. Awesome public datasets. 2025.
- AYUNTAMIENTO DE MADRID. Portal de datos abiertos del ayuntamiento de madrid. 2025.

- AYUNTAMIENTO DE MADRID. Portal de datos abiertos del ayuntamiento de madrid. 2026a.
- AYUNTAMIENTO DE MADRID. Sistema integral de la calidad del aire: interpretación de los datos de calidad del aire y meteorología. 2026b. Portal de Datos Abiertos del Ayuntamiento de Madrid, documentación asociada a los conjuntos de datos diarios.
- BARBUDO, R., VENTURA, S. y ROMERO, J. R. Eight years of automl: categorisation, review and trends. *Knowledge and Information Systems*, vol. 65(12), páginas 5097–5149, 2023.
- BENGIO, Y., DUCHARME, R., VINCENT, P. y JAUVIN, C. A neural probabilistic language model. *Journal of Machine Learning Research*, vol. 3(Feb), páginas 1137–1155, 2003.
- BENINGTON, J. Creating the public in order to create public value? *International Journal of Public Administration*, vol. 32(3-4), 2009.
- BIT2BRAIN. Historia de la IA Inteligencia Artificial. 2020.
- BOBROV, K. Data engineering: Now with 30 2025.
- BOMMALA, H. ET AL. Cloud verse: mapping the new frontiers of cloud computing. vol. 392, página 01081, 2024.
- BOZEMAN, B. *Public Values and Public Interest: Counterbalancing Economic Individualism*. Georgetown University Press, 2007. ISBN 9781589011779.
- BROWN, B., CHUI, M. y MANYIKA, J. Are you ready for the era of big data. *McKinsey Quarterly*, vol. 4(1), páginas 24–35, 2011.
- BROWNLEE, J. *Master Machine Learning Algorithms: Discover How They Work and Implement Them From Scratch*. Machine Learning Mastery, 2016.
- BROWNLEE, J. *Machine Learning Algorithms From Scratch*. Machine Learning Mastery, 2024a.
- BROWNLEE, J. A practical guide to choosing the right algorithm for your problem: From regression to neural networks. 2024b.
- BROWNLEE, J. Machine learning mastery. s.f.
- BÖER, J. Self-service ai for everyone? a comparison of automl services. 2023.
- CAMPBELL, M., HOANE JR., A. J. y HSU, F.-H. Deep Blue. *Artificial Intelligence*, vol. 134(1-2), páginas 57–83, 2002.

- CARSANIGA, G., DOGGER, J. y REGECZI, D. The use case observatory a 3-year monitoring of 30 reuse cases to understand the economic, governmental, social and environmental impact of open data volume i. *Publications Office of the European Union*, 2022.
- CHALLAPALLY, A., PEASE, C., RASKAR, R. y CHARI, P. State of ai in business 2025: The genai divide. 2025. Preliminary findings from AI Implementation Research, Research Period: January–June 2025.
- CHEOK, A. y ZHANG, E. From turing to transformers: A comprehensive review and tutorial on the evolution and applications of generative transformer models. 2023.
- CLOUDING.IO. clouding.io, infraestructura cloud a tu servicio. s.f.
- COMISIÓN NACIONAL DE LOS MERCADOS Y LA COMPETENCIA. Informe económico sectorial de telecomunicaciones y audiovisual 2025. 2026.
- CONCEPCIÓN DE LINARES, J. B. Open food facts. 2025a.
- CONCEPCIÓN DE LINARES, J. B. Planttes. 2025b.
- CONGRESO DE LOS ESTADOS UNIDOS DE AMERICA. Health insurance portability and accountability act of 1996 (hipaa). 1996.
- CONGRESO DE LOS ESTADOS UNIDOS DE AMERICA. Foundations for evidence-based policymaking act of 2018, title ii: Open government data act. 2019.
- CORNELLA, A. Conferencia - cómo sobrevivir a la infoxicación. 2000.
- DANYSOFT. El ataque de los botnets. s.f.
- DE DATOS ABIERTOS DEL GOBIERNO DE ESPAÑA, P. El potencial uso de la metodología de dama en la gestión de los datos abiertos. 2021.
- ESRI ESPAÑA. Portal de datos abiertos de esri españa. 2025.
- ESTADO DE CALIFORNIA. California consumer privacy act (ccpa). 2018.
- EUROPEAN COMMISSION. Simpl: Cloud-to-edge federations empowering eu data spaces. 2024.
- EUROPEAN COMMISSION. Cloud computing. s.f.a.
- EUROPEAN COMMISSION. From hype to action using the big data test infrastructure (bdti). s.f.b.

- EUROPEAN PARLIAMENT, C. Regulation (eu) 2022/868 of the european parliament and of the council of 30 may 2022 on european data governance and amending regulation (eu) 2018/1724 (data governance act). Official Journal of the European Union, L 152, pp. 1-44, 2022. Accessed: 28 August 2025.
- EUROSTAT. 53 % of eu enterprises used paid cloud services in 2025. 2026.
- FANG, X., XU, W., TAN, F. A., ZHANG, J., HU, Z., QI, Y., NICKLEACH, S., SOCOLINSKY, D., SENGAMEDU, S. y FALOUTSOS, C. Large language models (llms) on tabular data: Prediction, generation, and understanding – a survey. *arXiv preprint arXiv:2402.17944*, 2024. Version 4, last revised 21 June 2024.
- FERRER-SAPENA, A., PESET, F. y ALEIXANDRE-BENAVENT, R. Acceso a los datos públicos y su reutilización: Open data y open government. *El Profesional de la Información*, páginas 260–269, 2011.
- FEURER, M., EGGENSBERGER, K., FALKNER, S., LINDAUER, M. y HUTTER, F. Auto-sklearn 2.0: Hands-free automl via meta-learning. *arXiv:2007.04074 [cs.LG]*, 2020.
- FOWDUR, T. P. *Real-Time Cloud Computing and Machine Learning Applications*. Computer Science, Technology and Applications. Nova Science Publishers, Incorporated, New York, 2021. ISBN 978-1536198133. Description based upon print version of record.
- FSSPEC DEVELOPERS. fsspec: Filesystem interfaces for python. 2026.
- GABRIEL, I., MANZINI, A., KEELING, G., HENDRICKS, L. A., RIESER, V., IQBAL, H., TOMAŠEV, N., K TENA, I., KENTON, Z., RODRIGUEZ, M., EL-SAYED, S., BROWN, S., AKBULUT, C., TRASK, A., HUGHES, E., BERGMAN, A. S., SHELBY, R., MARCHAL, N., GRIFFIN, C., MATEOS-GARCIA, J., WEIDINGER, L., STREET, W., LANGE, B., INGERMAN, A., LENTZ, A., ENGER, R., BARAKAT, A., KRAKOVNA, V., SIY, J. O., KURTH-NELSON, Z., MCCROSKERY, A., BOLINA, V., LAW, H., SHANAHAN, M., ALBERTS, L., BALLE, B., DE HAAS, S., IBITOYE, Y., DAFOE, A., GOLDBERG, B., KRIER, S., REESE, A., WITHERSPOON, S., HAWKINS, W., RAUH, M., WALLACE, D., FRANKLIN, M., GOLDSTEIN, J. A., LEHMAN, J., KLENK, M., VALLOR, S., BILES, C., MORRIS, M. R., KING, H., y ARCAS, B. A., ISAAC, W. y MANYIKA, J. The ethics of advanced ai assistants. 2024.
- GEOPANDAS DEVELOPERS. Geopandas: Python tools for geographic data. 2026.
- GIGAS. Gigas - cloud hosting solutions. s.f.

- GMBH, N. Nextcloud - your own private cloud. s.f.
- GOBIERNO DE ESPAÑA. Big data test infrastructure: Un entorno gratuito para que las aa.pp experimenten con sus datos abiertos. 2021a.
- GOBIERNO DE ESPAÑA. Plan de digitalización de las administraciones públicas 2021-2025. 2021b.
- GOBIERNO DE ESPAÑA. Eventos datathon gobierno de españa. 2025a.
- GOBIERNO DE ESPAÑA. Eventos datos abiertos gobierno de españa. 2025b.
- GOBIERNO DE ESPAÑA. Portal de datos abiertos. 2025c.
- GOBIERNO DE ESPAÑA. Nubesara. s.f.a.
- GOBIERNO DE ESPAÑA. Plan de precios de nubesara. s.f.b.
- GOLEM NETWORK. Golem network. s.f.
- GOOGLE. Data commons. 2025a.
- GOOGLE. Google vertex ai platform. 2025b.
- GOOGLE. Welcome to colab! 2025c.
- GOOGLE CLOUD. Google cloud architecture framework. 2026.
- GOOGLE CLOUD. Amplía la infraestructura y la ia de google cloud on-premise. s.f.
- GOOGLE CLOUD PLATFORM. Creación de cuenta en Google Cloud Console. 2026a.
- GOOGLE CLOUD PLATFORM. Documentacion general de GCP. 2026b.
- GOOGLE CLOUD PLATFORM. Tutorial de GCP: Creación y activación de una cuenta de GCP. 2026c.
- GOOGLE TRENDS. Google trends artificial intelligence. 2025. Se puede observar un pico en 2011, posiblemente por la salida de Siri, y la tendencia creciente desde 2022 debido a chatGPT. Las cifras representan el interés de búsqueda en relación con el punto más alto del gráfico para la región y el momento determinados. Un valor de 100 es el pico de popularidad del término. Un valor de 50 significa que el término es la mitad de popular. Una puntuación de 0 significa que no había datos suficientes para este término.
- GÓMEZ-OBREGÓN, J. Jaime gómez-obregón. 2025a.
- GÓMEZ-OBREGÓN, J. La donación - jaime gómez-obregón. 2025b.

- GÓMEZ-OBREGÓN, J. Subvenciones - jaime gómez-obregón. 2025c.
- HERRERA CAPRIZ, M. E. El valor intangible de la transparencia: un análisis de los datos abiertos de España en el marco de la corriente "valor público". 2024. Tesis inédita de la Universidad Complutense de Madrid, Facultad de Ciencias de la Información, leída el 08/05/2024.
- HOPFIELD, J. J. Neurons with graded response have collective computational properties like those of two-state neurons. *Proc Natl Acad Sci U S A*, vol. 81(10), páginas 3088–3092, 1984.
- HUAWEI TECHNOLOGIES CO., LTD. *Cloud Computing Technology*. Springer and Posts & Telecom Press, Singapore and Beijing, 2023. ISBN 978-981-19-3026-3. Open access book.
- HUGGINGFACE. huggingface spaces. 2025.
- INSTITUTO NACIONAL DE ESTADÍSTICA. Encuesta sobre el uso de TIC y del comercio electrónico en las empresas. año 2024 - primer trimestre 2025. 2025.
- JIANG, A. Q., SABLAYROLLES, A., ROUX, A., MENSCH, A., SAVARY, B., BAMFORD, C., CHAPLOT, D. S., DE LAS CASAS, D., HANNA, E. B., BRESSAND, F., LENGUEL, G., BOUR, G., LAMPLE, G., LAUDAUD, L. R., SAULNIER, L., LACHAUX, M.-A., STOCK, P., SUBRAMANIAN, S., YANG, S., ANTONIAK, S., LE SCAO, T., GERVET, T., LAVRIL, T., WANG, T., LACROIX, T. y EL SAYED, W. Mixtral of Experts. *arXiv preprint arXiv:2401.04088*, 2024.
- JIN, H., CHOLLET, F., SONG, Q. y HU, X. Autokeras: An automl library for deep learning. *Journal of Machine Learning Research*, vol. 24(6), páginas 1–6, 2023.
- JORGE, R. y HERRERA, R. Aumenta la negativa a abrir datos públicos: Informa inai tendencia de 4t a opacidad. llama presidenta a ciudadanos a iniciar defensa de ente autónomo. 2023. Copyright - Copyright Editora El Sol, S.A. de C.V. Mar 24, 2023; Última actualización - 2023-03-24.
- KAGGLE. Kaggle code notebook. 2025a.
- KAGGLE. Kaggle datasets. 2025b.
- KHAN, S. y ALAM, M. File formats for big data storage systems. *International Journal of Engineering and Advanced Technology (IJEAT) Volume-9 Issue-1*, 2019.
- KREUZBERGER, D., KÜHL, N. y HIRSCHL, S. Machine learning operations (mlops): Overview, definition, and architecture. *IEEE Access*, vol. 11, páginas 31866–31879, 2023.

- KUMAR, R., ADWANI, L., KUMAWAT, S. y JANGIR, S. K. Opennebula: Open source IaaS cloud computing software platforms. 2014.
- LEONIDAS, T., ALEXANDRA, T. y YANNIS, S. A state-of-the-art review in big data management engineering: Real-life case studies, challenges, and future research directions. *Eng*, vol. 5(3), página 1266, 2024. Copyright - © 2024 by the authors. Licensee MDPI, Basel, Switzerland. This article is an open access article distributed under the terms and conditions of the Creative Commons Attribution (CC BY) license (<https://creativecommons.org/licenses/by/4.0/>). Notwithstanding the ProQuest Terms and Conditions, you may use this content in accordance with the terms of the License; Última actualización - 2024-09-27.
- LISDORF, A. *Cloud Computing Basics: A Non-Technical Introduction*. Apress, 2021. ISBN 978-1-4842-6921-3. Accessed: 2025-08-27.
- LLAMOCCA PORTELA, P. Integración y visualización de datos abiertos medioambientales. 2016. Máster en Ingeniería Informática, curso 2015-2016.
- LLM STATS. Llm leaderboard. s.f.
- MACQUEEN, J. B. Some methods for classification and analysis of multivariate observations. En *Proceedings of the Fifth Berkeley Symposium on Mathematical Statistics and Probability*, vol. 1, páginas 281–297. University of California Press, 1967.
- MATHEUS, R. y JANSSEN, M. A systematic literature study to unravel transparency enabled by open government data: The window theory. *Public Performance & Management Review*, vol. 43(3), páginas 503–534, 2020.
- MELENDREZ MORETO, I. Auditoría y metodología de implantación de open data para smart cities. 2016. Máster en Ingeniería Informática, curso 2015-2016, a destacar: gran compilación de datasets, conceptos interesantes como cinco estrellas del Open Data, manual de CKAN.
- MENESES VICENTE, G. y GARCÍA RUÍZ, J. F. Madrid, isla de calor. 2023. Trabajo de Fin de Master en Ingeniería Informática.
- MEYNHARDT, T. Public value inside: What is public value creation? *International Journal of Public Administration*, vol. 32(3-4), páginas 192–219, 2009.
- MICROSOFT. microsoft azure machine learning. 2025.
- MICROSOFT. Cloud computing terminology. s.f.a.
- MICROSOFT. What is the medallion lakehouse architecture? s.f.b.

- MICROSOFT. ¿qué es la tokenización? s.f.c.
- MOORE, M. Creating public value: Strategic management in government. 1995.
- MOSQUEIRA-REY, E., HERNÁNDEZ-PEREIRA, E., ALONSO-RÍOS, D., BOBES-BASCARÁN, J. y ÁNGEL FERNÁNDEZ-LEAL. Human-in-the-loop machine learning: a state of the art. *Artificial Intelligence Review*, vol. 56(4), páginas 3005–3054, 2023. ISSN 1573-7462.
- NIGRO, H. Cloud computing: Retos y oportunidades. *Rev. Ingeniería, Matemáticas y Ciencias de la Información*, vol. 9(18), páginas 11–16, 2022.
- NIJSEN, D. The use case observatory a 3-year monitoring of 30 reuse cases to understand the economic, governmental, social and environmental impact of open data volume ii. *Publications Office of the European Union*, 2022.
- NOV, O., ANDERSON, D. y ARAZY, O. Volunteer computing: A model of the factors determining contribution to community-based scientific research. *Proceedings of the 19th International Conference on World Wide Web, WWW '10*, páginas 741–750, 2010.
- OBSERVATORIO NACIONAL DE TECNOLOGÍA Y SOCIEDAD. Indicadores de uso de inteligencia artificial en las empresas españolas. edición 2025 - datos 2024. 2025. NIPO: 230250053, DOI: 10.30923/230250053.
- OECD. *The Path to Becoming a Data-Driven Public Sector*. OECD Digital Government Studies. OECD Publishing, 2019.
- OECD. 2023 oecd open, useful and re-usable data “ourdata” index: Results and key findings. *OECD Public Governance Policy Papers, No. 43, OECD Publishing, Paris*, 2023.
- OPEN DATA CHARTER. ¿qué son los datos abiertos? s.f.
- OPEN KNOWLEDGE FOUNDATION. Open definition. 2025.
- OPEN KNOWLEDGE FOUNDATION. Ckan 2.9 api guide: Action api and `package_show`. 2026a. Documentación oficial de CKAN, versión 2.9.11.
- OPEN KNOWLEDGE FOUNDATION. Ckan: open-source data management system. 2026b. Plataforma sobre la que opera el Portal de Datos Abiertos de Madrid.
- OVHCLOUD. Ovhcloud ai training. 2025.
- OVHCLOUD. Public cloud free trial ovhcloud. s.f.

- PANGARKAR, T. Big data statistics 2025 by patterns in the dimensions. 2025.
- SÁNCHEZ DE PAZ, M. Optimización de infraestructuras de cloud computing basadas en máquinas virtuales. 2023. Trabajo de Fin de Máster en Ingeniería Informática, Curso 2022/2023.
- PORTAL EUROPEO DE DATOS. ¿qué son los datos abiertos? 2025.
- PREPARATIC. Servicio nubesara. casos prÁcticos y ejemplos de aplicaciÓn. s.f.
- PRESS, G. A very short history of big data. 2013.
- RADWERE. What is mydoom malware? s.f.
- RAMOS-SIMÓN, L. F. El uso de las licencias libres en los datos públicos abiertos. *Revista Espanola de Documentacion Cientifica*, vol. 40(3), páginas 1–16, 2017. Copyright - Copyright Consejo Superior de Investigaciones Científicas Jul/Sep 2017; Última actualización - 2017-10-04.
- RAY, P. P. An introduction to dew computing: Definition, concept and implications. *IEEE Access*, vol. 6, páginas 723–737, 2018.
- REGISTRADORES DE ESPAÑA. Portal de datos abiertos de los registradores de españa. 2025.
- RENDER NETWORK. The distributed gpu render network. s.f.
- R.I.PIENAAR. Free for devs. 2025.
- ROSENBLATT, F. The perceptron: A probabilistic model for information storage and organization in the brain. *Psychological Review*, vol. 65(6), páginas 386–408, 1958.
- SALEHIN, I., ISLAM, M. S., SAHA, P., NOMAN, S., TUNI, A., HASAN, M. M. y BATEN, M. A. Automl: A systematic review on automated machine learning with neural architecture search. *Journal of Information and Intelligence*, vol. 2(1), páginas 52–81, 2024. ISSN 2949-7159.
- SANTOS, J. S. Análisis de datos de la ciudad de madrid. 2023. Trabajo de Fin de Grado en Ingeniería Informática.
- SAPKOTA, R., ROUMELIOTIS, K. I. y KARKEE, M. Ai agents vs. agentic ai: A conceptual taxonomy, applications and challenges. *Information Fusion*, vol. 126, 2025. ISSN 1566-2535.
- SARKER, I. H. Machine learning: Algorithms, real-world applications and research directions. *SN Computer Science*, vol. 2(3), página 160, 2021.

- SCIKIT-LEARN DEVELOPERS. scikit-learn: Machine learning in python. 2026.
- SONM. Sonm whitepaper. s.f.
- STANDING COMMITTEE OF THE NATIONAL PEOPLE'S CONGRESS. Data security law of the people's republic of china. 2021a.
- STANDING COMMITTEE OF THE NATIONAL PEOPLE'S CONGRESS. Personal information protection law of the people's republic of china. 2021b.
- SZE, V., CHEN, Y.-H., EMER, J., SULEIMAN, A. y ZHANG, Z. Hardware for machine learning: Challenges and opportunities. 2017.
- TALBOT, C. Paradoxes and prospects of public value. *Public Money & Management*, vol. 31(1), 2011.
- TAYLOR, P. Big data - statistics and facts. 2025.
- TELEFÓNICA. Telefónica tech cloud platform. s.f.
- THE PANDAS DEVELOPMENT TEAM. pandas documentation. 2026.
- THE SCIPY COMMUNITY. Scipy: Hierarchical clustering. 2026.
- DE LA TORRE, S. y NÚÑEZ, S. Transparencia en la administración pública municipal del ecuador. *Estudios de la Gestión*, (14), páginas 53–73, 2023. Copyright - Copyright null 2023; Última actualización - 2024-12-12; SubjectsTermNotLitGenreText - Ecuador.
- UNION EUROPEA. Data protection under gdpr. 2016.
- UNION EUROPEA. Explicación de la ley de gobernanza de datos. 2023.
- UNION EUROPEA. Reglamento de inteligencia artificial. 2024.
- UNION EUROPEA. European alternatives for popular services. 2025a.
- UNION EUROPEA. Portal de datos abiertos. 2025b.
- UNION EUROPEA. Reglamento Ómnibus digital sobre ia. 2026.
- UNIVERSIDATA. Análisis de desplazamientos interurbanos en estudiantes. 2020.
- UNIVERSIDATA. Ii datathon universidata. 2024.
- UNIVERSIDATA. Universidata. 2025.
- UNIVERSITAT AUTÒNOMA DE BARCELONA. infoparticipa. 2025.
- UNIVERSITY, T. Data mining without coding. 2024.

- URIARTE, R. B. y DE NICOLA, R. Blockchain-based decentralised cloud/fog solutions: Challenges, opportunities and standards. *IEEE Communications Standards Magazine*, 2018.
- VALERO TORRIJOS, J. y MARTÍNEZ GUTIERREZ, R. *DATOS ABIERTOS Y REUTILIZACIÓN DE LA INFORMACIÓN DEL SECTOR PÚBLICO*. CRC Press, 2022. ISBN 978-84-1369-269-2.
- VASWANI, A., SHAZEER, N., PARMAR, N., USZKOREIT, J., JONES, L., GOMEZ, A. N., KAISER, Ł. y POLOSUKHIN, I. Attention is all you need. páginas 5998–6008, 2017.
- VERHULST, S., YOUNG, A., ZAHURANEC, A., CALDERON, A., GEE, M. y AARONSON, S. The emergence of a third wave of open data: How to accelerate the re-use of data for public interest purposes while ensuring data rights and community flourishing. *International Journal of Public Administration*, página 8, 2020.
- VOGEL, A., GRIEBLER, D., MARON¹, C., SCHEPKE, C. y FERNANDES, L. Private iaas clouds: A comparative analysis of opennebula, cloudstack and openstack. páginas 672–679, 2016.
- WERBOS, P. Beyond regression: New tools for prediction and analysis in the behavioral science. thesis (ph. d.). appl. math. harvard university. 1974.
- WIKIPEDIA. Information age. 2025.
- WIKIPEDIA. listo of machine learning methods. s.f.

